Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 8 listopada 2026

Roboczy spis treści (usunąć przed oddaniem; razem ≤ 8 stron)

1. **Wstęp** (0,75 str.) — problem ukrytych wyświetleń, literatura, pytanie badawcze, wkład. *Napisany.*
2. **Dane i pomiar** (1 str.) — próba Brand24, skąd prawda na każdej platformie, Tabela 1, Rysunek 1. *Napisany, IG do uzupełnienia.*
3. **Metoda i walidacja** (1 str.) — cel i miara błędu, walidacja po markach i w czasie, dwa modele, przedziały, sufit szumu. *Napisany.*
4. **Wyniki A: platformy ze znanymi wyświetleniami** (1,25 str.) — błąd na TikToku, YouTube i X, pokrycie przedziałów, które pola są ważne. *Napisany.*
5. **Wyniki B: przeniesienie na Facebooka i Instagram** (1,5 str.) — wynik główny: FB ×2,4, IG ×2,65; kalibracja na 25 postach; macierz platform treningowych. *Napisany.*
6. **Wyniki C: brakujące dane i pewność** (0,5 str.) — co, gdy brakuje reakcji lub obserwujących; przedziały wyświetleń (np. 3 przedziały, trafność ok. 0,8). *Napisany.*
7. **Co nie działa** (0,5 str., tabela) — tekst, grafy, etykiety AI, dane zewnętrzne: wszystko poprawia o ≤0,01. *Napisany.*
8. **Zastosowania poboczne** (1 str.) — alert o wybiciu, rankingi marek, EMV, posty odstające. *Napisany, do rozbudowy.*
9. **Ograniczenia, dyskusja, rekomendacje** (0,75 str.) — mało marek na FB i IG, tylko filmy i rolki, posty wiralowe; co powinien zbierać dostawca; jeden wykres porównania z regułą Brand24. *Napisany, brak wykresu końcowego.*

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara takiego zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. Bez niej trudno ocenić, ile osób faktycznie zobaczyło dany post, a jeszcze trudniej przewidzieć, ile go zobaczy. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji. Taki mnożnik nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści w sieci jest szeroko badane [1]. Część prac sprawdza też przenoszenie modeli między serwisami: Shulman i in. [2] pokazują, że model uczony na jednym zbiorze (muzyka, książki, zdjęcia, linki) działa podobnie dobrze na pozostałych, a Roy i in. [3] przenoszą wiedzę z Twittera na popularność filmów na YouTube. Prace te opierają się jednak na innych sygnałach (tempo pierwszych odbiorców, tematy) i oceniają model tam, gdzie wynik jest znany. Nie znaleźliśmy pracy, która sprawdza oszacowanie wyświetleń z reakcji na platformach, gdzie wyświetlenia są ukryte, wobec niezależnie zmierzonej prawdy; tam, gdzie wyświetleń nie widać, zwykle nie ma też z czym porównać.

W tej pracy pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24. Dla Facebooka i Instagrama sami zebraliśmy wyświetlenia razem z reakcjami odczytanymi w tym samym momencie: 402 filmy z Facebooka i 338 rolek z Instagrama. Traktujemy je jako punkt odniesienia. Wszystkie modele oceniamy na markach, których nie widziały w treningu.

Nasz wkład jest następujący:

- Model uczony tylko na X i YouTube szacuje wyświetlenia na Facebooku z typowym błędem ×2,4, a na Instagramie ×2,65. Po kalibracji na 25 postach błąd na Instagramie spada do ×2,41, czyli prawie do poziomu modelu uczonego na samym Instagramie (×2,36).
- Prawie cały sygnał niosą reakcje. Tekst, etykiety treści, grafy autorów i marek oraz dane zewnętrzne o markach poprawiają błąd o najwyżej 0,01 w skali $\log_{10}$. Bez reakcji błąd rośnie do ×6–×11.

- Dla każdego posta podajemy przedział niepewności (pokrycie przedziału 90%: 0,89–0,90), który pozostaje wiarygodny także wtedy, gdy części danych brakuje.
- Pokazujemy, jakie dane musi zbierać dostawca monitoringu, żeby takie oszacowanie działało. Najważniejsze jest odczytywanie reakcji w tym samym momencie co wyświetleń.

2 Dane i pomiar

Korzystamy z 12 500 wzmianek o 348 markach, udostępnionych przez Brand24. Wzmianki pochodzą z pięciu platform (TikTok, YouTube, X, Facebook, Instagram), 85% z nich opublikowano między kwietniem a sierpniem 2026, a 85% jest po angielsku. Eksport zawiera liczbę wyświetleń dla prawie wszystkich wzmianek z TikToka (100%) i YouTube (99%) oraz dla 75% wzmianek z X. Dla Facebooka i Instagrama eksport nie podaje wyświetleń, dlatego pobraliśmy je własnym sposobem, razem z reakcjami z tego samego momentu.

Facebook. Mamy wyświetlenia, reakcje i komentarze dla 402 filmów z 20 marek. Facebook pokazuje osobno wyświetlenia i odtworzenia; używamy wyświetleń. Wyniki dla Facebooka dotyczą tylko filmów, bo inne posty nie mają licznika wyświetleń.

Instagram. **TODO:** zbieranie jeszcze trwa, uzupełnić liczbę rolek i marek. Wyniki dla Instagrama dotyczą tylko rolek, bo zwykłe posty (zdjęcia, karuzele) nie mają licznika wyświetleń.

Odczyty z tego samego momentu. Dla TikToka, YouTube i X pobraliśmy dodatkowo własny odczyt z jednego momentu i sprawdzamy na nim, o ile zmienia się błąd. Główne wyniki dla tych platform liczymy na danych z eksportu.

Etykiety treści. Typ i sentyment każdej wzmianki oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

Tabela 1 i Rysunek 1 podsumowują dane, na których oceniamy modele. Wyświetlenia na jeden post obejmują około siedmiu rzędów wielkości, a typowy post na X ma ich kilkadziesiąt razy mniej niż na Facebooku. Mediana liczby wyświetleń na jeden lajk różni się mniej: od 22 na X do 49 na Instagramie. Na każdej platformie post z 10 razy większą liczbą lajków ma od 6 do 11 razy więcej wyświetleń, ale na X aż 62% postów nie ma ani jednego lajka.

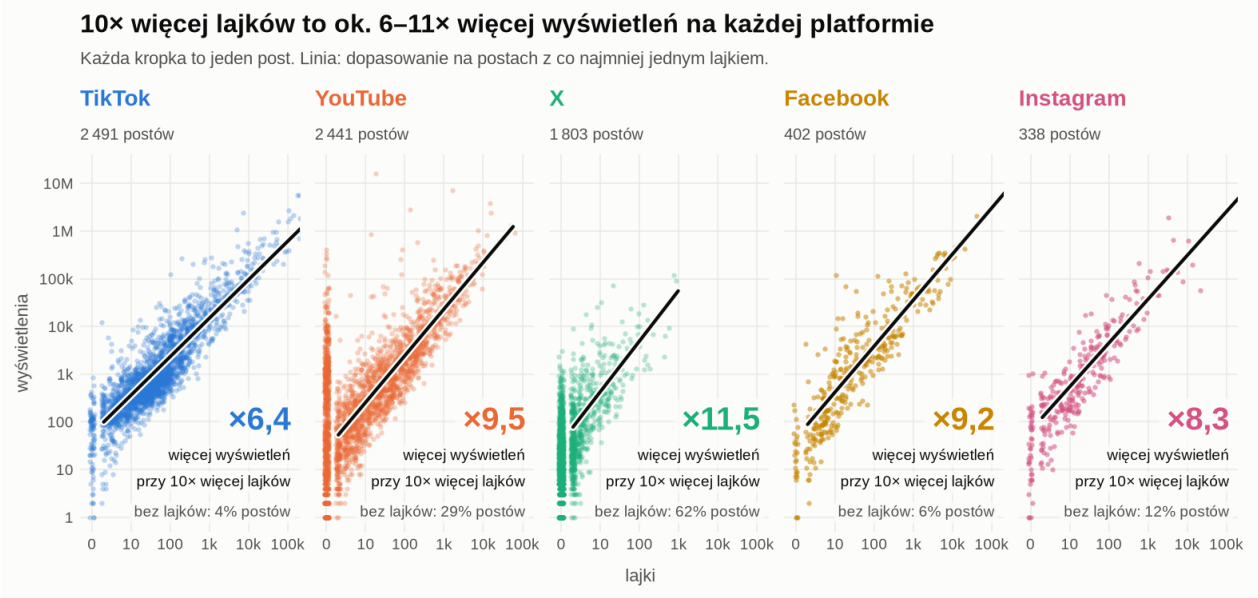
Tabela 1: Dane według platformy. Posty z wyświetleniami to te, które trafiają do modelu.

Platforma	Wzmianki	Marki	Źródło wyświetleń	Posty (marki)	Mediana		
					wyśw.	lajków	wyśw./lajk
TikTok	2 500	266	eksport Brand24	2 491 (266)	729	32	25
YouTube	2 500	273	eksport Brand24	2 441 (273)	433	6	26
X	2 500	273	eksport Brand24	1 803 (252)	27	0	22
Facebook	2 500	22	własny odczyt (filmy)	402 (20)	1 413	23	35
Instagram	2 500	11	własny odczyt (rolki)	338 (11)	506	10	49

3 Metoda i walidacja

Co przewidujemy. Celem jest $y = \log_{10}(\text{wyświetlenia})$ jednego posta. Skala logarytmiczna odpowiada temu, jak myli się każdy model zasięgu: o czynnik, a nie o stałą liczbę. Błąd mierzymy średnim błędem bezwzględnym (MAE) w tej skali i zawsze podajemy go też jako mnożnik 10^{MAE}: MAE równe 0,30 to typowy błąd $\times 2$, czyli oszacowanie dwa razy za duże albo dwa razy za małe.

Jak sprawdzamy. Posty jednej marki są do siebie podobne, więc losowy podział na trening i test zawyżałby wyniki. Wszystkie modele oceniamy pięciokrotną walidacją krzyżową z podziałem po markach: marka trafia w całości albo do treningu, albo do testu. Dodatkowo sprawdzamy model w czasie: uczymy go na postach sprzed 1 czerwca 2026 i testujemy na późniejszych. Przedziały ufności dla błędu i dla różnic między modelami liczymy bootstrapem po markach.



Rysunek 1: Wyświetlenia a lajki dla każdego posta, osobno dla każdej platformy (obie osie w skali logarytmicznej). Linia: dopasowanie prostej na postach z co najmniej jednym lajkiem; liczba w rogu mówi, ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków. TikTok, YouTube i X: eksport Brand24; Facebook (filmy) i Instagram (rolki): nasz odczyt.

Model na platformach ze znanymi wyświetleniami. Na TikToku, YouTube i X używamy gradientowego wzmacniania drzew CatBoost [4]. Model dostaje liczbę obserwujących autora, lajki, komentarze i udostępnienia (w skali log) oraz informację, których z tych pól brakuje. Różne rodziny modeli po dostrojeniu dają prawie ten sam błąd, dlatego nie porównujemy ich dalej.

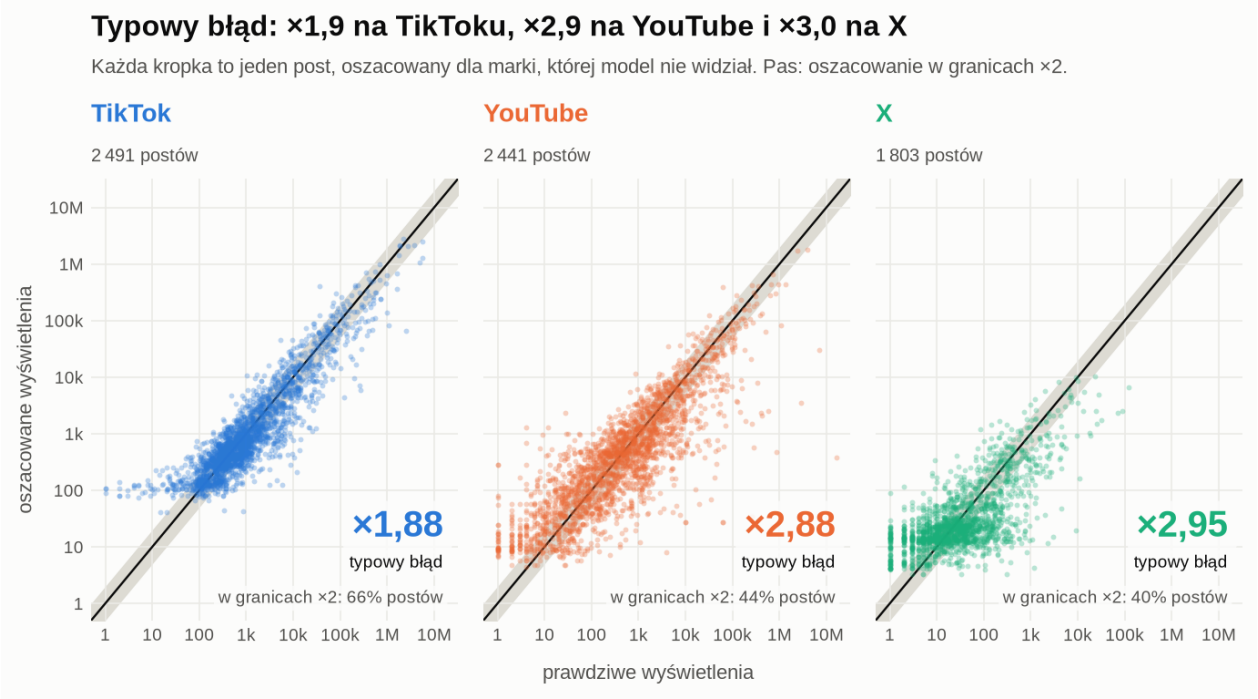
Model do przeniesienia na inne platformy. Na Facebooku i Instagramie model nie widzi w treningu ani jednego posta. Używamy tu regresji grzbietowej (ridge) na dwóch cechach, które ma każda platforma: $\log(1 + \text{lajki})$ i $\log(1 + \text{komentarze})$, uczonej na wszystkich postach z X i YouTube razem. Prosty model przenosi się lepiej niż CatBoost i lepiej niż metody przenoszenia z literatury, które sprawdziliśmy. Jako punkt odniesienia uczymy ten sam model na samej platformie docelowej, z tym samym podziałem po markach. Sprawdzamy też wariant, w którym klient zna wyświetlenia 25 swoich postów: wtedy przesuwamy oszacowania o medianę błędu na tych postach.

Przedziały niepewności. Dla każdego posta podajemy przedział, w którym na 50% i na 90% leży prawdziwa liczba wyświetleń. Używamy konformalnej regresji kwantylowej (CQR) [5]: model przewiduje kwantyle, a ich szerokość poprawiamy na markach odłożonych z treningu, tak żeby przedział 90% faktycznie trafiał w 90% postów.

Granica błędu. Nawet idealny model nie odgadnie wyświetleń dokładnie: dwa posty o prawie tych samych obserwujących i reakcjach potrafią mieć bardzo różną liczbę wyświetleń. Szacujemy tę granicę na parach takich postów. Wynosi ona 0,24 na TikToku, 0,39 na YouTube i 0,33 na X (×1,8 / ×2,4 / ×2,1). Błędu poniżej tego poziomu nie da się osiągnąć z tymi danymi.

4 Wyniki A: platformy ze znanymi wyświetleniami

Na TikToku, YouTube i X model zna prawdziwe wyświetlenia z eksportu, więc możemy go ocenić bezpośrednio. Typowy błąd wynosi ×1,9 na TikToku, ×2,9 na YouTube i ×3,0 na X (MAE 0,27 / 0,46 / 0,47, przedziały ufności 0,26–0,29 / 0,44–0,48 / 0,45–0,49; Rysunek 2). W granicach ×2 od prawdy mieści się 66% postów na TikToku, 44% na YouTube i 40% na X. Model nie ma skłonności w żadną stronę: połowa postów jest przeszacowana, połowa niedoszacowana, a mediana błędu jest bliska zera. Na X model ma najtrudniej, bo większość postów ma zero lub jeden lajk (Rysunek 1) i reakcje niewiele tam mówią.



Rysunek 2: Oszacowane a prawdziwe wyświetlenia na TikToku, YouTube i X. Każdy post jest oszacowany przez model, który nie widział jego marki w treningu. Szary pas: oszacowanie w granicach ×2.

Przedziały niepewności. Przedział 90% obejmuje prawdę w 89% postów na TikToku, 90% na YouTube i 89% na X, czyli tak, jak powinien. Jest jednak szeroki: górna granica jest typowo 14 razy większa od dolnej na TikToku, 50 razy na YouTube i 117 razy na X. Przedział 50% jest węższy (górna granica ×2,8 / ×5,5 / ×7,6 dolnej) i również trafia w połowę postów. Przedziały pozostają trafne także w teście w czasie, na miesiącach, których model nie widział (pokrycie 0,90–0,93).

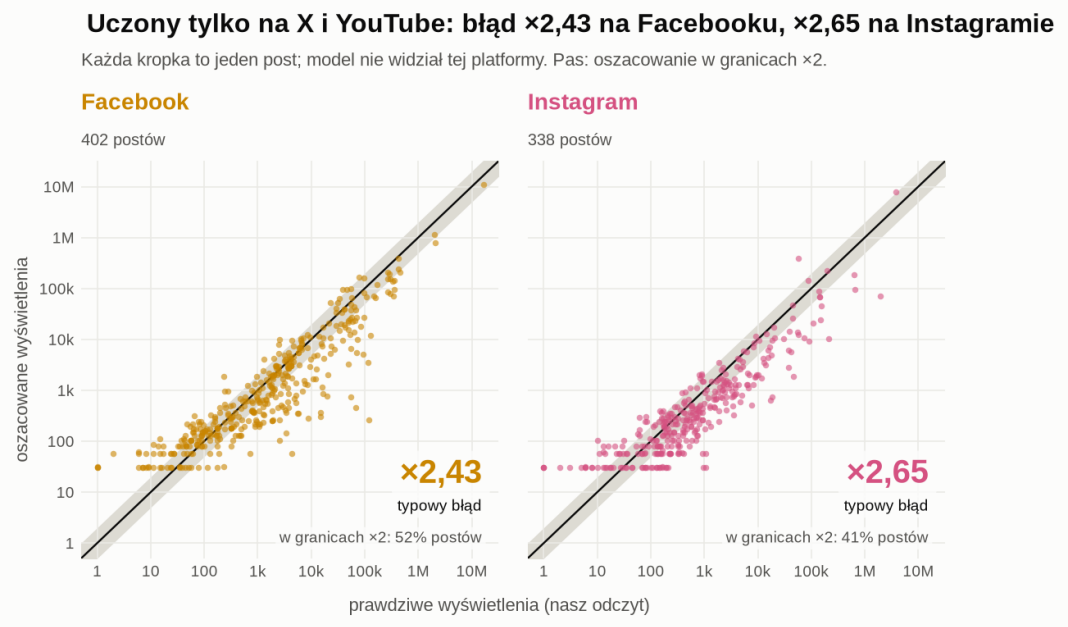
Co niesie sygnał. Najważniejsze są reakcje: same lajki dają błąd 0,31 na TikToku, a usunięcie ich z pełnego modelu pogarsza go o 0,11–0,31. Liczba obserwujących dodaje najwyżej 0,04. Wszystkie pozostałe cechy, które sprawdziliśmy, zmieniają błąd o mniej niż 0,01 (rozdział 7). Dwie rzeczy, których eksport nie zawiera, pomogłyby wyraźnie: drugi odczyt wyświetleń tego samego posta obniża błąd o 0,11–0,27, a historia autora o 0,10 na postach autorów, których model już widział.

Stabilność. Model uczony tylko na wcześniejszych miesiącach myli się na późniejszych tak samo jak przy walidacji po markach (różnica najwyżej 0,03, głównie w maju). Błąd nie rośnie z czasem w ciągu 2–3 miesięcy danych. Na X część postów nie ma wyświetleń w eksporcie; są to posty mniejsze (około ×1,8 mniej wyświetleń), a po uwzględnieniu ich błąd na X wynosi 0,49 zamiast 0,47.

5 Wyniki B: przeniesienie na Facebooka i Instagram

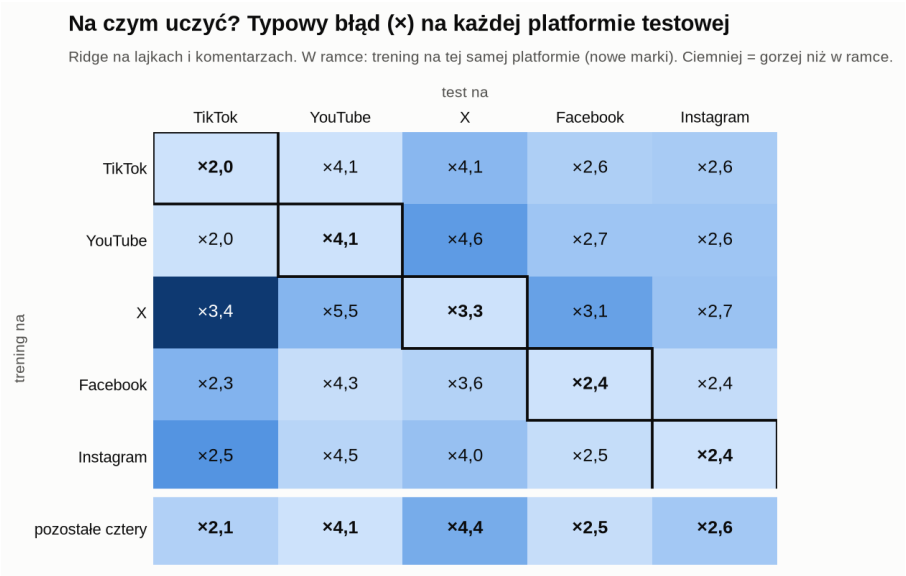
To główny wynik pracy. Model uczony tylko na X i YouTube, bez żadnego posta z Facebooka ani z Instagrama, szacuje wyświetlenia filmów na Facebooku z typowym błędem ×2,43 (MAE 0,385, przedział ufności 0,31–0,48, 402 filmy z 20 marek), a rolek na Instagramie z błędem ×2,65 (MAE 0,424, 0,38–0,49, 338 rolek z 11 marek; Rysunek 3). To mniej więcej tyle, ile osiąga ten sam model uczony na samej platformie docelowej: ×2,42 na Facebooku i ×2,36 na Instagramie. W granicach ×2 mieści się 52% filmów i 41% rolek. Kolejność postów jest zachowana bardzo dobrze (korelacja rang Spearmana 0,91 i 0,88). Na Instagramie model częściej zaniża (70% rolek), typowo o około ×1,8.

Kilka postów z wyświetleniami. Jeżeli klient zna wyświetlenia 25 swoich postów, możemy przesunąć oszacowania o medianę błędu na nich. Na Instagramie błąd spada wtedy z ×2,65 do ×2,41, prawie do poziomu modelu uczonego na Instagramie. Na Facebooku, TikToku i YouTube taka kalibracja nie pomaga (model trafia już w poziom), a na X pomaga wyraźnie: 25–50 postów obniża błąd z 0,65 do 0,55–0,56.



Rysunek 3: Oszacowane a zmierzone przez nas wyświetlenia na Facebooku (filmy) i Instagramie (rolki). Model uczony wyłącznie na X i YouTube. Szary pas: oszacowanie w granicach ×2.

Na czym uczyć. Rysunek 4 pokazuje typowy błąd na każdej platformie dla modelu uczonego na jednej platformie albo na czterech pozostałych. Facebook i Instagram dają się oszacować z dowolnej platformy z błędem ×2,4–×3,1. Najtrudniej przenieść się na X i z X: model uczony na X myli się na YouTube ×5,5, a modele uczone gdzie indziej mylą się na X ×3,6–×4,6. Uczenie na wszystkich pozostałych platformach naraz nie zawsze pomaga: na X daje ×4,4, gorzej niż sam Facebook (×3,6). Liczy się, które platformy są w treningu i w jakich proporcjach, a nie sama liczba platform.



Rysunek 4: Typowy błąd ($\times 10^{\mathrm{MAE}}$) modelu ridge na lajkach i komentarzach, uczonego na platformie z wiersza i testowanego na platformie z kolumny. W ramce: model uczony na tej samej platformie (walidacja po markach). Kolor pokazuje, o ile gorzej jest niż w ramce.

Warunek: reakcje z tego samego momentu. Przeniesienie działa tylko wtedy, gdy reakcje są odczytane razem z wyświetleniami. Ten sam model na lajkach i komentarzach z eksportu, odczytanych w innym czasie niż nasze wyświetlenia, myli się na Facebooku ×6,8 zamiast ×2,4.

Niepewność po przeniesieniu. Bez danych z platformy docelowej przedziały muszą być szersze. Przedział 90% skalibrowany na pozostałych platformach trafia na Facebooku w 93% filmów kont poniżej miliona obserwujących, ale tylko w 80–86% dla największych kont, dla których przedział trzeba poszerzyć.

6 Wyniki C: brakujące dane i pewność

W praktyce część pól często nie dociera: brakuje reakcji, liczby obserwujących albo obu. Model uczony na pełnych danych i karmiony niepełnymi podaje wtedy przedziały, które trafiają tylko w 46–83% postów zamiast w 90%. Dlatego dla każdego układu dostępnych pól (pełne dane, bez reakcji, bez obserwujących, nic) uczymy osobny model z osobnym przedziałem. Każdy z nich trafia w 88–90% postów. Szacujemy też, z jakim prawdopodobieństwem błąd będzie mniejszy niż $\times 2$: od 0,66 przy pełnych danych na TikToku do 0,19 bez żadnych danych na YouTube. To prawdopodobieństwo jest trafne dla całej grupy postów z danym układem pól, ale nie mówi, który post w grupie jest pewniejszy.

Przedziały wyświetleń zamiast liczby. Klient często nie potrzebuje dokładnej liczby, tylko rzędu wielkości. Gdy oszacowanie zamieniamy na trzy przedziały (poniżej 1 000, 1 000–10 000, powyżej 10 000), trafiamy w 82% postów na TikToku, 81% na YouTube, 80% na Facebooku i 78% na Instagramie. Na X trafność wynosi 95%, ale tyle samo daje odpowiedź „zawsze poniżej 1 000". Przy czterech przedziałach trafność spada do około 0,7, a przy przedziałach co rząd wielkości do około 0,6. Osobny klasyfikator przedziałów jest wszędzie gorszy niż pocięcie oszacowania regresji.

7 Co nie działa

Sprawdziliśmy wiele źródeł sygnału poza reakcjami. Żadne nie poprawia błędu o więcej niż 0,01 w skali $\log_{10}$ (Tabela 2). Powód jest prosty: reakcje już zawierają to, co te cechy mogłyby powiedzieć o popularności posta, a reszta tylko to powtarza.

Tabela 2: Cechy, które nie poprawiają oszacowania (zmiana MAE względem modelu na obserwujących i reakcjach; ujemna = lepiej). TikTok / YouTube / X, a w ostatniej kolumnie przeniesienie na Facebooka.

Grupa cech	Zmiana MAE (TT / YT / X)	Facebook
Tekst: statystyki, tematy TF-IDF, sentyment	$\leq$0,01	—
Osadzenia tekstu i transformery	$\leq$0,01	0,385 → 0,436 (gorzej)
Etykiety AI: typ i sentyment wzmianki	$\leq$0,005	—
Grafy autor–marka i treści	$\leq$0,01	—
Kontekst marki (wielkość, branża)	do +0,014 (gorzej na YT)	—
Dane zewnętrzne o marce (Wikipedia, Wikidata)	−0,002 / −0,007 / −0,003	0,385 → 0,388
Popularność marki w czasie	−0,001 / −0,010 / −0,007	—
Popularność platformy w czasie	+0,002 / 0,000 / +0,009	—
Kalendarz (dzień, godzina)	$\leq$0,006	—

8 Zastosowania poboczne

Oszacowanie wyświetleń przydaje się nie tylko jako liczba przy wzmiance. Sprawdziliśmy cztery zastosowania, o które pytają klienci monitoringu.

Alert o wybiciu. Klient chce wiedzieć wcześnie, który post zaczyna zbierać dużo wyświetleń. Jeśli mamy pierwszy odczyt wyświetleń i reakcji, model wskazujący 5% postów o największych przyszłych wyświetleniach trafia w 82% przypadków na TikToku, 86% na YouTube i 71% na X. Same reakcje dają 71% / 64% / 35%. Gdy dopuścimy trzy razy więcej alertów, łapiemy 82% / 100% / 94% postów, które naprawdę się wybiły. Dla najwyższego 1% postów mamy za mało przykładów, żeby to zmierzyć.

Ranking marek. Klient porównuje swoją markę z konkurencją z tej samej branży. Gdy sumujemy oszacowane wyświetlenia marek w branży i miesiącu, kolejność marek zgadza się z prawdziwą w dużym stopniu: średni współczynnik Kendalla wynosi 0,73 na TikToku, 0,70 na YouTube i 0,60 na X. W 79% / 75% / 60% par branża–miesiąc ranking jest co najmniej dobry (Kendall $\geq$ 0,6).

Wartość medialna (EMV). Agencje przeliczają wyświetlenia na pieniądze, mnożąc je przez stawkę za tysiąc wyświetleń. Jeśli EMV marki liczymy z oszacowanych wyświetleń, mieści się ono w ±50% prawdziwego dla 61% marek na TikToku, 57% na YouTube i 47% na X. Błąd pojedynczych postów częściowo się znosi, ale nie całkiem, bo duże posty są zaniżane (rozdział 9).

Które posty odstają. Posty, które mają dużo więcej wyświetleń, niż wynika z ich reakcji, to na TikToku częściej treści promocyjne (51% wobec 34% w całej próbie), a posty z dużo mniejszą liczbą wyświetleń to częściej spam (26% wobec 13%). Na YouTube i X takiej zależności nie widać. Odstępstwo od oszacowania może więc służyć jako sygnał do przejrzenia posta.

TODO: rozbudować do pełnej strony: np. wykres alertu (precyzja przy liczbie alertów) albo ranking marek; zdecydować o fałszywych dopasowaniach marek.

9 Ograniczenia, dyskusja, rekomendacje

Mało marek na Facebooku i Instagramie. Wynik dla Facebooka opiera się na 20 markach, a trzy z nich dają 39% filmów. Bez nich błąd rośnie do 0,46 (×2,9); pomijanie po jednej marce daje 0,36–0,41. Na Instagramie mamy 11 marek, trzy największe dają 44% rolek, a bez nich błąd wynosi ×2,95. Wyniki dotyczą tylko filmów na Facebooku i rolek na Instagramie; zwykłe posty nie mają licznika wyświetleń, więc nie mamy dla nich punktu odniesienia. Na Facebooku posty w innych językach niż angielski są zaniżane około ×2,2.

Posty wiralowe. Model zaniża najpopularniejsze posty: 1% postów z największą liczbą wyświetleń jest niedoszacowany ×9–×14. Przez to sumy wyświetleń marki mylą się o więcej niż ×2 dla 29% marek na TikToku, 37% na YouTube i 47% na X. Żadna z funkcji straty, które sprawdziliśmy, tego nie naprawia.

Czego nie wiemy. Reakcje i wyświetlenia odczytane w jednym momencie mamy tylko dla Facebooka i Instagrama. Nasze wyniki opisują zależności, nie przyczyny: nie twierdzimy, że lajki powodują wyświetlenia.

Rekomendacje dla dostawcy monitoringu.

1. Odczytywać reakcje w tym samym momencie co wyświetlenia; bez tego błąd na Facebooku rośnie z ×2,4 do ×6,8.
2. Zapisywać brakujące pola jako brak, a nie jako zero.
3. Robić drugi odczyt wyświetleń tego samego posta.
4. Przechowywać historię autorów.

TODO: jeden wykres końcowy: nasz model a stały mnożnik Brand24 na wszystkich platformach.

Odtwarzalność i użycie AI. Kod, skrypty i rejestr wszystkich eksperymentów, także nieudanych, są w repozytorium projektu. Przy analizie i redakcji tekstu korzystaliśmy z narzędzi AI. **TODO:** dokładny opis zgodnie z wymaganiami kursu.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.