Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 9 listopada 2026

Streszczenie

Na Facebooku i Instagramie dane z monitoringu mediów nie zawierają liczby wyświetleń postów. Sprawdzamy, czy można ją oszacować z lajków i komentarzy modelem, który nie widział ani jednego wyświetlenia z tych platform. Regresja liniowa na lajkach i komentarzach, uczona tylko na X i YouTube, szacuje wyświetlenia 402 filmów z Facebooka z typowym błędem $\times 2{,}43$ (MAE 0,385 w skali $\log_{10}$), tyle samo co ten sam model uczony na Facebooku, a 642 rolek z Instagramu z błędem $\times 2{,}72$, gorzej niż ten sam model uczony na Instagramie ($\times 2{,}41$). Mediana wyświetleń z platform źródłowych myli się tam $\times 9$–$\times 20$. Model w praktyce przenosi stosunek wyświetleń do lajków: od samego stałego mnożnika lajków jest lepszy na trzech z sześciu platform docelowych, nie gorszy na dwóch i gorszy na X. Przeniesienie wymaga reakcji odczytanych razem z wyświetleniami; na Stack Exchange przenosi się tylko kolejność, a poziom jest gorszy niż ze stałej mediany. Wyniki opierają się odpowiednio na 20 i 11 markach, a wyświetlenia źródłowe i docelowe odczytano w różnym wieku postów (23 wobec ponad 300 dni), co może częściowo maskować różnice.

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. Zasięg przybliża się wtedy regułą z liczby obserwujących lub reakcji, która nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] przenoszą wiedzę z Twittera na filmy z YouTube. Prace te przewidują jednak przyszłą popularność i mają dane o popularności z platformy docelowej, na których model się uczy lub kalibruje. Nasze zadanie to przeniesienie bez etykiet z dziedziny docelowej [4]: szacujemy bieżące wyświetlenia z widocznych reakcji na platformie, z której model nie dostaje w treningu ani jednej wartości wyświetleń. Wyświetlenia z tej platformy zbieramy osobno i używamy ich tylko do oceny. Nie znaleźliśmy pracy, która tak sprawdza przeniesienie modelu wyświetleń między platformami.

Nasz wkład:

- pokazujemy, że wystarczy prosta regresja liniowa na lajkach i komentarzach, uczona tylko na X i YouTube: szacuje wyświetlenia filmów na Facebooku z błędem $\times 2{,}43$, tyle samo co model uczony na Facebooku, a rolek na Instagramie $\times 2{,}72$ (model uczony na Instagramie: $\times 2{,}41$);
- porównujemy ją uczciwie z prostymi regułami na sześciu platformach docelowych i pokazujemy, kiedy przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi (X, poziom na Stack Exchange);
- dla każdego posta podajemy przedział niepewności, trafny na tej samej platformie; poza platformą wymaga on kalibracji na kilku markach z platformy docelowej;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

2 Dane

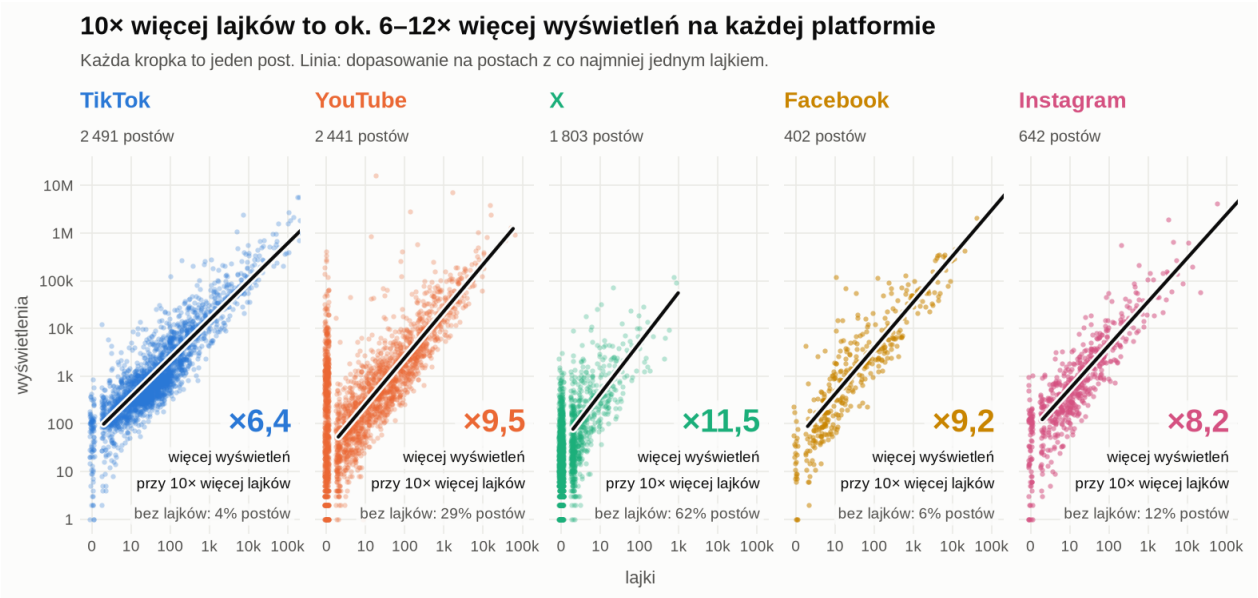
Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę; marka może występować na kilku platformach; 85% wzmianek opublikowano między kwietniem a sierpniem 2026 r., a 85% jest po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Eksport ma też kolumnę zasięgu, którą Brand24 wylicza regułą z reakcji i obserwujących (według naszej rekonstrukcji) i która na Facebooku i Instagramie zastępuje wyświetlenia. Dla Facebooka i Instagramu zebraliśmy wyświetlenia sami w listopadzie 2026 r., razem z lajkami i komentarzami z tej samej chwili. Z 470 filmów na Facebooku

68 było już usuniętych, zostaje 402 z 20 marek. Z 976 rolek na Instagramie 261 było usuniętych, 19 nie miało licznika wyświetleń, a 54 miało ukryte lajki, zostaje 642 z 11 marek. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Ponownie odczytaliśmy też wyświetlenia i reakcje 2 013 postów z X, 1 376 z YouTube i 426 z TikToka (rozdz. 5).

Tabela 1: Dane według platformy.

Platforma	Marki	Autorzy	Źródło wyświetleń	Posty z wyśw.	Mediana wyśw.	Wyśw./lajk
TikTok	266	2 411	eksport Brand24	2 491	729	25
YouTube	273	2 041	eksport Brand24	2 441	433	26
X	252	1 658	eksport Brand24	1 803	27	22
Facebook	20	≥182[a]	własny odczyt (filmy)	402	1 413	35
Instagram	11	?[b]	własny odczyt (rolki)	642	504	53

a: autor znany dla 74% filmów. b: autor znany tylko dla 11% rolek (59 autorów wśród 72). Wyśw./lajk: mediana stosunku na postach z co najmniej jednym lajkiem.



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków (6–12). TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako *typowy błąd*, czyli mnożnik 10^{MAE} (MAE 0,30 $\approx \times 2$; to średnia geometryczna stosunku oszacowania do prawdy). Zgodność kolejności mierzymy korelacją rang Spearmana między oszacowanymi a prawdziwymi wyświetleniami. Każdy model porównujemy z dwiema regułami: medianą wyświetleń i *stałym mnożnikiem lajków* (wyświetlenia = k·lajki, k to mediana stosunku wyświetleń do lajków w danych treningowych, około 25). Przedziały ufności liczymy bootstrapem po markach, a różnice między modelami na tych samych postach sparowanym bootstrapem po markach.

Walidacja. Łączymy posty w grupy, jeśli mają wspólną markę, wspólnego autora albo identyczny tekst (jeden autor pisze czasem o kilku markach, a ten sam tekst bywa wklejany na różnych kontach), i dzielimy całe grupy na pięć części. Każda ocena dotyczy więc marki i autora, których model nie widział. Porównania metod (Tabela 4 i Rys. 4B) robimy na prostszym podziale po samych markach; ich liczby różnią się od Rys. 2 o najwyżej 0,012 (CatBoost na X: $\times 2{,}95$ wobec $\times 3{,}03$), a kolejność metod się nie zmienia.

Dwa scenariusze, oznaczane na każdym wykresie. *Na tej samej platformie*: CatBoost uczony na postach z danej platformy (TikTok, YouTube, X), oceniany na markach i autorach, których nie widział. *Poza platformą*: regresja ridge, która nie widzi w treningu ani jednego posta z platformy docelowej (Facebook, Instagram, Stack Exchange; w Tabelach 2 i 3 także TikTok, YouTube i X po kolei); wyświetlenia celu służą tylko do oceny.

Modele. Na tej samej platformie używamy CatBoost [5] na obserwujących, reakcjach i flagach braków (osobna cecha mówi, czy pole było puste, bo brak to nie zero). Poza platformą używamy regresji ridge [6] na $\log(1 + \text{lajki})$ i $\log(1 + \text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem. Przy pominiętej platformie przenosi się ona lepiej niż CatBoost i sieci MLP (o 0,014–0,062 MAE na każdej z pięciu platform, także po augmentacji danych). Główne liczby dla Facebooka i Instagramu pochodzą z eksportu Brand24 dla X i YouTube; wariant ze źródłem odczytanym ponownie (rozdz. 5) podajemy osobno, bo był sprawdzany już po obejrzeniu części rolek. Przedziały 50% i 90% dla każdego posta daje konformalna regresja kwantylowa (CQR) [7]: model kwantylowy wyznacza wstępny przedział, a jego szerokość poprawiamy na odłożonej części danych tak, żeby pokrycie było zgodne z założonym.

4 Wyniki

Główne wyniki: o ile mylimy się na pojedynczym poście

		Posty / marki	**Nasz błąd**	W granicach ×2	Stała mediana
Na tej samej platformie	TikTok	2 491 / 266	×**1,87**	67%	×4,6
	YouTube	2 441 / 273	×**2,90**	43%	×8,8
	X	1 803 / 252	×**3,03**	40%	×4,6
Poza platformą (0 postów celu)	Facebook	402 / 20	×**2,43**	53%	×19,9
	Instagram	642 / 11	×**2,72**	40%	×8,7

Nasz błąd: typowy błąd 10^{MAE}, np. ×2,43 to oszacowanie zwykle 2,43 razy za duże albo za małe. Stała mediana: jedna liczba dla wszystkich postów (mediana tej samej platformy, a poza platformą mediana X i YouTube).

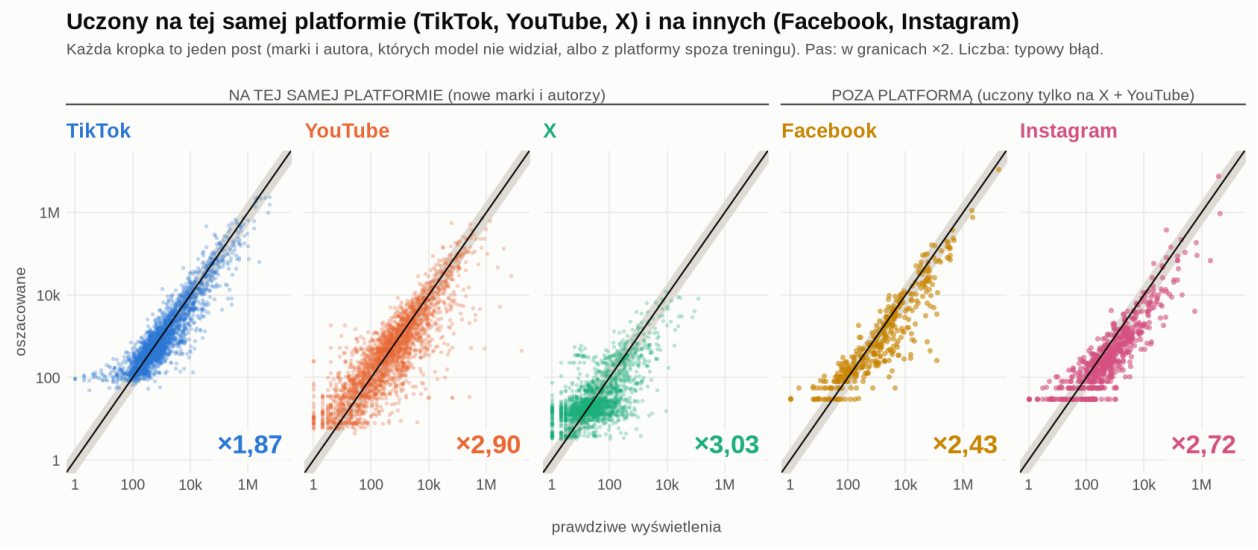
Na tej samej platformie. Na TikToku, YouTube i X typowy błąd wynosi ×1,87, ×2,90 i ×3,03 (MAE 0,273 / 0,462 / 0,482; Rys. 2). Stały mnożnik lajków daje tu ×2,23, ×4,06 i ×3,63, więc CatBoost jest od niego lepszy na każdej platformie o 0,075–0,15 MAE (przedziały ufności różnic nie obejmują zera).

Poza platformą. Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się o MAE 0,385 (×2,43, 95% CI ×2,05–×3,03) i 0,435 (×2,72, ×2,49–×3,05). Na Facebooku błąd jest taki sam jak przy uczeniu tego samego modelu na Facebooku (×2,42; różnica 0,001, 95% CI [−0,03; 0,03], czyli różnica co najwyżej ×1,07 w którąkolwiek stronę). Na Instagramie jest wyraźnie gorzej niż przy uczeniu ridge na samym Instagramie (×2,41; różnica 0,054, 95% CI [0,021; 0,093]), a 72% rolek jest niedoszacowanych, bo mediana rolki to 53 wyświetlenia na lajk, a na X i YouTube około 25 (Tabela 1). Wynik nie zależy od wyboru X i YouTube: mediana po wszystkich 15 zestawach treningowych bez platformy docelowej to ×2,58 na Facebooku i ×2,65 na Instagramie. Kolejność postów jest zachowana dobrze (Spearman 0,91 i 0,86, wewnątrz jednej marki 0,80 i 0,83), ale tak samo dobrze porządkują je same lajki. Typowa marka ma większy błąd niż całość: mediana po markach to ×2,7 na Facebooku i ×2,9 na Instagramie. Źródło i cel różnią się też wiekiem odczytu (rozdz. 8), co może częściowo maskować różnice między platformami.

Regresja a stały mnożnik. Regresja w praktyce przenosi stosunek wyświetleń do lajków, więc trzeba ją porównać z samym mnożnikiem wyznaczonym na tych samych danych (Tabela 2). Regresja jest lepsza na TikToku, Instagramie i Stack Exchange, nie lepsza na Facebooku i YouTube (przedziały ufności sięgają zera) i gorsza na X, gdzie 62% postów nie ma lajka, a komentarze ciągną oszacowanie w złą stronę. Obie metody są 2–8 razy dokładniejsze od mediany platform źródłowych na każdej platformie z filmami, ale na Stack Exchange mediana wygrywa z obiema.

Kto jest źle szacowany. Na każdej platformie, także poza platformą, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże. To regresja do średniej: reakcje nie odróżniają dobrze posta, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone około 10 razy; poza platformą Instagram zaniża duże rolki około ×3.

Przedziały. Na tej samej platformie przedział 90% trafia w 87–91% postów na TikToku, YouTube i X, także gdy model uczymy na wcześniejszych miesiącach, a testujemy na późniejszym (0,90–0,93). Poza platformą



Rysunek 2: Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post. TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie, walidacja bez wspólnych marek, autorów i tekstów; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (642 rolki, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube, bez żadnego posta z platformy docelowej; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd 10^{MAE}.

Tabela 2: Poza platformą: regresja a proste reguły wyznaczone na tych samych platformach źródłowych.
Typowy błąd (×); różnica MAE regresja − mnożnik ze sparowanym 95% CI po markach (ujemna: regresja lepsza). Źródło: X + YouTube, a dla X i YouTube jako celu pozostałe cztery platformy. Mediana: jedna liczba dla wszystkich postów, mediana wyświetleń źródła.

Cel	Źródło	Regresja	Mnożnik lajków	Różnica [95% CI]	Mediana źródła
TikTok	X + YT	×2,05	×2,22	−0,034 [−0,038; −0,029]	×11,0
YouTube	pozostałe 4	×4,08	×4,03	+0,004 [0,000; 0,009]	×8,9
X	pozostałe 4	×4,37	×3,45	+0,103 [0,084; 0,120]	×22,1
Facebook	X + YT	×2,43	×2,42	+0,002 [−0,017; 0,022]	×19,9
Instagram	X + YT	×2,72	×2,94	−0,034 [−0,047; −0,020]	×8,7
Stack Exchange	X + YT	×3,14	×5,33	−0,229 [−0,240; −0,207]	×2,1

sam rozrzut błędów z X i YouTube daje za szeroki przedział (na Facebooku trafia w 96% filmów). Trafny przedział wymaga kalibracji na kilku markach z platformy docelowej, czyli kilkudziesięciu postach ze znanymi wyświetleniami: po kalibracji na 25% marek trafia w 89% filmów na Facebooku, ale tylko w 84% dla 70 filmów z kont powyżej miliona obserwujących (±9 punktów procentowych). Na Instagramie do kalibracji są tylko 2 marki, więc tego nie oceniamy.

5 Przeniesienie między platformami

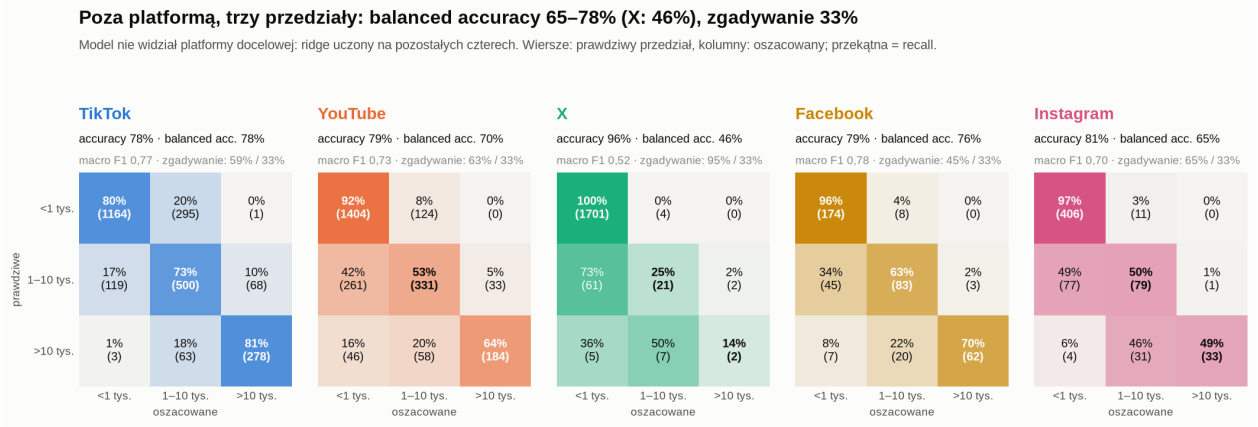
Różne zestawy treningowe. Prawdziwe wyświetlenia mamy na wszystkich pięciu platformach, więc każdą możemy potraktować jak „ukrytą” (Tabela 3). Facebook i Instagram dają się oszacować z prawie dowolnego zestawu z błędem ×2,4–×3,1: na Facebooku tyle, co ridge uczony na nim samym (×2,4), na Instagramie ×2,5–×2,8 wobec ×2,4. Najgorszy jest trening na samym X. X jest wyjątkiem w obie strony: model uczony na X myli się na YouTube ×5,5, a żaden zestaw nie osiąga na X błędu mniejszego niż ×3,6, wobec ×3,3 przy uczeniu na X. Część tej różnicy to wczesny odczyt wyświetleń w eksporcie: na danych odczytanych ponownie X jako cel ma ×3,0 zamiast ×4,4, a YouTube ×2,2 zamiast ×4,1 (mediany po zestawach). Przedziały ufności mają około ±0,013–0,032 MAE na TikToku, YouTube i X, ±0,04 na Instagramie i ±0,07 na Facebooku, więc różnice między zestawami poniżej około ×1,1–×1,2 na Facebooku i Instagramie mieszczą się w szumie.

Trzy przedziały zamiast liczby. Ten test jest w całości poza platformą, także dla TikToka, YouTube i X, więc model jest tu inny niż na Rys. 2. Dzielimy wyświetlenia na trzy przedziały: poniżej 1 000, 1 000–10 000 i powyżej 10 000 (Rys. 3). Trafność (*accuracy*) wynosi 78–81%, ale przedziały mają bardzo różną liczebność, więc ważniejsza jest zrównoważona trafność (*balanced accuracy*, średnia czułość, *recall*, po przedziałach): 78% na TikToku, 76% na Facebooku, 70% na YouTube i 65% na Instagramie, wobec 33% przy zgadywaniu; macro

Tabela 3: Typowy błąd (×) regresji na lajkach i komentarzach przy różnych platformach treningowych.
Ridge na log lajków i komentarzy, posty z platform treningowych połączone w jeden zbiór. Wiersz: platformy w treningu (TT TikTok, YT YouTube, X, FB Facebook, IG Instagram): pojedyncze, X + YouTube (zestaw główny), TikTok + YouTube + X i wszystkie z czterema platformami; pełna tabela 30 zestawów jest w repozytorium. Kolumna: platforma testowa, której nie było w treningu. Pierwszy wiersz: ten sam ridge uczony na platformie testowej (walidacja po markach), a nie CatBoost z Rys. 2. Pogrubione: najlepszy wynik w kolumnie wśród pokazanych. Ciemniej: większy błąd.

Trening na	TikTok	YouTube	X	Facebook	Instagram
ridge, ta sama platforma	2,0	4,1	3,3	2,4	2,4
YT	**2,0**	trening	4,6	2,7	2,6
FB	2,3	4,3	**3,6**	trening	**2,5**
IG	2,5	4,5	4,1	2,5	trening
TT	trening	**4,1**	4,1	2,6	2,6
X	3,4	5,5	trening	3,1	2,7
YT + X	2,1	trening	trening	**2,4**	2,7
TT + YT + X	trening	trening	trening	2,5	2,7
YT + X + FB + IG	2,1	trening	trening	trening	trening
TT + YT + X + IG	trening	trening	trening	2,5	trening
TT + YT + X + FB	trening	trening	trening	trening	2,7
TT + X + FB + IG	trening	4,1	trening	trening	trening
TT + YT + FB + IG	trening	trening	4,4	trening	trening

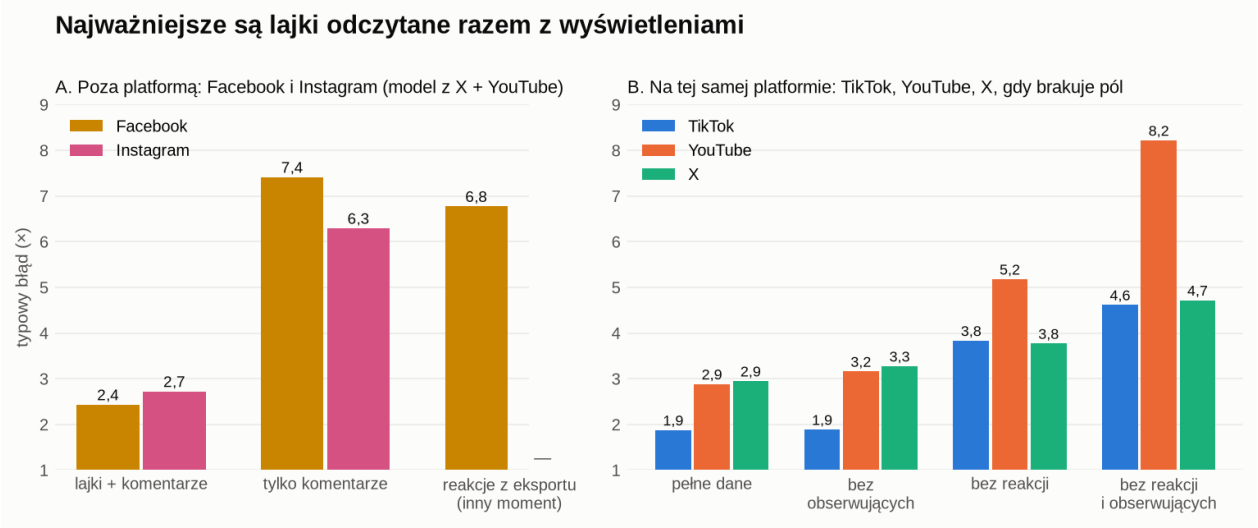
F1 0,70–0,78. O dwa przedziały mylimy się w 0,2–1,9% postów. Najsłabszy jest zwykle środkowy przedział (recall 50–73%), na Instagramie górny (49%). Na X model praktycznie nie działa: trafność 96% bierze się stąd, że 95% postów ma poniżej tysiąca wyświetleń, a zrównoważona trafność to tylko 46% (z 98 postów powyżej tysiąca trafia 23). Widzimy dwa powody: 62% postów na X nie ma lajka (usunięcie ich z danych treningowych zmniejsza błąd na X o 0,08), a wyświetlenia w eksporcie X są odczytane wcześnie, około dwukrotnie niżej niż w naszym ponownym odczycie.



Rysunek 3: Oszacowanie poza platformą pocięte na trzy przedziały wyświetleń.
Dla każdej platformy ridge na lajkach i komentarzach uczony na pozostałych czterech. Wiersz: prawdziwy przedział; kolumna: oszacowany; w komórce udział w wierszu i liczba postów; przekątna (pogrubiona) to recall przedziału. Nad tabelą: accuracy, balanced accuracy (średni recall), macro F1; szare: wartości przy zgadywaniu zawsze najczęstszego przedziału.

Czego model potrzebuje. Przeniesienie działa tylko z lajkami odczytanymi w tej samej chwili co wyświetlenia (Rys. 4A). Same komentarze dają ×6,3–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na tej samej platformie (Rys. 4B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dlatego dla każdego układu dostępnych pól uczymy osobny model z osobnym przedziałem.

Świeże dane źródłowe. Gdy ten sam model uczymy na X i YouTube odczytanych ponownie, razem z reakcjami z tej samej chwili, błąd na Instagramie spada z ×2,72 do ×2,41 (przypadkiem tyle samo, co ridge uczony na samym Instagramie), a na Facebooku zostaje ×2,44. Niedoszacowanie dużych postów i sum dla marek zmniejsza się mniej więcej o połowę. Samo przesunięcie wyświetleń z eksportu do późniejszego wieku tego nie daje, więc ważne jest, żeby wyświetlenia i reakcje pochodziły z tego samego momentu. Ten wariant nie zastępuje wyniku głównego, bo zysk na Instagramie sprawdziliśmy już po obejrzeniu części rolek.



Rysunek 4: Typowy błąd przy różnych danych wejściowych.
A (poza platformą): Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak tych danych). B (na tej samej platformie): TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach.

Szósta platforma. Pobraliśmy przez publiczne API 538 pytań z serwisów Stack Exchange (m.in. Stack Overflow, Super User, Android) o 48 markach z naszych danych, z kwietnia–sierpnia 2026. Głos za traktujemy jak lajk, a odpowiedzi i komentarze jak komentarze; to przypisanie ustaliliśmy przed oceną. Przenosi się kolejność, ale nie poziom: model z X i YouTube myli się ×3,14, gorzej niż stała mediana z samego Stack Exchange (×1,96) i niż mediana z X i YouTube (×2,10), bo 96% pytań jest niedoszacowanych (wyświetlenia pytań zbierają się miesiącami, a głos to nie lajk). Kolejność pytań zachowuje tak samo jak ridge uczony na Stack Exchange (Spearman 0,57 w obu przypadkach). Wyświetlenia pytań mają mały rozrzut (odchylenie standardowe 0,40 wobec 1,21 na Facebooku), więc nawet ridge uczony na Stack Exchange (×1,77) jest tylko o 15% lepszy od mediany. Stosunek wyświetleń do reakcji przenosi się więc między serwisami z filmami, a na serwis z pytaniami tylko kolejność.

6 Porównanie metod

Rodziny modeli. Tabela 4 porównuje modele na tej samej platformie, na tych samych danych wejściowych. Po dostrojeniu prawie wszystkie rodziny dają ten sam błąd. TabPFN v2 [8] wyprzedza CatBoost o 0,004–0,009, mniej niż przedział ufności (±0,012–0,021), a liczy się około 150 razy dłużej. Stos wszystkich rodzin (model drugiego poziomu ważący ich oszacowania) poprawia wynik o 0,012–0,029, na YouTube i X więcej niż szum. Zostajemy jednak przy jednym modelu: zysk to ×1,03–×1,07 wobec typowego błędu ×1,9–×3,0, stos wymaga utrzymania kilkunastu modeli, a przedziały CQR i przeniesienie budujemy na jednym modelu, przy czym poza platformą i tak wygrywa model liniowy.

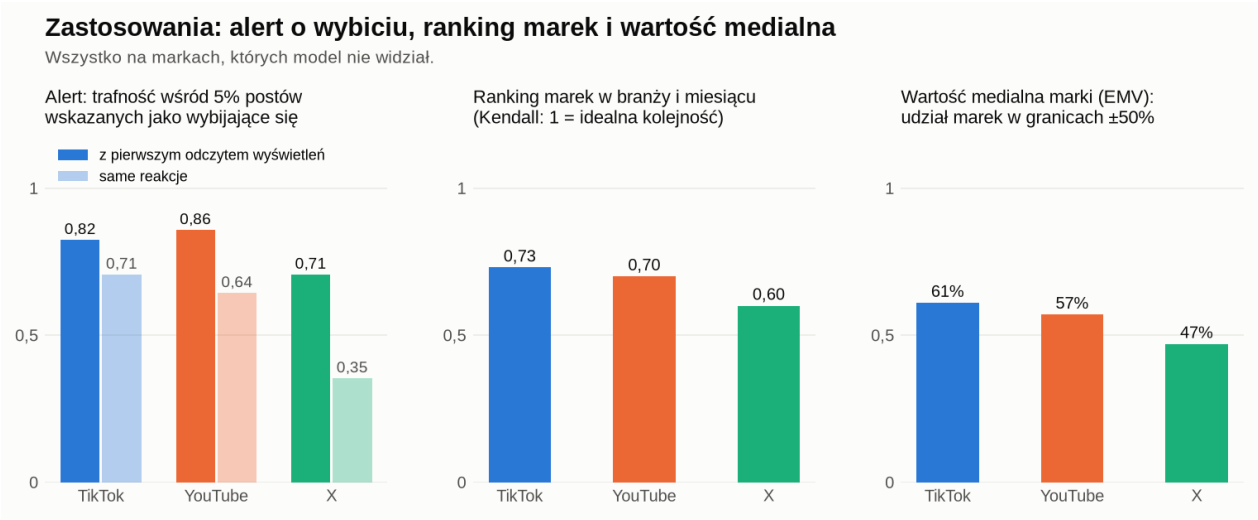
Dodatkowe dane i cechy. Sprawdziliśmy ponad dwadzieścia dodatkowych źródeł sygnału: tekst (od TF-IDF po osadzenia zdań e5 [11] i słownik sentymentu VADER [12]), etykiety typu i sentymentu z modelu językowego, grafy autorów i marek (GraphSAGE [13], metapath2vec [14]), dane o markach z Wikipedii i Wikidata, syntetyczne duże posty (SMOTER/SMOGN [15]), reprezentacje uczone bez etykiet (SCARF [16]) i pseudo-etykiety. Żadne nie poprawia błędu o więcej niż ×1,04, większość mniej niż ×1,02, a niektóre pogarszają go do ×1,06. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436).

Historia autora. Ten sam autor ma podobną nadwyżkę wyświetleń (prawda minus oszacowanie) w kolejnych postach: korelacja między pierwszym a późniejszymi postami wynosi 0,68–0,70. Dodanie do oszacowania średniej nadwyżki wcześniejszych postów autora, ściągniętej do zera przy małej liczbie postów, zmniejsza błąd na tych postach ×1,3–×1,4. To jednak inne zadanie, bo wymaga znanych wyświetleń autora na tej samej platformie, a taka historia jest tylko dla 3–16% postów (w średnim błędzie ≤0,003). Ten sam autor na innej platformie występuje w 0,67% postów.

Tabela 4: Na tej samej platformie: rodziny modeli, MAE w skali $\log_{10}$ i typowy błąd (×).
Obserwujący, reakcje i flagi braków, walidacja po markach, strojenie zagnieżdżone (40 ustawień na fałd). TabPFN, TabICL i stos z osobnych przebiegów na tych samych danych. 95% CI dla CatBoost: ±0,012 / ±0,021 / ±0,021, więc różnice poniżej około 0,01 są w granicach szumu. *: podział bez wspólnych marek, autorów i tekstów. Pełna tabela 17 modeli jest w repozytorium.

Model	TikTok	YouTube	X
mediana wyświetleń platformy	0,663 (×4,60)	0,944 (×8,79)	0,667 (×4,65)
stały mnożnik liczby obserwujących	0,919 (×8,30)	0,855 (×7,16)	0,879 (×7,57)
stały mnożnik lajków*	0,348 (×2,23)	0,609 (×4,06)	0,560 (×3,63)
regresja liniowa (ridge)	0,277 (×1,89)	0,545 (×3,51)	0,487 (×3,07)
las losowy	0,275 (×1,88)	0,463 (×2,90)	0,473 (×2,97)
XGBoost [9]	0,273 (×1,87)	0,450 (×2,82)	0,467 (×2,93)
CatBoost (model końcowy)	0,272 (×1,87)	0,452 (×2,83)	0,470 (×2,95)
perceptron wielowarstwowy (MLP)	0,276 (×1,89)	0,454 (×2,84)	0,477 (×3,00)
TabPFN v2	0,268 (×1,85)	0,443 (×2,77)	0,465 (×2,92)
TabICL [10]	0,272 (×1,87)	0,445 (×2,79)	0,466 (×2,92)
stos wszystkich rodzin	0,260 (×1,82)	0,425 (×2,66)	0,441 (×2,76)

7 Zastosowania



Rysunek 5: Zastosowania oszacowania na TikToku, YouTube i X (na tej samej platformie).
Alert: z pierwszego, wczesnego odczytu wyświetleń i reakcji model wskazuje 5% postów, które skończą w górnych 5% wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik korelacji rang Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV (*earned media value*): wyświetlenia przeliczone na pieniądze stałą stawką 5 USD za tysiąc wyświetleń; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

Alert o wybiciu. Z pierwszego odczytu model wskazuje 5% postów, które skończą w górnych 5% wyświetleń, z trafnością 0,82 / 0,86 / 0,71; ten sam alert z samych reakcji, bez modelu, daje 0,71 / 0,64 / 0,35 (Rys. 5).

Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek. Stawka tylko skaluje wynik, więc odsetki od niej nie zależą.

Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%; typ wzmianki z etykiet modelu językowego). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży, wzmianki nie o marce (E224).

8 Ograniczenia i rekomendacje

Mało marek. Wynik dla Facebooka opiera się na 20 markach, a dla Instagramu na 11; trzy największe marki to 39% i 44% postów, a bez nich błąd rośnie do ×2,89 i ×2,96. Błąd pojedynczej marki waha się od ×1,5 do ×6,2 na Facebooku i od ×2,2 do ×4,3 na Instagramie. Przy tak małej liczbie marek przedziały ufności z bootstrapu po markach mogą być za wąskie.

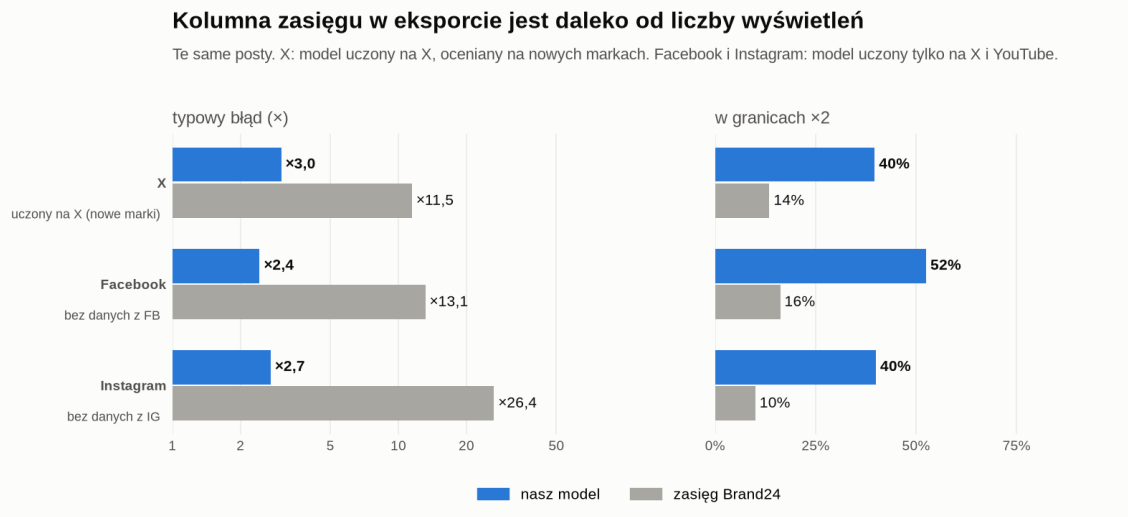
Wybór postów. Mierzymy tylko filmy i rolki, które były jeszcze dostępne. Na Instagramie odpadły też rolki z ukrytymi lajkami, czyli dokładnie te, dla których szacunek byłby w praktyce najbardziej potrzebny; tam model musiałby opierać się na samych komentarzach (×6,3).

Wiek odczytu. Wyświetlenia w eksporcie X i YouTube odczytano w medianie po 23 dniach od publikacji, a nasze odczyty z Facebooka i Instagramu po 310 i 334 dniach. Zgodność na Facebooku może więc częściowo wynikać ze znoszenia się dwóch efektów: gdy przesuniemy same wyświetlenia źródłowe do późniejszego wieku, błąd na Facebooku rośnie o 0,10 (×3,05), a dopiero przesunięcie wyświetleń razem z reakcjami przywraca ×2,44.

Wzmianki nie o marce. Brand24 dopasowuje wzmianki po słowach kluczowych. W 6,7% wzmianek nazwy marki w ogóle nie ma w tekście, a według osobnych etykiet tematu z modelu językowego (niesprawdzonych jeszcze przez człowieka) marka nie jest głównym tematem w około 64% wzmianek. Nie zmienia to błędu oszacowania wyświetleń posta, ale sumy marek zawierają przez to także posty o czymś innym, a podział walidacji po markach jest mniej czysty.

Inne. Na tej samej platformie najpopularniejszy 1% postów na YouTube i X jest zaniżany ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek. Prawie każdy post ma innego autora (2 411 autorów na 2 491 postów na TikToku, 2 041 na 2 441 na YouTube, 1 658 na 1 803 na X), więc historii autora nie da się użyć dla większości postów. Wyniki opisują zależności, nie przyczyny. Kod, liczby i karty wszystkich eksperymentów są w repozytorium projektu.

Rekomendacje. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów. Rys. 6 pokazuje, co daje to dziś: kolumna zasięgu w eksporcie, czytana przez klientów jako liczba odbiorców, jest dalej od wyświetleń niż nasze oszacowanie.



Rysunek 6: Nasze oszacowanie a kolumna zasięgu w eksporcie Brand24, na tych samych postach.
Tylko platformy, na których zasięg nie jest liczbą wyświetleń. Zasięg to inna miara niż wyświetlenia, więc rysunek pokazuje, jak daleko od wyświetleń jest liczba, którą klient dostaje dziś, a nie porównanie dwóch modeli. X (1 803 posty): model uczony na X, oceniany na markach i autorach, których nie widział; prawda z eksportu. Facebook (402 filmy) i Instagram (642 rolki): model poza platformą, uczony tylko na X i YouTube; prawda z naszego odczytu.

Użycie AI i odtwarzalność. **TODO:** do napisania przez zespół własnymi słowami. Fakty do ujęcia: agenci AI (Claude Code, DeepSeek) pisali kod analiz i odczytu danych, uruchamiali eksperymenty, robili wykresy i szkic tekstu; modele językowe oznaczyły typ i sentyment wzmianek; logi sesji agentów są w `logs/`. Każdy wynik ma kartę eksperymentu, wiersz w rejestrze (`docs/pl/experiments.md`), skrypt w `src/` i liczby w `data/processed/`.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan. A theory of learning from different domains. *Machine Learning*, 79, 2010.

[5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[6] A. E. Hoerl, R. W. Kennard. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 1970.

[7] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.

[8] N. Hollmann i in. Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 2025.

[9] T. Chen, C. Guestrin. XGBoost: a scalable tree boosting system. *KDD*, 2016.

[10] J. Qu, D. Holzmüller, G. Varoquaux, M. Le Morvan. TabICL: a tabular foundation model for in-context learning on large data. *ICML*, 2025.

[11] L. Wang i in. Text embeddings by weakly-supervised contrastive pre-training. arXiv:2212.03533, 2022.

[12] C. J. Hutto, E. Gilbert. VADER: a parsimonious rule-based model for sentiment analysis of social media text. *ICWSM*, 2014.

[13] W. L. Hamilton, R. Ying, J. Leskovec. Inductive representation learning on large graphs. *NeurIPS*, 2017.

[14] Y. Dong, N. V. Chawla, A. Swami. metapath2vec: scalable representation learning for heterogeneous networks. *KDD*, 2017.

[15] P. Branco, L. Torgo, R. P. Ribeiro. SMOGN: a pre-processing approach for imbalanced regression. *LIDTA*, PMLR 74, 2017.

[16] D. Bahri, H. Jiang, Y. Tay, D. Metzler. SCARF: self-supervised contrastive learning using random feature corruption. *ICLR*, 2022.