Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 8 listopada 2026

Roboczy spis treści (usunąć przed oddaniem)

1. **Wstęp** — problem, literatura, pytanie, wkład.
2. **Dane** — skąd prawda na każdej platformie; Tabela 1, Rys. 1.
3. **Metoda** — miara błędu, walidacja po markach, dwa modele, przedziały.
4. **Wyniki** — Rys. 2 (wynik główny), Rys. 3 (na czym uczyć), Rys. 4 (czego model potrzebuje), Rys. 5 (kto jest źle szacowany), przedziały.
5. **Porównanie metod** — Tabela 2: rodziny modeli (regresja, lasy, boosting, sieci, grafy, transformery); Rys. 6: dodatkowe dane.
6. **Zastosowania** (1 str.) — Rys. 7: alert, ranking marek, EMV, posty odstające.
7. **Ograniczenia i rekomendacje**.

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji, który nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] wiedzę z Twittera na filmy z YouTube. Prace te przewidują jednak przyszłą popularność i mają dane o popularności z platformy docelowej, na których model się uczy lub kalibruje. Nasze zadanie jest inne: szacujemy bieżące wyświetlenia z widocznych reakcji na platformie, z której model nie dostaje w treningu ani jednej wartości wyświetleń. Wyświetlenia z tej platformy zbieramy osobno i używamy ich tylko do oceny. Nie znaleźliśmy pracy, która tak sprawdza przeniesienie modelu wyświetleń między platformami.

Pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Nasz wkład:

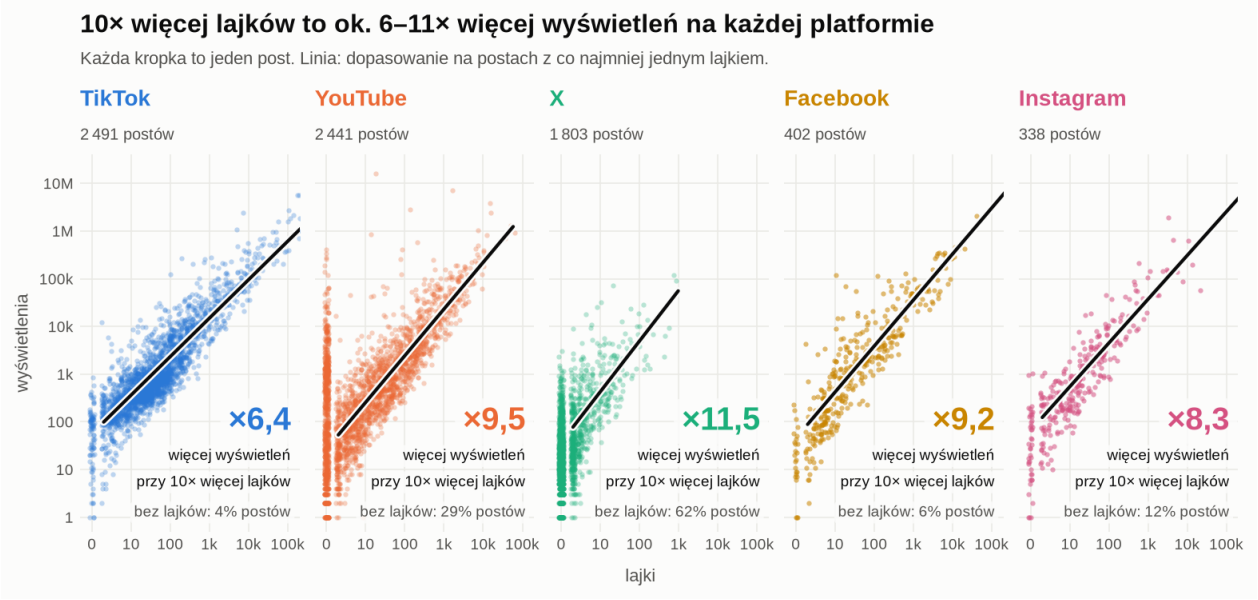
- model uczony tylko na X i YouTube szacuje wyświetlenia filmów na Facebooku z typowym błędem $\times 2{,}4$, a rolek na Instagramie $\times 2{,}65$, tak samo dobrze jak model uczony na samej platformie docelowej;
- pokazujemy, kiedy to przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi;
- dla każdego posta podajemy przedział niepewności, trafny także przy brakujących danych;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

2 Dane

Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę, 85% z nich opublikowano między kwietniem a sierpniem 2026 r., a 85% jest po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Dla Facebooka i Instagrama ich nie ma, więc pobraliśmy je własnym sposobem razem z reakcjami z tego samego momentu: 402 filmy z 20 marek na Facebooku i **TODO:** IG po partii 3: 338 rolek z 11 marek na Instagramie. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Typ i sentyment wzmianek oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

Tabela 1: Dane według platformy.

Platforma	Marki	Źródło wyświetleń	Posty z wyświetleniami	Mediana wyśw.	Wyśw. na lajk
TikTok	266	eksport Brand24	2 491	729	25
YouTube	273	eksport Brand24	2 441	433	26
X	252	eksport Brand24	1 803	27	22
Facebook	20	własny odczyt (filmy)	402	1 413	35
Instagram	11	własny odczyt (rolki)	338	506	49



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków. TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

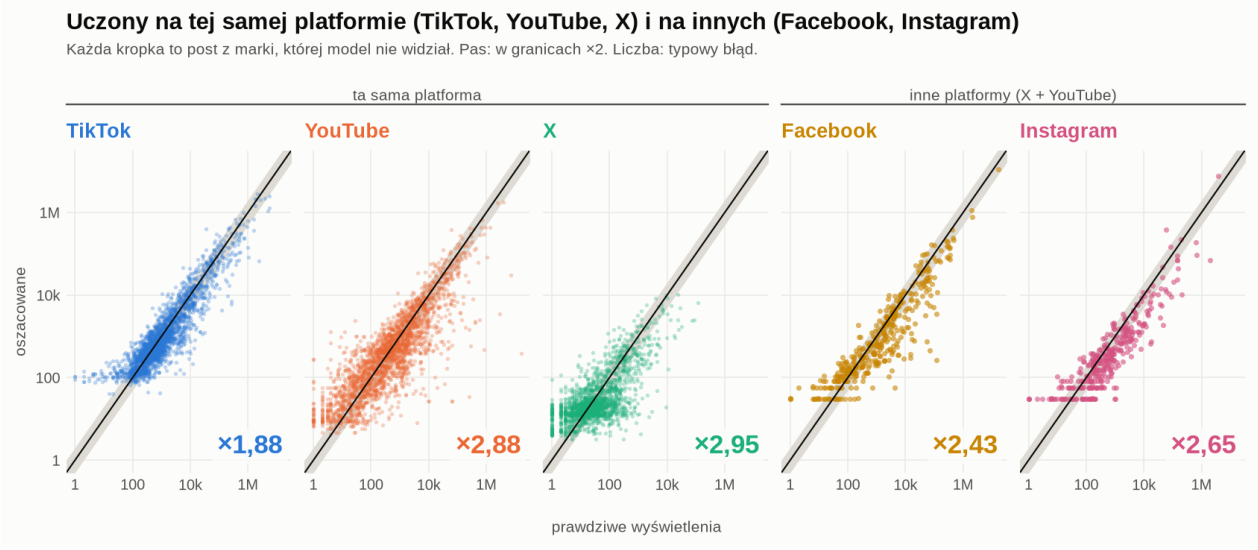
3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako mnożnik 10^{MAE} (MAE 0,30 $\approx \times 2$). Wszystkie modele oceniamy pięciokrotną walidacją krzyżową z podziałem po markach, więc każda ocena dotyczy marki, której model nie widział; przedziały ufności liczymy bootstrapem po markach. Na TikToku, YouTube i X używamy CatBoost [4] na obserwujących, reakcjach i flagach braków. Do przeniesienia na Facebooka i Instagram używamy regresji ridge na $\log(1+\text{lajki})$ i $\log(1+\text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem; przy pominiętej platformie przenosi się ona lepiej niż CatBoost. Przedziały 50% i 90% dla każdego posta dają konformalna regresja kwantylowa [5].

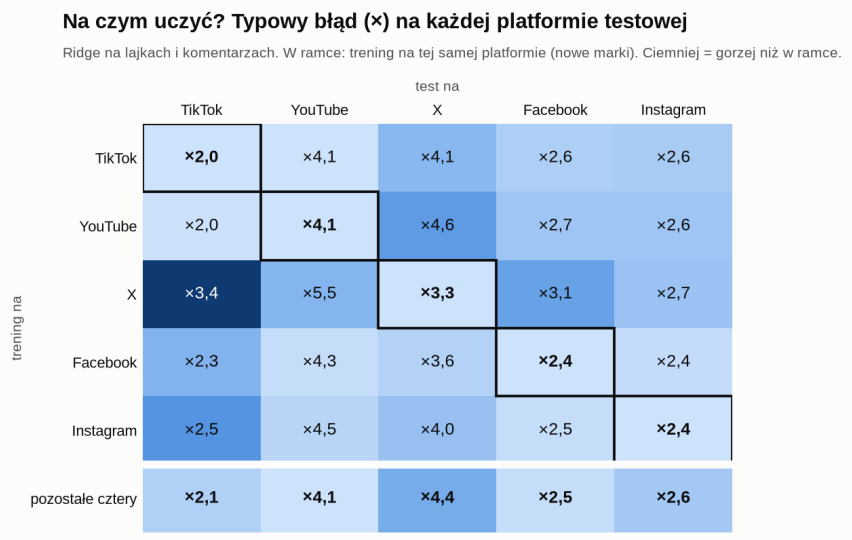
4 Wyniki

Wynik główny. Rys. 2 zestawia oba scenariusze. Na TikToku, YouTube i X, gdzie model uczy się na tej samej platformie, typowy błąd wynosi $\times$1,9, $\times$2,9 i $\times$3,0. Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się $\times$2,43 (przedział ufności $\times$2,05–$\times$3,03) i $\times$2,65 ($\times$2,39–$\times$3,12). To tyle samo, co ten sam model uczony na samej platformie docelowej ($\times$2,42 i $\times$2,36), więc zależność między reakcjami a wyświetleniami przenosi się między platformami prawie bez straty. Kolejność postów jest zachowana bardzo dobrze (Spearman 0,91 i 0,88).

Na czym uczyć. Facebook i Instagram dają się oszacować z dowolnej platformy z błędem $\times$2,4–$\times$3,1 (Rys. 3). Wyjątkiem jest X: model uczony na X myli się na YouTube $\times$5,5, a modele uczone gdzie indziej mylą się na X $\times$3,6–$\times$4,6. Na X większość postów ma zero lub jeden lajk (Rys. 1), więc reakcje mówią tam mało. Więcej platform w treningu nie zawsze pomaga: wszystkie cztery pozostałe dają na X $\times$4,4, a sam Facebook $\times$3,6. **TODO:** później: szósta platforma z publicznymi wyświetleniami (backlog B30).



Rysunek 2: Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post, oszacowany przez model, który nie widział jego marki (walidacja krzyżowa po markach). TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (338 rolek, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd 10^{MAE}.

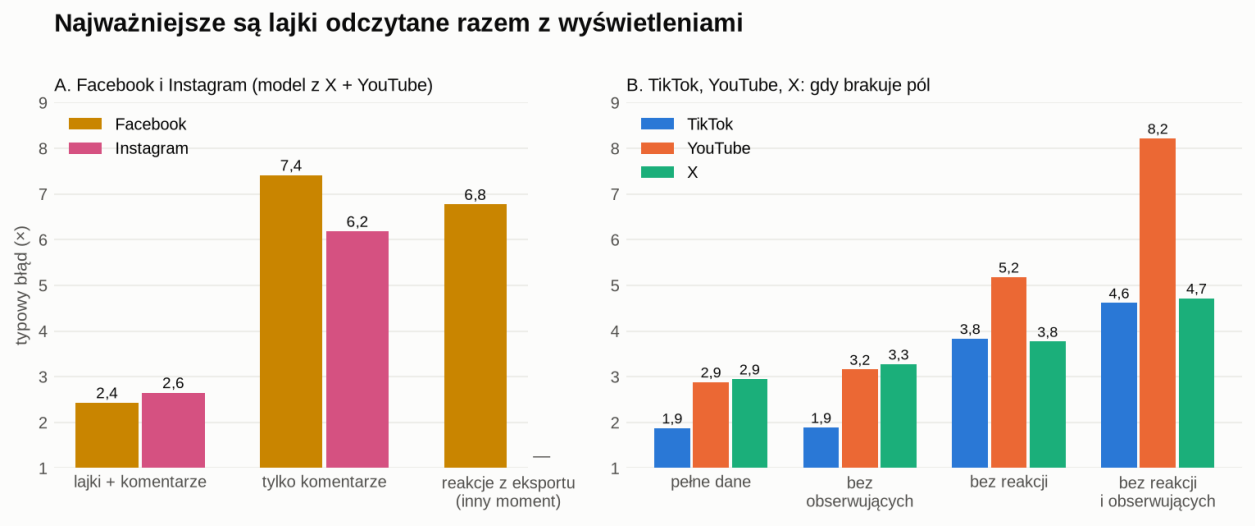


Rysunek 3: Typowy błąd przy uczeniu na jednej platformie i teście na innej.
Ridge na log lajków i komentarzy (jedyne dwa pola, które ma każda platforma). Wiersz: platforma treningowa, ostatni wiersz: wszystkie cztery pozostałe naraz. Kolumna: platforma testowa. W ramce: trening i test na tej samej platformie, na markach spoza treningu. Kolor: o ile błąd jest większy niż w ramce danej kolumny.

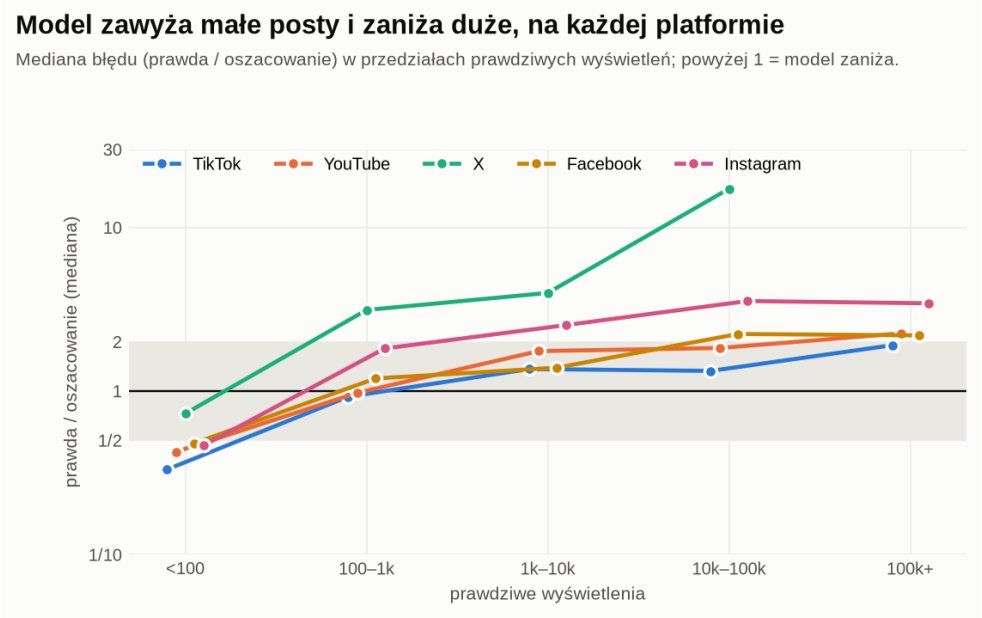
Czego model potrzebuje. Przeniesienie działa tylko z lajkami odczytanymi razem z wyświetleniami (Rys. 4A). Same komentarze dają ×6,2–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na platformach ze znanymi wyświetleniami (Rys. 4B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dla każdego układu dostępnych pól uczymy osobny model z osobnym przedziałem, dzięki czemu przedział 90% trafia w 88–90% postów w każdym przypadku; model uczony na pełnych danych i karmiony niepełnymi trafiałby tylko w 46–83%.

Kto jest źle szacowany. Na każdej platformie, także po przeniesieniu, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże (Rys. 5). To typowe ściąganie do średniej: reakcje nie odróżniają dobrze postu, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone kilkanaście razy; po przeniesieniu Instagram zaniża duże rolki około ×3.

Przedziały. Przedział 90% trafia w 89–90% postów na TikToku, YouTube i X, także na miesiącach spoza treningu (0,90–0,93). Na Facebooku trafia w 93% filmów kont poniżej miliona obserwujących, ale dla najwięk-



Rysunek 4: Typowy błąd przy różnych danych wejściowych.
A: Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": nasze pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak). B: TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach.



Rysunek 5: Błąd według wielkości posta.
Mediana stosunku prawdziwych do oszacowanych wyświetleń w przedziałach prawdziwych wyświetleń (pokazane przedziały z co najmniej 10 postami). Powyżej 1: model zaniża. Szary pas: w granicach ×2. Modele jak na Rys. 2.

szych kont tylko w 80–86%. Jeśli zamiast liczby podamy jeden z trzech przedziałów (<1 000, 1 000–10 000, >10 000), trafiamy w 78–82% postów na TikToku, YouTube, Facebooku i Instagramie.

5 Porównanie metod

Rodziny modeli. Tabela 2 porównuje modele na tych samych danych wejściowych. Po dostrojeniu prawie wszystkie rodziny dają ten sam błąd: ×1,85–×1,92 na TikToku, ×2,8–×2,9 na YouTube i ×2,9–×3,1 na X. Wyraźnie gorsze są tylko proste odniesienia (×4,6–×8,8) oraz regresja liniowa i kNN na YouTube (×3,0–×3,5). Najlepszym pojedynczym modelem jest TabPFN v2, ale wyprzedza CatBoost tylko o 0,002–0,010, czyli w granicach szumu między przebiegami, a liczy się około 150 razy dłużej. Sieć grafowa i transformer czytający post jako tekst są gorsze od CatBoost.

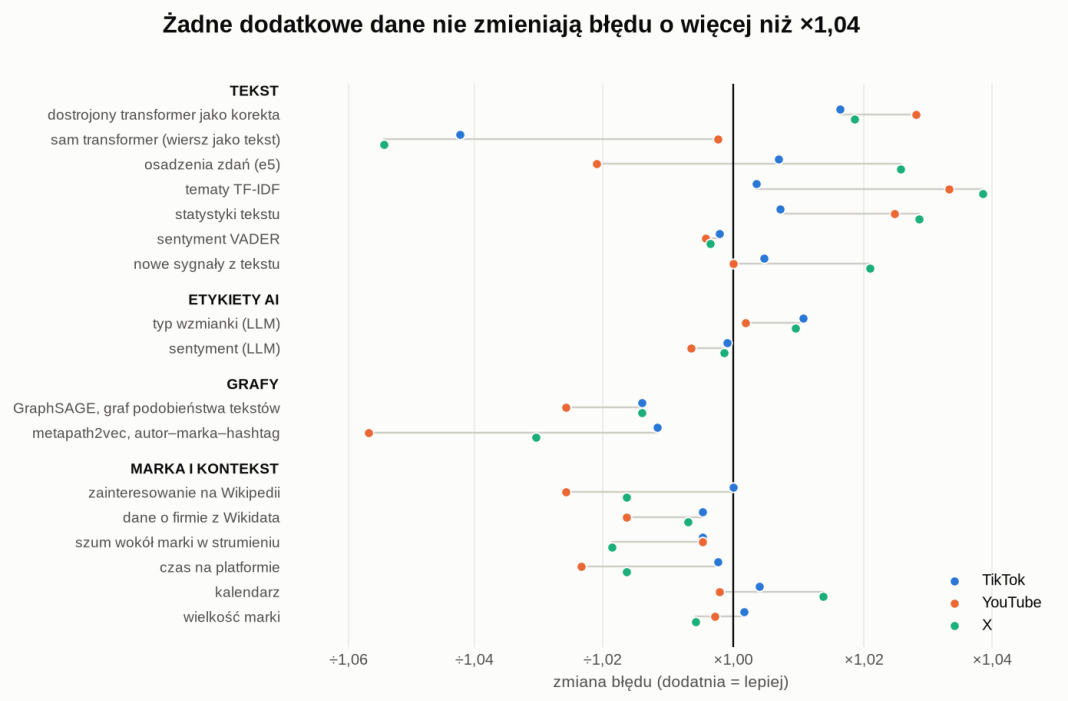
Dlaczego nie zespół. Zespół łączy oszacowania kilku modeli, np. przez ich średnią („średnia 3 najlepszych") albo przez model drugiego poziomu, który uczy się, jak ważyć oszacowania wszystkich rodzin („stos"). Błędy różnych modeli częściowo się znoszą, więc zespół jest zwykle trochę lepszy od każdego członka. U nas stos poprawia wynik o 0,011–0,028 (×1,03–×1,07). Zostajemy przy jednym modelu z trzech powodów: (1) zysk jest mały wobec typowego błędu ×1,9–×3,0; (2) stos wymaga trenowania i utrzymania kilkunastu modeli, a przedziały niepewności (CQR) i przeniesienie na inne platformy budujemy na jednym modelu; (3) przy przeniesieniu i tak wygrywa najprostszy model liniowy (rozdział 3), więc złożoność nie przekłada się na główny wynik.

Tabela 2: Porównanie rodzin modeli: MAE w skali $\log_{10}$ i typowy błąd (×).
Wszystkie modele na obserwujących, reakcjach i flagach braków, walidacja krzyżowa po markach. Modele z drzew, liniowe, jądrowe i MLP po strojeniu hiperparametrów (40 ustawień na fałd, strojenie zagnieżdżone). TabPFN, TabICL, GraphSAGE, transformer i stos pochodzą z osobnych przebiegów na tych samych danych; CatBoost w tych przebiegach mieścił się w 0,271–0,273 / 0,452–0,456 / 0,466–0,470, więc różnice poniżej około 0,005 są w granicach szumu. Pogrubione: najlepszy pojedynczy model w kolumnie. Zespoły pokazujemy tylko dla porównania.

Model	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	0,663 (×4,60)	0,944 (×8,79)	0,667 (×4,65)
stały mnożnik liczby obserwujących	0,919 (×8,30)	0,855 (×7,16)	0,879 (×7,57)
Modele liniowe i jądrowe			
regresja liniowa (ridge)	0,277 (×1,89)	0,545 (×3,51)	0,487 (×3,07)
k najbliższych sąsiadów (kNN)	0,283 (×1,92)	0,483 (×3,04)	0,490 (×3,09)
SVR z jądrem RBF	0,271 (×1,87)	0,463 (×2,90)	0,480 (×3,02)
Drzewa decyzyjne			
las losowy (random forest)	0,275 (×1,88)	0,463 (×2,90)	0,473 (×2,97)
extra trees	0,275 (×1,88)	0,459 (×2,88)	0,475 (×2,99)
gradient boosting (scikit-learn)	0,276 (×1,89)	0,453 (×2,84)	0,474 (×2,98)
LightGBM	0,275 (×1,88)	0,457 (×2,86)	0,475 (×2,99)
XGBoost	0,273 (×1,87)	0,450 (×2,82)	0,467 (×2,93)
CatBoost (model końcowy)	0,272 (×1,87)	0,452 (×2,83)	0,470 (×2,95)
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	0,276 (×1,89)	0,454 (×2,84)	0,477 (×3,00)
sieć grafowa GraphSAGE (graf podobnych tekstów)	0,279 (×1,90)	0,467 (×2,93)	0,474 (×2,98)
dostrojony transformer (wiersz jako tekst)	0,289 (×1,95)	0,454 (×2,84)	0,490 (×3,09)
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	**0,268 (×1,85)**	**0,443 (×2,77)**	**0,465 (×2,92)**
TabICL	0,272 (×1,87)	0,445 (×2,79)	0,466 (×2,92)
Zespoły modeli (dla porównania)			
średnia 3 najlepszych rodzin	0,270 (×1,86)	0,446 (×2,79)	0,469 (×2,94)
stos wszystkich rodzin	0,260 (×1,82)	0,425 (×2,66)	0,441 (×2,76)

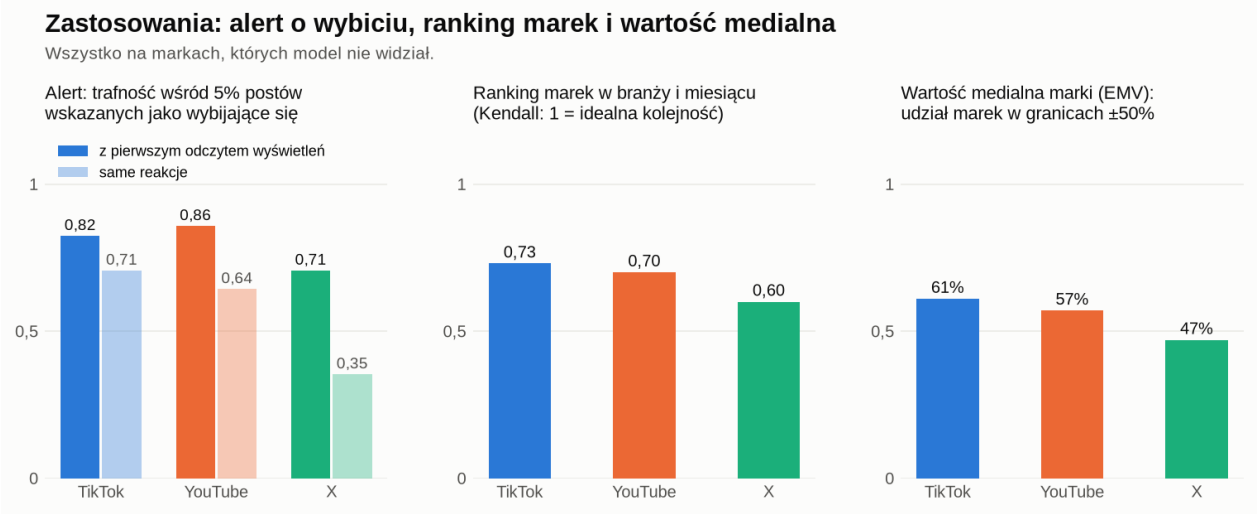
Dodatkowe dane. Sprawdziliśmy też ponad dwadzieścia dodatkowych źródeł sygnału (Rys. 6): tekst (od TF-IDF po osadzenia zdań), etykiety AI, grafy autorów i marek oraz dane zewnętrzne o markach. Żadne nie zmienia błędu o więcej niż ×1,04, a większość mniej niż ×1,02 albo pogarsza wynik. Tekst pomaga trochę na YouTube i X, grafy i dane zewnętrzne szkodzą. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436). Historię autora opisujemy osobno poniżej.

Historia autora. Jedynym sygnałem, który pomaga wyraźnie, jest historia autora. Ten sam autor ma podobną liczbę wyświetleń w kolejnych postach, niezależnie od reakcji: korelacja nadwyżki wyświetleń (prawda minus oszacowanie) między pierwszym a późniejszymi postami autora wynosi 0,68–0,70 na wszystkich trzech platformach, a autorzy z górnej jednej trzeciej mają przy tym samym oszacowaniu 4–9 razy więcej wyświetleń niż autorzy z dolnej. Wykorzystujemy to prosto: do oszacowania nowego posta dodajemy średnią nadwyżkę wcześniejszych postów tego autora, ściągniętą do zera, gdy postów jest mało (suma nadwyżek podzielona przez liczbę postów plus stała dobrana na innych markach). Na postach autorów z historią błąd spada z 0,37 do 0,26 na TikToku, z 0,50 do 0,35 na YouTube i z 0,53 do 0,43 na X (×1,3–×1,4); większość zysku daje już jeden wcześniejszy post. Taka historia jest jednak tylko dla 3–16% postów w naszej próbie, więc w średnim błędzie zysk znika (≤0,003). Sprawdziliśmy też tego samego autora na innej platformie: po dokładnym dopasowaniu nazwy pokrywa się 0–0,1% postów, za mało, żeby to ocenić. **TODO:** dopasowanie autorów między platformami po znormalizowanej nazwie konta, nie tylko dokładnej (pomysł do sprawdzenia).



Rysunek 6: Dodatkowe dane i cechy.
Zmiana typowego błędu względem modelu końcowego (transformer jako korekta, osadzenia, grafy, dane zewnętrzne) albo względem modelu na obserwujących i reakcjach (TF-IDF, statystyki tekstu, VADER, etykiety AI, kalendarz, wielkość marki). W prawo: lepiej, w lewo: gorzej; ×1,02 to zmiana MAE o około 0,01. *Transformer jako korekta*: dostrojony model językowy przewiduje błąd CatBoost z tekstu posta. *Osadzenia e5*: wielojęzyczny model zdań. *Etykiety LLM*: typ i sentyment wzmianki z modelu językowego. *GraphSAGE*: sieć grafowa na grafie podobnych tekstów; *metapath2vec*: osadzenia grafu autor–marka–hashtag. *Wikipedia, Wikidata*: zainteresowanie marką i dane o firmie. Wszystko z walidacją po markach.

6 Zastosowania



Rysunek 7: Zastosowania oszacowania na TikToku, YouTube i X.
Alert: z postów odczytanych po raz pierwszy model wskazuje 5%, które będą miały najwięcej wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV: wyświetlenia przeliczone na pieniądze stawką za tysiąc; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

Alert o wybiciu. Z pierwszym odczytem wyświetleń model wskazuje 5% postów, które się wybiją, z trafnością 0,82 / 0,86 / 0,71; same reakcje dają 0,71 / 0,64 / 0,35 (Rys. 7). Przy trzy razy większej liczbie alertów łapie 82–100% wybijających się postów.

Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek.

Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży.

7 Ograniczenia i rekomendacje

Wynik dla Facebooka opiera się na 20 markach (bez trzech największych ×2,9), a dla Instagramu na 11 (×2,95). Posty wiralowe są zaniżane ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek. Wyniki opisują zależności, nie przyczyny. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów.

TODO: jeden wykres końcowy: nasz model a stały mnożnik Brand24. **TODO:** opis użycia AI zgodnie z wymaganiami kursu; odtwarzalność: repozytorium, skrypty, rejestr eksperymentów.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.