# Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 9 listopada 2026

**Streszczenie**

Na Facebooku i Instagramie dane z monitoringu mediów nie zawierają liczby wyświetleń postów. Sprawdzamy, czy można ją oszacować z lajków i komentarzy modelem, który nie widział ani jednego wyświetlenia z tych platform. Regresja liniowa na lajkach i komentarzach, uczona tylko na X i YouTube, szacuje wyświetlenia 402 filmów z Facebooka z typowym błędem $\times 2{,}43$ (MAE 0,385 w skali $\log_{10}$), tyle samo co ten sam model uczony na Facebooku, a 642 rolek z Instagramu z błędem $\times 2{,}72$, gorzej niż ten sam model uczony na Instagramie ($\times 2{,}41$). Mediana wyświetleń z platform źródłowych myli się tam $\times 9$–$\times 20$. Model w praktyce przenosi stosunek wyświetleń do lajków: od samego stałego mnożnika lajków jest lepszy na trzech z sześciu platform docelowych, nie gorszy na dwóch i gorszy na X. Przeniesienie wymaga reakcji odczytanych razem z wyświetleniami; na Stack Exchange przenosi się tylko kolejność, a poziom jest gorszy niż ze stałej mediany. Wyniki opierają się odpowiednio na 20 i 11 markach, a wyświetlenia źródłowe i docelowe odczytano w różnym wieku postów (23 wobec ponad 300 dni), co może częściowo maskować różnice.

## 1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. Zasięg przybliża się wtedy regułą z liczby obserwujących lub reakcji, która nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] przenoszą wiedzę z Twittera na filmy z YouTube. Prace te przewidują jednak przyszłą popularność i mają dane o popularności z platformy docelowej, na których model się uczy lub kalibruje. Nasze zadanie to przeniesienie bez etykiet z dziedziny docelowej [4]: szacujemy bieżące wyświetlenia z widocznych reakcji na platformie, z której model nie dostaje w treningu ani jednej wartości wyświetleń. Wyświetlenia z tej platformy zbieramy osobno i używamy ich tylko do oceny. Nie znaleźliśmy pracy, która tak sprawdza przeniesienie modelu wyświetleń między platformami.

Nasz wkład:

- pokazujemy, że wystarczy prosta regresja liniowa na lajkach i komentarzach, uczona tylko na X i YouTube: szacuje wyświetlenia filmów na Facebooku z błędem $\times 2{,}43$, tyle samo co model uczony na Facebooku, a rolek na Instagramie $\times 2{,}72$ (model uczony na Instagramie: $\times 2{,}41$);
- porównujemy ją uczciwie z prostymi regułami na sześciu platformach docelowych i pokazujemy, kiedy przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi (X, poziom na Stack Exchange);
- dla każdego posta podajemy przedział niepewności, trafny na tej samej platformie; poza platformą wymaga on kalibracji na kilku markach z platformy docelowej;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

## 2 Dane

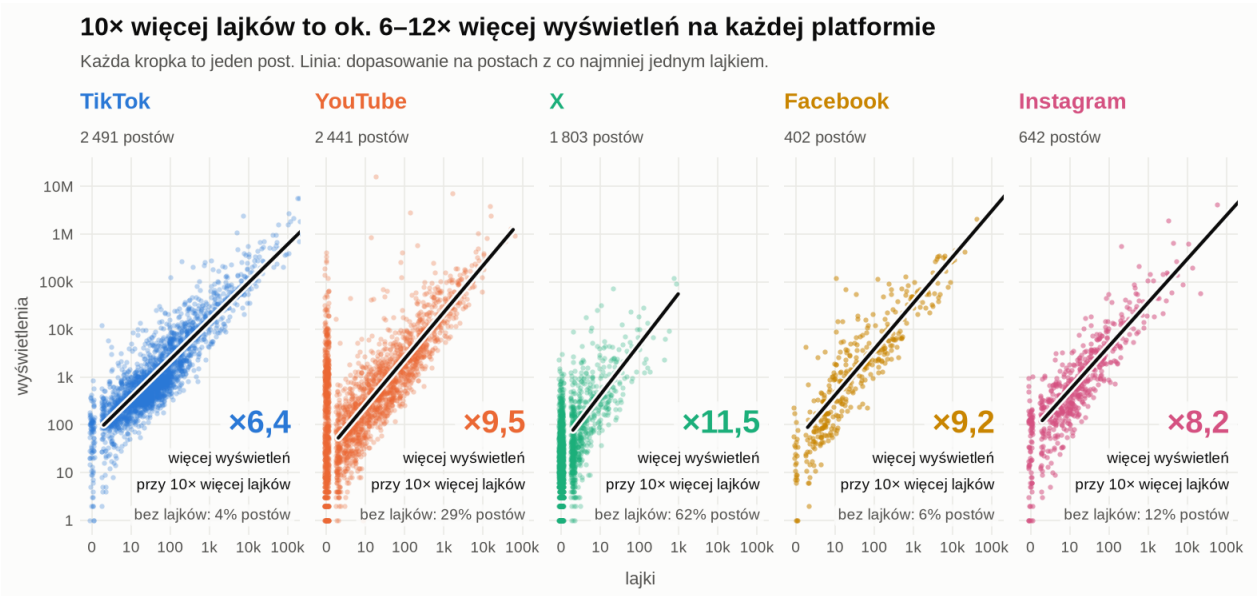
Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę; marka może występować na kilku platformach; 85% wzmianek opublikowano między kwietniem a sierpniem 2026 r., a 85% jest po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Eksport ma też kolumnę zasięgu, którą Brand24 wylicza regułą z reakcji i obserwujących (według naszej rekonstrukcji) i która na Facebooku i Instagramie zastępuje wyświetlenia. Dla Facebooka i Instagramu zebraliśmy wyświetlenia sami w listopadzie 2026 r., razem z lajkami i komentarzami z tej samej chwili. Z 470 filmów na Facebooku

68 było już usuniętych, zostaje 402 z 20 marek. Z 976 rolek na Instagramie 261 było usuniętych, 19 nie miało licznika wyświetleń, a 54 miało ukryte lajki, zostaje 642 z 11 marek. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Ponownie odczytaliśmy też wyświetlenia i reakcje 2 013 postów z X, 1 376 z YouTube i 426 z TikToka (rozdz. 5).

**Tabela 1:** Dane według platformy.

| Platforma | Marki | Autorzy | Źródło wyświetleń | Posty z wyśw. | Mediana wyśw. | Wyśw./lajk |
|---|---|---|---|---|---|---|
| TikTok | 266 | 2 411 | eksport Brand24 | 2 491 | 729 | 25 |
| YouTube | 273 | 2 041 | eksport Brand24 | 2 441 | 433 | 26 |
| X | 252 | 1 658 | eksport Brand24 | 1 803 | 27 | 22 |
| Facebook | 20 | $\geq$182[a] | własny odczyt (filmy) | 402 | 1 413 | 35 |
| Instagram | 11 | 541[b] | własny odczyt (rolki) | 642 | 504 | 53 |

a: autor znany dla 74% filmów. b: właściciel odczytany z publicznej strony rolki dla 627 z 642 rolek (98%); pozostałe są prywatne albo usunięte. Wyśw./lajk: mediana stosunku na postach z co najmniej jednym lajkiem.




**Rysunek 1:** Wyświetlenia a lajki, osobno dla każdej platformy.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków (6–12). TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

# 3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako *typowy błąd*, czyli mnożnik $10^{\text{MAE}}$ (MAE 0,30 $\approx \times 2$; to średnia geometryczna stosunku oszacowania do prawdy). Zgodność kolejności mierzymy korelacją rang Spearmana między oszacowanymi a prawdziwymi wyświetleniami. Każdy model porównujemy z dwiema regułami: medianą wyświetleń i *stałym mnożnikiem lajków* (wyświetlenia $= k \cdot$lajki, $k$ to mediana stosunku wyświetleń do lajków w danych treningowych, około 25). Przedziały ufności liczymy bootstrapem po markach, a różnice między modelami na tych samych postach sparowanym bootstrapem po markach.

**Walidacja.** Łączymy posty w grupy, jeśli mają wspólną markę, wspólnego autora albo identyczny tekst (jeden autor pisze czasem o kilku markach, a ten sam tekst bywa wklejany na różnych kontach), i dzielimy całe grupy na pięć części. Każda ocena dotyczy więc marki i autora, których model nie widział. Porównania metod (Tabela 4 i Rys. 4B) robimy na prostszym podziale po samych markach; ich liczby różnią się od Rys. 2 o najwyżej 0,012 (CatBoost na X: $\times$2,95 wobec $\times$3,03), a kolejność metod się nie zmienia.

**Dwa scenariusze, oznaczane na każdym wykresie.** *Na tej samej platformie*: CatBoost uczony na postach z danej platformy (TikTok, YouTube, X), oceniany na markach i autorach, których nie widział. *Poza platformą*: regresja ridge, która nie widzi w treningu ani jednego posta z platformy docelowej (Facebook, Instagram, Stack Exchange; w Tabelach 2 i 3 także TikTok, YouTube i X po kolei); wyświetlenia celu służą tylko do oceny.

**Modele.** Na tej samej platformie używamy CatBoost [5] na obserwujących, reakcjach i flagach braków (osobna cecha mówi, czy pole było puste, bo brak to nie zero). Poza platformą używamy regresji ridge [6] na $\log(1 + \text{lajki})$ i $\log(1 + \text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem. Przy pominiętej platformie przenosi się ona lepiej niż CatBoost i sieci MLP (o 0,014–0,062 MAE na każdej z pięciu platform, także po augmentacji danych). Główne liczby dla Facebooka i Instagramu pochodzą z eksportu Brand24 dla X i YouTube; wariant ze źródłem odczytanym ponownie (rozdz. 5) podajemy osobno, bo był sprawdzany już po obejrzeniu części rolek. Przedziały 50% i 90% dla każdego posta daje konformalna regresja kwantylowa (CQR) [7]: model kwantylowy wyznacza wstępny przedział, a jego szerokość poprawiamy na odłożonej części danych tak, żeby pokrycie było zgodne z założonym.

# 4 Wyniki

**Główne wyniki: o ile mylimy się na pojedynczym poście**

| | | Posty / marki | **Nasz błąd** | W granicach ×2 | Stała mediana |
|---|---|---|---|---|---|
| Na tej samej platformie | TikTok | 2 491 / 266 | ×**1,87** | 67% | ×4,6 |
| | YouTube | 2 441 / 273 | ×**2,90** | 43% | ×8,8 |
| | X | 1 803 / 252 | ×**3,03** | 40% | ×4,6 |
| Poza platformą (0 postów celu) | Facebook | 402 / 20 | ×**2,43** | 53% | ×19,9 |
| | Instagram | 642 / 11 | ×**2,72** | 40% | ×8,7 |

Nasz błąd: typowy błąd $10^{\text{MAE}}$, np. ×2,43 to oszacowanie zwykle 2,43 razy za duże albo za małe. Stała mediana: jedna liczba dla wszystkich postów (mediana tej samej platformy, a poza platformą mediana X i YouTube).

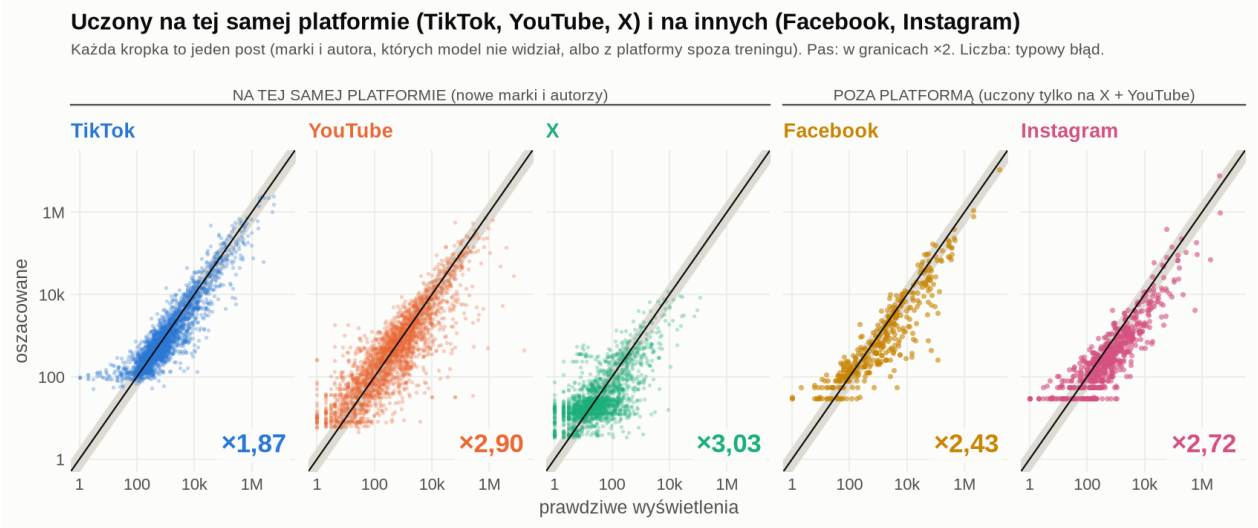
**Na tej samej platformie.** Na TikToku, YouTube i X typowy błąd wynosi ×1,87, ×2,90 i ×3,03 (MAE 0,273 / 0,462 / 0,482; Rys. 2). Stały mnożnik lajków daje tu ×2,23, ×4,06 i ×3,63, więc CatBoost jest od niego lepszy na każdej platformie o 0,075–0,15 MAE (przedziały ufności różnic nie obejmują zera).

**Poza platformą.** Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się o MAE 0,385 (×2,43, 95% CI ×2,05–×3,03) i 0,435 (×2,72, ×2,49–×3,05). Na Facebooku błąd jest taki sam jak przy uczeniu tego samego modelu na Facebooku (×2,42; różnica 0,001, 95% CI [−0,03; 0,03], czyli różnica co najwyżej ×1,07 w którąkolwiek stronę). Na Instagramie jest wyraźnie gorzej niż przy uczeniu ridge na samym Instagramie (×2,41; różnica 0,054, 95% CI [0,021; 0,093]), a 72% rolek jest niedoszacowanych, bo mediana rolki to 53 wyświetlenia na lajk, a na X i YouTube około 25 (Tabela 1). Wynik nie zależy od wyboru X i YouTube: mediana po wszystkich 15 zestawach treningowych bez platformy docelowej to ×2,58 na Facebooku i ×2,65 na Instagramie. Kolejność postów jest zachowana dobrze (Spearman 0,91 i 0,86, wewnątrz jednej marki 0,80 i 0,83), ale tak samo dobrze porządkują je same lajki. Typowa marka ma większy błąd niż całość: mediana po markach to ×2,7 na Facebooku i ×2,9 na Instagramie. Źródło i cel różnią się też wiekiem odczytu (rozdz. 8), co może częściowo maskować różnice między platformami.

**Regresja a stały mnożnik.** Regresja w praktyce przenosi stosunek wyświetleń do lajków, więc trzeba ją porównać z samym mnożnikiem wyznaczonym na tych samych danych (Tabela 2). Regresja jest lepsza na TikToku, Instagramie i Stack Exchange, nie lepsza na Facebooku i YouTube (przedziały ufności sięgają zera) i gorsza na X, gdzie 62% postów nie ma lajka, a komentarze ciągną oszacowanie w złą stronę. Obie metody są 2–8 razy dokładniejsze od mediany platform źródłowych na każdej platformie z filmami, ale na Stack Exchange mediana wygrywa z obiema.

**Kto jest źle szacowany.** Na każdej platformie, także poza platformą, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże. To regresja do średniej: reakcje nie odróżniają dobrze posta, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone około 10 razy; poza platformą Instagram zaniża duże rolki około ×3.

**Przedziały.** Na tej samej platformie przedział 90% trafia w 87–91% postów na TikToku, YouTube i X, także gdy model uczymy na wcześniejszych miesiącach, a testujemy na późniejszym (0,90–0,93). Poza platformą




**Rysunek 2:** Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post. TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie, walidacja bez wspólnych marek, autorów i tekstów; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (642 rolki, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube, bez żadnego posta z platformy docelowej; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd $10^{\mathrm{MAE}}$.

**Tabela 2:** Poza platformą: regresja a proste reguły wyznaczone na tych samych platformach źródłowych.
Typowy błąd (×); różnica MAE regresja − mnożnik ze sparowanym 95% CI po markach (ujemna: regresja lepsza). Źródło: X + YouTube, a dla X i YouTube jako celu pozostałe cztery platformy. Mediana: jedna liczba dla wszystkich postów, mediana wyświetleń źródła.

| Cel | Źródło | Regresja | Mnożnik lajków | Różnica [95% CI] | Mediana źródła |
|---|---|---|---|---|---|
| TikTok | X + YT | ×2,05 | ×2,22 | −0,034 [−0,038; −0,029] | ×11,0 |
| YouTube | pozostałe 4 | ×4,08 | ×4,03 | +0,004 [0,000; 0,009] | ×8,9 |
| X | pozostałe 4 | ×4,37 | ×3,45 | +0,103 [0,084; 0,120] | ×22,1 |
| Facebook | X + YT | ×2,43 | ×2,42 | +0,002 [−0,017; 0,022] | ×19,9 |
| Instagram | X + YT | ×2,72 | ×2,94 | −0,034 [−0,047; −0,020] | ×8,7 |
| Stack Exchange | X + YT | ×3,14 | ×5,33 | −0,229 [−0,240; −0,207] | ×2,1 |

sam rozrzut błędów z X i YouTube daje za szeroki przedział (na Facebooku trafia w 96% filmów). Trafny przedział wymaga kalibracji na kilku markach z platformy docelowej, czyli kilkudziesięciu postach ze znanymi wyświetleniami: po kalibracji na 25% marek trafia w 89% filmów na Facebooku, ale tylko w 84% dla 70 filmów z kont powyżej miliona obserwujących (±9 punktów procentowych). Na Instagramie do kalibracji są tylko 2 marki, więc tego nie oceniamy.

# 5 Przeniesienie między platformami

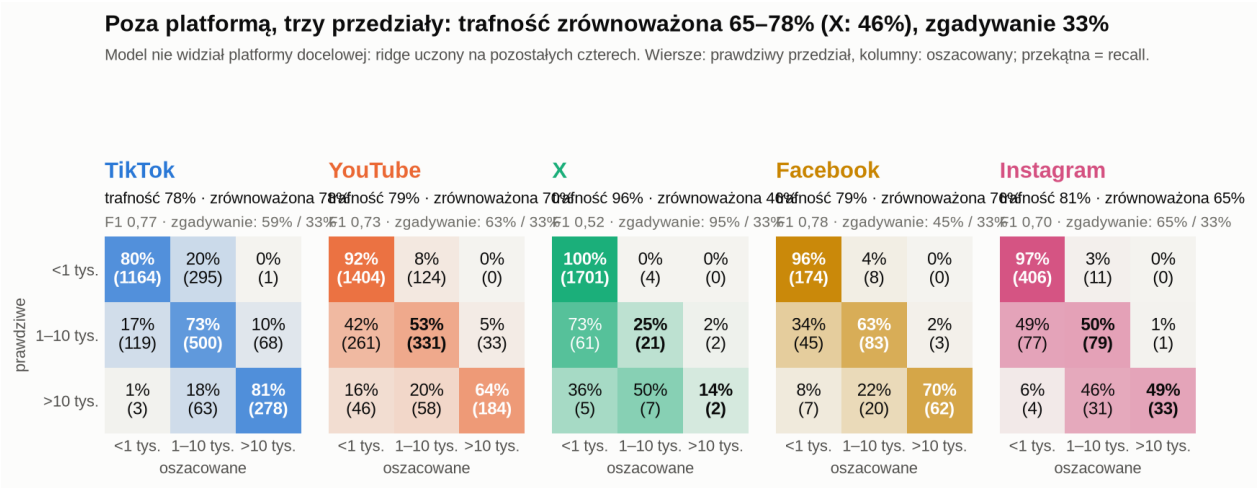
**Różne zestawy treningowe.** Prawdziwe wyświetlenia mamy na wszystkich pięciu platformach, więc każdą możemy potraktować jak „ukrytą” (Tabela 3). Facebook i Instagram dają się oszacować z prawie dowolnego zestawu z błędem ×2,4–×3,1: na Facebooku tyle, co ridge uczony na nim samym (×2,4), na Instagramie ×2,5–×2,8 wobec ×2,4. Najgorszy jest trening na samym X. X jest wyjątkiem w obie strony: model uczony na X myli się na YouTube ×5,5, a żaden zestaw nie osiąga na X błędu mniejszego niż ×3,6, wobec ×3,3 przy uczeniu na X. Część tej różnicy to wczesny odczyt wyświetleń w eksporcie: na danych odczytanych ponownie X jako cel ma ×3,0 zamiast ×4,4, a YouTube ×2,2 zamiast ×4,1 (mediany po zestawach). Przedziały ufności mają około ±0,013–0,032 MAE na TikToku, YouTube i X, ±0,04 na Instagramie i ±0,07 na Facebooku, więc różnice między zestawami poniżej około ×1,1–×1,2 na Facebooku i Instagramie mieszczą się w szumie.

**Trzy przedziały zamiast liczby.** Ten test jest w całości poza platformą, także dla TikToka, YouTube i X, więc model jest tu inny niż na Rys. 2. Dzielimy wyświetlenia na trzy przedziały: poniżej 1 000, 1 000–10 000 i powyżej 10 000 (Rys. 3). Trafność (*accuracy*) wynosi 78–81%, ale przedziały mają bardzo różną liczebność, więc ważniejsza jest zrównoważona trafność (*balanced accuracy*, średnia czułość, *recall*, po przedziałach): 78% na TikToku, 76% na Facebooku, 70% na YouTube i 65% na Instagramie, wobec 33% przy zgadywaniu; macro

**Tabela 3:** Typowy błąd (×) regresji na lajkach i komentarzach przy różnych platformach treningowych.
Ridge na log lajków i komentarzy, posty z platform treningowych połączone w jeden zbiór. Wiersz: platformy w treningu (TT TikTok, YT YouTube, X, FB Facebook, IG Instagram): pojedyncze, X + YouTube (zestaw główny), TikTok + YouTube + X i wszystkie z czterema platformami; pełna tabela 30 zestawów jest w repozytorium. Kolumna: platforma testowa, której nie było w treningu. Pierwszy wiersz: ten sam ridge uczony na platformie testowej (walidacja po markach), a nie CatBoost z Rys. 2. Pogrubione: najlepszy wynik w kolumnie wśród pokazanych zestawów (bez pierwszego wiersza). Ciemniej: większy błąd.

| Trening na | TikTok | YouTube | X | Facebook | Instagram |
|---|---|---|---|---|---|
| *ridge, ta sama platforma* | 1,99 | 4,15 | 3,30 | 2,42 | 2,41 |
| YT | **2,00** | trening | 4,64 | 2,72 | 2,63 |
| FB | 2,30 | 4,26 | **3,60** | trening | **2,47** |
| IG | 2,46 | 4,50 | 4,06 | 2,48 | trening |
| TT | trening | **4,07** | 4,15 | 2,61 | 2,59 |
| X | 3,38 | 5,52 | trening | 3,07 | 2,74 |
| X + YT | 2,05 | trening | trening | **2,43** | 2,72 |
| TT + YT + X | trening | trening | trening | 2,49 | 2,69 |
| YT + X + FB + IG | 2,12 | trening | trening | trening | trening |
| TT + YT + X + IG | trening | trening | trening | 2,46 | trening |
| TT + YT + X + FB | trening | trening | trening | trening | 2,66 |
| TT + X + FB + IG | trening | 4,08 | trening | trening | trening |
| TT + YT + FB + IG | trening | trening | 4,37 | trening | trening |

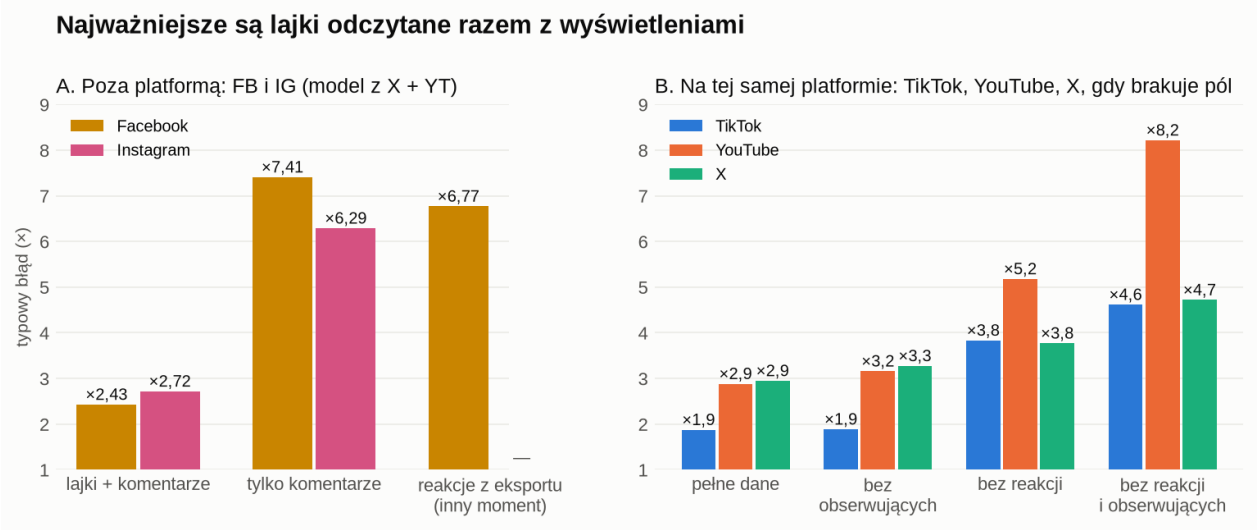
F1 0,70–0,78. O dwa przedziały mylimy się w 0,2–1,9% postów. Najsłabszy jest zwykle środkowy przedział (recall 50–73%), na Instagramie górny (49%). Na X model praktycznie nie działa: trafność 96% bierze się stąd, że 95% postów ma poniżej tysiąca wyświetleń, a zrównoważona trafność to tylko 46% (z 98 postów powyżej tysiąca trafia 23). Widzimy dwa powody: 62% postów na X nie ma lajka (usunięcie ich z danych treningowych zmniejsza błąd na X o 0,08), a wyświetlenia w eksporcie X są odczytane wcześnie, około dwukrotnie niżej niż w naszym ponownym odczycie.




**Rysunek 3:** Oszacowanie poza platformą pocięte na trzy przedziały wyświetleń.
Dla każdej platformy ridge na lajkach i komentarzach uczony na pozostałych czterech. Wiersz: prawdziwy przedział; kolumna: oszacowany; w komórce udział w wierszu i liczba postów; przekątna (pogrubiona) to recall przedziału. Nad tabelą: accuracy, balanced accuracy (średni recall), macro F1; szare: wartości przy zgadywaniu zawsze najczęstszego przedziału.

**Czego model potrzebuje.** Przeniesienie działa tylko z lajkami odczytanymi w tej samej chwili co wyświetlenia (Rys. 4A). Same komentarze dają ×6,3–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na tej samej platformie (Rys. 4B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dlatego dla każdego układu dostępnych pól uczymy osobny model z osobnym przedziałem.

**Świeże dane źródłowe.** Gdy ten sam model uczymy na X i YouTube odczytanych ponownie, razem z reakcjami z tej samej chwili, błąd na Instagramie spada z ×2,72 do ×2,41 (przypadkiem tyle samo, co ridge




**Rysunek 4:** Typowy błąd przy różnych danych wejściowych.
A (poza platformą): Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak tych danych). B (na tej samej platformie): TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach.

uczony na samym Instagramie), a na Facebooku zostaje ×2,44. Niedoszacowanie dużych postów i sum dla marek zmniejsza się mniej więcej o połowę. Samo przesunięcie wyświetleń z eksportu do późniejszego wieku tego nie daje, więc ważne jest, żeby wyświetlenia i reakcje pochodziły z tego samego momentu. Ten wariant nie zastępuje wyniku głównego, bo zysk na Instagramie sprawdziliśmy już po obejrzeniu części rolek.

**Szósta platforma.** Pobraliśmy przez publiczne API 538 pytań z serwisów Stack Exchange (m.in. Stack Overflow, Super User, Android) o 48 markach z naszych danych, z kwietnia–sierpnia 2026. Głos za traktujemy jak lajk, a odpowiedzi i komentarze jak komentarze; to przypisanie ustaliliśmy przed oceną. Przenosi się kolejność, ale nie poziom: model z X i YouTube myli się ×3,14, gorzej niż stała mediana z samego Stack Exchange (×1,96) i niż mediana z X i YouTube (×2,10), bo 96% pytań jest niedoszacowanych (wyświetlenia pytań zbierają się miesiącami, a głos to nie lajk). Kolejność pytań zachowuje tak samo jak ridge uczony na Stack Exchange (Spearman 0,57 w obu przypadkach). Wyświetlenia pytań mają mały rozrzut (odchylenie standardowe 0,40 wobec 1,21 na Facebooku), więc nawet ridge uczony na Stack Exchange (×1,77) jest tylko o 15% lepszy od mediany. Stosunek wyświetleń do reakcji przenosi się więc między serwisami z filmami, a na serwis z pytaniami tylko kolejność.

# 6 Porównanie metod

**Rodziny modeli.** Tabela 4 porównuje modele na tej samej platformie, na tych samych danych wejściowych. Po dostrojeniu prawie wszystkie rodziny dają ten sam błąd. TabPFN v2 [9] wyprzedza CatBoost o 0,004–0,009, mniej niż przedział ufności (±0,012–0,021), a liczy się około 150 razy dłużej. Stos wszystkich rodzin (model drugiego poziomu ważący ich oszacowania) poprawia wynik o 0,012–0,029, na YouTube i X więcej niż szum. Zostajemy jednak przy jednym modelu: zysk to ×1,03–×1,07 wobec typowego błędu ×1,9–×3,0, stos wymaga utrzymania kilkunastu modeli, a przedziały CQR i przeniesienie budujemy na jednym modelu, przy czym poza platformą i tak wygrywa model liniowy.

**Dodatkowe dane i cechy.** Sprawdziliśmy ponad dwadzieścia dodatkowych źródeł sygnału: tekst (od TF-IDF po osadzenia zdań e5 [12] i słownik sentymentu VADER [13]), etykiety typu i sentymentu z modelu językowego, grafy autorów i marek (GraphSAGE [14], metapath2vec [15]), dane o markach z Wikipedii i Wikidata, syntetyczne duże posty (SMOTER/SMOGN [16]), reprezentacje uczone bez etykiet (SCARF [17]) i pseudo-etykiety. Żadne nie poprawia błędu o więcej niż ×1,04, większość mniej niż ×1,02, a niektóre pogarszają go do ×1,06. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436).

**Historia autora.** Ten sam autor ma podobną nadwyżkę wyświetleń (prawda minus oszacowanie) w kolejnych postach: korelacja między pierwszym a późniejszymi postami wynosi 0,68–0,70. Dodanie do oszacowania średniej nadwyżki wcześniejszych postów autora, ściągniętej do zera przy małej liczbie postów, zmniejsza błąd

**Tabela 4:** Na tej samej platformie: rodziny modeli, MAE w skali $\log_{10}$ i typowy błąd (×).
Obserwujący, reakcje i flagi braków, walidacja po markach, strojenie zagnieżdżone (40 ustawień na fałd). TabPFN, TabICL, GraphSAGE, transformer i zespoły z osobnych przebiegów na tych samych danych. 95% CI dla CatBoost: ±0,012 / ±0,021 / ±0,021, więc różnice poniżej około 0,01 są w granicach szumu. *: podział bez wspólnych marek, autorów i tekstów.

| Model | TikTok | YouTube | X |
|---|---|---|---|
| *Proste odniesienia* | | | |
| mediana wyświetleń platformy | 0,663 (×4,60) | 0,944 (×8,79) | 0,667 (×4,65) |
| stały mnożnik liczby obserwujących | 0,919 (×8,30) | 0,855 (×7,16) | 0,879 (×7,57) |
| stały mnożnik lajków* | 0,348 (×2,23) | 0,609 (×4,06) | 0,560 (×3,63) |
| *Modele liniowe i jądrowe* | | | |
| regresja liniowa (ridge) | 0,277 (×1,89) | 0,545 (×3,51) | 0,487 (×3,07) |
| k najbliższych sąsiadów (kNN) | 0,283 (×1,92) | 0,483 (×3,04) | 0,490 (×3,09) |
| SVR z jądrem RBF | 0,271 (×1,87) | 0,463 (×2,90) | 0,480 (×3,02) |
| *Drzewa decyzyjne* | | | |
| las losowy (random forest) | 0,275 (×1,88) | 0,463 (×2,90) | 0,473 (×2,97) |
| extra trees | 0,275 (×1,88) | 0,459 (×2,88) | 0,475 (×2,99) |
| gradient boosting (scikit-learn) | 0,276 (×1,89) | 0,453 (×2,84) | 0,474 (×2,98) |
| LightGBM [8] | 0,275 (×1,88) | 0,457 (×2,86) | 0,475 (×2,99) |
| XGBoost [10] | 0,273 (×1,87) | 0,450 (×2,82) | 0,467 (×2,93) |
| CatBoost (model końcowy) | 0,272 (×1,87) | 0,452 (×2,83) | 0,470 (×2,95) |
| *Sieci neuronowe* | | | |
| perceptron wielowarstwowy (MLP) | 0,276 (×1,89) | 0,454 (×2,84) | 0,477 (×3,00) |
| GraphSAGE [14] (graf podobnych tekstów) | 0,279 (×1,90) | 0,467 (×2,93) | 0,474 (×2,98) |
| dostrojony transformer (wiersz jako tekst) | 0,289 (×1,95) | 0,454 (×2,84) | 0,490 (×3,09) |
| *Modele wstępnie wytrenowane dla tabel* | | | |
| TabPFN v2 | 0,268 (×1,85) | 0,443 (×2,77) | 0,465 (×2,92) |
| TabICL [11] | 0,272 (×1,87) | 0,445 (×2,79) | 0,466 (×2,92) |
| *Zespoły modeli (dla porównania)* | | | |
| średnia 3 najlepszych rodzin | 0,270 (×1,86) | 0,446 (×2,79) | 0,469 (×2,94) |
| stos wszystkich rodzin | 0,260 (×1,82) | 0,425 (×2,66) | 0,441 (×2,76) |

na tych postach ×1,3–×1,4. To jednak inne zadanie, bo wymaga znanych wyświetleń autora na tej samej platformie, a taka historia jest tylko dla 3–16% postów (w średnim błędzie ≤0,003). Ten sam autor na innej platformie występuje w 0,67% postów.

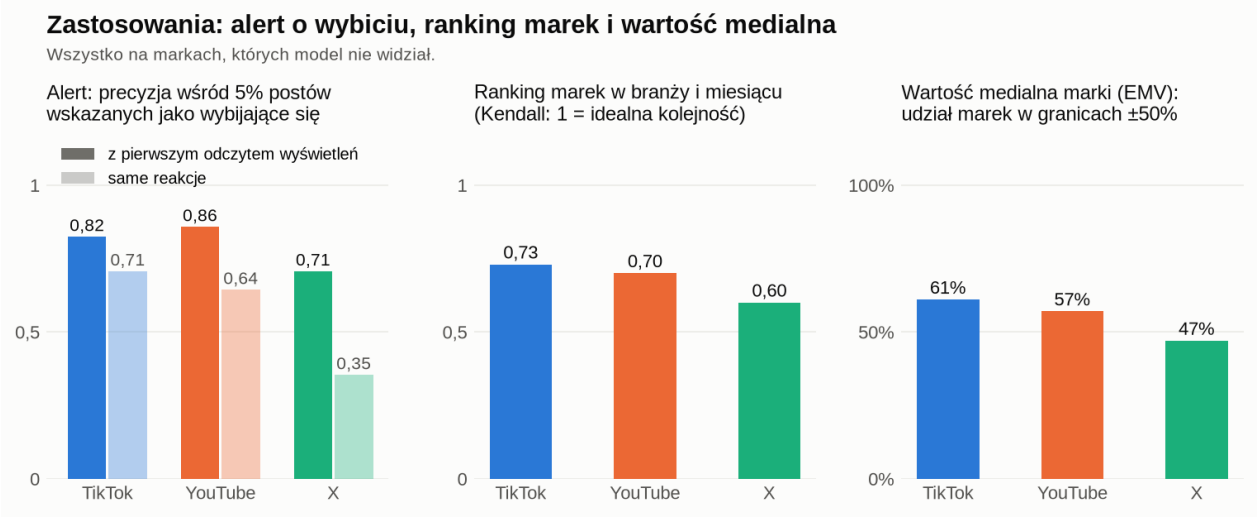
# 7 Zastosowania

**Alert o wybiciu.** Z pierwszego odczytu model wskazuje 5% postów, które skończą w górnych 5% wyświetleń, z trafnością 0,82 / 0,86 / 0,71; ten sam alert z samych reakcji, bez modelu, daje 0,71 / 0,64 / 0,35 (Rys. 5).

**Ranking marek.** Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

**Wartość medialna.** EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek. Stawka tylko skaluje wynik, więc odsetki od niej nie zależą.

**Posty odstające.** Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%; typ wzmianki z etykiet modelu językowego). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży, wzmianki nie o marce (E224).




**Rysunek 5:** Zastosowania oszacowania na TikToku, YouTube i X (na tej samej platformie).
Alert: z pierwszego, wczesnego odczytu wyświetleń i reakcji model wskazuje 5% postów, które skończą w górnych 5% wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik korelacji rang Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV (*earned media value*): wyświetlenia przeliczone na pieniądze stałą stawką 5 USD za tysiąc wyświetleń; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

# 8 Ograniczenia i rekomendacje

**Mało marek.** Wynik dla Facebooka opiera się na 20 markach, a dla Instagramu na 11; trzy największe marki to 39% i 44% postów, a bez nich błąd rośnie do ×2,89 i ×2,96. Błąd pojedynczej marki waha się od ×1,5 do ×6,2 na Facebooku i od ×2,2 do ×4,3 na Instagramie. Przy tak małej liczbie marek przedziały ufności z bootstrapu po markach mogą być za wąskie.

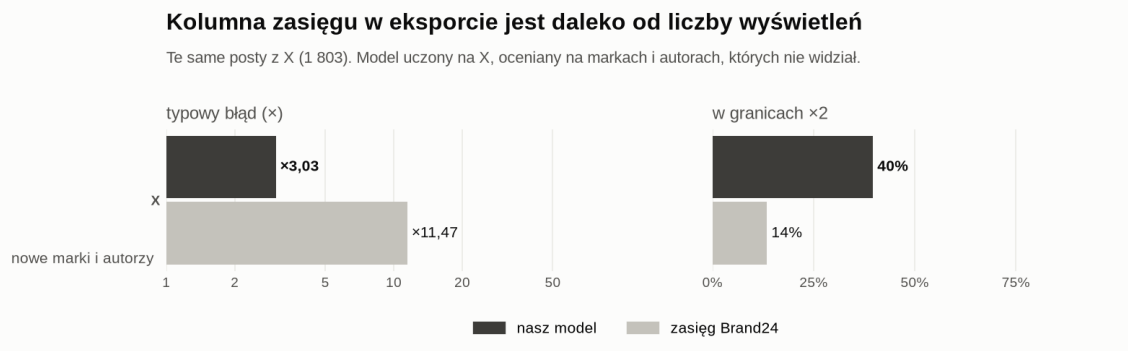
**Wybór postów.** Mierzymy tylko filmy i rolki, które były jeszcze dostępne. Na Instagramie odpadły też rolki z ukrytymi lajkami, czyli dokładnie te, dla których szacunek byłby w praktyce najbardziej potrzebny; tam model musiałby opierać się na samych komentarzach (×6,3).

**Wiek odczytu.** Wyświetlenia w eksporcie X i YouTube odczytano w medianie po 23 dniach od publikacji, a nasze odczyty z Facebooka i Instagramu po 310 i 334 dniach. Zgodność na Facebooku może więc częściowo wynikać ze znoszenia się dwóch efektów: gdy przesuniemy same wyświetlenia źródłowe do późniejszego wieku, błąd na Facebooku rośnie o 0,10 (×3,05), a dopiero przesunięcie wyświetleń razem z reakcjami przywraca ×2,44.

**Wzmianki nie o marce.** Brand24 dopasowuje wzmianki po słowach kluczowych. W 6,7% wzmianek nazwy marki w ogóle nie ma w tekście, a według osobnych etykiet tematu z modelu językowego (niesprawdzonych jeszcze przez człowieka) marka nie jest głównym tematem w około 64% wzmianek. Nie zmienia to błędu oszacowania wyświetleń posta, ale sumy marek zawierają przez to także posty o czymś innym, a podział walidacji po markach jest mniej czysty.

**Inne.** Na tej samej platformie najpopularniejszy 1% postów na YouTube i X jest zaniżany ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek. Prawie każdy post ma innego autora (2 411 autorów na 2 491 postów na TikToku, 2 041 na 2 441 na YouTube, 1 658 na 1 803 na X), więc historii autora nie da się użyć dla większości postów. Wyniki opisują zależności, nie przyczyny. Kod, liczby i karty wszystkich eksperymentów są w repozytorium projektu.

**Rekomendacje.** Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów. Rys. 6 pokazuje, co daje to dziś: kolumna zasięgu w eksporcie, czytana przez klientów jako liczba odbiorców, jest dalej od wyświetleń niż nasze oszacowanie.




**Rysunek 6:** Nasze oszacowanie a kolumna zasięgu w eksporcie Brand24, na tych samych 1 803 postach z X. Zasięg to inna miara niż wyświetlenia, więc rysunek pokazuje, jak daleko od wyświetleń jest liczba, którą klient dostaje dziś, a nie porównanie dwóch modeli. Model uczony na X, oceniany na nowych markach i autorach (których nie widział w treningu); prawda z eksportu.

**Użycie AI i odtwarzalność.** **TODO:** do napisania przez zespół własnymi słowami. Fakty do ujęcia: agenci AI (Claude Code, DeepSeek) pisali kod analiz i odczytu danych, uruchamiali eksperymenty, robili wykresy i szkic tekstu; modele językowe oznaczyły typ i sentyment wzmianek; logi sesji agentów są w `logs/`. Każdy wynik ma kartę eksperymentu, wiersz w rejestrze (`docs/pl/experiments.md`), skrypt w `src/` i liczby w `data/processed/`.

# Literatura


[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan. A theory of learning from different domains. *Machine Learning*, 79, 2010.

[5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[6] A. E. Hoerl, R. W. Kennard. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 1970.

[7] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.

[8] G. Ke i in. LightGBM: a highly efficient gradient boosting decision tree. *NeurIPS*, 2017.

[9] N. Hollmann i in. Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 2025.

[10] T. Chen, C. Guestrin. XGBoost: a scalable tree boosting system. *KDD*, 2016.

[11] J. Qu, D. Holzmüller, G. Varoquaux, M. Le Morvan. TabICL: a tabular foundation model for in-context learning on large data. *ICML*, 2025.

[12] L. Wang i in. Text embeddings by weakly-supervised contrastive pre-training. arXiv:2212.03533, 2022.

[13] C. J. Hutto, E. Gilbert. VADER: a parsimonious rule-based model for sentiment analysis of social media text. *ICWSM*, 2014.

[14] W. L. Hamilton, R. Ying, J. Leskovec. Inductive representation learning on large graphs. *NeurIPS*, 2017.

[15] Y. Dong, N. V. Chawla, A. Swami. metapath2vec: scalable representation learning for heterogeneous networks. *KDD*, 2017.

[16] P. Branco, L. Torgo, R. P. Ribeiro. SMOGN: a pre-processing approach for imbalanced regression. *LIDTA*, PMLR 74, 2017.

[17] D. Bahri, H. Jiang, Y. Tay, D. Metzler. SCARF: self-supervised contrastive learning using random feature corruption. *ICLR*, 2022.