Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 8 listopada 2026

Roboczy spis treści (usunąć przed oddaniem; razem ≤ 8 stron)

1. **Wstęp** (0,75 str.) — problem ukrytych wyświetleń, literatura, pytanie badawcze, wkład. *Napisany.*
2. **Dane i pomiar** (1 str.) — próba Brand24, skąd prawda na każdej platformie, Tabela 1, Rysunek 1. *Napisany, IG do uzupełnienia.*
3. **Metoda i walidacja** (1 str.) — cel i miara błędu, walidacja po markach i w czasie, dwa modele, przedziały, sufit szumu. *Napisany.*
4. **Wyniki A: platformy ze znanymi wyświetleniami** (1,25 str.) — błąd na TikToku, YouTube i X, pokrycie przedziałów, które pola są ważne.
5. **Wyniki B: przeniesienie na Facebooka i Instagram** (1,5 str.) — wynik główny: FB ×2,4, IG ×2,65; kalibracja na 25 postach; macierz platform treningowych.
6. **Wyniki C: brakujące dane i pewność** (0,5 str.) — co, gdy brakuje reakcji lub obserwujących; przedziały wyświetleń (np. 3 przedziały, trafność ok. 0,8).
7. **Co nie działa** (0,5 str., tabela) — tekst, grafy, etykiety AI, dane zewnętrzne: wszystko poprawia o ≤0,01.
8. **Zastosowania poboczne** (0,5 str.) — alert o wybiciu, rankingi marek, EMV.
9. **Ograniczenia, dyskusja, rekomendacje** (0,75 str.) — mało marek na FB i IG, tylko filmy i rolki, posty wiralowe; co powinien zbierać dostawca; jeden wykres porównania z regułą Brand24.

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara takiego zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. Bez niej trudno ocenić, ile osób faktycznie zobaczyło dany post, a jeszcze trudniej przewidzieć, ile go zobaczy. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji. Taki mnożnik nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści w sieci jest szeroko badane [1]. Część prac sprawdza też przenoszenie modeli między serwisami: Shulman i in. [2] pokazują, że model uczony na jednym zbiorze (muzyka, książki, zdjęcia, linki) działa podobnie dobrze na pozostałych, a Roy i in. [3] przenoszą wiedzę z Twittera na popularność filmów na YouTube. Prace te opierają się jednak na innych sygnałach (tempo pierwszych odbiorców, tematy) i oceniają model tam, gdzie wynik jest znany. Nie znaleźliśmy pracy, która sprawdza oszacowanie wyświetleń z reakcji na platformach, gdzie wyświetlenia są ukryte, wobec niezależnie zmierzonej prawdy; tam, gdzie wyświetleń nie widać, zwykle nie ma też z czym porównać.

W tej pracy pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24. Dla Facebooka i Instagrama sami zebraliśmy wyświetlenia razem z reakcjami odczytanymi w tym samym momencie: 402 filmy z Facebooka i 338 rolek z Instagrama. Traktujemy je jako punkt odniesienia. Wszystkie modele oceniamy na markach, których nie widziały w treningu.

Nasz wkład jest następujący:

- Model uczony tylko na X i YouTube szacuje wyświetlenia na Facebooku z typowym błędem ×2,4, a na Instagramie ×2,65. Po kalibracji na 25 postach błąd na Instagramie spada do ×2,41, czyli prawie do poziomu modelu uczonego na samym Instagramie (×2,36).
- Prawie cały sygnał niosą reakcje. Tekst, etykiety treści, grafy autorów i marek oraz dane zewnętrzne o markach poprawiają błąd o najwyżej 0,01 w skali $\log_{10}$. Bez reakcji błąd rośnie do ×6–×11.
- Dla każdego posta podajemy przedział niepewności (pokrycie przedziału 90%: 0,89–0,90), który pozostaje wiarygodny także wtedy, gdy części danych brakuje.

- Pokazujemy, jakie dane musi zbierać dostawca monitoringu, żeby takie oszacowanie działało. Najważniejsze jest odczytywanie reakcji w tym samym momencie co wyświetleń.

2 Dane i pomiar

Korzystamy z 12 500 wzmianek o 348 markach, udostępnionych przez Brand24. Wzmianki pochodzą z pięciu platform (TikTok, YouTube, X, Facebook, Instagram), 85% z nich opublikowano między kwietniem a sierpniem 2026, a 85% jest po angielsku. Eksport zawiera liczbę wyświetleń dla prawie wszystkich wzmianek z TikToka (100%) i YouTube (99%) oraz dla 75% wzmianek z X. Dla Facebooka i Instagrama eksport nie podaje wyświetleń, dlatego pobraliśmy je własnym sposobem, razem z reakcjami z tego samego momentu.

Facebook. Mamy wyświetlenia, reakcje i komentarze dla 402 filmów z 20 marek. Facebook pokazuje osobno wyświetlenia i odtworzenia; używamy wyświetleń. Wyniki dla Facebooka dotyczą tylko filmów, bo inne posty nie mają licznika wyświetleń.

Instagram. **TODO:** zbieranie jeszcze trwa, uzupełnić liczbę rolek i marek. Wyniki dla Instagrama dotyczą tylko rolek, bo zwykłe posty (zdjęcia, karuzele) nie mają licznika wyświetleń.

Odczyty z tego samego momentu. Dla TikToka, YouTube i X pobraliśmy dodatkowo własny odczyt z jednego momentu i sprawdzamy na nim, o ile zmienia się błąd. Główne wyniki dla tych platform liczymy na danych z eksportu.

Etykiety treści. Typ i sentyment każdej wzmianki oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

Tabela 1 i Rysunek 1 podsumowują dane, na których oceniamy modele. Wyświetlenia na jeden post obejmują około siedmiu rzędów wielkości, a typowy post na X ma ich kilkadziesiąt razy mniej niż na Facebooku. Mediana liczby wyświetleń na jeden lajk różni się mniej: od 22 na X do 49 na Instagramie. Na każdej platformie post z 10 razy większą liczbą lajków ma od 6 do 11 razy więcej wyświetleń, ale na X aż 62% postów nie ma ani jednego lajka.

Tabela 1: Dane według platformy. Posty z wyświetleniami to te, które trafiają do modelu.

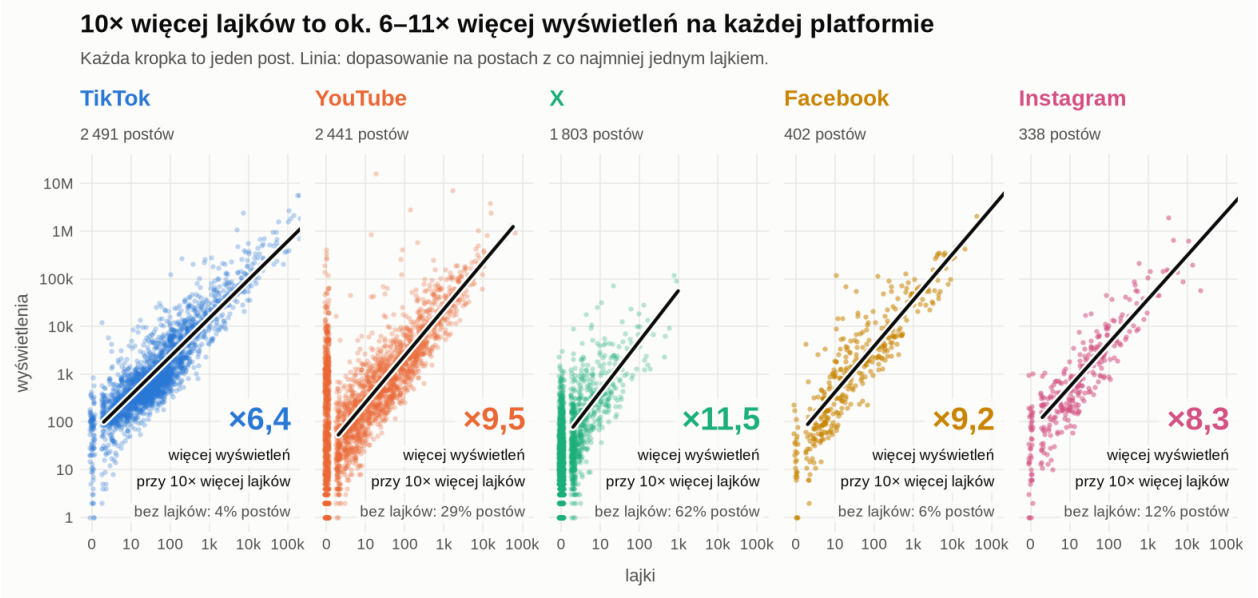
Platforma	Wzmianki	Marki	Źródło wyświetleń	Posty (marki)	Mediana		
					wyśw.	lajków	wyśw./lajk
TikTok	2 500	266	eksport Brand24	2 491 (266)	729	32	25
YouTube	2 500	273	eksport Brand24	2 441 (273)	433	6	26
X	2 500	273	eksport Brand24	1 803 (252)	27	0	22
Facebook	2 500	22	własny odczyt (filmy)	402 (20)	1 413	23	35
Instagram	2 500	11	własny odczyt (rolki)	338 (11)	506	10	49

3 Metoda i walidacja

Co przewidujemy. Celem jest $y = \log_{10}(\text{wyświetlenia})$ jednego posta. Skala logarytmiczna odpowiada temu, jak myli się każdy model zasięgu: o czynnik, a nie o stałą liczbę. Błąd mierzymy średnim błędem bezwzględnym (MAE) w tej skali i zawsze podajemy go też jako mnożnik 10^{MAE}: MAE równe 0,30 to typowy błąd $\times 2$, czyli oszacowanie dwa razy za duże albo dwa razy za małe.

Jak sprawdzamy. Posty jednej marki są do siebie podobne, więc losowy podział na trening i test zawyżałby wyniki. Wszystkie modele oceniamy pięciokrotną walidacją krzyżową z podziałem po markach: marka trafia w całości albo do treningu, albo do testu. Dodatkowo sprawdzamy model w czasie: uczymy go na postach sprzed 1 czerwca 2026 i testujemy na późniejszych. Przedziały ufności dla błędu i dla różnic między modelami liczymy bootstrapem po markach.

Model na platformach ze znanymi wyświetleniami. Na TikToku, YouTube i X używamy gradientowego wzmacniania drzew CatBoost [4]. Model dostaje liczbę obserwujących autora, lajki, komentarze i udostępnienia (w skali log) oraz informację, których z tych pól brakuje. Różne rodziny modeli po dostrojeniu dają prawie ten sam błąd, dlatego nie porównujemy ich dalej.



Rysunek 1: Wyświetlenia a lajki dla każdego posta, osobno dla każdej platformy (obie osie w skali logarytmicznej). Linia: dopasowanie prostej na postach z co najmniej jednym lajkiem; liczba w rogu mówi, ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków. TikTok, YouTube i X: eksport Brand24; Facebook (filmy) i Instagram (rolki): nasz odczyt.

Model do przeniesienia na inne platformy. Na Facebooku i Instagramie model nie widzi w treningu ani jednego posta. Używamy tu regresji grzbietowej (ridge) na dwóch cechach, które ma każda platforma: $\log(1 + \text{lajki})$ i $\log(1 + \text{komentarze})$, uczonej na wszystkich postach z X i YouTube razem. Prosty model przenosi się lepiej niż CatBoost i lepiej niż metody przenoszenia z literatury, które sprawdziliśmy. Jako punkt odniesienia uczymy ten sam model na samej platformie docelowej, z tym samym podziałem po markach. Sprawdzamy też wariant, w którym klient zna wyświetlenia 25 swoich postów: wtedy przesuwamy oszacowania o medianę błędu na tych postach.

Przedziały niepewności. Dla każdego posta podajemy przedział, w którym na 50% i na 90% leży prawdziwa liczba wyświetleń. Używamy konformalnej regresji kwantylowej (CQR) [5]: model przewiduje kwantyle, a ich szerokość poprawiamy na markach odłożonych z treningu, tak żeby przedział 90% faktycznie trafiał w 90% postów.

Granica błędu. Nawet idealny model nie odgadnie wyświetleń dokładnie: dwa posty o prawie tych samych obserwujących i reakcjach potrafią mieć bardzo różną liczbę wyświetleń. Szacujemy tę granicę na parach takich postów. Wynosi ona 0,24 na TikToku, 0,39 na YouTube i 0,33 na X ($\times 1{,}8$ / $\times 2{,}4$ / $\times 2{,}1$). Błędu poniżej tego poziomu nie da się osiągnąć z tymi danymi.

4 Wyniki A: platformy ze znanymi wyświetleniami

TODO: do napisania.

5 Wyniki B: przeniesienie na Facebooka i Instagram

TODO: do napisania.

6 Wyniki C: brakujące dane i pewność

TODO: do napisania.

7 Co nie działa

TODO: do napisania.

8 Zastosowania poboczne

TODO: do napisania.

9 Ograniczenia, dyskusja, rekomendacje

TODO: do napisania.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.