Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 8 listopada 2026

Roboczy spis treści (usunąć przed oddaniem)

1. **Wstęp** — problem, literatura, pytanie, wkład.
2. **Dane** — skąd prawda na każdej platformie; Tabela 1, Rys. 1.
3. **Metoda** — miara błędu, walidacja po markach, dwa modele, przedziały.
4. **Wyniki** — Rys. 2 (wynik główny), Rys. 3 (na czym uczyć), Rys. 4 (czego model potrzebuje), Rys. 5 (kto jest źle szacowany), przedziały.
5. **Co nie działa** — Rys. 6: wszystkie sprawdzone metody.
6. **Zastosowania** (1 str.) — Rys. 7: alert, ranking marek, EMV, posty odstające.
7. **Ograniczenia i rekomendacje**.

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji, który nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] wiedzę z Twittera na filmy z YouTube. Prace te oceniają jednak model tam, gdzie wynik jest znany. Nie znaleźliśmy pracy, która sprawdza oszacowanie wyświetleń z reakcji na platformach, gdzie wyświetlenia są ukryte, wobec niezależnie zmierzonej prawdy.

Pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Nasz wkład:

- model uczony tylko na X i YouTube szacuje wyświetlenia filmów na Facebooku z typowym błędem $\times 2{,}4$, a rolek na Instagramie $\times 2{,}65$, tak samo dobrze jak model uczony na samej platformie docelowej;
- pokazujemy, kiedy to przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi;
- dla każdego posta podajemy przedział niepewności, trafny także przy brakujących danych;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

2 Dane

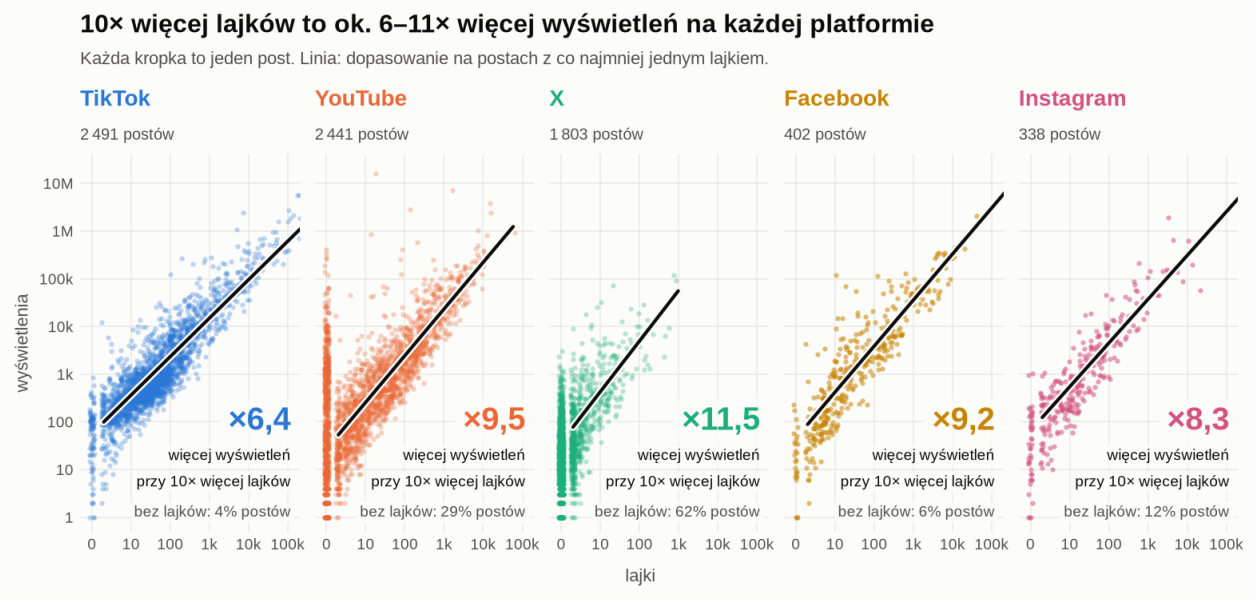
Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę, 85% z IV–VIII 2026, 85% po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Dla Facebooka i Instagrama ich nie ma, więc pobraliśmy je własnym sposobem razem z reakcjami z tego samego momentu: 402 filmy z 20 marek na Facebooku i **TODO:** IG po partii 3: 338 rolek z 11 marek na Instagramie. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Typ i sentyment wzmianek oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako mnożnik 10^{MAE} (MAE $0{,}30 \approx \times 2$). Wszystkie modele oceniamy pięciokrotną walidacją krzyżową z podziałem po markach, więc

Tabela 1: Dane według platformy.

Platforma	Marki	Źródło wyświetleń	Posty z wyświetleniami	Mediana wyśw.	Wyśw. na lajk
TikTok	266	eksport Brand24	2 491	729	25
YouTube	273	eksport Brand24	2 441	433	26
X	252	eksport Brand24	1 803	27	22
Facebook	20	własny odczyt (filmy)	402	1 413	35
Instagram	11	własny odczyt (rolki)	338	506	49



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków. TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

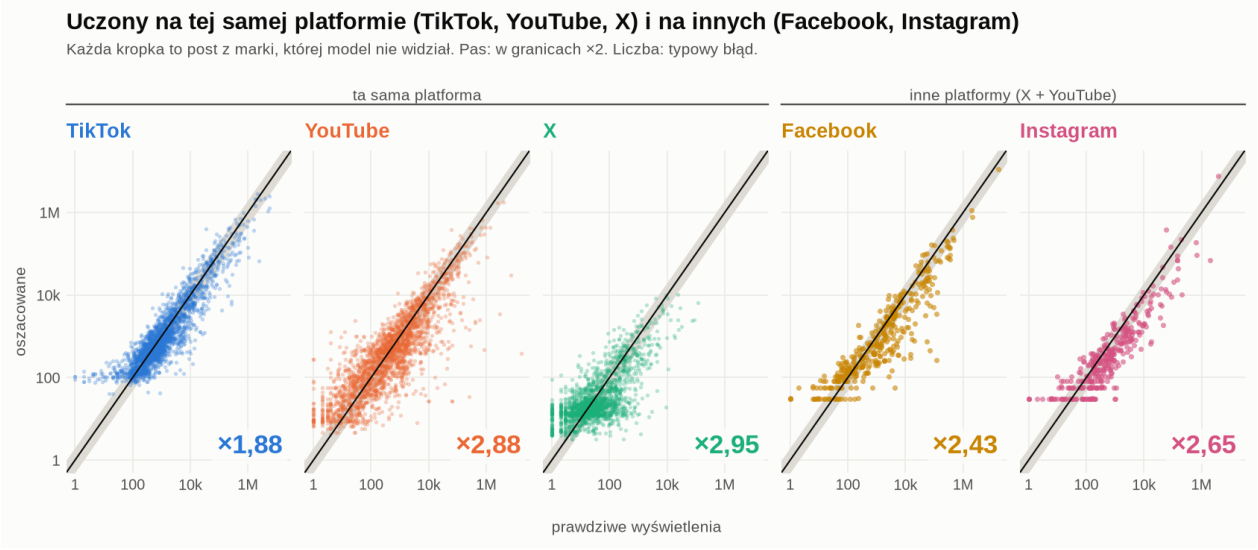
każda ocena dotyczy marki, której model nie widział; przedziały ufności liczymy bootstrapem po markach. Na TikToku, YouTube i X używamy CatBoost [4] na obserwujących, reakcjach i flagach braków. Do przeniesienia na Facebooka i Instagram używamy regresji ridge na $\log(1+\text{lajki})$ i $\log(1+\text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem; przy pominiętej platformie przenosi się ona lepiej niż CatBoost. Przedziały 50% i 90% dla każdego posta dają konformalna regresja kwantylowa [5].

4 Wyniki

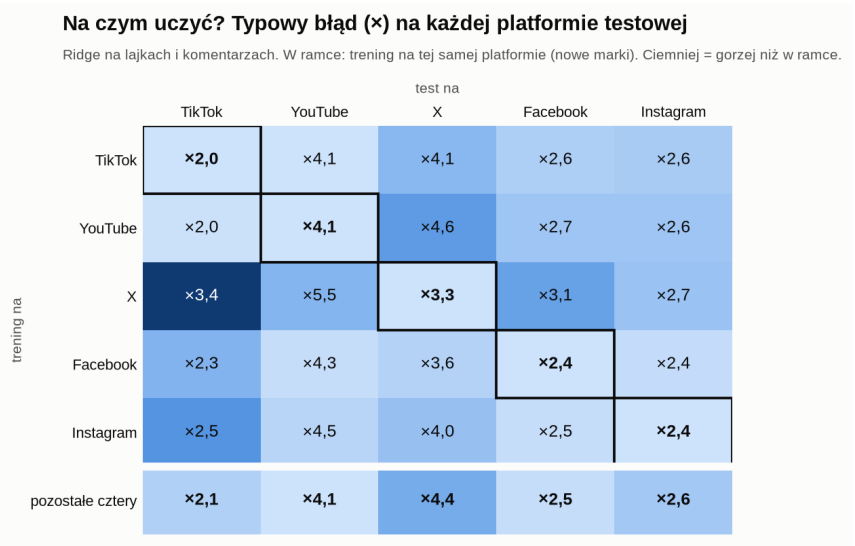
Wynik główny. Rys. 2 zestawia oba scenariusze. Na TikToku, YouTube i X, gdzie model uczy się na tej samej platformie, typowy błąd wynosi ×1,9, ×2,9 i ×3,0. Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się ×2,43 (przedział ufności ×2,05–×3,03) i ×2,65 (×2,39–×3,12). To tyle samo, co ten sam model uczony na samej platformie docelowej (×2,42 i ×2,36), więc zależność między reakcjami a wyświetleniami przenosi się między platformami prawie bez straty. Kolejność postów jest zachowana bardzo dobrze (Spearman 0,91 i 0,88).

Na czym uczyć. Facebook i Instagram dają się oszacować z dowolnej platformy z błędem ×2,4–×3,1 (Rys. 3). Wyjątkiem jest X: model uczony na X myli się na YouTube ×5,5, a modele uczone gdzie indziej mylą się na X ×3,6–×4,6. Na X większość postów ma zero lub jeden lajk (Rys. 1), więc reakcje mówią tam mało. Więcej platform w treningu nie zawsze pomaga: wszystkie cztery pozostałe dają na X ×4,4, a sam Facebook ×3,6. **TODO:** później: szósta platforma z publicznymi wyświetleniami (backlog B30).

Czego model potrzebuje. Przeniesienie działa tylko z lajkami odczytanymi razem z wyświetleniami (Rys. 4A). Same komentarze dają ×6,2–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na platformach ze znanymi wyświetleniami (Rys. 4B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dla każdego układu dostępnych pól uczymy osobny



Rysunek 2: Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post, oszacowany przez model, który nie widział jego marki (walidacja krzyżowa po markach). TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (338 rolek, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd 10^{MAE}.

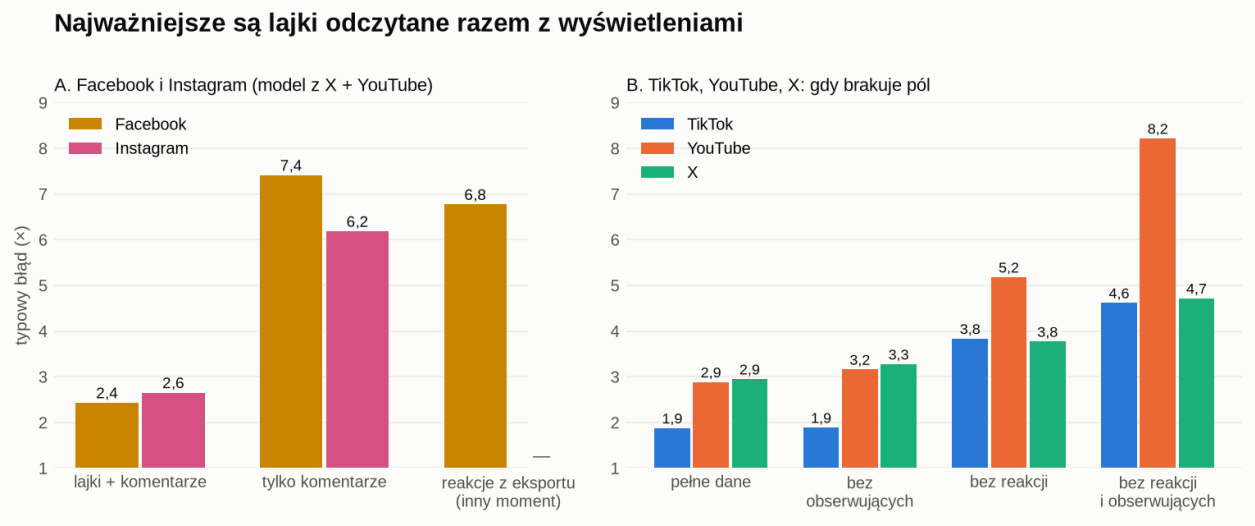


Rysunek 3: Typowy błąd przy uczeniu na jednej platformie i teście na innej.
Ridge na log lajków i komentarzy (jedyne dwa pola, które ma każda platforma). Wiersz: platforma treningowa, ostatni wiersz: wszystkie cztery pozostałe naraz. Kolumna: platforma testowa. W ramce: trening i test na tej samej platformie, na markach spoza treningu. Kolor: o ile błąd jest większy niż w ramce danej kolumny.

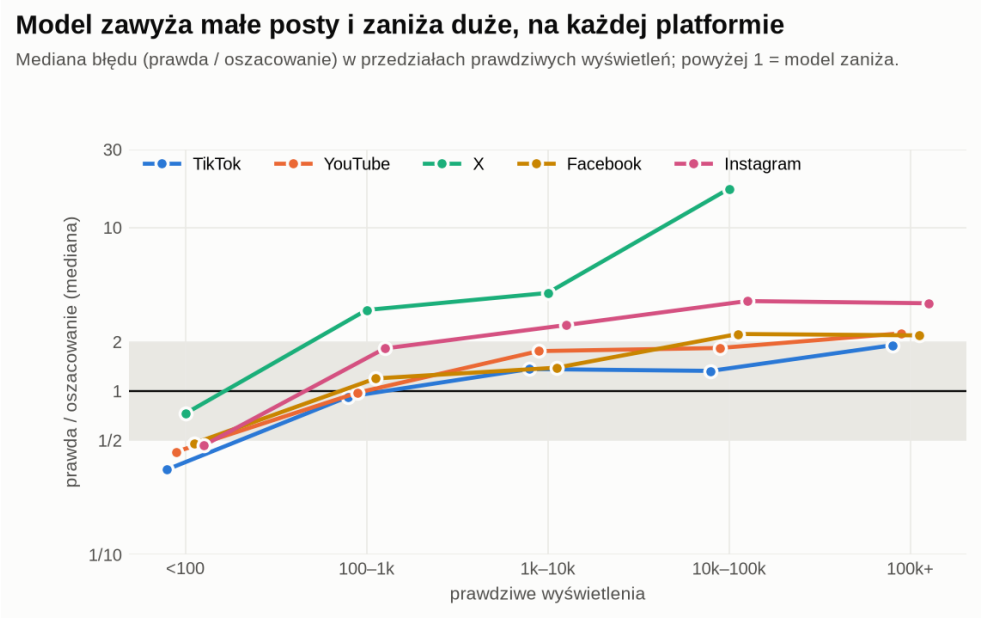
model z osobnym przedziałem, dzięki czemu przedział 90% trafia w 88–90% postów w każdym przypadku; model uczony na pełnych danych i karmiony niepełnymi trafiałby tylko w 46–83%.

Kto jest źle szacowany. Na każdej platformie, także po przeniesieniu, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże (Rys. 5). To typowe ściąganie do średniej: reakcje nie odróżniają dobrze postu, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone kilkanaście razy; po przeniesieniu Instagram zaniża duże rolki około ×3.

Przedziały. Przedział 90% trafia w 89–90% postów na TikToku, YouTube i X, także na miesiącach spoza treningu (0,90–0,93). Na Facebooku trafia w 93% filmów kont poniżej miliona obserwujących, ale dla największych kont tylko w 80–86%. Jeśli zamiast liczby podamy jeden z trzech przedziałów (<1 000, 1 000–10 000, >10 000), trafiamy w 78–82% postów na TikToku, YouTube, Facebooku i Instagramie.



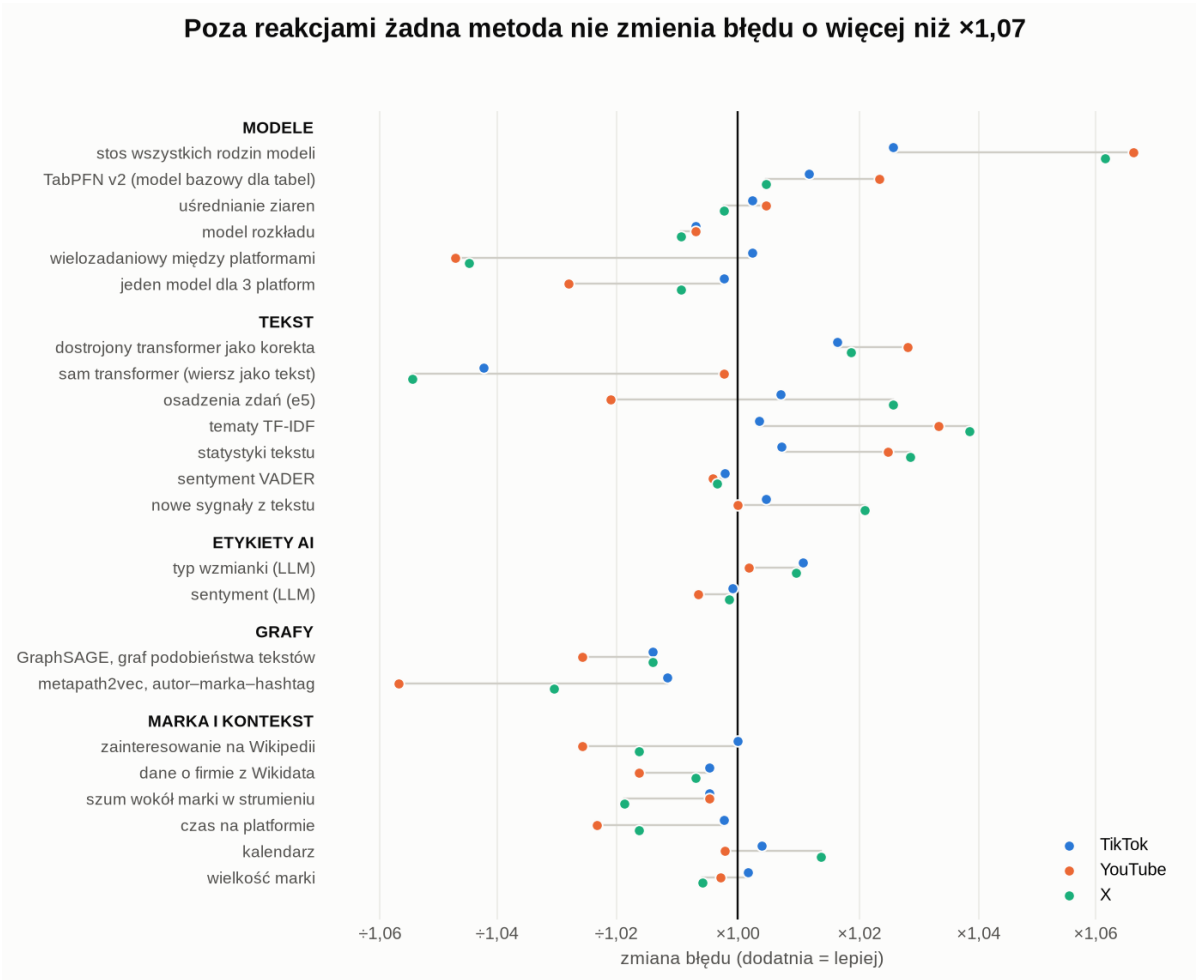
Rysunek 4: Typowy błąd przy różnych danych wejściowych.
A: Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": nasze pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak). B: TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach.



Rysunek 5: Błąd według wielkości posta.
Mediana stosunku prawdziwych do oszacowanych wyświetleń w przedziałach prawdziwych wyświetleń (pokazane przedziały z co najmniej 10 postami). Powyżej 1: model zaniża. Szary pas: w granicach ×2. Modele jak na Rys. 2.

5 Co nie działa

Sprawdziliśmy ponad dwadzieścia sposobów poprawienia modelu poza reakcjami i obserwującymi (Rys. 6): inne rodziny modeli, tekst (od TF-IDF po dostrojone transformery), etykiety AI, grafy autorów i marek oraz dane zewnętrzne o markach. Żaden nie zmienia błędu o więcej niż ×1,07, a większość mniej niż ×1,02 albo pogarsza wynik. Najwięcej daje połączenie wszystkich rodzin modeli (do ×1,07 na YouTube), ale kosztem dużo bardziej złożonego modelu. Tekst pomaga trochę na YouTube i X, grafy i dane zewnętrzne szkodzą. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436). Jedyna cecha, która pomaga wyraźnie, to historia autora: dla postów autorów, których model już widział, błąd spada o 0,10–0,15, ale takich postów jest tylko 3–16%.



Rysunek 6: Wszystkie sprawdzone metody i źródła danych.
Zmiana typowego błędu względem modelu końcowego (modele, transformery, osadzenia, grafy, dane zewnętrzne) albo względem modelu na obserwujących i reakcjach (TF-IDF, statystyki tekstu, VADER, etykiety AI, kalendarz, wielkość marki). W prawo: lepiej, w lewo: gorzej; ×1,02 to zmiana MAE o około 0,01. *Stos*: średnia wszystkich rodzin modeli na tych samych podziałach. *TabPFN v2*: wstępnie wytrenowany model dla tabel. *Wielozadaniowy*: jedna sieć dla trzech platform. *Transformer jako korekta*: dostrojony model językowy przewiduje błąd CatBoost z tekstu posta; *sam transformer*: cały wiersz zapisany jako tekst. *Osadzenia e5*: wielojęzyczny model zdań. *Etykiety LLM*: typ i sentyment z modelu językowego. *GraphSAGE*: sieć grafowa na grafie podobnych tekstów; *metapath2vec*: osadzenia grafu autor–marka–hashtag. *Wikipedia, Wikidata*: zainteresowanie marką i dane o firmie. Wszystko z walidacją po markach.

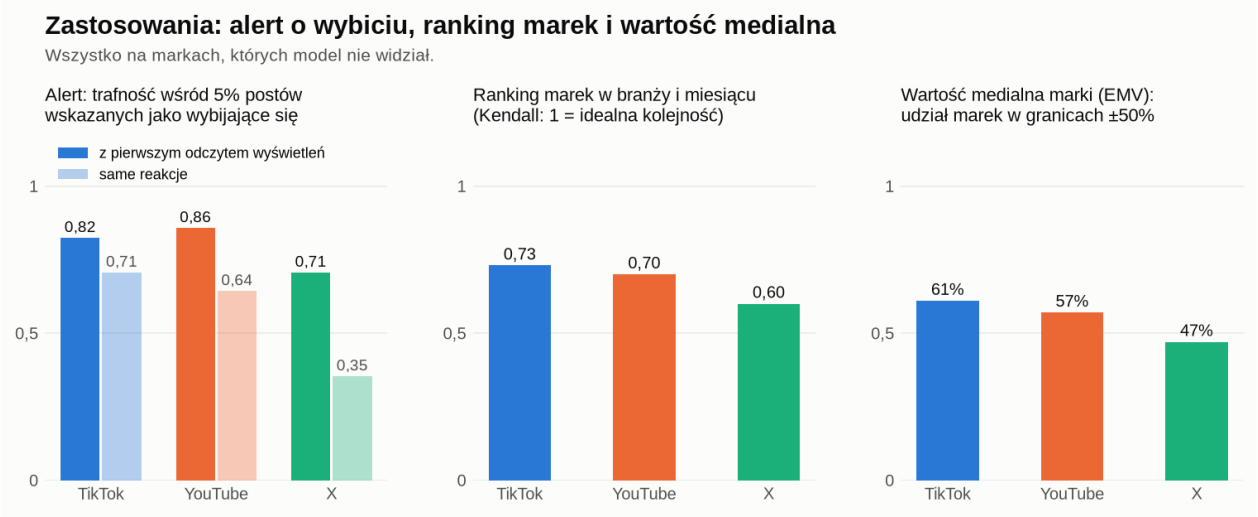
6 Zastosowania

Alert o wybiciu. Z pierwszym odczytem wyświetleń model wskazuje 5% postów, które się wybiją, z trafnością 0,82 / 0,86 / 0,71; same reakcje dają 0,71 / 0,64 / 0,35 (Rys. 7). Przy trzy razy większej liczbie alertów łapie 82–100% wybijających się postów.

Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek.

Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży.



Rysunek 7: Zastosowania oszacowania na TikToku, YouTube i X.
Alert: z postów odczytanych po raz pierwszy model wskazuje 5%, które będą miały najwięcej wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV: wyświetlenia przeliczone na pieniądze stawką za tysiąc; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

7 Ograniczenia i rekomendacje

Wynik dla Facebooka opiera się na 20 markach (bez trzech największych $\times$2,9), a dla Instagramu na 11 ($\times$2,95). Posty wiralowe są zaniżane $\times$9–$\times$14, więc sumy marek mylą się o więcej niż $\times$2 dla 29–47% marek. Wyniki opisują zależności, nie przyczyny. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów.

TODO: jeden wykres końcowy: nasz model a stały mnożnik Brand24. **TODO:** opis użycia AI zgodnie z wymaganiami kursu; odtwarzalność: repozytorium, skrypty, rejestr eksperymentów.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.