Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 9 listopada 2026

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji, który nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] wiedzę z Twittera na filmy z YouTube. Prace te przewidują jednak przyszłą popularność i mają dane o popularności z platformy docelowej, na których model się uczy lub kalibruje. Nasze zadanie jest inne: szacujemy bieżące wyświetlenia z widocznych reakcji na platformie, z której model nie dostaje w treningu ani jednej wartości wyświetleń. Wyświetlenia z tej platformy zbieramy osobno i używamy ich tylko do oceny. Nie znaleźliśmy pracy, która tak sprawdza przeniesienie modelu wyświetleń między platformami.

Pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Nasz wkład:

- pokazujemy, że stosunek wyświetleń do lajków, wyznaczony tylko na X i YouTube, przenosi się na inne platformy: model szacuje wyświetlenia filmów na Facebooku z typowym błędem (mnożnikiem 10^{MAE}, rozdz. 3) $\times$2,43, tak samo jak model uczony na samym Facebooku, a rolek na Instagramie $\times$2,72 (model uczony na Instagramie: $\times$2,41); najprostsza reguła, która nie zna wyświetleń z platformy docelowej, myli się $\times$9–$\times$20;
- pokazujemy, kiedy to przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi (X, Stack Exchange);
- dla każdego posta podajemy przedział niepewności, na tej samej platformie trafny także przy brakujących danych;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

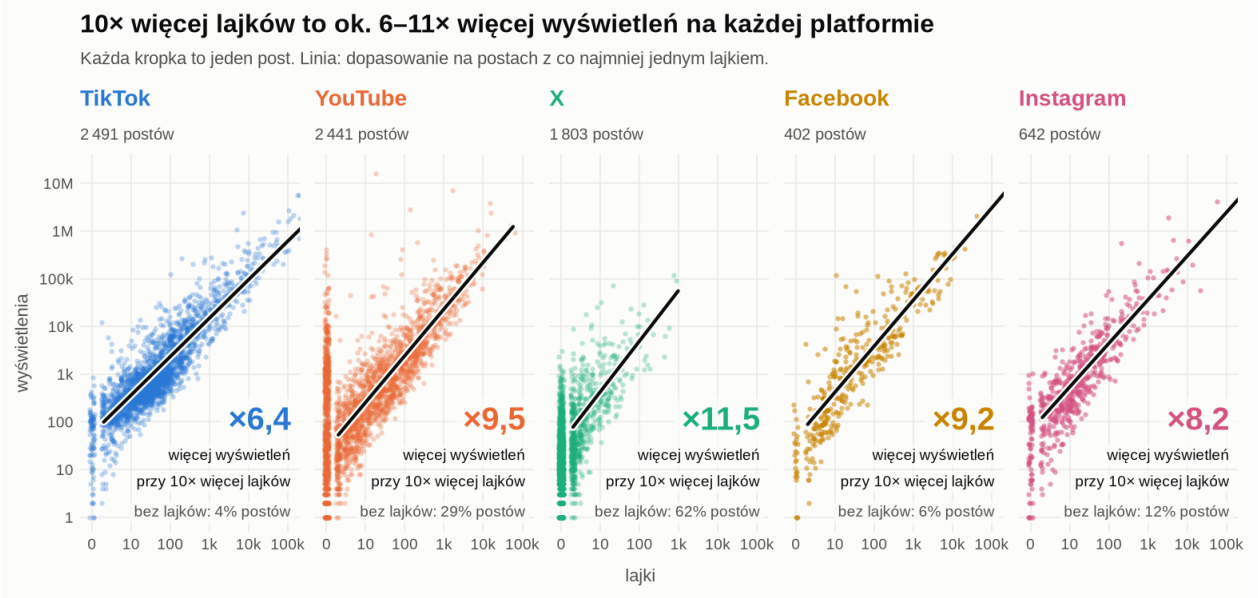
2 Dane

Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę, 85% z nich opublikowano między kwietniem a sierpniem 2026 r., a 85% jest po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Dla Facebooka i Instagramu ich nie ma, więc odczytaliśmy je w listopadzie 2026 r. z publicznych stron postów, bez logowania, razem z lajkami i komentarzami z tej samej chwili. Na Facebooku licznik wyświetleń z odtwarzacza filmu odczytał skrypt (5 listopada): 402 z 470 filmów (68 usuniętych lub niedostępnych) z 20 z 22 marek. Na Instagramie strony rolek odczytał agent w przeglądarce (6–8 listopada): z 976 rolek 261 było usuniętych, 19 nie miało licznika, a 54 miało ukryte lajki; zostaje 642 rolki z 11 marek. Próba na Instagramie obejmuje więc tylko rolki z widocznymi lajkami. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Typ i sentyment wzmianek oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

Tabela 1: Dane według platformy.

Platforma	Marki	Autorzy	Źródło wyświetleń	Posty z wyśw.	Mediana wyśw.	Wyśw./lajk
TikTok	266	2 411	eksport Brand24	2 491	729	25
YouTube	273	2 041	eksport Brand24	2 441	433	26
X	252	1 658	eksport Brand24	1 803	27	22
Facebook	20	≥182[a]	własny odczyt (filmy)	402	1 413	35
Instagram	11	?[b]	własny odczyt (rolki)	642	504	53

a: autor znany dla 74% filmów. b: autor znany tylko dla 11% rolek (59 autorów wśród 72). Wyśw./lajk: mediana stosunku na postach z co najmniej jednym lajkiem.



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy. Na każdej platformie 10 razy więcej lajków to 6–11 razy więcej wyświetleń.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków. TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako *typowy błąd*, czyli mnożnik 10^{MAE} (MAE 0,30 $\approx \times 2$). Zgodność kolejności mierzymy korelacją rang Spearmana między oszacowanymi a prawdziwymi wyświetleniami. Każdy model porównujemy z dwiema regułami: medianą wyświetleń i *stałym mnożnikiem lajków* (wyświetlenia = k·lajki, k to mediana stosunku wyświetleń do lajków w danych treningowych, około 25). Przewagę nad medianą podajemy jako $1 - \text{MAE}/\text{MAE}_{\text{mediany}}$, bo platformy mają bardzo różny rozrzut wyświetleń. Model końcowy oceniamy pięciokrotną walidacją krzyżową, w której ta sama marka, ten sam autor ani identyczny tekst nigdy nie trafia jednocześnie do treningu i testu: jeden autor może pisać o kilku markach (1–9% postów), a ten sam tekst bywa wklejany na różnych kontach. Każda ocena dotyczy więc marki i autora, których model nie widział. Przedziały ufności liczymy bootstrapem po markach. Porównania metod (rozdział 6 i Rys. 5B, tylko na tej samej platformie) robimy na prostszym podziale po samych markach, więc ich liczby różnią się od Rys. 2 o 0,01–0,03 (np. CatBoost na X: ×2,95 po markach wobec ×3,03 po markach, autorach i tekstach); kolejność metod się nie zmienia.

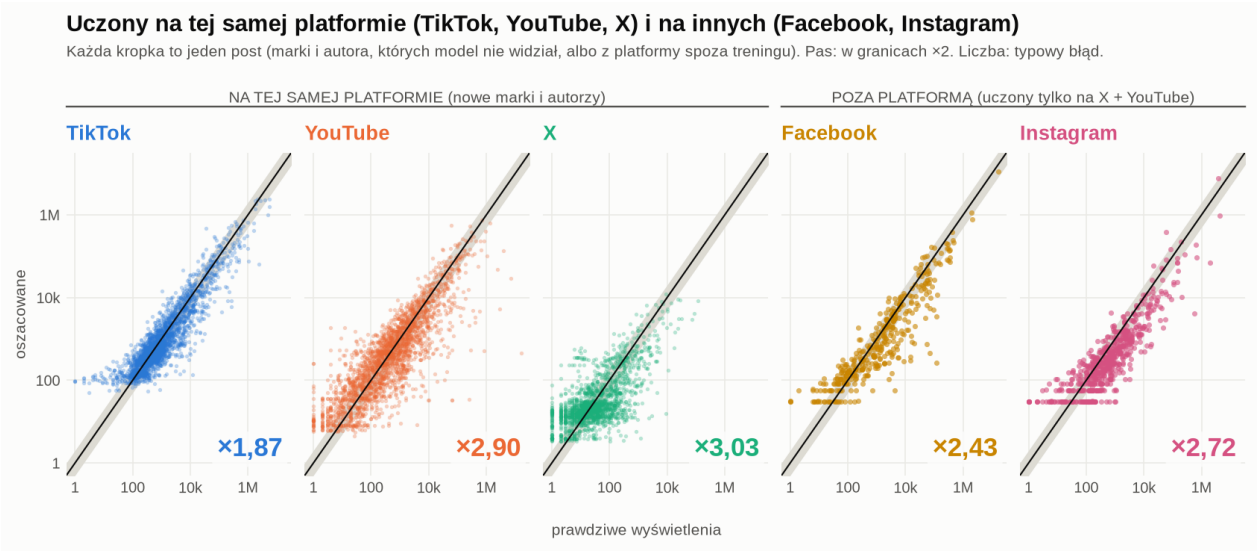
Dwa scenariusze, oznaczane na każdym wykresie. *Na tej samej platformie*: model uczy się na postach z danej platformy (TikTok, YouTube, X), a oceniamy go na markach i autorach, których nie widział. *Poza platformą*: model nie widzi w treningu ani jednego posta z platformy docelowej (Facebook, Instagram, Stack Exchange; w Tabeli 2 każda platforma po kolei), a jej wyświetlenia służą tylko do oceny.

Na TikToku, YouTube i X używamy CatBoost [4] na obserwujących, reakcjach i flagach braków (osobna cecha mówi, czy dane pole było puste, bo brak to nie zero). Do przeniesienia na Facebooka i Instagram używamy regresji ridge na $\log(1+\text{lajki})$ i $\log(1+\text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem [6]; przy pominiętej platformie przenosi się ona lepiej niż CatBoost i sieci

MLP (o 0,014–0,062 MAE na każdej z pięciu platform). Przedziały 50% i 90% dla każdego posta daje konformalna regresja kwantylowa (CQR) [5]: model kwantylowy wyznacza wstępny przedział, a jego szerokość poprawiamy na odłożonej części danych treningowych tak, żeby pokrycie było takie, jak zakładane. Dla Facebooka i Instagramu wszystkie główne liczby pochodzą z eksportu Brand24 dla X i YouTube; wariant z danymi źródłowymi odczytanymi ponownie (rozdz. 5) podajemy osobno, bo był sprawdzany już po obejrzeniu części rolek z Instagramu.

4 Wyniki

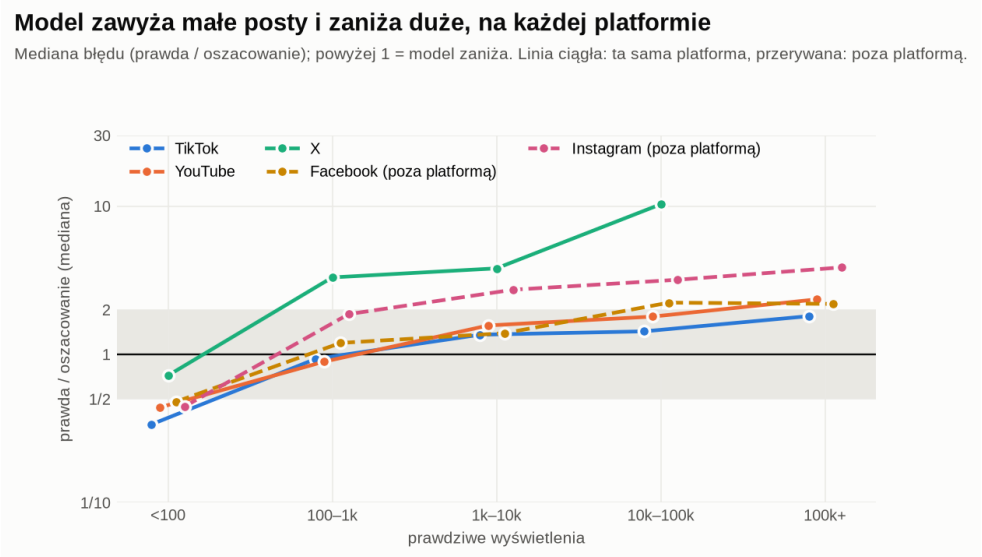
Wynik główny. Rys. 2 zestawia oba scenariusze. Na TikToku, YouTube i X, gdzie model uczy się na tej samej platformie, typowy błąd wynosi ×1,9, ×2,9 i ×3,0. Stały mnożnik lajków daje tu ×2,2, ×4,1 i ×3,6, więc CatBoost jest od niego lepszy na każdej platformie (o 0,08–0,15 MAE, przedziały ufności nie obejmują zera). Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się ×2,43 (przedział ufności ×2,05–×3,03) i ×2,72 (×2,49–×3,05). Mediana wyświetleń z X i YouTube myli się tam ×20 i ×9, a nawet mediana z samej platformy docelowej ×11 i ×6. Na Facebooku to tyle samo, co ten sam model uczony na samym Facebooku (×2,42; różnica 0,001, przedział −0,03–0,03). Na Instagramie jest wyraźnie gorzej niż przy uczeniu na samym Instagramie (×2,41; różnica 0,054, przedział 0,021–0,093), a 72% rolek jest niedoszacowanych. Przeniesienie to w praktyce przeniesienie stosunku wyświetleń do lajków: stały mnożnik lajków z X i YouTube daje na Facebooku ×2,42, a na Instagramie ×2,94, o 0,034 gorzej od ridge. Kolejność postów jest zachowana dobrze (Spearman 0,91 i 0,86, a wewnątrz jednej marki 0,80 i 0,83). Typowa marka ma jednak większy błąd niż całość: mediana po markach to ×2,7 na Facebooku i ×2,9 na Instagramie.



Rysunek 2: Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post. TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie, walidacja krzyżowa bez wspólnych marek, autorów i tekstów; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (642 rolki, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube, bez żadnego posta z platformy docelowej; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd 10^{MAE}.

Kto jest źle szacowany. Na każdej platformie, także po przeniesieniu, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże (Rys. 3). To typowe ściąganie do średniej: reakcje nie odróżniają dobrze postu, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone około 10 razy; po przeniesieniu Instagram zaniża duże rolki około ×3.

Przedziały. Na tej samej platformie przedział 90% trafia w 87–91% postów na TikToku, YouTube i X, także na miesiącach spoza treningu (0,90–0,93). Poza platformą, na Facebooku, przedział kalibrowany na 25% marek z Facebooka trafia w 92% filmów: w 94% filmów kont poniżej miliona obserwujących, ale tylko w około 85% dla 70 filmów z największych kont (przy tej liczbie ±8 punktów procentowych).



Rysunek 3: Błąd według wielkości posta.
Mediana stosunku prawdziwych do oszacowanych wyświetleń w przedziałach prawdziwych wyświetleń (pokazane przedziały z co najmniej 10 postami). Powyżej 1: model zaniża. Szary pas: w granicach ×2. Linia ciągła: na tej samej platformie, przerywana: poza platformą. Modele jak na Rys. 2.

5 Przeniesienie między platformami

Gdzie znamy prawdę. Prawdziwe wyświetlenia mamy na wszystkich pięciu platformach (Tabela 1): na TikToku, YouTube i X z eksportu Brand24, na Facebooku (filmy) i Instagramie (rolki) z naszego odczytu, razem z lajkami i komentarzami z tej samej chwili. Dzięki temu każdą platformę możemy potraktować jak „ukrytą": uczymy model na pozostałych i sprawdzamy na niej. Używamy tylko dwóch pól, które ma każda platforma, lajków i komentarzy, i prostej regresji ridge, bo przy pominiętej platformie przenosi się ona lepiej niż CatBoost. W praktyce ważne są Facebook i Instagram, bo tam wyświetleń w danych monitoringu nie ma; pozostałe platformy pokazują, jak ogólny jest ten wynik.

Wszystkie kombinacje. Tabela 2 pokazuje błąd dla każdego z 31 zestawów platform treningowych. Widać trzy rzeczy. Po pierwsze, Facebook i Instagram dają się oszacować z prawie dowolnego zestawu z błędem ×2,4–×3,1, czyli blisko modelu uczonego na nich samych (×2,4); najgorszy jest trening na samym X. Po drugie, X jest wyjątkiem w obie strony: model uczony na X myli się na YouTube ×5,5, a żaden zestaw nie schodzi na X poniżej ×3,6, wobec ×3,3 przy uczeniu na X. Na X większość postów ma zero lub jeden lajk (Rys. 1), więc zależność wyświetleń od lajków wygląda tam inaczej. Po trzecie, YouTube jest trudny nawet dla modelu uczonego na nim samym (×4,1 dla ridge wobec ×2,9 dla CatBoost na wszystkich polach). To głównie skutek etykiet z eksportu: na wyświetleniach YouTube odczytanych ponownie, razem z reakcjami, ten sam ridge z pozostałych platform myli się ×2,2. Więcej platform w treningu nie zawsze pomaga: liczy się, które platformy są w zestawie i w jakich proporcjach. Przedziały ufności (bootstrap po markach) mają około ±0,013–0,032 MAE na TikToku, YouTube i X, ±0,04 na Instagramie i ±0,07 na Facebooku, więc różnice między zestawami poniżej około ×1,1–×1,2 na Facebooku i Instagramie mieszczą się w szumie.

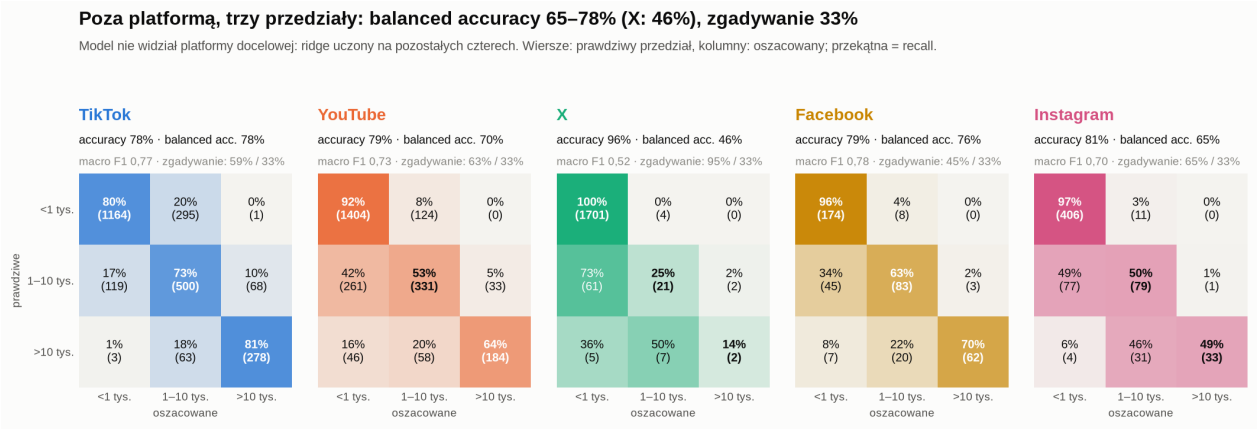
Trzy przedziały zamiast liczby. W raporcie często wystarczy powiedzieć, czy post miał mniej niż tysiąc, od tysiąca do dziesięciu tysięcy, czy ponad dziesięć tysięcy wyświetleń. Rys. 4 pokazuje to poza platformą dla każdej z pięciu platform: model uczony na pozostałych czterech, bez żadnego posta z platformy docelowej. Accuracy wynosi 78–81%, ale przedziały mają bardzo różną liczebność, więc ważniejsza jest balanced accuracy (średni recall po przedziałach): 78% na TikToku, 76% na Facebooku, 70% na YouTube i 65% na Instagramie, wobec 33% przy zgadywaniu; macro F1 0,70–0,78. O dwa przedziały mylimy się w 0,2–1,9% postów. Najsłabiej wypada zwykle środkowy przedział (1–10 tys. wyświetleń, recall 50–73%), którego posty zaniżamy o jeden przedział; na Instagramie najsłabszy jest górny (49%).

X wygląda inaczej: accuracy 96%, ale balanced accuracy tylko 46%, a macro F1 0,52. Na X 95% postów ma poniżej tysiąca wyświetleń (mediana 27), więc model, który prawie zawsze mówi „poniżej tysiąca", ma wysoką accuracy za darmo. Z 98 postów powyżej tysiąca trafia tylko 23. Widzimy dwa powody. Po pierwsze, 62% postów na X nie ma ani jednego lajka, więc model widzi tam tylko zero i nie odróżnia małego posta od dużego; usunięcie takich postów z danych treningowych zmniejsza błąd na X o 0,08. Po drugie, wyświetlenia

Tabela 2: Typowy błąd (×) dla wszystkich 31 zestawów platform treningowych.
Ridge na log lajków i komentarzy, posty z platform treningowych połączone w jeden zbiór. Wiersz: platformy w treningu (TT TikTok, YT YouTube, X, FB Facebook, IG Instagram), w grupach po 1, 2, 3 i 4 platformy, w grupie od najlepszego średnio. Kolumna: platforma testowa, której nie było w treningu. Pierwszy wiersz: ten sam model uczony na platformie testowej (walidacja po markach). Pogrubione: najlepszy wynik w kolumnie. Ciemniej: większy błąd.

Trening na	TikTok	YouTube	X	Facebook	Instagram
ta sama platforma (CV po markach)	2,0	4,1	3,3	2,4	2,4
YT	**2,0**	trening	4,6	2,7	2,6
FB	2,3	4,3	**3,6**	trening	**2,5**
IG	2,5	4,5	4,1	2,5	trening
TT	trening	4,1	4,1	2,6	2,6
X	3,4	5,5	trening	3,1	2,7
YT + X	2,1	trening	trening	2,4	2,7
YT + FB	2,0	trening	4,5	trening	2,5
YT + IG	2,0	trening	4,6	2,6	trening
TT + X	trening	4,1	trening	2,6	2,8
TT + YT	trening	trening	4,5	2,6	2,6
X + FB	2,5	4,5	trening	trening	2,7
X + IG	2,8	4,7	trening	2,6	trening
FB + IG	2,4	4,4	3,9	trening	trening
TT + FB	trening	**4,1**	4,0	trening	2,6
TT + IG	trening	4,1	4,2	2,6	trening
YT + X + IG	2,1	trening	trening	**2,4**	trening
YT + X + FB	2,1	trening	trening	trening	2,6
TT + YT + X	trening	trening	trening	2,5	2,7
YT + FB + IG	2,0	trening	4,4	trening	trening
TT + X + IG	trening	4,1	trening	2,5	trening
TT + YT + FB	trening	trening	4,4	trening	2,6
TT + X + FB	trening	4,1	trening	trening	2,8
TT + YT + IG	trening	trening	4,4	2,6	trening
X + FB + IG	2,6	4,5	trening	trening	trening
TT + FB + IG	trening	4,1	4,1	trening	trening
YT + X + FB + IG	2,1	trening	trening	trening	trening
TT + YT + X + IG	trening	trening	trening	2,5	trening
TT + YT + X + FB	trening	trening	trening	trening	2,7
TT + X + FB + IG	trening	4,1	trening	trening	trening
TT + YT + FB + IG	trening	trening	4,4	trening	trening

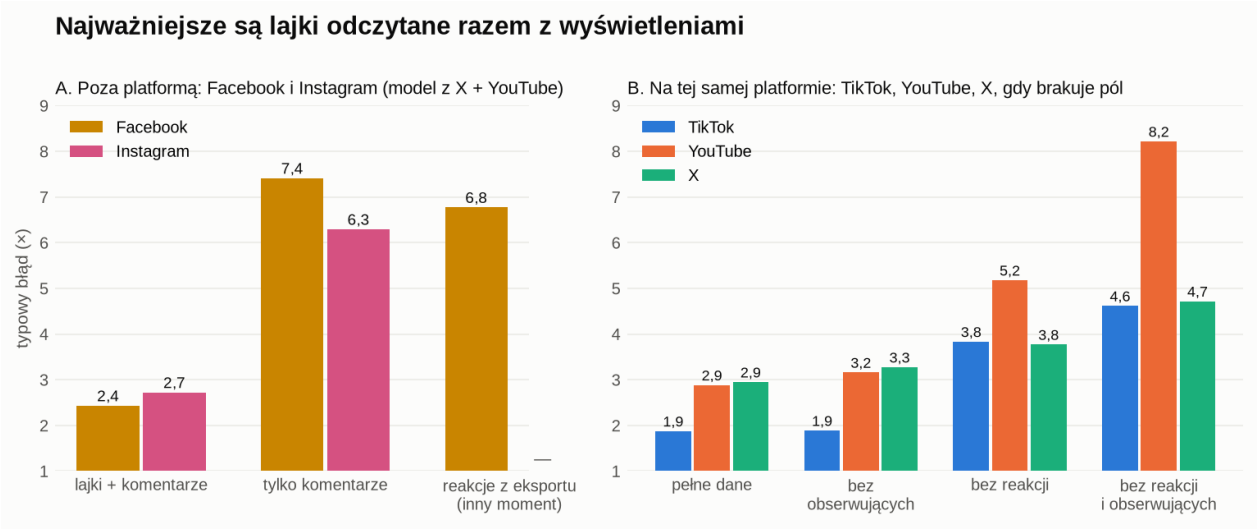
w eksporcie X są odczytane wcześnie, około dwa razy niżej niż w naszym ponownym odczycie; na postach X odczytanych ponownie (to częściowo inne posty) ten sam model myli się o 0,49 zamiast 0,64.



Rysunek 4: Oszacowanie poza platformą pocięte na trzy przedziały wyświetleń.
Dla każdej platformy ridge na lajkach i komentarzach uczony na pozostałych czterech (jak w ostatnim wierszu Tabeli 2). Wiersz: prawdziwy przedział; kolumna: oszacowany; w komórce udział w wierszu i liczba postów; przekątna (pogrubiona) to recall przedziału. Nad tabelą: accuracy, balanced accuracy (średni recall), macro F1; szare: accuracy i balanced accuracy przy zgadywaniu zawsze najczęstszego przedziału.

Czego model potrzebuje. Przeniesienie działa tylko z lajkami odczytanymi razem z wyświetleniami (Rys. 5A). Same komentarze dają ×6,3–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na platformach ze znanymi wyświetleniami (Rys. 5B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dla każdego układu dostępnych pól uczymy osobny model z osobnym przedziałem, dzięki czemu przedział 90% trafia w 88–90% postów w każdym przypadku;

model uczony na pełnych danych i karmiony niepełnymi trafiałby tylko w 46–83%.



Rysunek 5: Typowy błąd przy różnych danych wejściowych.
A: Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": nasze pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak). B: TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach. A: poza platformą, B: na tej samej platformie.

Świeże dane źródłowe. Wyświetlenia w eksporcie są odczytane krótko po publikacji, a nasze odczyty z Facebooka i Instagramu kilka miesięcy później. Gdy ten sam model uczymy na X i YouTube odczytanych ponownie, razem z reakcjami z tej samej chwili, błąd na Instagramie spada z ×2,72 do ×2,41 (tyle, co model uczony na samym Instagramie), a na Facebooku zostaje ×2,44. Niedoszacowanie dużych postów i sum dla marek zmniejsza się mniej więcej o połowę. Samo przesunięcie wyświetleń z eksportu do późniejszego wieku tego nie daje, więc ważne jest, żeby wyświetlenia i reakcje pochodziły z tego samego momentu. Ten wariant nie zastępuje wyniku głównego, bo zysk na Instagramie sprawdziliśmy już po obejrzeniu części rolek.

Szósta platforma. Żeby sprawdzić przeniesienie poza mediami społecznościowymi, pobraliśmy przez publiczne API 538 pytań z serwisów Stack Exchange (m.in. Stack Overflow, Super User, Android, Apple, Mechanics) o 48 markach z naszych danych, z tego samego okresu (kwiecień–sierpień 2026). Głos za traktujemy jak lajk, a odpowiedzi i komentarze jak komentarze; to przypisanie ustaliliśmy przed oceną. Tu przeniesienie zawodzi. Model uczony na X i YouTube myli się ×3,14, czyli gorzej niż stała mediana z samego Stack Exchange (×1,96), a nawet mediana z X i YouTube (×2,10). 96% pytań jest niedoszacowanych: wyświetlenia pytań zbierają się miesiącami, a głos to nie lajk, więc cały poziom jest przesunięty. Kolejność przenosi się tylko umiarkowanie (Spearman 0,57, wewnątrz marki 0,43). Wyświetlenia pytań mają też mały rozrzut (odchylenie standardowe 0,40 wobec 1,21 na Facebooku), więc nawet ridge uczony na samym Stack Exchange (×1,77) jest tylko o 15% lepszy od mediany. Stały mnożnik lajków przenosi się jeszcze gorzej (×5,33). Wniosek: stosunek wyświetleń do reakcji przenosi się między serwisami społecznościowymi z filmami, ale nie na serwis z pytaniami, gdzie reakcje znaczą co innego.

6 Porównanie metod

Rodziny modeli. Tabela 3 porównuje modele na tych samych danych wejściowych. Po dostrojeniu prawie wszystkie rodziny dają ten sam błąd: ×1,85–×1,92 na TikToku, ×2,8–×2,9 na YouTube i ×2,9–×3,1 na X. Wyraźnie gorsze są tylko proste reguły (×2,2–×8,8) oraz regresja liniowa i kNN na YouTube (×3,0–×3,5). Najlepszym pojedynczym modelem jest TabPFN v2 [9], ale wyprzedza CatBoost tylko o 0,002–0,010, mniej niż szerokość przedziału ufności (±0,012–0,021), a liczy się około 150 razy dłużej. Sieć grafowa i transformer czytający post jako tekst są gorsze od CatBoost.

Dlaczego nie zespół. Zespół łączy oszacowania kilku modeli, np. przez ich średnią („średnia 3 najlepszych") albo przez model drugiego poziomu, który uczy się, jak ważyć oszacowania wszystkich rodzin („stos"). Błędy różnych modeli częściowo się znoszą, więc zespół jest zwykle trochę lepszy od każdego członka. U nas

stos poprawia wynik o 0,011–0,028 (×1,03–×1,07). Zostajemy przy jednym modelu z trzech powodów: (1) zysk jest mały wobec typowego błędu ×1,9–×3,0; (2) stos wymaga trenowania i utrzymania kilkunastu modeli, a przedziały niepewności (CQR) i przeniesienie na inne platformy budujemy na jednym modelu; (3) przy przeniesieniu i tak wygrywa najprostszy model liniowy (o 0,014–0,062 MAE, rozdział 3), więc złożoność nie przekłada się na główny wynik.

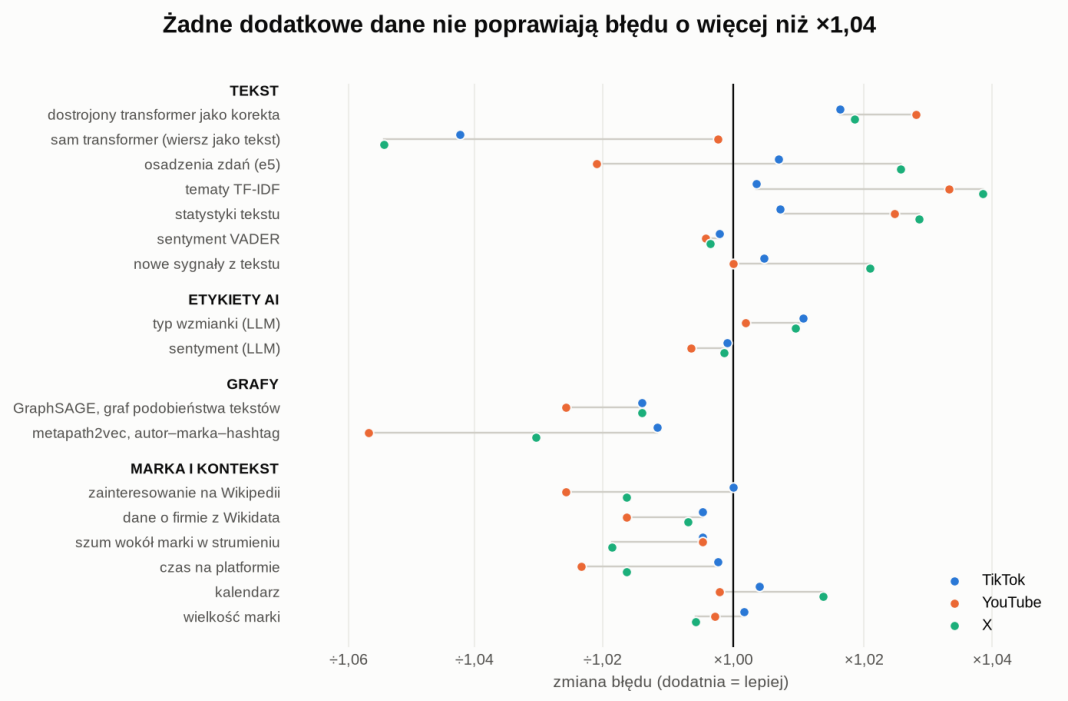
Tabela 3: Porównanie rodzin modeli: MAE w skali $\log_{10}$ i typowy błąd (×).
Wszystkie modele na obserwujących, reakcjach i flagach braków, walidacja krzyżowa po markach. Modele z drzew, liniowe, jądrowe i MLP po strojeniu hiperparametrów (40 ustawień na fałd, strojenie zagnieżdżone). TabPFN, TabICL, GraphSAGE, transformer i stos pochodzą z osobnych przebiegów na tych samych danych; CatBoost w tych przebiegach mieścił się w 0,271–0,273 / 0,452–0,456 / 0,466–0,470, więc różnice poniżej około 0,005 są w granicach szumu. Przedział ufności 95% (bootstrap po markach) dla CatBoost: ±0,012 / ±0,021 / ±0,021. Pogrubione: najlepszy pojedynczy model w kolumnie. Zespoły pokazujemy tylko dla porównania. *: podział bez wspólnych marek, autorów i tekstów.

Model	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	0,663 (×4,60)	0,944 (×8,79)	0,667 (×4,65)
stały mnożnik liczby obserwujących	0,919 (×8,30)	0,855 (×7,16)	0,879 (×7,57)
stały mnożnik lajków*	0,348 (×2,23)	0,609 (×4,06)	0,560 (×3,63)
Modele liniowe i jądrowe			
regresja liniowa (ridge)	0,277 (×1,89)	0,545 (×3,51)	0,487 (×3,07)
k najbliższych sąsiadów (kNN)	0,283 (×1,92)	0,483 (×3,04)	0,490 (×3,09)
SVR z jądrem RBF	0,271 (×1,87)	0,463 (×2,90)	0,480 (×3,02)
Drzewa decyzyjne			
las losowy (random forest)	0,275 (×1,88)	0,463 (×2,90)	0,473 (×2,97)
extra trees	0,275 (×1,88)	0,459 (×2,88)	0,475 (×2,99)
gradient boosting (scikit-learn)	0,276 (×1,89)	0,453 (×2,84)	0,474 (×2,98)
LightGBM [8]	0,275 (×1,88)	0,457 (×2,86)	0,475 (×2,99)
XGBoost [7]	0,273 (×1,87)	0,450 (×2,82)	0,467 (×2,93)
CatBoost (model końcowy)	0,272 (×1,87)	0,452 (×2,83)	0,470 (×2,95)
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	0,276 (×1,89)	0,454 (×2,84)	0,477 (×3,00)
GraphSAGE [11] (graf podobnych tekstów)	0,279 (×1,90)	0,467 (×2,93)	0,474 (×2,98)
dostrojony transformer (wiersz jako tekst)	0,289 (×1,95)	0,454 (×2,84)	0,490 (×3,09)
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	**0,268 (×1,85)**	**0,443 (×2,77)**	**0,465 (×2,92)**
TabICL [10]	0,272 (×1,87)	0,445 (×2,79)	0,466 (×2,92)
Zespoły modeli (dla porównania)			
średnia 3 najlepszych rodzin	0,270 (×1,86)	0,446 (×2,79)	0,469 (×2,94)
stos wszystkich rodzin	0,260 (×1,82)	0,425 (×2,66)	0,441 (×2,76)

Dodatkowe dane. Sprawdziliśmy też ponad dwadzieścia dodatkowych źródeł sygnału (Rys. 6): tekst (od TF-IDF po osadzenia zdań e5 [15] i słownik sentymentu VADER [16]), etykiety AI, grafy autorów i marek oraz dane zewnętrzne o markach. Żadne nie poprawia błędu o więcej niż ×1,04, większość poprawia mniej niż ×1,02, a niektóre pogarszają go do ×1,06. Tekst pomaga trochę na YouTube i X, grafy i dane zewnętrzne szkodzą. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436). Historię autora opisujemy osobno poniżej.

Więcej danych bez nowych etykiet. Sprawdziliśmy też metody, które dokładają danych albo uczą się ich struktury bez wyświetleń. Syntetyczne duże posty (SMOTER/SMOGN [13]) zmniejszają niedoszacowanie najpopularniejszej dziesiątej części postów, ale tylko przez rozciągnięcie skali oszacowań, i podnoszą błąd o 0,006–0,019. Losowe zaburzanie danych wzdłuż trendu i mixup nie pozwalają CatBoost ani sieci MLP przenosić się tak dobrze jak ridge (zostają o 0,014–0,062 w tyle na każdej z pięciu platform). Reprezentacja uczona bez etykiet (autoenkoder odszumiający, SCARF [14]) zmienia błąd o najwyżej 0,005, a pseudo-etykiety dla postów bez wyświetleń o najwyżej 0,008. Model końcowy zostaje więc bez augmentacji.

Historia autora. Jedynym sygnałem, który pomaga wyraźnie, jest historia autora. Ten sam autor ma podobną liczbę wyświetleń w kolejnych postach, niezależnie od reakcji: korelacja nadwyżki wyświetleń (prawda minus oszacowanie) między pierwszym a późniejszymi postami autora wynosi 0,68–0,70 na wszystkich trzech platformach, a autorzy z górnej jednej trzeciej mają przy tym samym oszacowaniu 4–9 razy więcej wyświetleń niż autorzy z dolnej. Wykorzystujemy to prosto: do oszacowania nowego posta dodajemy średnią nadwyżkę



Rysunek 6: Dodatkowe dane i cechy.
Zmiana typowego błędu względem modelu końcowego (transformer jako korekta, osadzenia, grafy, dane zewnętrzne) albo względem modelu na obserwujących i reakcjach (TF-IDF, statystyki tekstu, VADER, etykiety AI, kalendarz, wielkość marki). W prawo: lepiej, w lewo: gorzej; ×1,02 to zmiana MAE o około 0,01. *Transformer jako korekta*: dostrojony model językowy przewiduje błąd CatBoost z tekstu posta. *Osadzenia e5*: wielojęzyczny model zdań. *Etykiety LLM*: typ i sentyment wzmianki z modelu językowego. *GraphSAGE*: sieć grafowa na grafie podobnych tekstów; *metapath2vec* [12]: osadzenia grafu autor–marka–hashtag. *Wikipedia, Wikidata*: zainteresowanie marką i dane o firmie. Wszystko z walidacją po markach.

wcześniejszych postów tego autora, ściągniętą do zera, gdy postów jest mało (suma nadwyżek podzielona przez liczbę postów plus stała dobrana na innych markach). Na postach autorów z historią błąd spada z 0,37 do 0,26 na TikToku, z 0,50 do 0,35 na YouTube i z 0,53 do 0,43 na X (×1,3–×1,4); większość zysku daje już jeden wcześniejszy post. Taka historia jest jednak tylko dla 3–16% postów w naszej próbie, więc w średnim błędzie zysk znika ($\leq$0,003). Sprawdziliśmy też tego samego autora na innej platformie. Po ujednoliceniu nazw (małe litery, bez znaków specjalnych i dopisków typu „official") i uchwytów z adresów profili tylko 56 z 8 332 postów z wyświetleniami (0,67%; razem z postami X i YouTube odczytanymi ponownie) ma post tego samego autora na innej platformie, więc tego sygnału nie da się użyć na danych z monitoringu.

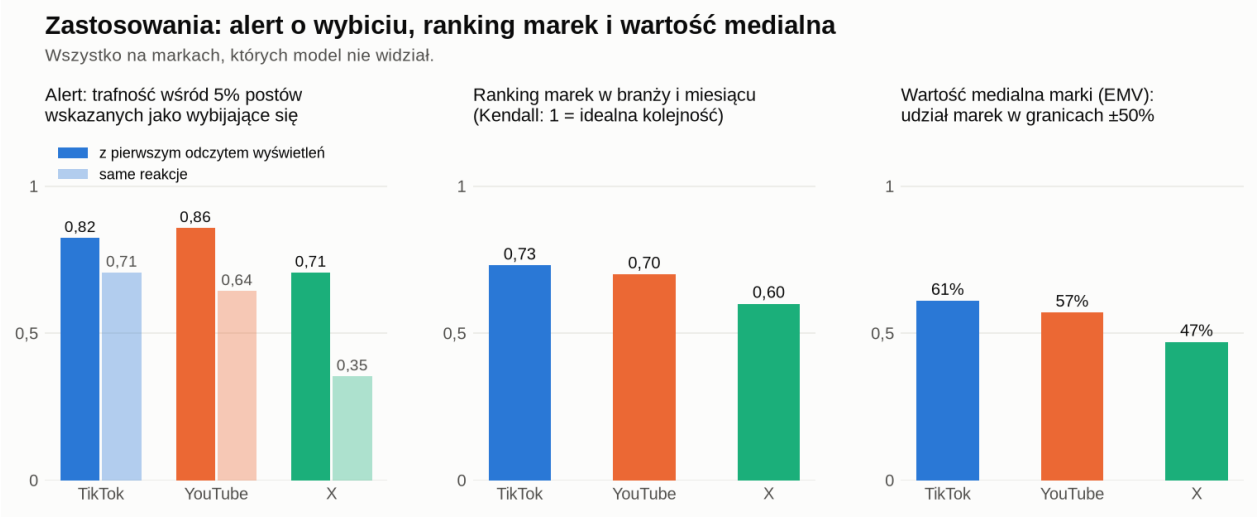
7 Zastosowania

Alert o wybiciu. Z pierwszym odczytem wyświetleń model wskazuje 5% postów, które się wybiją, z trafnością 0,82 / 0,86 / 0,71; same reakcje dają 0,71 / 0,64 / 0,35 (Rys. 7). Przy trzy razy większej liczbie alertów łapie 82–100% wybijających się postów.

Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek.

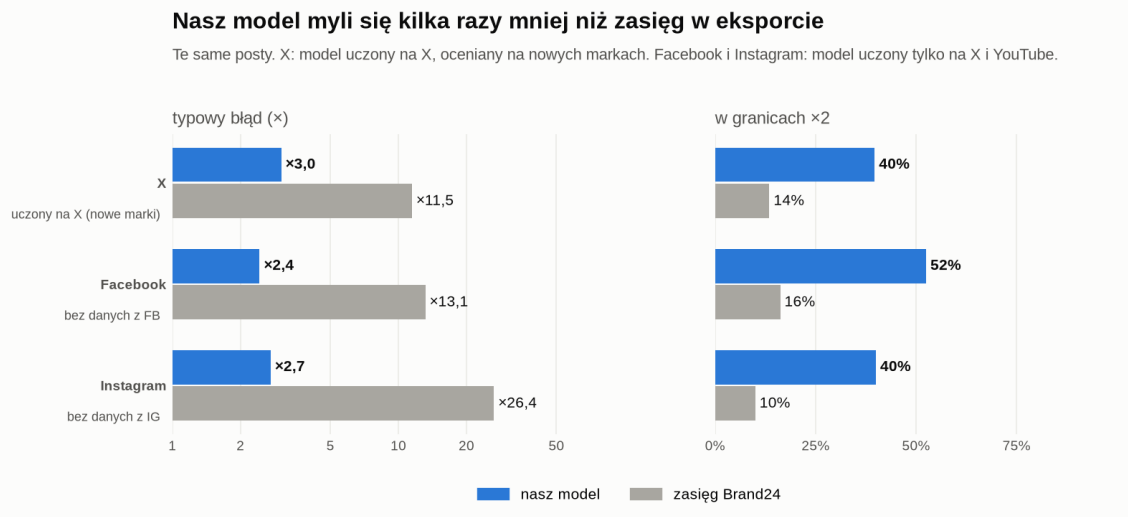
Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży.



Rysunek 7: Zastosowania oszacowania na TikToku, YouTube i X.
Alert: z postów odczytanych po raz pierwszy model wskazuje 5%, które będą miały najwięcej wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV: wyświetlenia przeliczone na pieniądze stawką za tysiąc; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

8 Ograniczenia i rekomendacje

Wynik dla Facebooka opiera się na 20 markach, a dla Instagramu na 11; trzy największe marki to 39% i 44% postów, a bez nich błąd rośnie do ×2,89 i ×2,96. Przy tak małej liczbie marek przedziały ufności z bootstrapu po markach mogą być za wąskie. Na Instagramie mierzymy tylko rolki z widocznymi lajkami. Na tej samej platformie najpopularniejszy 1% postów na YouTube i X jest zaniżany ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek (Rys. 8 pokazuje, że kolumna zasięgu w eksporcie myli się jeszcze bardziej). Prawie każdy post ma innego autora (2 411 autorów na 2 491 postów na TikToku, 2 041 na 2 441 na YouTube, 1 658 na 1 803 na X), więc historii autora nie da się użyć dla większości postów, a na Instagramie autor jest zwykle nieznany. Wyniki opisują zależności, nie przyczyny. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów.



Rysunek 8: Nasze oszacowanie a kolumna zasięgu w eksporcie Brand24, na tych samych postach.
Tylko platformy, na których zasięg nie jest liczbą wyświetleń. X (1 803 posty): model uczony na X, oceniany na markach i autorach, których nie widział; prawda z eksportu. Facebook (402 filmy) i Instagram (642 rolki): model poza platformą, uczony tylko na X i YouTube, bez żadnego posta z FB ani IG; prawda z naszego odczytu. Zasięg Brand24 zawyża wyświetlenia na X (74% postów) i Facebooku (67%), a zaniża na Instagramie (97%).

Użycie AI i odtwarzalność. **TODO:** do napisania przez zespół własnymi słowami. Fakty do ujęcia: agenci AI (Claude Code, DeepSeek) pisali kod analiz i odczytu danych, uruchamiali eksperymenty, robili wykresy i szkic tekstu; modele językowe oznaczyły typ i sentyment wzmianek, a etykiety poprawił członek zespołu; logi sesji agentów są w `logs/`. Każdy wynik ma kartę eksperymentu, wiersz w rejestrze (`docs/pl/experiments.md`, 220 pozycji), skrypt w `src/` i liczby w `data/processed/`.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.

[6] A. E. Hoerl, R. W. Kennard. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 1970.

[7] T. Chen, C. Guestrin. XGBoost: a scalable tree boosting system. *KDD*, 2016.

[8] G. Ke i in. LightGBM: a highly efficient gradient boosting decision tree. *NeurIPS*, 2017.

[9] N. Hollmann i in. Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 2025.

[10] J. Qu, D. Holzmüller, G. Varoquaux, M. Le Morvan. TabICL: a tabular foundation model for in-context learning on large data. *ICML*, 2025.

[11] W. L. Hamilton, R. Ying, J. Leskovec. Inductive representation learning on large graphs. *NeurIPS*, 2017.

[12] Y. Dong, N. V. Chawla, A. Swami. metapath2vec: scalable representation learning for heterogeneous networks. *KDD*, 2017.

[13] P. Branco, L. Torgo, R. P. Ribeiro. SMOGN: a pre-processing approach for imbalanced regression. *LIDTA*, PMLR 74, 2017.

[14] D. Bahri, H. Jiang, Y. Tay, D. Metzler. SCARF: self-supervised contrastive learning using random feature corruption. *ICLR*, 2022.

[15] L. Wang i in. Text embeddings by weakly-supervised contrastive pre-training. arXiv:2212.03533, 2022.

[16] C. J. Hutto, E. Gilbert. VADER: a parsimonious rule-based model for sentiment analysis of social media text. *ICWSM*, 2014.