Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 8 listopada 2026

Roboczy spis treści (usunąć przed oddaniem)

1. **Wstęp** — problem, literatura, pytanie, wkład.
2. **Dane** — skąd prawda na każdej platformie; Tabela 1, Rys. 1.
3. **Metoda** — miara błędu, walidacja po markach, dwa modele, przedziały.
4. **Wyniki** — Rys. 2 (wynik główny), Rys. 3 (na czym uczyć), Rys. 4 (warunki przeniesienia), Rys. 5 (kto jest zaniżany), Rys. 6 (brakujące dane).
5. **Co nie działa** — Tabela 2.
6. **Zastosowania** (1 str.) — Rys. 7: alert, ranking marek, EMV.
7. **Ograniczenia i rekomendacje**.

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji, który nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] wiedzę z Twittera na filmy z YouTube. Prace te oceniają jednak model tam, gdzie wynik jest znany. Nie znaleźliśmy pracy, która sprawdza oszacowanie wyświetleń z reakcji na platformach, gdzie wyświetlenia są ukryte, wobec niezależnie zmierzonej prawdy.

Pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Nasz wkład:

- model uczony tylko na X i YouTube szacuje wyświetlenia filmów na Facebooku z typowym błędem $\times 2{,}4$, a rolek na Instagramie $\times 2{,}65$, tak samo dobrze jak model uczony na samej platformie docelowej;
- pokazujemy, kiedy to przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi;
- dla każdego posta podajemy przedział niepewności, trafny także przy brakujących danych;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

2 Dane

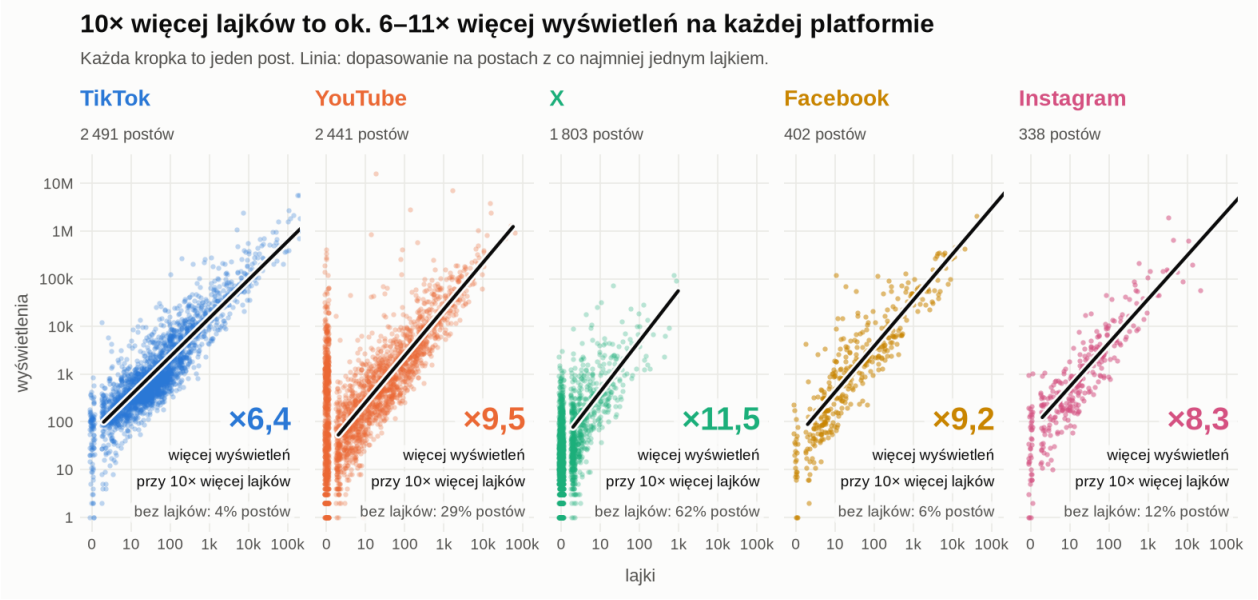
Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę, 85% z IV–VIII 2026, 85% po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Dla Facebooka i Instagrama ich nie ma, więc pobraliśmy je własnym sposobem razem z reakcjami z tego samego momentu: 402 filmy z 20 marek na Facebooku i **TODO:** IG po partii 3: 338 rolek z 11 marek na Instagramie. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Typ i sentyment wzmianek oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako mnożnik 10^{MAE} (MAE $0{,}30 \approx \times 2$). Wszystkie modele oceniamy pięciokrotną walidacją krzyżową z podziałem po markach, więc

Tabela 1: Dane według platformy.

Platforma	Marki	Źródło wyświetleń	Posty z wyświetleniami	Mediana wyśw.	Wyśw. na lajk
TikTok	266	eksport Brand24	2 491	729	25
YouTube	273	eksport Brand24	2 441	433	26
X	252	eksport Brand24	1 803	27	22
Facebook	20	własny odczyt (filmy)	402	1 413	35
Instagram	11	własny odczyt (rolki)	338	506	49



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy. Linia: dopasowanie na postach z co najmniej jednym lajkiem.

każda ocena dotyczy marki, której model nie widział; przedziały ufności liczymy bootstrapem po markach. Na TikToku, YouTube i X używamy CatBoost [4] na obserwujących, reakcjach i flagach braków. Do przeniesienia na Facebooka i Instagram używamy regresji ridge na $\log(1+\text{lajki})$ i $\log(1+\text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem; przy pominiętej platformie przenosi się ona lepiej niż CatBoost. Przedziały 50% i 90% dla każdego posta dają konformalna regresja kwantylowa [5].

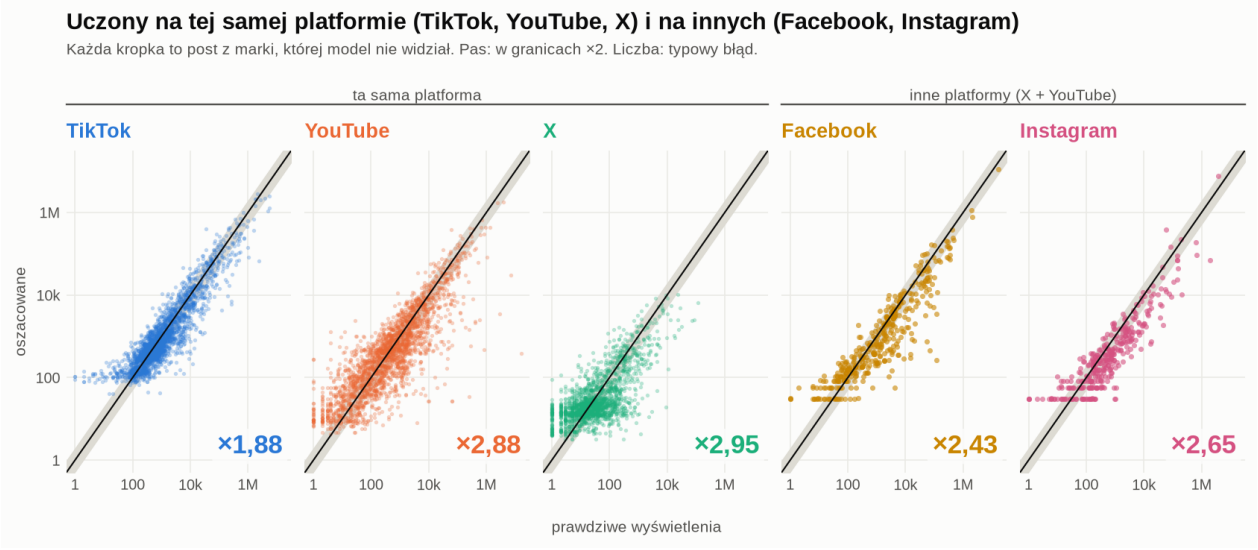
4 Wyniki

Wynik główny. Na platformach ze znanymi wyświetleniami typowy błąd wynosi ×1,9 na TikToku, ×2,9 na YouTube i ×3,0 na X (Rys. 2). Model uczony tylko na X i YouTube myli się na Facebooku ×2,43 (przedział ufności ×2,05–×3,03), a na Instagramie ×2,65 (×2,39–×3,12). To tyle samo, co ten sam model uczony na samej platformie docelowej (×2,42 i ×2,36). Kolejność postów jest zachowana bardzo dobrze (Spearman 0,91 i 0,88).

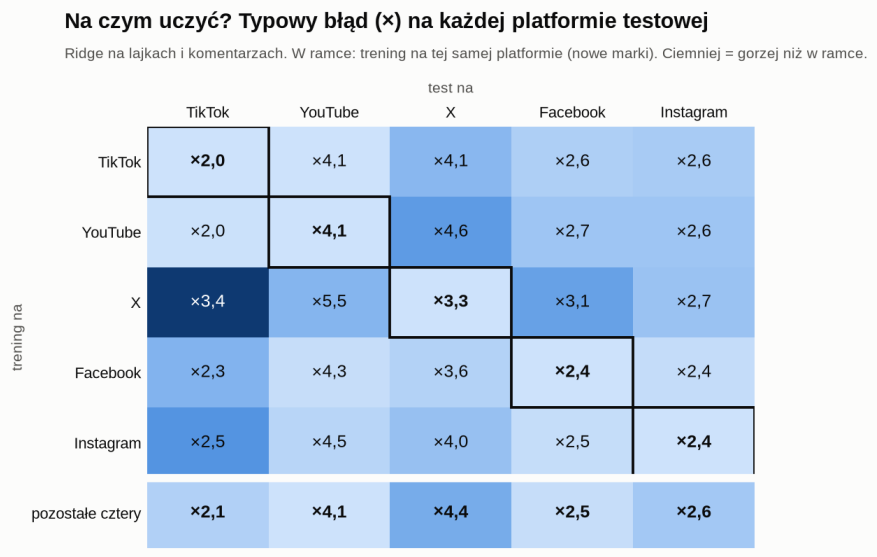
Na czym uczyć. Facebook i Instagram dają się oszacować z dowolnej platformy z błędem ×2,4–×3,1 (Rys. 3). Najgorzej przenosi się na X i z X. Więcej platform w treningu nie zawsze pomaga: wszystkie cztery pozostałe dają na X ×4,4, a sam Facebook ×3,6. **TODO:** później: szósta platforma z publicznymi wyświetleniami (backlog B30).

Kiedy przeniesienie działa. Tylko wtedy, gdy lajki i komentarze są odczytane razem z wyświetleniami (Rys. 4). Te same pola z eksportu, odczytane w innym momencie, dają na Facebooku ×6,8. Same komentarze, bez lajków, dają ×6,2–×7,4.

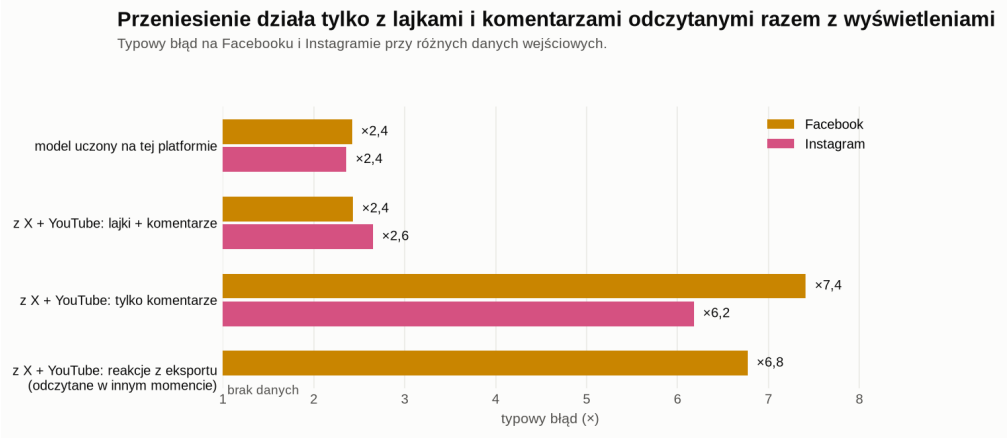
Kto jest źle szacowany. Na każdej platformie, także po przeniesieniu, model zawyża posty z małą liczbą wyświetleń i zaniża duże (Rys. 5). Po X najsilniej zaniżany jest Instagram (duże rolki około ×3), a najsłabiej TikTok; na X posty powyżej 10 000 wyświetleń są zaniżone kilkanaście razy.



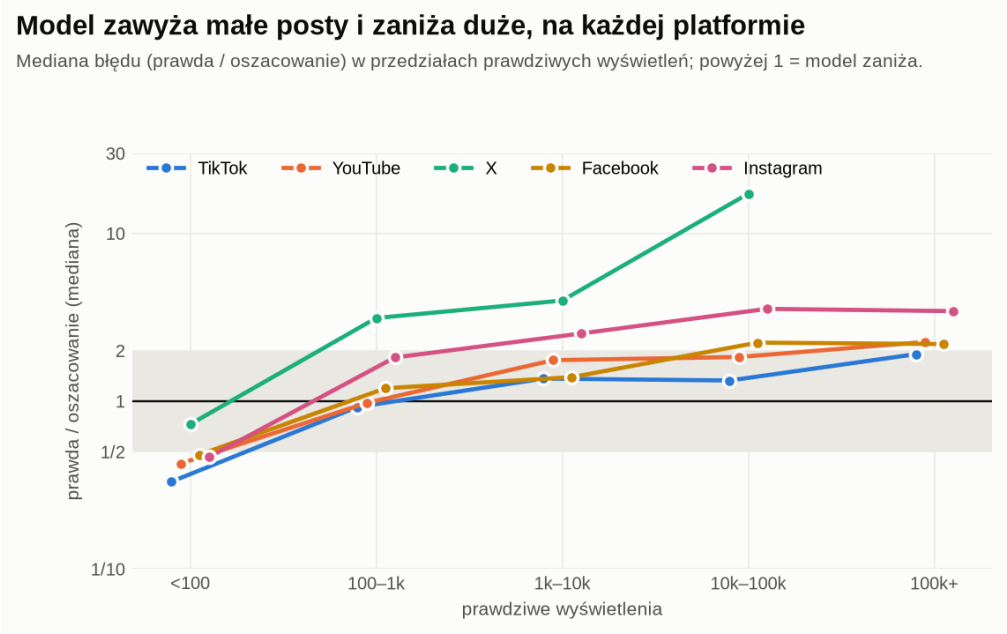
Rysunek 2: Oszacowane a prawdziwe wyświetlenia. TikTok, YouTube, X: model uczony na tej samej platformie (inne marki). Facebook, Instagram: model uczony tylko na X i YouTube.



Rysunek 3: Typowy błąd modelu uczonego na platformie z wiersza i testowanego na platformie z kolumny.

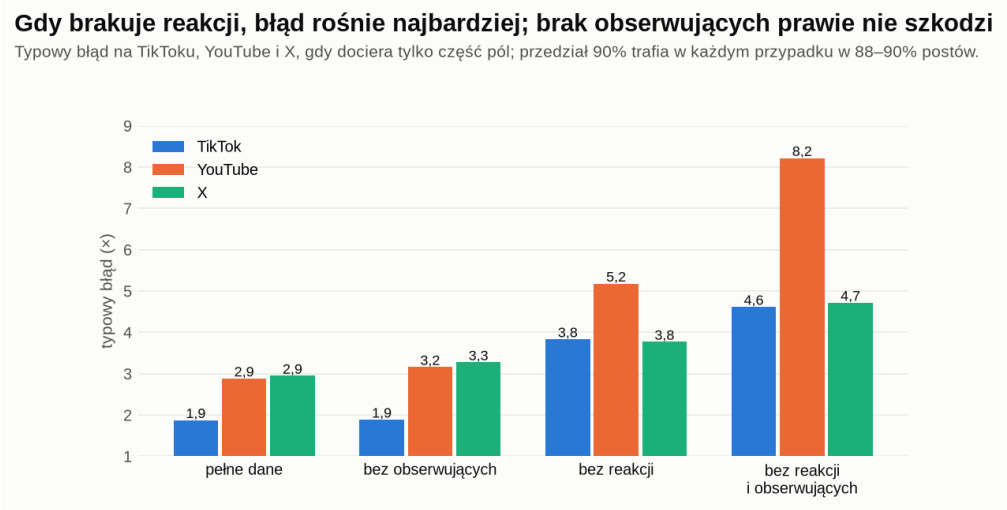


Rysunek 4: Typowy błąd na Facebooku i Instagramie przy różnych danych wejściowych.



Rysunek 5: Mediana stosunku prawdziwych do oszacowanych wyświetleń w przedziałach prawdziwych wyświetleń.

Brakujące dane i niepewność. Gdy brakuje reakcji, błąd rośnie do ×3,8–×5,2; brak obserwujących prawie nie szkodzi (Rys. 6). Dla każdego układu pól uczymy osobny model, więc przedział 90% trafia w 88–90% postów w każdym przypadku. Jeśli zamiast liczby podamy jeden z trzech przedziałów (<1 000, 1 000–10 000, >10 000), trafiamy w 78–82% postów na TikToku, YouTube, Facebooku i Instagramie.



Rysunek 6: Typowy błąd na TikToku, YouTube i X, gdy dociera tylko część pól.

5 Co nie działa

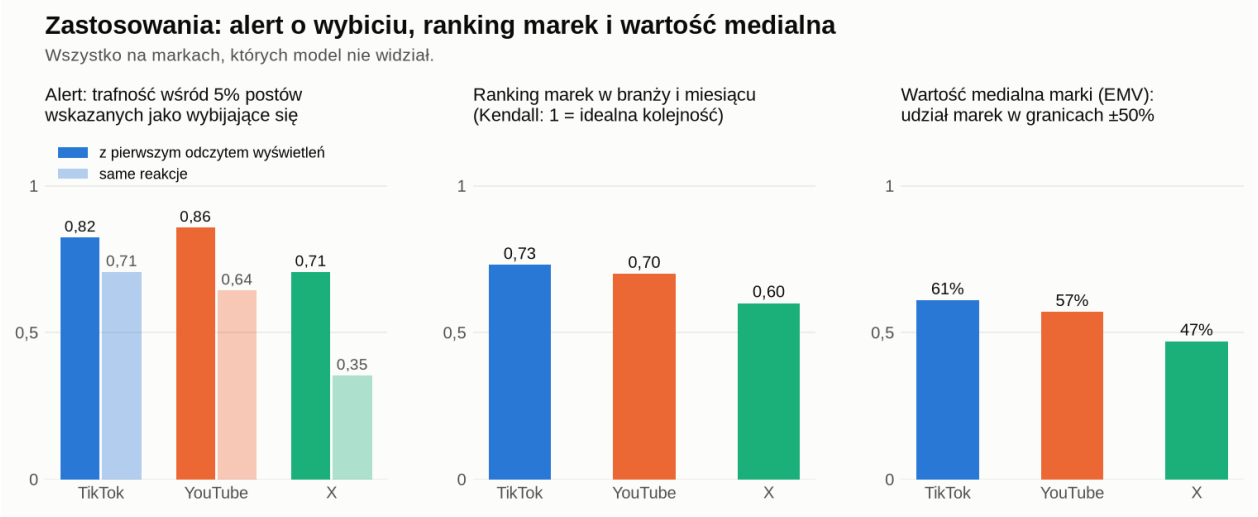
Żadne źródło sygnału poza reakcjami i obserwującymi nie poprawia błędu o więcej niż 0,01 (Tabela 2): reakcje już zawierają to, co te cechy mówią o popularności posta.

6 Zastosowania

Alert o wybiciu. Z pierwszym odczytem wyświetleń model wskazuje 5% postów, które się wybiją, z trafnością 0,82 / 0,86 / 0,71; same reakcje dają 0,71 / 0,64 / 0,35 (Rys. 7). Przy trzy razy większej liczbie alertów łapie 82–100% wybijających się postów.

Tabela 2: Zmiana MAE po dodaniu cechy (ujemna = lepiej), TikTok / YouTube / X oraz przeniesienie na Facebooka.

Grupa cech	TT / YT / X	Facebook
Tekst: statystyki, tematy, sentyment	≤0,01	—
Osadzenia tekstu i transformery	≤0,01	gorzej (0,385 → 0,436)
Etykiety AI: typ i sentyment	≤0,005	—
Grafy autor–marka i treści	≤0,01	—
Dane zewnętrzne o marce	−0,002 / −0,007 / −0,003	0,385 → 0,388
Popularność marki i platformy w czasie	≤0,01	—
Kalendarz	≤0,006	—



Rysunek 7: Trzy zastosowania oszacowania na TikToku, YouTube i X, na markach, których model nie widział.

Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek.

Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży.

7 Ograniczenia i rekomendacje

Wynik dla Facebooka opiera się na 20 markach (bez trzech największych ×2,9), a dla Instagramu na 11 (×2,95). Posty wiralowe są zaniżane ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek. Wyniki opisują zależności, nie przyczyny. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów.

TODO: jeden wykres końcowy: nasz model a stały mnożnik Brand24. **TODO:** opis użycia AI zgodnie z wymaganiami kursu; odtwarzalność: repozytorium, skrypty, rejestr eksperymentów.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.