Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 8 listopada 2026

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. W praktyce zasięg przybliża się więc stałym mnożnikiem liczby obserwujących lub reakcji, który nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] wiedzę z Twittera na filmy z YouTube. Prace te przewidują jednak przyszłą popularność i mają dane o popularności z platformy docelowej, na których model się uczy lub kalibruje. Nasze zadanie jest inne: szacujemy bieżące wyświetlenia z widocznych reakcji na platformie, z której model nie dostaje w treningu ani jednej wartości wyświetleń. Wyświetlenia z tej platformy zbieramy osobno i używamy ich tylko do oceny. Nie znaleźliśmy pracy, która tak sprawdza przeniesienie modelu wyświetleń między platformami.

Pytamy, czy wyświetlenia posta na Facebooku i Instagramie da się oszacować z jego reakcji modelem uczonym wyłącznie na innych platformach, i z jaką niepewnością. Nasz wkład:

- model uczony tylko na X i YouTube szacuje wyświetlenia filmów na Facebooku z typowym błędem $\times 2{,}4$, a rolek na Instagramie $\times 2{,}72$, prawie tak samo dobrze jak model uczony na samej platformie docelowej;
- pokazujemy, kiedy to przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi;
- dla każdego posta podajemy przedział niepewności, trafny także przy brakujących danych;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

2 Dane

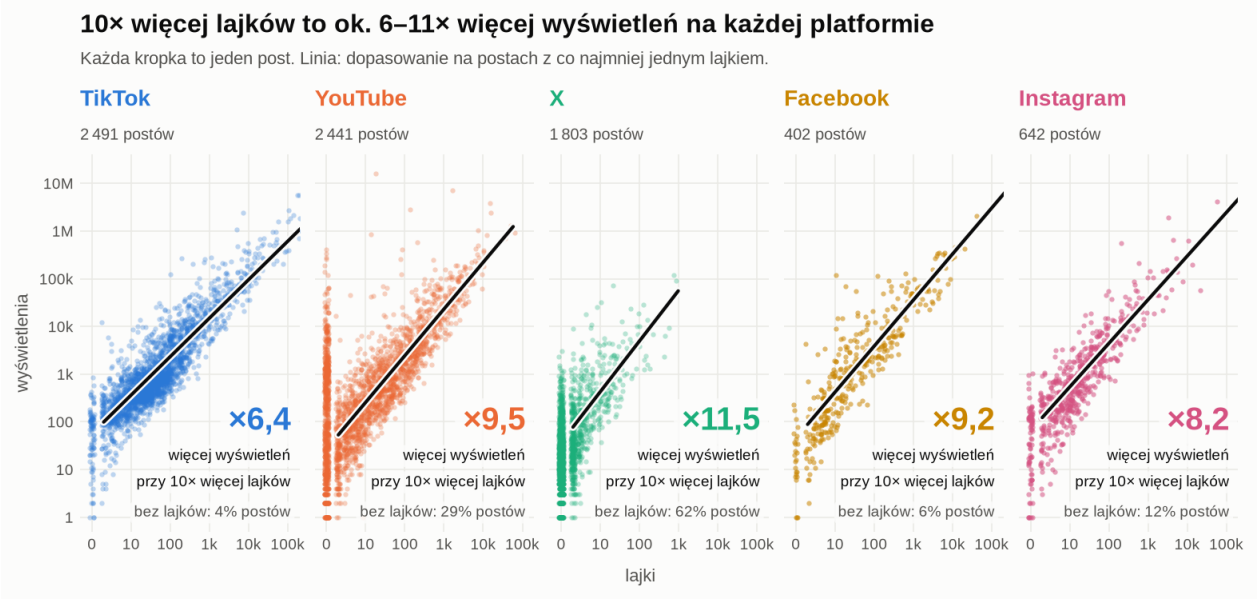
Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę, 85% z nich opublikowano między kwietniem a sierpniem 2026 r., a 85% jest po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Dla Facebooka i Instagrama ich nie ma, więc pobraliśmy je własnym sposobem razem z reakcjami z tego samego momentu: 402 filmy z 20 marek na Facebooku i 642 rolki z 11 marek na Instagramie. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Typ i sentyment wzmianek oznaczyły modele językowe, a następnie członek zespołu je sprawdził i poprawił.

Tabela 1: Dane według platformy.

Platforma	Marki	Źródło wyświetleń	Posty z wyświetleniami	Mediana wyśw.	Wyśw. na lajk
TikTok	266	eksport Brand24	2 491	729	25
YouTube	273	eksport Brand24	2 441	433	26
X	252	eksport Brand24	1 803	27	22
Facebook	20	własny odczyt (filmy)	402	1 413	35
Instagram	11	własny odczyt (rolki)	642	504	53

3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako mnożnik 10^{MAE} (MAE $0{,}30 \approx \times 2$). Model końcowy oceniamy pięciokrotną walidacją krzyżową, w której ta sama marka, ten sam



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków. TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

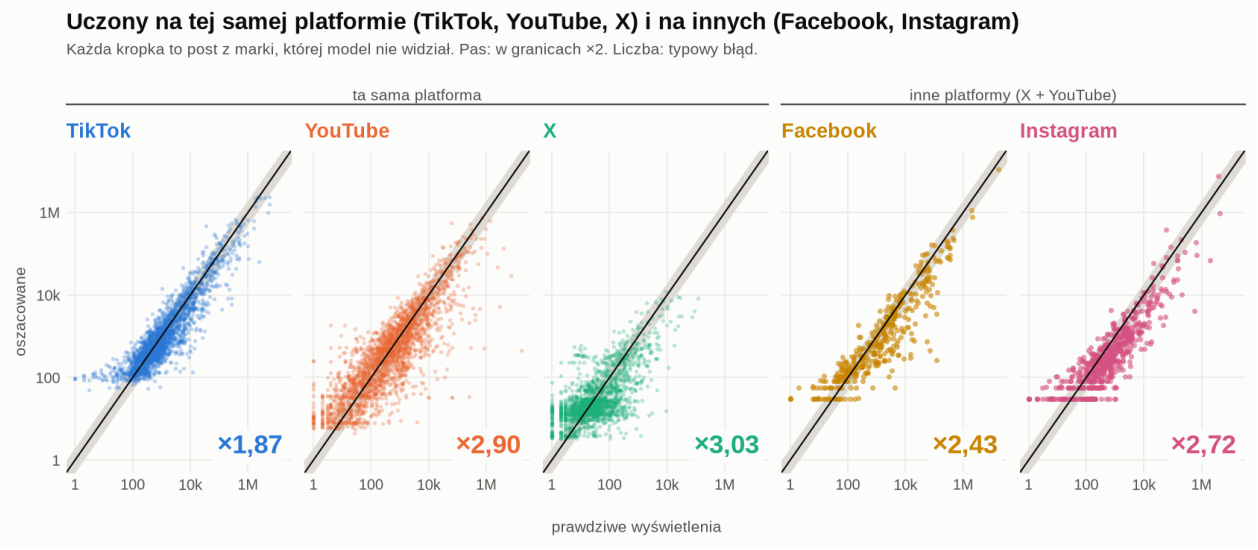
autor ani identyczny tekst nigdy nie trafia jednocześnie do treningu i testu: jeden autor może pisać o kilku markach (1–9% postów), a ten sam tekst bywa wklejany na różnych kontach. Każda ocena dotyczy więc marki i autora, których model nie widział. Przedziały ufności liczymy bootstrapem po markach. Porównania metod (rozdział 6) robimy na prostszym podziale po samych markach; ostrzejszy podział zmienia błąd o najwyżej 0,002 na TikToku i YouTube i o 0,012 na X, tak samo dla wszystkich metod. Na TikToku, YouTube i X używamy CatBoost [4] na obserwujących, reakcjach i flagach braków. Do przeniesienia na Facebooka i Instagram używamy regresji ridge na $\log(1+\text{lajki})$ i $\log(1+\text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem; przy pominiętej platformie przenosi się ona lepiej niż CatBoost. Przedziały 50% i 90% dla każdego posta dają konformalna regresja kwantylowa [5].

4 Wyniki

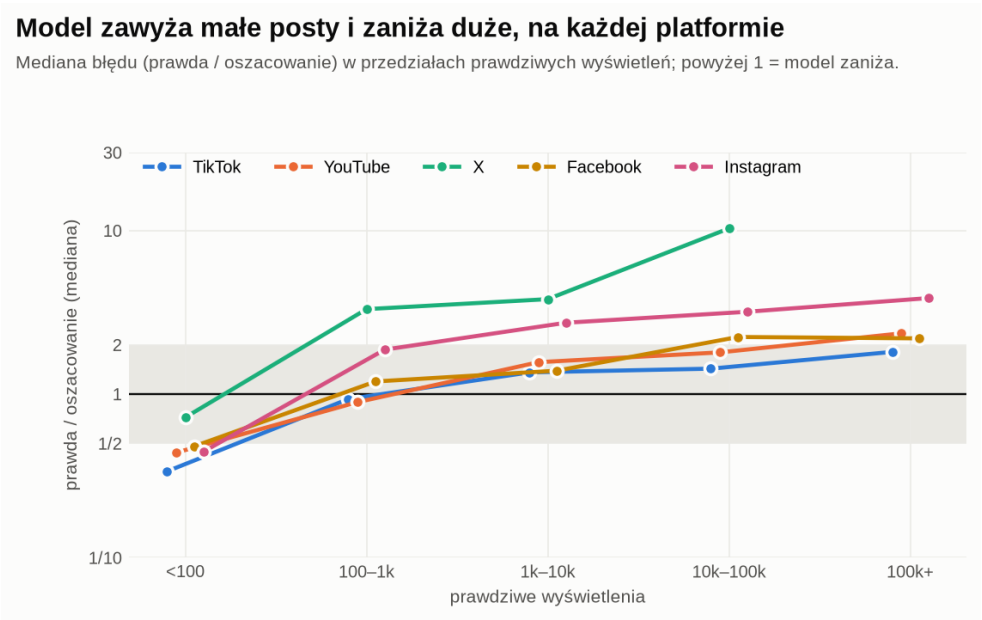
Wynik główny. Rys. 2 zestawia oba scenariusze. Na TikToku, YouTube i X, gdzie model uczy się na tej samej platformie, typowy błąd wynosi ×1,9, ×2,9 i ×3,0. Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się ×2,43 (przedział ufności ×2,05–×3,03) i ×2,72 (×2,49–×3,05). Na Facebooku to tyle samo, co ten sam model uczony na samej platformie docelowej (×2,42), a na Instagramie trochę więcej niż przy uczeniu na samym Instagramie (×2,41; 72% rolek jest niedoszacowanych), więc zależność między reakcjami a wyświetleniami przenosi się między platformami prawie bez straty. Kolejność postów jest zachowana bardzo dobrze (Spearman 0,91 i 0,86).

Kto jest źle szacowany. Na każdej platformie, także po przeniesieniu, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże (Rys. 3). To typowe ściąganie do średniej: reakcje nie odróżniają dobrze postu, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone kilkanaście razy; po przeniesieniu Instagram zaniża duże rolki około ×3.

Trzy przedziały zamiast liczby. W raporcie często wystarczy powiedzieć, czy post miał mniej niż tysiąc, od tysiąca do dziesięciu tysięcy, czy ponad dziesięć tysięcy wyświetleń. Gdy tym samym modelem tniemy oszacowanie na te trzy przedziały, trafiamy w dobry w 80–82% postów na TikToku, YouTube, Facebooku i Instagramie (Rys. 4), wobec 45–65% przy zgadywaniu zawsze najczęstszego przedziału. Prawie nigdy nie mylimy się o dwa przedziały (0,2–1,7% postów). Najczęstszy błąd to zaniżenie o jeden przedział postów od tysiąca do dziesięciu tysięcy. Na X 95% postów ma poniżej tysiąca wyświetleń, więc trafienie 95% nie mówi tam nic ponad zgadywanie.



Rysunek 2: Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post, oszacowany przez model, który nie widział jego marki (walidacja krzyżowa po markach). TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (642 rolki, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd 10^{MAE}.

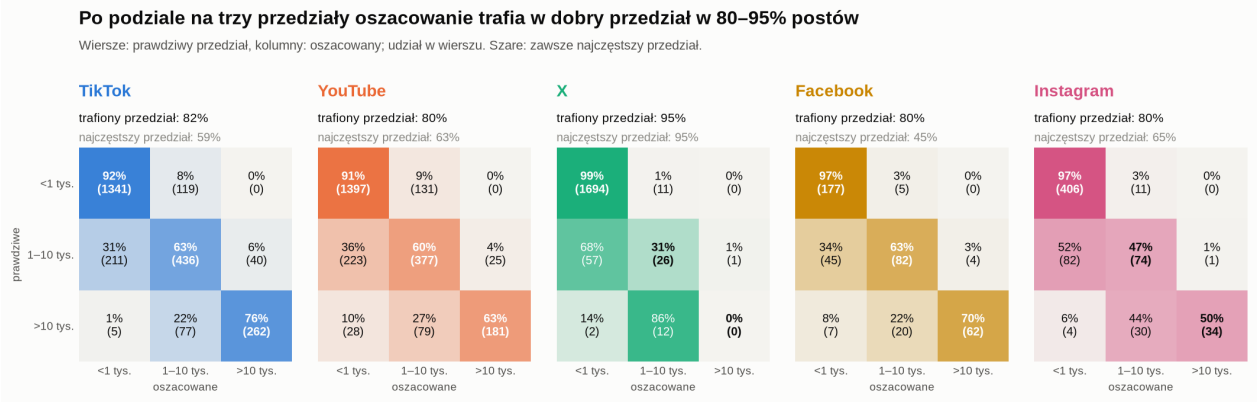


Rysunek 3: Błąd według wielkości posta.
Mediana stosunku prawdziwych do oszacowanych wyświetleń w przedziałach prawdziwych wyświetleń (pokazane przedziały z co najmniej 10 postami). Powyżej 1: model zaniża. Szary pas: w granicach ×2. Modele jak na Rys. 2.

Przedziały. Przedział 90% trafia w 87–91% postów na TikToku, YouTube i X, także na miesiącach spoza treningu (0,90–0,93). Na Facebooku trafia w 93% filmów kont poniżej miliona obserwujących, ale dla największych kont tylko w 80–86%. Jeśli zamiast liczby podamy jeden z trzech przedziałów (<1 000, 1 000–10 000, >10 000), trafiamy w 78–82% postów na TikToku, YouTube, Facebooku i Instagramie.

5 Przeniesienie między platformami

Gdzie znamy prawdę. Prawdziwe wyświetlenia mamy na wszystkich pięciu platformach (Tabela 1): na TikToku, YouTube i X z eksportu Brand24, na Facebooku (filmy) i Instagramie (rolki) z naszego odczytu, razem z lajkami i komentarzami z tej samej chwili. Dzięki temu każdą platformę możemy potraktować jak „ukrytą”: uczymy model na pozostałych i sprawdzamy na niej. Używamy tylko dwóch pól, które ma każda platforma, lajków i komentarzy, i prostej regresji ridge, bo przy pominiętej platformie przenosi się ona lepiej



Rysunek 4: Oszacowanie pocięte na trzy przedziały wyświetleń.
Ten sam model co na Rys. 2: TikTok, YouTube, X z walidacji po markach i autorach, Facebook i Instagram z przeniesienia z X i YouTube. Wiersz: prawdziwy przedział; kolumna: oszacowany; w komórce udział w wierszu i liczba postów. Pogrubione: trafiony przedział. Szara liczba nad tabelą: wynik przy zgadywaniu zawsze najczęstszego przedziału.

niż CatBoost. W praktyce ważne są Facebook i Instagram, bo tam wyświetleń w danych monitoringu nie ma; pozostałe platformy pokazują, jak ogólny jest ten wynik.

Wszystkie kombinacje. Tabela 2 pokazuje błąd dla każdego z 31 zestawów platform treningowych. Widać trzy rzeczy. Po pierwsze, Facebook i Instagram dają się oszacować z prawie dowolnego zestawu z błędem ×2,4–×3,1, czyli blisko modelu uczonego na nich samych (×2,4); najgorszy jest trening na samym X. Po drugie, X jest wyjątkiem w obie strony: model uczony na X myli się na YouTube ×5,5, a żaden zestaw nie schodzi na X poniżej ×3,6, wobec ×3,3 przy uczeniu na X. Na X większość postów ma zero lub jeden lajk (Rys. 1), więc zależność wyświetleń od lajków wygląda tam inaczej. Po trzecie, YouTube jest trudny nawet dla modelu uczonego na nim samym (×4,1 dla ridge wobec ×2,8 dla CatBoost), bo dużo filmów ma wyświetlenia bez żadnych reakcji. Więcej platform w treningu nie zawsze pomaga: liczy się, które platformy są w zestawie i w jakich proporcjach.

Czego model potrzebuje. Przeniesienie działa tylko z lajkami odczytanymi razem z wyświetleniami (Rys. 5A). Same komentarze dają ×6,2–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na platformach ze znanymi wyświetleniami (Rys. 5B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dla każdego układu dostępnych pól uczymy osobny model z osobnym przedziałem, dzięki czemu przedział 90% trafia w 88–90% postów w każdym przypadku; model uczony na pełnych danych i karmiony niepełnymi trafiałby tylko w 46–83%.

Świeże dane źródłowe. Wyświetlenia w eksporcie są odczytane krótko po publikacji, a nasze odczyty z Facebooka i Instagramu kilka miesięcy później. Gdy ten sam model uczymy na X i YouTube odczytanych ponownie, razem z reakcjami z tej samej chwili, błąd na Instagramie spada z ×2,72 do ×2,41 (tyle, co model uczony na samym Instagramie), a na Facebooku zostaje ×2,44. Niedoszacowanie dużych postów i sum dla marek zmniejsza się mniej więcej o połowę. Samo przesunięcie wyświetleń z eksportu do późniejszego wieku tego nie daje, więc ważne jest, żeby wyświetlenia i reakcje pochodziły z tego samego momentu. Z tego samego powodu X jako platforma testowa wypada źle głównie przez nieaktualne etykiety: ten sam model myli się na X z eksportu o 0,64, a na X odczytanym ponownie o 0,49. Posty X bez lajków nie są tu przyczyną.

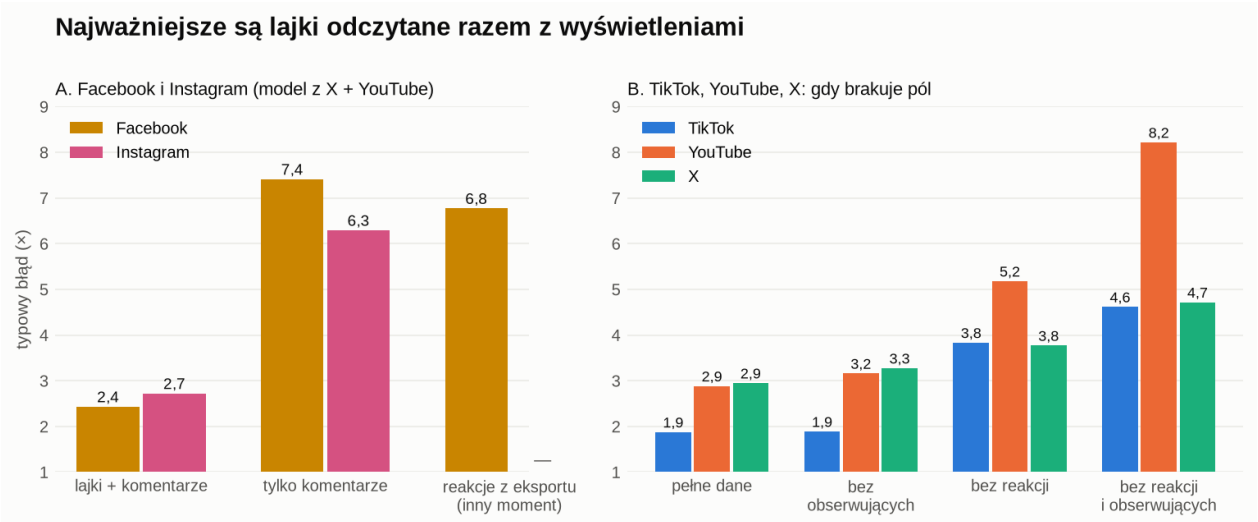
TODO: później: szósta platforma z publicznymi wyświetleniami (backlog B30).

6 Porównanie metod

Rodziny modeli. Tabela 3 porównuje modele na tych samych danych wejściowych. Po dostrojeniu prawie wszystkie rodziny dają ten sam błąd: ×1,85–×1,92 na TikToku, ×2,8–×2,9 na YouTube i ×2,9–×3,1 na X. Wyraźnie gorsze są tylko proste odniesienia (×4,6–×8,8) oraz regresja liniowa i kNN na YouTube (×3,0–×3,5). Najlepszym pojedynczym modelem jest TabPFN v2, ale wyprzedza CatBoost tylko o 0,002–0,010, czyli w granicach szumu między przebiegami, a liczy się około 150 razy dłużej. Sieć grafowa i transformer czytający post jako tekst są gorsze od CatBoost.

Tabela 2: Typowy błąd (×) dla wszystkich 31 zestawów platform treningowych.
Ridge na log lajków i komentarzy, posty z platform treningowych połączone w jeden zbiór. Wiersz: platformy w treningu (TT TikTok, YT YouTube, X, FB Facebook, IG Instagram), w grupach po 1, 2, 3 i 4 platformy, w grupie od najlepszego średnio. Kolumna: platforma testowa, której nie było w treningu. Pierwszy wiersz: ten sam model uczony na platformie testowej (walidacja po markach). Pogrubione: najlepszy wynik w kolumnie. Ciemniej: większy błąd.

Trening na	TikTok	YouTube	X	Facebook	Instagram
ta sama platforma (CV po markach)	2,0	4,1	3,3	2,4	2,4
YT	**2,0**	trening	4,6	2,7	2,6
FB	2,3	4,3	**3,6**	trening	**2,5**
IG	2,5	4,5	4,1	2,5	trening
TT	trening	4,1	4,1	2,6	2,6
X	3,4	5,5	trening	3,1	2,7
YT + X	2,1	trening	trening	2,4	2,7
YT + FB	2,0	trening	4,5	trening	2,5
YT + IG	2,0	trening	4,6	2,6	trening
TT + X	trening	4,1	trening	2,6	2,8
TT + YT	trening	trening	4,5	2,6	2,6
X + FB	2,5	4,5	trening	trening	2,7
X + IG	2,8	4,7	trening	2,6	trening
FB + IG	2,4	4,4	3,9	trening	trening
TT + FB	trening	**4,1**	4,0	trening	2,6
TT + IG	trening	4,1	4,2	2,6	trening
YT + X + IG	2,1	trening	trening	**2,4**	trening
YT + X + FB	2,1	trening	trening	trening	2,6
TT + YT + X	trening	trening	trening	2,5	2,7
YT + FB + IG	2,0	trening	4,4	trening	trening
TT + X + IG	trening	4,1	trening	2,5	trening
TT + YT + FB	trening	trening	4,4	trening	2,6
TT + X + FB	trening	4,1	trening	trening	2,8
TT + YT + IG	trening	trening	4,4	2,6	trening
X + FB + IG	2,6	4,5	trening	trening	trening
TT + FB + IG	trening	4,1	4,1	trening	trening
YT + X + FB + IG	2,1	trening	trening	trening	trening
TT + YT + X + IG	trening	trening	trening	2,5	trening
TT + YT + X + FB	trening	trening	trening	trening	2,7
TT + X + FB + IG	trening	4,1	trening	trening	trening
TT + YT + FB + IG	trening	trening	4,4	trening	trening



Rysunek 5: Typowy błąd przy różnych danych wejściowych.
A: Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": nasze pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak). B: TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach.

Dlaczego nie zespół. Zespół łączy oszacowania kilku modeli, np. przez ich średnią („średnia 3 najlepszych") albo przez model drugiego poziomu, który uczy się, jak ważyć oszacowania wszystkich rodzin („stos"). Błędy różnych modeli częściowo się znoszą, więc zespół jest zwykle trochę lepszy od każdego członka. U nas stos poprawia wynik o 0,011–0,028 (×1,03–×1,07). Zostajemy przy jednym modelu z trzech powodów: (1) zysk jest mały wobec typowego błędu ×1,9–×3,0; (2) stos wymaga trenowania i utrzymania kilkunastu modeli, a przedziały niepewności (CQR) i przeniesienie na inne platformy budujemy na jednym modelu; (3)

przy przeniesieniu i tak wygrywa najprostszy model liniowy (rozdział 3), więc złożoność nie przekłada się na główny wynik.

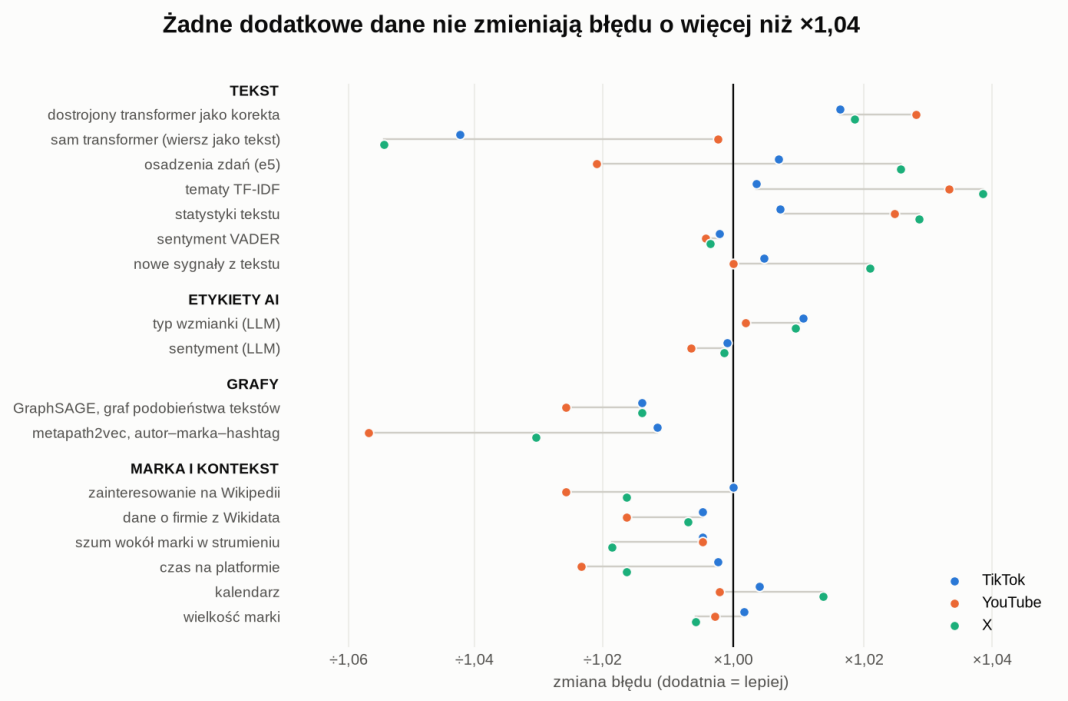
Tabela 3: Porównanie rodzin modeli: MAE w skali $\log_{10}$ i typowy błąd (×).
Wszystkie modele na obserwujących, reakcjach i flagach braków, walidacja krzyżowa po markach. Modele z drzew, liniowe, jądrowe i MLP po strojeniu hiperparametrów (40 ustawień na fałd, strojenie zagnieżdżone). TabPFN, TabICL, GraphSAGE, transformer i stos pochodzą z osobnych przebiegów na tych samych danych; CatBoost w tych przebiegach mieścił się w 0,271–0,273 / 0,452–0,456 / 0,466–0,470, więc różnice poniżej około 0,005 są w granicach szumu. Pogrubione: najlepszy pojedynczy model w kolumnie. Zespoły pokazujemy tylko dla porównania.

Model	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	0,663 (×4,60)	0,944 (×8,79)	0,667 (×4,65)
stały mnożnik liczby obserwujących	0,919 (×8,30)	0,855 (×7,16)	0,879 (×7,57)
Modele liniowe i jądrowe			
regresja liniowa (ridge)	0,277 (×1,89)	0,545 (×3,51)	0,487 (×3,07)
k najbliższych sąsiadów (kNN)	0,283 (×1,92)	0,483 (×3,04)	0,490 (×3,09)
SVR z jądrem RBF	0,271 (×1,87)	0,463 (×2,90)	0,480 (×3,02)
Drzewa decyzyjne			
las losowy (random forest)	0,275 (×1,88)	0,463 (×2,90)	0,473 (×2,97)
extra trees	0,275 (×1,88)	0,459 (×2,88)	0,475 (×2,99)
gradient boosting (scikit-learn)	0,276 (×1,89)	0,453 (×2,84)	0,474 (×2,98)
LightGBM	0,275 (×1,88)	0,457 (×2,86)	0,475 (×2,99)
XGBoost	0,273 (×1,87)	0,450 (×2,82)	0,467 (×2,93)
CatBoost (model końcowy)	0,272 (×1,87)	0,452 (×2,83)	0,470 (×2,95)
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	0,276 (×1,89)	0,454 (×2,84)	0,477 (×3,00)
sieć grafowa GraphSAGE (graf podobnych tekstów)	0,279 (×1,90)	0,467 (×2,93)	0,474 (×2,98)
dostrojony transformer (wiersz jako tekst)	0,289 (×1,95)	0,454 (×2,84)	0,490 (×3,09)
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	**0,268 (×1,85)**	**0,443 (×2,77)**	**0,465 (×2,92)**
TabICL	0,272 (×1,87)	0,445 (×2,79)	0,466 (×2,92)
Zespoły modeli (dla porównania)			
średnia 3 najlepszych rodzin	0,270 (×1,86)	0,446 (×2,79)	0,469 (×2,94)
stos wszystkich rodzin	0,260 (×1,82)	0,425 (×2,66)	0,441 (×2,76)

Dodatkowe dane. Sprawdziliśmy też ponad dwadzieścia dodatkowych źródeł sygnału (Rys. 6): tekst (od TF-IDF po osadzenia zdań), etykiety AI, grafy autorów i marek oraz dane zewnętrzne o markach. Żadne nie zmienia błędu o więcej niż ×1,04, a większość mniej niż ×1,02 albo pogarsza wynik. Tekst pomaga trochę na YouTube i X, grafy i dane zewnętrzne szkodzą. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436). Historię autora opisujemy osobno poniżej.

Więcej danych bez nowych etykiet. Sprawdziliśmy też metody, które dokładają danych albo uczą się ich struktury bez wyświetleń. Syntetyczne duże posty (SMOTER/SMOGN) zmniejszają niedoszacowanie najpopularniejszej dziesiątej części postów, ale tylko przez rozciągnięcie skali oszacowań, i podnoszą błąd o 0,006–0,019. Losowe zaburzanie danych wzdłuż trendu i mixup nie pozwalają CatBoost ani sieci MLP przenosić się tak dobrze jak ridge (zostają o 0,014–0,062 w tyle na każdej z pięciu platform). Reprezentacja uczona bez etykiet (autoenkoder odszumiający, SCARF) zmienia błąd o najwyżej 0,005, a pseudo-etykiety dla postów bez wyświetleń o najwyżej 0,008. Model końcowy zostaje więc bez augmentacji.

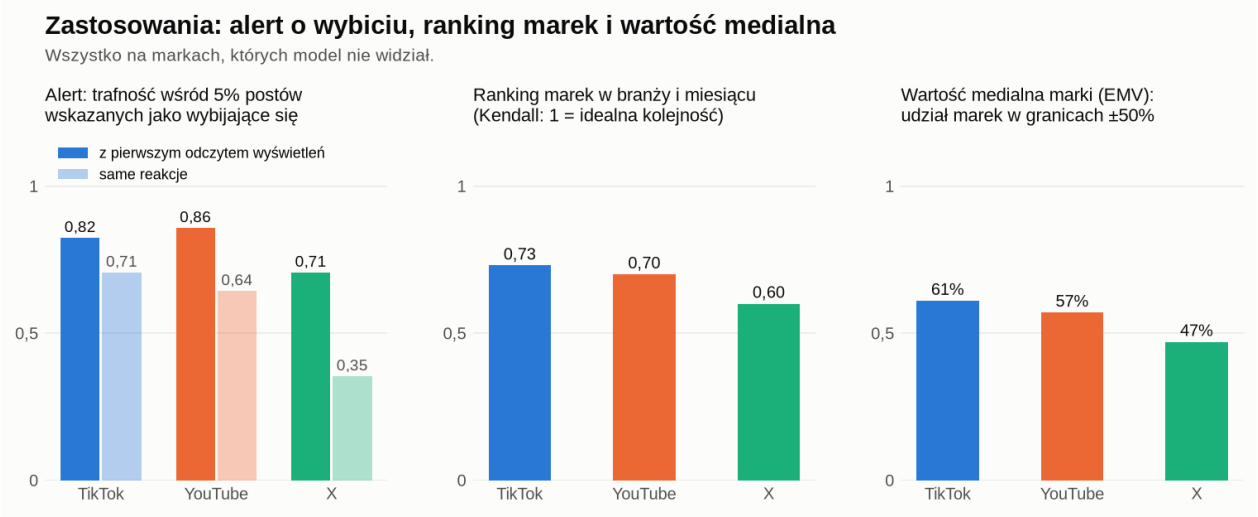
Historia autora. Jedynym sygnałem, który pomaga wyraźnie, jest historia autora. Ten sam autor ma podobną liczbę wyświetleń w kolejnych postach, niezależnie od reakcji: korelacja nadwyżki wyświetleń (prawda minus oszacowanie) między pierwszym a późniejszymi postami autora wynosi 0,68–0,70 na wszystkich trzech platformach, a autorzy z górnej jednej trzeciej mają przy tym samym oszacowaniu 4–9 razy więcej wyświetleń niż autorzy z dolnej. Wykorzystujemy to prosto: do oszacowania nowego posta dodajemy średnią nadwyżkę wcześniejszych postów tego autora, ściągniętą do zera, gdy postów jest mało (suma nadwyżek podzielona przez liczbę postów plus stała dobrana na innych markach). Na postach autorów z historią błąd spada z 0,37 do 0,26 na TikToku, z 0,50 do 0,35 na YouTube i z 0,53 do 0,43 na X (×1,3–×1,4); większość zysku daje już jeden wcześniejszy post. Taka historia jest jednak tylko dla 3–16% postów w naszej próbie, więc w średnim błędzie zysk znika (≤0,003). Sprawdziliśmy też tego samego autora na innej platformie: po dokładnym dopasowaniu nazwy pokrywa się 0–0,1% postów, za mało, żeby to ocenić. Po ujednoliceniu nazw (małe litery,



Rysunek 6: Dodatkowe dane i cechy.
Zmiana typowego błędu względem modelu końcowego (transformer jako korekta, osadzenia, grafy, dane zewnętrzne) albo względem modelu na obserwujących i reakcjach (TF-IDF, statystyki tekstu, VADER, etykiety AI, kalendarz, wielkość marki). W prawo: lepiej, w lewo: gorzej; ×1,02 to zmiana MAE o około 0,01. *Transformer jako korekta*: dostrojony model językowy przewiduje błąd CatBoost z tekstu posta. *Osadzenia e5*: wielojęzyczny model zdań. *Etykiety LLM*: typ i sentyment wzmianki z modelu językowego. *GraphSAGE*: sieć grafowa na grafie podobnych tekstów; *metapath2vec*: osadzenia grafu autor–marka–hashtag. *Wikipedia, Wikidata*: zainteresowanie marką i dane o firmie. Wszystko z walidacją po markach.

bez znaków specjalnych i dopisków typu „official”) i uchwytów z adresów profili tylko 56 z 8 332 postów z wyświetleniami (0,67%) ma post tego samego autora na innej platformie, więc tego sygnału nie da się użyć na danych z monitoringu.

7 Zastosowania



Rysunek 7: Zastosowania oszacowania na TikToku, YouTube i X.
Alert: z postów odczytanych po raz pierwszy model wskazuje 5%, które będą miały najwięcej wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV: wyświetlenia przeliczone na pieniądze stawką za tysiąc; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

Alert o wybiciu. Z pierwszym odczytem wyświetleń model wskazuje 5% postów, które się wybiją, z trafnością 0,82 / 0,86 / 0,71; same reakcje dają 0,71 / 0,64 / 0,35 (Rys. 7). Przy trzy razy większej liczbie alertów łapie 82–100% wybijających się postów.

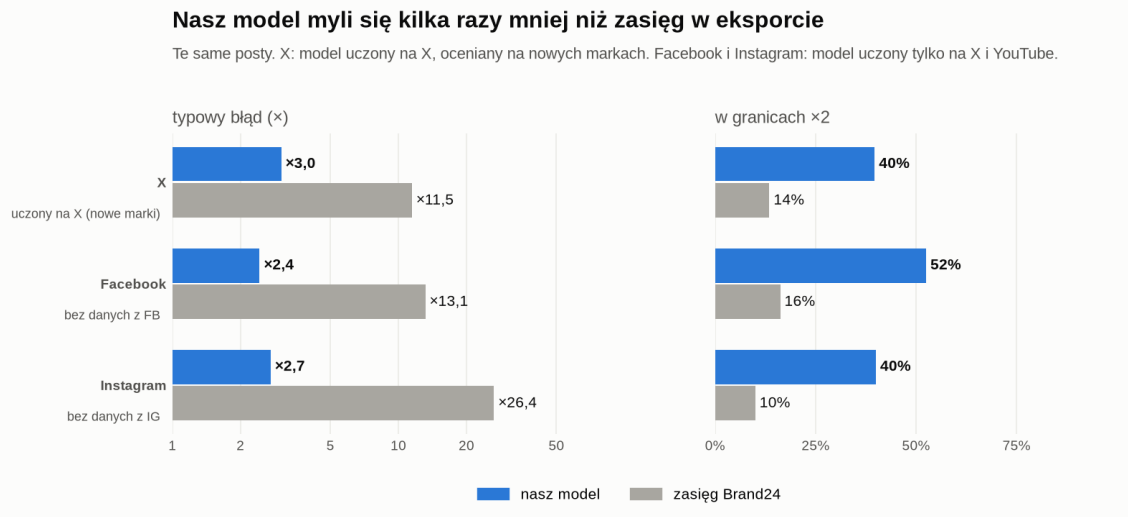
Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek.

Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży.

8 Ograniczenia i rekomendacje

Wynik dla Facebooka opiera się na 20 markach (bez trzech największych ×2,9), a dla Instagramu na 11 (×2,96). Posty wiralowe są zaniżane ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek. Wyniki opisują zależności, nie przyczyny. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów.



Rysunek 8: Nasze oszacowanie a kolumna zasięgu w eksporcie Brand24, na tych samych postach.
Tylko platformy, na których zasięg nie jest liczbą wyświetleń. X (1 803 posty): model uczony na X, oceniany na markach i autorach, których nie widział; prawda z eksportu. Facebook (402 filmy) i Instagram (642 rolki): model poza platformą, uczony tylko na X i YouTube, bez żadnego posta z FB ani IG; prawda z naszego odczytu. Zasięg Brand24 zawyża wyświetlenia na X (74% postów) i Facebooku (67%), a zaniża na Instagramie (97%).

Użycie AI i odtwarzalność. **TODO:** do napisania przez zespół własnymi słowami. Fakty do ujęcia: agenci AI (Claude Code, DeepSeek) pisali kod analiz i odczytu danych, uruchamiali eksperymenty, robili wykresy i szkic tekstu; modele językowe oznaczyły typ i sentyment wzmianek, a etykiety poprawił członek zespołu; logi sesji agentów są w `logs/`. Każdy wynik ma kartę eksperymentu, wiersz w rejestrze (`docs/pl/experiments.md`, 220 pozycji), skrypt w `src/` i liczby w `data/processed/`.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[5] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.