Szacowanie ukrytych wyświetleń postów z reakcji: przeniesienie modelu między platformami

Zespół projektu AMC, Politechnika Wrocławska

wersja robocza, 9 listopada 2026

Streszczenie

Na Facebooku i Instagramie dane z monitoringu mediów nie zawierają liczby wyświetleń postów. Sprawdzamy, czy można ją oszacować z lajków i komentarzy modelem, który nie widział ani jednego wyświetlenia z tych platform. Regresja liniowa na lajkach i komentarzach, uczona tylko na X i YouTube, szacuje wyświetlenia 402 filmów z Facebooka z typowym błędem $\times 2{,}43$ (MAE 0,385 w skali $\log_{10}$), tyle samo co ten sam model uczony na Facebooku, a 642 rolek z Instagramu z błędem $\times 2{,}72$, gorzej niż ten sam model uczony na Instagramie ($\times 2{,}41$). Mediana wyświetleń z platform źródłowych myli się tam $\times 9$–$\times 20$. Model w praktyce przenosi stosunek wyświetleń do lajków: od samego stałego mnożnika lajków jest lepszy na trzech z sześciu platform docelowych, nie gorszy na dwóch i gorszy na X. Przeniesienie wymaga reakcji odczytanych razem z wyświetleniami; na Stack Exchange przenosi się tylko kolejność, a poziom jest gorszy niż ze stałej mediany. Wyniki opierają się odpowiednio na 20 i 11 markach, a wyświetlenia źródłowe i docelowe odczytano w różnym wieku postów (23 wobec ponad 300 dni), co może częściowo maskować różnice.

1 Wstęp

Firmy monitorujące media, takie jak Brand24, raportują klientom, ile osób mogło zobaczyć wzmiankę o ich marce. Najprostsza miara zasięgu, liczba wyświetleń, często nie jest jednak widoczna: platformy ograniczają to, co pokazują publicznie, a zakres tych danych zmienia się między platformami, formatami postów i w czasie. Zasięg przybliża się wtedy regułą z liczby obserwujących lub reakcji, która nie mówi, jak bardzo może się mylić.

Przewidywanie popularności treści jest szeroko badane [1], także między serwisami: Shulman i in. [2] przenoszą model między zbiorami muzyki, książek, zdjęć i linków, a Roy i in. [3] przenoszą wiedzę z Twittera na filmy z YouTube. Prace te przewidują jednak przyszłą popularność i mają dane o popularności z platformy docelowej, na których model się uczy lub kalibruje. Nasze zadanie to przeniesienie bez etykiet z dziedziny docelowej [4]: szacujemy bieżące wyświetlenia z widocznych reakcji na platformie, z której model nie dostaje w treningu ani jednej wartości wyświetleń. Wyświetlenia z tej platformy zbieramy osobno i używamy ich tylko do oceny. Nie znaleźliśmy pracy, która tak sprawdza przeniesienie modelu wyświetleń między platformami.

Nasz wkład:

- pokazujemy, że wystarczy prosta regresja liniowa na lajkach i komentarzach, uczona tylko na X i YouTube: szacuje wyświetlenia filmów na Facebooku z błędem $\times 2{,}43$, tyle samo co model uczony na Facebooku, a rolek na Instagramie $\times 2{,}72$ (model uczony na Instagramie: $\times 2{,}41$);
- porównujemy ją uczciwie z prostymi regułami na sześciu platformach docelowych i pokazujemy, kiedy przeniesienie działa (reakcje odczytane razem z wyświetleniami) i kiedy zawodzi (X, poziom na Stack Exchange);
- dla każdego posta podajemy przedział niepewności, trafny na tej samej platformie; poza platformą wymaga on kalibracji na kilku markach z platformy docelowej;
- pokazujemy zastosowania: alert o wybiciu, ranking marek i wartość medialną.

2 Dane

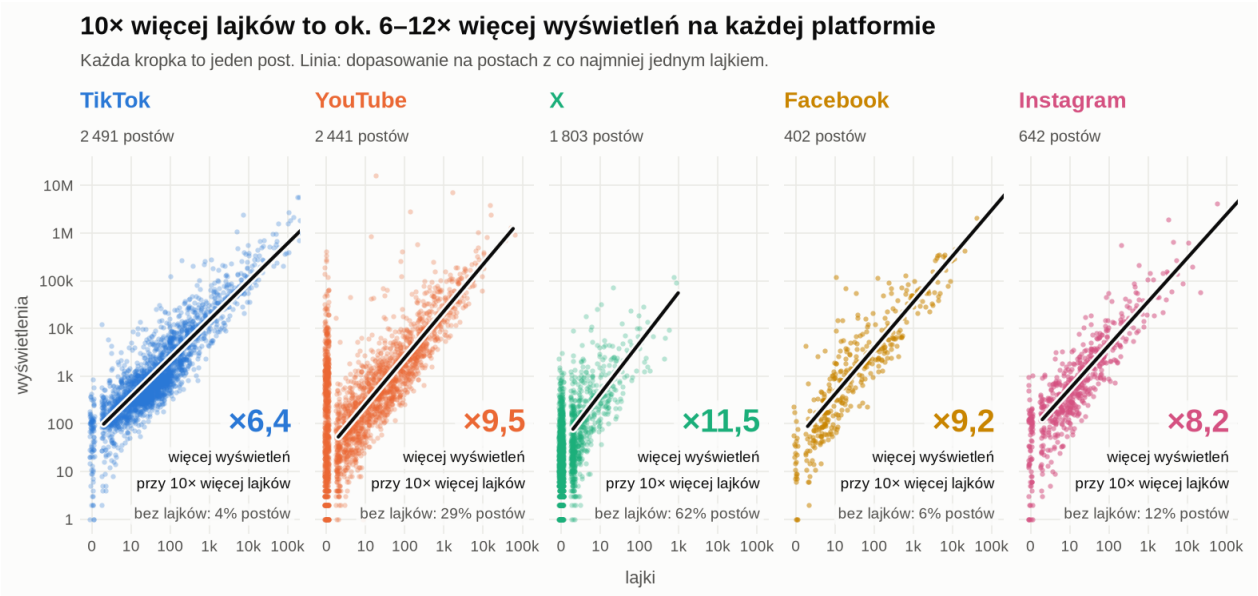
Korzystamy z 12 500 wzmianek o 348 markach z pięciu platform, udostępnionych przez Brand24 (po 2 500 na platformę; marka może występować na kilku platformach; 85% wzmianek opublikowano między kwietniem a sierpniem 2026 r., a 85% jest po angielsku). Dla TikToka, YouTube i X wyświetlenia są w eksporcie. Eksport ma też kolumnę zasięgu, którą Brand24 wylicza regułą z reakcji i obserwujących (według naszej rekonstrukcji) i która na Facebooku i Instagramie zastępuje wyświetlenia. Dla Facebooka i Instagramu zebraliśmy wyświetlenia sami w listopadzie 2026 r., razem z lajkami i komentarzami z tej samej chwili. Z 470 filmów na Facebooku

68 było już usuniętych, zostaje 402 z 20 marek. Z 976 rolek na Instagramie 261 było usuniętych, 19 nie miało licznika wyświetleń, a 54 miało ukryte lajki, zostaje 642 z 11 marek. Zwykłe posty na tych platformach nie mają licznika wyświetleń, więc wyniki dotyczą tylko filmów i rolek. Ponownie odczytaliśmy też wyświetlenia i reakcje 2 013 postów z X, 1 376 z YouTube i 426 z TikToka (rozdz. 5).

Tabela 1: Dane według platformy.

Platforma	Marki	Autorzy	Źródło wyświetleń	Posty z wyśw.	Mediana wyśw.	Wyśw./lajk
TikTok	266	2 411	eksport Brand24	2 491	729	25
YouTube	273	2 041	eksport Brand24	2 441	433	26
X	252	1 658	eksport Brand24	1 803	27	22
Facebook	20	$\geq$182[a]	własny odczyt (filmy)	402	1 413	35
Instagram	11	?[b]	własny odczyt (rolki)	642	504	53

a: autor znany dla 74% filmów. b: autor znany tylko dla 11% rolek (59 autorów wśród 72). Wyśw./lajk: mediana stosunku na postach z co najmniej jednym lajkiem.



Rysunek 1: Wyświetlenia a lajki, osobno dla każdej platformy.
Obie osie w skali logarytmicznej; posty bez lajków przy zerze. Linia: prosta dopasowana na postach z co najmniej jednym lajkiem; liczba: ile razy więcej wyświetleń ma post z 10 razy większą liczbą lajków (6–12). TikTok, YouTube, X: eksport Brand24; Facebook (filmy), Instagram (rolki): nasz odczyt.

3 Metoda

Przewidujemy $y = \log_{10}(\text{wyświetlenia})$. Błąd podajemy jako MAE w tej skali i jako *typowy błąd*, czyli mnożnik 10^{MAE} (MAE 0,30 $\approx \times 2$; to średnia geometryczna stosunku oszacowania do prawdy). Zgodność kolejności mierzymy korelacją rang Spearmana między oszacowanymi a prawdziwymi wyświetleniami. Każdy model porównujemy z dwiema regułami: medianą wyświetleń i *stałym mnożnikiem lajków* (wyświetlenia = k·lajki, k to mediana stosunku wyświetleń do lajków w danych treningowych, około 25). Przedziały ufności liczymy bootstrapem po markach, a różnice między modelami na tych samych postach sparowanym bootstrapem po markach.

Walidacja. Łączymy posty w grupy, jeśli mają wspólną markę, wspólnego autora albo identyczny tekst (jeden autor pisze czasem o kilku markach, a ten sam tekst bywa wklejany na różnych kontach), i dzielimy całe grupy na pięć części. Każda ocena dotyczy więc marki i autora, których model nie widział. Porównania metod (Tabela 4 i Rys. 4B) robimy na prostszym podziale po samych markach; ich liczby różnią się od Rys. 2 o najwyżej 0,012 (CatBoost na X: $\times$2,95 wobec $\times$3,03), a kolejność metod się nie zmienia.

Dwa scenariusze, oznaczane na każdym wykresie. *Na tej samej platformie*: CatBoost uczony na postach z danej platformy (TikTok, YouTube, X), oceniany na markach i autorach, których nie widział. *Poza platformą*: regresja ridge, która nie widzi w treningu ani jednego posta z platformy docelowej (Facebook, Instagram, Stack Exchange; w Tabelach 2 i 3 także TikTok, YouTube i X po kolei); wyświetlenia celu służą tylko do oceny.

Modele. Na tej samej platformie używamy CatBoost [5] na obserwujących, reakcjach i flagach braków (osobna cecha mówi, czy pole było puste, bo brak to nie zero). Poza platformą używamy regresji ridge [6] na $\log(1 + \text{lajki})$ i $\log(1 + \text{komentarze})$, czyli dwóch polach, które ma każda platforma, uczonej na X i YouTube razem. Przy pominiętej platformie przenosi się ona lepiej niż CatBoost i sieci MLP (o 0,014–0,062 MAE na każdej z pięciu platform, także po augmentacji danych). Główne liczby dla Facebooka i Instagramu pochodzą z eksportu Brand24 dla X i YouTube; wariant ze źródłem odczytanym ponownie (rozdz. 5) podajemy osobno, bo był sprawdzany już po obejrzeniu części rolek. Przedziały 50% i 90% dla każdego posta daje konformalna regresja kwantylowa (CQR) [7]: model kwantylowy wyznacza wstępny przedział, a jego szerokość poprawiamy na odłożonej części danych tak, żeby pokrycie było zgodne z założonym.

4 Wyniki

Główne wyniki: o ile mylimy się na pojedynczym poście

		Posty / marki	**Nasz błąd**	W granicach ×2	Stała mediana
Na tej samej platformie	TikTok	2 491 / 266	×**1,87**	67%	×4,6
	YouTube	2 441 / 273	×**2,90**	43%	×8,8
	X	1 803 / 252	×**3,03**	40%	×4,6
Poza platformą (0 postów celu)	Facebook	402 / 20	×**2,43**	53%	×19,9
	Instagram	642 / 11	×**2,72**	40%	×8,7

Nasz błąd: typowy błąd 10^{MAE}, np. ×2,43 to oszacowanie zwykle 2,43 razy za duże albo za małe. Stała mediana: jedna liczba dla wszystkich postów (mediana tej samej platformy, a poza platformą mediana X i YouTube).

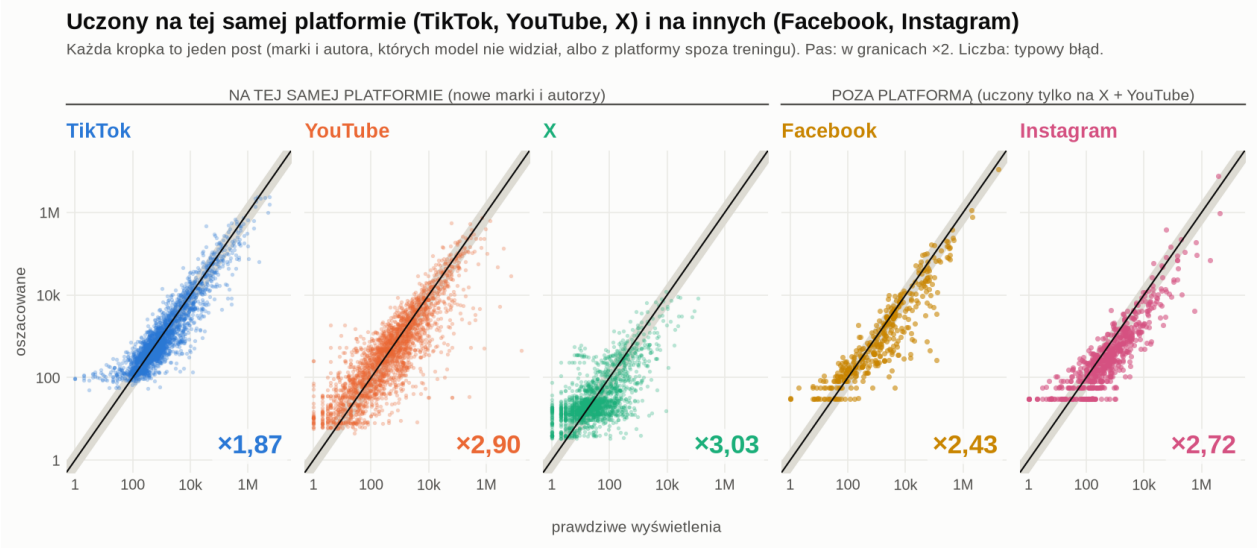
Na tej samej platformie. Na TikToku, YouTube i X typowy błąd wynosi ×1,87, ×2,90 i ×3,03 (MAE 0,273 / 0,462 / 0,482; Rys. 2). Stały mnożnik lajków daje tu ×2,23, ×4,06 i ×3,63, więc CatBoost jest od niego lepszy na każdej platformie o 0,075–0,15 MAE (przedziały ufności różnic nie obejmują zera).

Poza platformą. Na Facebooku i Instagramie model nie widział ani jednego posta z tych platform, a myli się o MAE 0,385 (×2,43, 95% CI ×2,05–×3,03) i 0,435 (×2,72, ×2,49–×3,05). Na Facebooku błąd jest taki sam jak przy uczeniu tego samego modelu na Facebooku (×2,42; różnica 0,001, 95% CI [−0,03; 0,03], czyli różnica co najwyżej ×1,07 w którąkolwiek stronę). Na Instagramie jest wyraźnie gorzej niż przy uczeniu ridge na samym Instagramie (×2,41; różnica 0,054, 95% CI [0,021; 0,093]), a 72% rolek jest niedoszacowanych, bo mediana rolki to 53 wyświetlenia na lajk, a na X i YouTube około 25 (Tabela 1). Wynik nie zależy od wyboru X i YouTube: mediana po wszystkich 15 zestawach treningowych bez platformy docelowej to ×2,58 na Facebooku i ×2,65 na Instagramie. Kolejność postów jest zachowana dobrze (Spearman 0,91 i 0,86, wewnątrz jednej marki 0,80 i 0,83), ale tak samo dobrze porządkują je same lajki. Typowa marka ma większy błąd niż całość: mediana po markach to ×2,7 na Facebooku i ×2,9 na Instagramie. Źródło i cel różnią się też wiekiem odczytu (rozdz. 8), co może częściowo maskować różnice między platformami.

Regresja a stały mnożnik. Regresja w praktyce przenosi stosunek wyświetleń do lajków, więc trzeba ją porównać z samym mnożnikiem wyznaczonym na tych samych danych (Tabela 2). Regresja jest lepsza na TikToku, Instagramie i Stack Exchange, nie lepsza na Facebooku i YouTube (przedziały ufności sięgają zera) i gorsza na X, gdzie 62% postów nie ma lajka, a komentarze ciągną oszacowanie w złą stronę. Obie metody są 2–8 razy dokładniejsze od mediany platform źródłowych na każdej platformie z filmami, ale na Stack Exchange mediana wygrywa z obiema.

Kto jest źle szacowany. Na każdej platformie, także poza platformą, model zawyża posty z małą liczbą wyświetleń (ok. ×2 poniżej 100 wyświetleń) i zaniża duże. To regresja do średniej: reakcje nie odróżniają dobrze posta, który się wybił, od zwykłego. Najsilniej widać to na X, gdzie posty powyżej 10 000 wyświetleń są zaniżone około 10 razy; poza platformą Instagram zaniża duże rolki około ×3.

Przedziały. Na tej samej platformie przedział 90% trafia w 87–91% postów na TikToku, YouTube i X, także gdy model uczymy na wcześniejszych miesiącach, a testujemy na późniejszym (0,90–0,93). Poza platformą



Rysunek 2: Oszacowane a prawdziwe wyświetlenia.
Każda kropka to jeden post. TikTok, YouTube, X: CatBoost na obserwujących, reakcjach i flagach braków, uczony na tej samej platformie, walidacja bez wspólnych marek, autorów i tekstów; prawda z eksportu Brand24. Facebook (402 filmy, 20 marek), Instagram (642 rolki, 11 marek): ridge na log lajków i komentarzy uczony tylko na X i YouTube, bez żadnego posta z platformy docelowej; prawda z naszego odczytu. Szary pas: oszacowanie w granicach ×2. Liczba: typowy błąd 10^{MAE}.

Tabela 2: Poza platformą: regresja a proste reguły wyznaczone na tych samych platformach źródłowych.
Typowy błąd (×); różnica MAE regresja − mnożnik ze sparowanym 95% CI po markach (ujemna: regresja lepsza). Źródło: X + YouTube, a dla X i YouTube jako celu pozostałe cztery platformy. Mediana: jedna liczba dla wszystkich postów, mediana wyświetleń źródła.

Cel	Źródło	Regresja	Mnożnik lajków	Różnica [95% CI]	Mediana źródła
TikTok	X + YT	×2,05	×2,22	−0,034 [−0,038; −0,029]	×11,0
YouTube	pozostałe 4	×4,08	×4,03	+0,004 [0,000; 0,009]	×8,9
X	pozostałe 4	×4,37	×3,45	+0,103 [0,084; 0,120]	×22,1
Facebook	X + YT	×2,43	×2,42	+0,002 [−0,017; 0,022]	×19,9
Instagram	X + YT	×2,72	×2,94	−0,034 [−0,047; −0,020]	×8,7
Stack Exchange	X + YT	×3,14	×5,33	−0,229 [−0,240; −0,207]	×2,1

sam rozrzut błędów z X i YouTube daje za szeroki przedział (na Facebooku trafia w 96% filmów). Trafny przedział wymaga kalibracji na kilku markach z platformy docelowej, czyli kilkudziesięciu postach ze znanymi wyświetleniami: po kalibracji na 25% marek trafia w 89% filmów na Facebooku, ale tylko w 84% dla 70 filmów z kont powyżej miliona obserwujących (±9 punktów procentowych). Na Instagramie do kalibracji są tylko 2 marki, więc tego nie oceniamy.

5 Przeniesienie między platformami

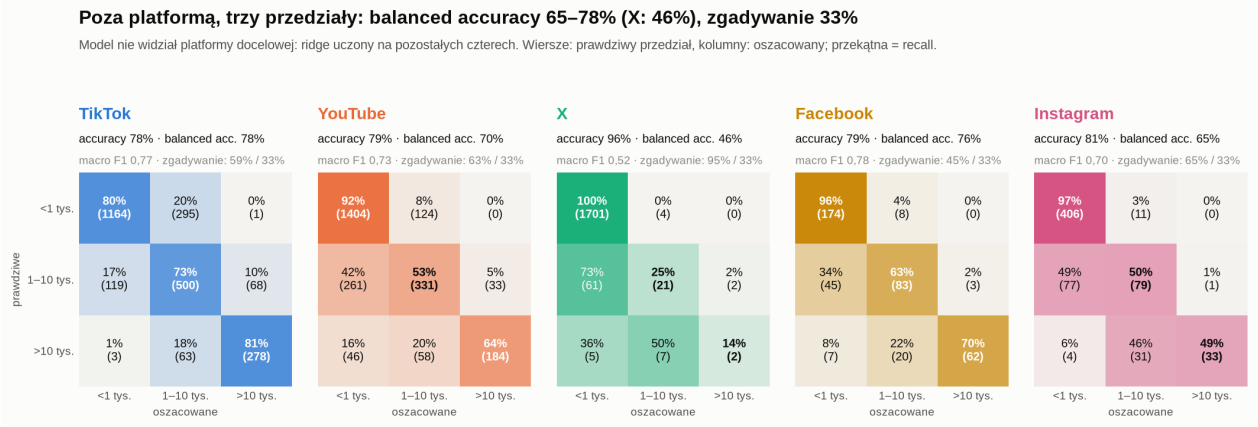
Różne zestawy treningowe. Prawdziwe wyświetlenia mamy na wszystkich pięciu platformach, więc każdą możemy potraktować jak „ukrytą” (Tabela 3). Facebook i Instagram dają się oszacować z prawie dowolnego zestawu z błędem ×2,4–×3,1: na Facebooku tyle, co ridge uczony na nim samym (×2,4), na Instagramie ×2,5–×2,8 wobec ×2,4. Najgorszy jest trening na samym X. X jest wyjątkiem w obie strony: model uczony na X myli się na YouTube ×5,5, a żaden zestaw nie osiąga na X błędu mniejszego niż ×3,6, wobec ×3,3 przy uczeniu na X. Część tej różnicy to wczesny odczyt wyświetleń w eksporcie: na danych odczytanych ponownie X jako cel ma ×3,0 zamiast ×4,4, a YouTube ×2,2 zamiast ×4,1 (mediany po zestawach). Przedziały ufności mają około ±0,013–0,032 MAE na TikToku, YouTube i X, ±0,04 na Instagramie i ±0,07 na Facebooku, więc różnice między zestawami poniżej około ×1,1–×1,2 na Facebooku i Instagramie mieszczą się w szumie.

Trzy przedziały zamiast liczby. Ten test jest w całości poza platformą, także dla TikToka, YouTube i X, więc model jest tu inny niż na Rys. 2. Dzielimy wyświetlenia na trzy przedziały: poniżej 1 000, 1 000–10 000 i powyżej 10 000 (Rys. 3). Trafność (*accuracy*) wynosi 78–81%, ale przedziały mają bardzo różną liczebność, więc ważniejsza jest zrównoważona trafność (*balanced accuracy*, średnia czułość, *recall*, po przedziałach): 78% na TikToku, 76% na Facebooku, 70% na YouTube i 65% na Instagramie, wobec 33% przy zgadywaniu; macro

Tabela 3: Typowy błąd (×) regresji na lajkach i komentarzach przy różnych platformach treningowych.
Ridge na log lajków i komentarzy, posty z platform treningowych połączone w jeden zbiór. Wiersz: platformy w treningu (TT TikTok, YT YouTube, X, FB Facebook, IG Instagram): pojedyncze, X + YouTube (zestaw główny), TikTok + YouTube + X i wszystkie z czterema platformami; pełna tabela 30 zestawów jest w repozytorium. Kolumna: platforma testowa, której nie było w treningu. Pierwszy wiersz: ten sam ridge uczony na platformie testowej (walidacja po markach), a nie CatBoost z Rys. 2. Pogrubione: najlepszy wynik w kolumnie wśród pokazanych. Ciemniej: większy błąd.

Trening na	TikTok	YouTube	X	Facebook	Instagram
ridge, ta sama platforma	2,0	4,1	3,3	2,4	2,4
YT	**2,0**	trening	4,6	2,7	2,6
FB	2,3	4,3	**3,6**	trening	**2,5**
IG	2,5	4,5	4,1	2,5	trening
TT	trening	**4,1**	4,1	2,6	2,6
X	3,4	5,5	trening	3,1	2,7
YT + X	2,1	trening	trening	**2,4**	2,7
TT + YT + X	trening	trening	trening	2,5	2,7
YT + X + FB + IG	2,1	trening	trening	trening	trening
TT + YT + X + IG	trening	trening	trening	2,5	trening
TT + YT + X + FB	trening	trening	trening	trening	2,7
TT + X + FB + IG	trening	4,1	trening	trening	trening
TT + YT + FB + IG	trening	trening	4,4	trening	trening

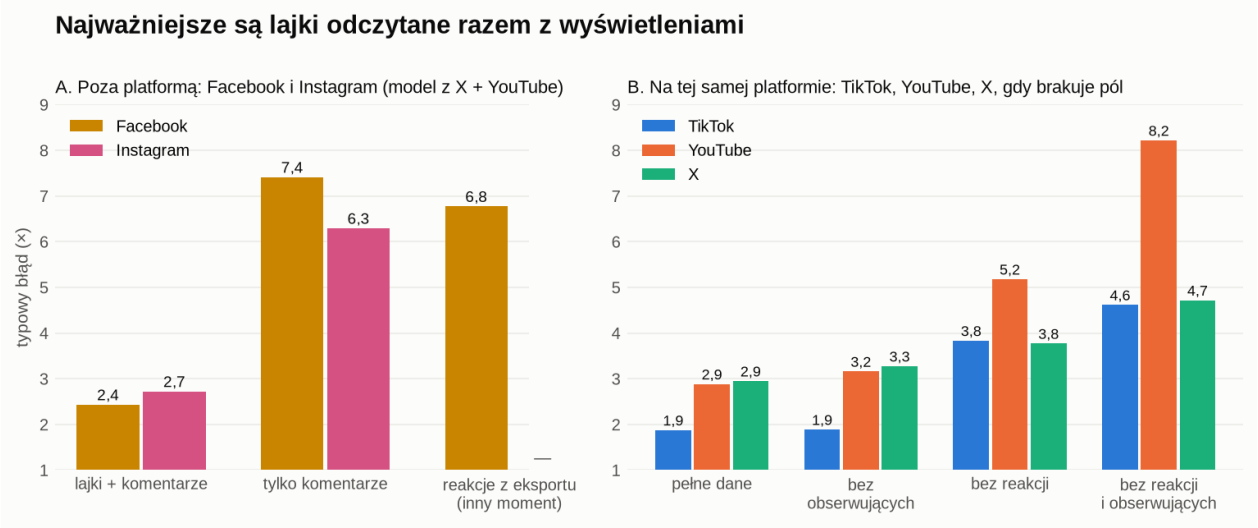
F1 0,70–0,78. O dwa przedziały mylimy się w 0,2–1,9% postów. Najsłabszy jest zwykle środkowy przedział (recall 50–73%), na Instagramie górny (49%). Na X model praktycznie nie działa: trafność 96% bierze się stąd, że 95% postów ma poniżej tysiąca wyświetleń, a zrównoważona trafność to tylko 46% (z 98 postów powyżej tysiąca trafia 23). Widzimy dwa powody: 62% postów na X nie ma lajka (usunięcie ich z danych treningowych zmniejsza błąd na X o 0,08), a wyświetlenia w eksporcie X są odczytane wcześnie, około dwukrotnie niżej niż w naszym ponownym odczycie.



Rysunek 3: Oszacowanie poza platformą pocięte na trzy przedziały wyświetleń.
Dla każdej platformy ridge na lajkach i komentarzach uczony na pozostałych czterech. Wiersz: prawdziwy przedział; kolumna: oszacowany; w komórce udział w wierszu i liczba postów; przekątna (pogrubiona) to recall przedziału. Nad tabelą: accuracy, balanced accuracy (średni recall), macro F1; szare: wartości przy zgadywaniu zawsze najczęstszego przedziału.

Czego model potrzebuje. Przeniesienie działa tylko z lajkami odczytanymi w tej samej chwili co wyświetlenia (Rys. 4A). Same komentarze dają ×6,3–×7,4, a lajki i komentarze z eksportu, odczytane w innym momencie niż wyświetlenia, ×6,8. Na tej samej platformie (Rys. 4B) brak obserwujących prawie nie szkodzi, a brak reakcji podnosi błąd do ×3,8–×5,2. Dlatego dla każdego układu dostępnych pól uczymy osobny model z osobnym przedziałem.

Świeże dane źródłowe. Gdy ten sam model uczymy na X i YouTube odczytanych ponownie, razem z reakcjami z tej samej chwili, błąd na Instagramie spada z ×2,72 do ×2,41 (przypadkiem tyle samo, co ridge uczony na samym Instagramie), a na Facebooku zostaje ×2,44. Niedoszacowanie dużych postów i sum dla marek zmniejsza się mniej więcej o połowę. Samo przesunięcie wyświetleń z eksportu do późniejszego wieku tego nie daje, więc ważne jest, żeby wyświetlenia i reakcje pochodziły z tego samego momentu. Ten wariant nie zastępuje wyniku głównego, bo zysk na Instagramie sprawdziliśmy już po obejrzeniu części rolek.



Rysunek 4: Typowy błąd przy różnych danych wejściowych.
A (poza platformą): Facebook i Instagram, ridge uczony na X i YouTube. „Lajki + komentarze": pola odczytane razem z wyświetleniami; „tylko komentarze": model na samych komentarzach; „reakcje z eksportu": lajki i komentarze z eksportu Brand24, odczytane w innym momencie niż wyświetlenia (dla Instagramu brak tych danych). B (na tej samej platformie): TikTok, YouTube, X, osobny CatBoost dla każdego układu dostępnych pól, walidacja po markach.

Szósta platforma. Pobraliśmy przez publiczne API 538 pytań z serwisów Stack Exchange (m.in. Stack Overflow, Super User, Android) o 48 markach z naszych danych, z kwietnia–sierpnia 2026. Głos za traktujemy jak lajk, a odpowiedzi i komentarze jak komentarze; to przypisanie ustaliliśmy przed oceną. Przenosi się kolejność, ale nie poziom: model z X i YouTube myli się ×3,14, gorzej niż stała mediana z samego Stack Exchange (×1,96) i niż mediana z X i YouTube (×2,10), bo 96% pytań jest niedoszacowanych (wyświetlenia pytań zbierają się miesiącami, a głos to nie lajk). Kolejność pytań zachowuje tak samo jak ridge uczony na Stack Exchange (Spearman 0,57 w obu przypadkach). Wyświetlenia pytań mają mały rozrzut (odchylenie standardowe 0,40 wobec 1,21 na Facebooku), więc nawet ridge uczony na Stack Exchange (×1,77) jest tylko o 15% lepszy od mediany. Stosunek wyświetleń do reakcji przenosi się więc między serwisami z filmami, a na serwis z pytaniami tylko kolejność.

6 Porównanie metod

Rodziny modeli. Tabela 4 porównuje modele na tej samej platformie, na tych samych danych wejściowych. Po dostrojeniu prawie wszystkie rodziny dają ten sam błąd. TabPFN v2 [9] wyprzedza CatBoost o 0,004–0,009, mniej niż przedział ufności (±0,012–0,021), a liczy się około 150 razy dłużej. Stos wszystkich rodzin (model drugiego poziomu ważący ich oszacowania) poprawia wynik o 0,012–0,029, na YouTube i X więcej niż szum. Zostajemy jednak przy jednym modelu: zysk to ×1,03–×1,07 wobec typowego błędu ×1,9–×3,0, stos wymaga utrzymania kilkunastu modeli, a przedziały CQR i przeniesienie budujemy na jednym modelu, przy czym poza platformą i tak wygrywa model liniowy.

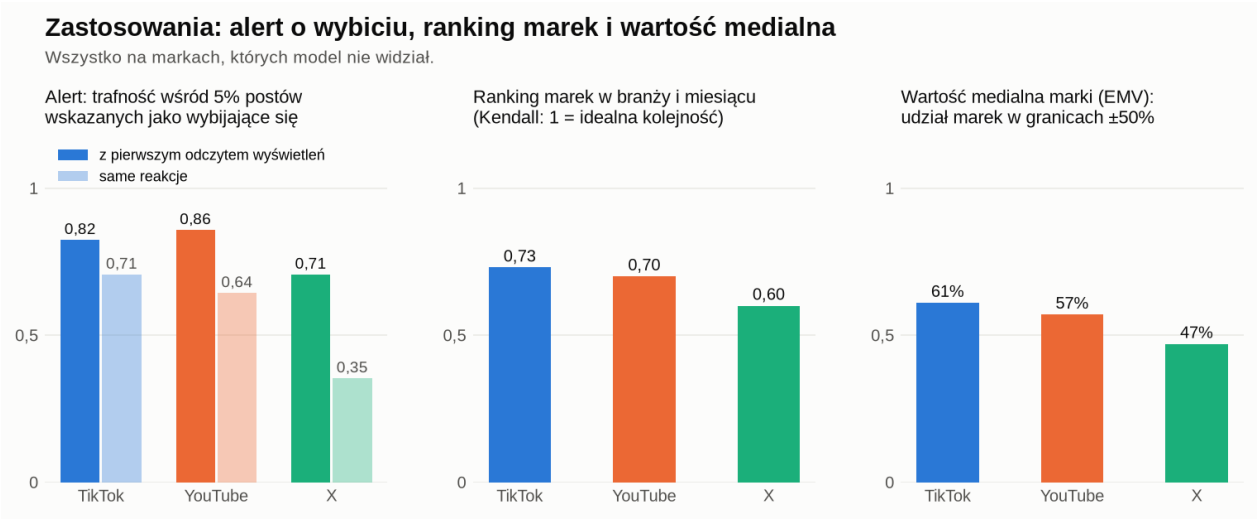
Dodatkowe dane i cechy. Sprawdziliśmy ponad dwadzieścia dodatkowych źródeł sygnału: tekst (od TF-IDF po osadzenia zdań e5 [12] i słownik sentymentu VADER [13]), etykiety typu i sentymentu z modelu językowego, grafy autorów i marek (GraphSAGE [14], metapath2vec [15]), dane o markach z Wikipedii i Wikidata, syntetyczne duże posty (SMOTER/SMOGN [16]), reprezentacje uczone bez etykiet (SCARF [17]) i pseudo-etykiety. Żadne nie poprawia błędu o więcej niż ×1,04, większość mniej niż ×1,02, a niektóre pogarszają go do ×1,06. Na Facebooku tekst pogarsza przeniesienie (MAE 0,385 → 0,436).

Historia autora. Ten sam autor ma podobną nadwyżkę wyświetleń (prawda minus oszacowanie) w kolejnych postach: korelacja między pierwszym a późniejszymi postami wynosi 0,68–0,70. Dodanie do oszacowania średniej nadwyżki wcześniejszych postów autora, ściągniętej do zera przy małej liczbie postów, zmniejsza błąd na tych postach ×1,3–×1,4. To jednak inne zadanie, bo wymaga znanych wyświetleń autora na tej samej platformie, a taka historia jest tylko dla 3–16% postów (w średnim błędzie ≤0,003). Ten sam autor na innej platformie występuje w 0,67% postów.

Tabela 4: Na tej samej platformie: rodziny modeli, MAE w skali $\log_{10}$ i typowy błąd (×).
Obserwujący, reakcje i flagi braków, walidacja po markach, strojenie zagnieżdżone (40 ustawień na fałd). TabPFN, TabICL, GraphSAGE, transformer i zespoły z osobnych przebiegów na tych samych danych. 95% CI dla CatBoost: ±0,012 / ±0,021 / ±0,021, więc różnice poniżej około 0,01 są w granicach szumu. *: podział bez wspólnych marek, autorów i tekstów.

Model	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	0,663 (×4,60)	0,944 (×8,79)	0,667 (×4,65)
stały mnożnik liczby obserwujących	0,919 (×8,30)	0,855 (×7,16)	0,879 (×7,57)
stały mnożnik lajków*	0,348 (×2,23)	0,609 (×4,06)	0,560 (×3,63)
Modele liniowe i jądrowe			
regresja liniowa (ridge)	0,277 (×1,89)	0,545 (×3,51)	0,487 (×3,07)
k najbliższych sąsiadów (kNN)	0,283 (×1,92)	0,483 (×3,04)	0,490 (×3,09)
SVR z jądrem RBF	0,271 (×1,87)	0,463 (×2,90)	0,480 (×3,02)
Drzewa decyzyjne			
las losowy (random forest)	0,275 (×1,88)	0,463 (×2,90)	0,473 (×2,97)
extra trees	0,275 (×1,88)	0,459 (×2,88)	0,475 (×2,99)
gradient boosting (scikit-learn)	0,276 (×1,89)	0,453 (×2,84)	0,474 (×2,98)
LightGBM [8]	0,275 (×1,88)	0,457 (×2,86)	0,475 (×2,99)
XGBoost [10]	0,273 (×1,87)	0,450 (×2,82)	0,467 (×2,93)
CatBoost (model końcowy)	0,272 (×1,87)	0,452 (×2,83)	0,470 (×2,95)
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	0,276 (×1,89)	0,454 (×2,84)	0,477 (×3,00)
GraphSAGE [14] (graf podobnych tekstów)	0,279 (×1,90)	0,467 (×2,93)	0,474 (×2,98)
dostrojony transformer (wiersz jako tekst)	0,289 (×1,95)	0,454 (×2,84)	0,490 (×3,09)
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	0,268 (×1,85)	0,443 (×2,77)	0,465 (×2,92)
TabICL [11]	0,272 (×1,87)	0,445 (×2,79)	0,466 (×2,92)
Zespoły modeli (dla porównania)			
średnia 3 najlepszych rodzin	0,270 (×1,86)	0,446 (×2,79)	0,469 (×2,94)
stos wszystkich rodzin	0,260 (×1,82)	0,425 (×2,66)	0,441 (×2,76)

7 Zastosowania



Rysunek 5: Zastosowania oszacowania na TikToku, YouTube i X (na tej samej platformie).
Alert: z pierwszego, wczesnego odczytu wyświetleń i reakcji model wskazuje 5% postów, które skończą w górnych 5% wyświetleń; słupek to odsetek trafnych wskazań (289–336 postów na platformę, jeden miesiąc). Ranking: średni współczynnik korelacji rang Kendalla między oszacowaną a prawdziwą kolejnością marek w parach branża–miesiąc (52 / 51 / 42 par). EMV (*earned media value*): wyświetlenia przeliczone na pieniądze stałą stawką 5 USD za tysiąc wyświetleń; odsetek marek, dla których oszacowane EMV mieści się w ±50% prawdziwego (238 / 213 / 189 marek).

Alert o wybiciu. Z pierwszego odczytu model wskazuje 5% postów, które skończą w górnych 5% wyświetleń, z trafnością 0,82 / 0,86 / 0,71; ten sam alert z samych reakcji, bez modelu, daje 0,71 / 0,64 / 0,35

(Rys. 5).

Ranking marek. Sumując oszacowane wyświetlenia marek w branży i miesiącu, odtwarzamy ich kolejność (Kendall 0,73 / 0,70 / 0,60).

Wartość medialna. EMV marki liczone z oszacowanych wyświetleń mieści się w ±50% prawdziwego dla 61% / 57% / 47% marek. Stawka tylko skaluje wynik, więc odsetki od niej nie zależą.

Posty odstające. Na TikToku posty z dużo większą liczbą wyświetleń niż wynika z reakcji to częściej promocja (51% wobec 34%), a z dużo mniejszą częściej spam (26% wobec 13%; typ wzmianki z etykiet modelu językowego). **TODO:** dobić do pełnej strony: np. krzywa trafności alertu od liczby alertów, przykład rankingu jednej branży, wzmianki nie o marce (E224).

8 Ograniczenia i rekomendacje

Mało marek. Wynik dla Facebooka opiera się na 20 markach, a dla Instagramu na 11; trzy największe marki to 39% i 44% postów, a bez nich błąd rośnie do ×2,89 i ×2,96. Błąd pojedynczej marki waha się od ×1,5 do ×6,2 na Facebooku i od ×2,2 do ×4,3 na Instagramie. Przy tak małej liczbie marek przedziały ufności z bootstrapu po markach mogą być za wąskie.

Wybór postów. Mierzymy tylko filmy i rolki, które były jeszcze dostępne. Na Instagramie odpadły też rolki z ukrytymi lajkami, czyli dokładnie te, dla których szacunek byłby w praktyce najbardziej potrzebny; tam model musiałby opierać się na samych komentarzach (×6,3).

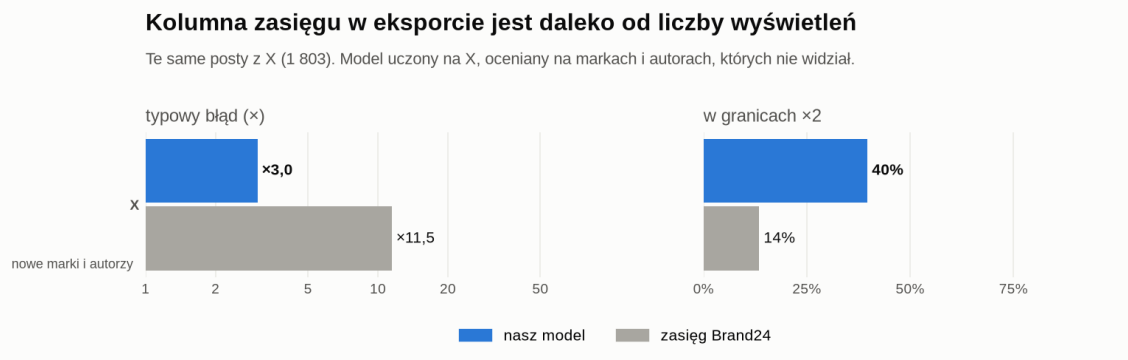
Wiek odczytu. Wyświetlenia w eksporcie X i YouTube odczytano w medianie po 23 dniach od publikacji, a nasze odczyty z Facebooka i Instagramu po 310 i 334 dniach. Zgodność na Facebooku może więc częściowo wynikać ze znoszenia się dwóch efektów: gdy przesuniemy same wyświetlenia źródłowe do późniejszego wieku, błąd na Facebooku rośnie o 0,10 (×3,05), a dopiero przesunięcie wyświetleń razem z reakcjami przywraca ×2,44.

Wzmianki nie o marce. Brand24 dopasowuje wzmianki po słowach kluczowych. W 6,7% wzmianek nazwy marki w ogóle nie ma w tekście, a według osobnych etykiet tematu z modelu językowego (niesprawdzonych jeszcze przez człowieka) marka nie jest głównym tematem w około 64% wzmianek. Nie zmienia to błędu oszacowania wyświetleń posta, ale sumy marek zawierają przez to także posty o czymś innym, a podział walidacji po markach jest mniej czysty.

Inne. Na tej samej platformie najpopularniejszy 1% postów na YouTube i X jest zaniżany ×9–×14, więc sumy marek mylą się o więcej niż ×2 dla 29–47% marek. Prawie każdy post ma innego autora (2 411 autorów na 2 491 postów na TikToku, 2 041 na 2 441 na YouTube, 1 658 na 1 803 na X), więc historii autora nie da się użyć dla większości postów. Wyniki opisują zależności, nie przyczyny. Kod, liczby i karty wszystkich eksperymentów są w repozytorium projektu.

Rekomendacje. Dostawcy monitoringu rekomendujemy: odczytywać reakcje razem z wyświetleniami, zapisywać braki jako brak, a nie zero, robić drugi odczyt wyświetleń i przechowywać historię autorów. Rys. 6 pokazuje, co daje to dziś: kolumna zasięgu w eksporcie, czytana przez klientów jako liczba odbiorców, jest dalej od wyświetleń niż nasze oszacowanie.

Użycie AI i odtwarzalność. **TODO:** do napisania przez zespół własnymi słowami. Fakty do ujęcia: agenci AI (Claude Code, DeepSeek) pisali kod analiz i odczytu danych, uruchamiali eksperymenty, robili wykresy i szkic tekstu; modele językowe oznaczyły typ i sentyment wzmianek; logi sesji agentów są w `logs/`. Każdy wynik ma kartę eksperymentu, wiersz w rejestrze (`docs/pl/experiments.md`), skrypt w `src/` i liczby w `data/processed/`.



Rysunek 6: Nasze oszacowanie a kolumna zasięgu w eksporcie Brand24, na tych samych 1 803 postach z X. Zasięg to inna miara niż wyświetlenia, więc rysunek pokazuje, jak daleko od wyświetleń jest liczba, którą klient dostaje dziś, a nie porównanie dwóch modeli. Model uczony na X, oceniany na nowych markach i autorach (których nie widział w treningu); prawda z eksportu.

Literatura

[1] A. Tatar, M. D. de Amorim, S. Fdida, P. Antoniadis. A survey on predicting the popularity of web content. *Journal of Internet Services and Applications*, 5:8, 2014.

[2] B. Shulman, A. Sharma, D. Cosley. Predictability of popularity: gaps between prediction and understanding. *ICWSM*, 2016.

[3] S. D. Roy, T. Mei, W. Zeng, S. Li. Towards cross-domain learning for social video popularity prediction. *IEEE Transactions on Multimedia*, 15(6), 2013.

[4] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan. A theory of learning from different domains. *Machine Learning*, 79, 2010.

[5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, A. Gulin. CatBoost: unbiased boosting with categorical features. *NeurIPS*, 2018.

[6] A. E. Hoerl, R. W. Kennard. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 1970.

[7] Y. Romano, E. Patterson, E. Candès. Conformalized quantile regression. *NeurIPS*, 2019.

[8] G. Ke i in. LightGBM: a highly efficient gradient boosting decision tree. *NeurIPS*, 2017.

[9] N. Hollmann i in. Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 2025.

[10] T. Chen, C. Guestrin. XGBoost: a scalable tree boosting system. *KDD*, 2016.

[11] J. Qu, D. Holzmüller, G. Varoquaux, M. Le Morvan. TabICL: a tabular foundation model for in-context learning on large data. *ICML*, 2025.

[12] L. Wang i in. Text embeddings by weakly-supervised contrastive pre-training. arXiv:2212.03533, 2022.

[13] C. J. Hutto, E. Gilbert. VADER: a parsimonious rule-based model for sentiment analysis of social media text. *ICWSM*, 2014.

[14] W. L. Hamilton, R. Ying, J. Leskovec. Inductive representation learning on large graphs. *NeurIPS*, 2017.

[15] Y. Dong, N. V. Chawla, A. Swami. metapath2vec: scalable representation learning for heterogeneous networks. *KDD*, 2017.

[16] P. Branco, L. Torgo, R. P. Ribeiro. SMOGN: a pre-processing approach for imbalanced regression. *LIDTA*, PMLR 74, 2017.

[17] D. Bahri, H. Jiang, Y. Tay, D. Metzler. SCARF: self-supervised contrastive learning using random feature corruption. *ICLR*, 2022.