Szacowanie widoczności postów społecznościowych

Przeniesienie modelu między platformami

Malwina Juchiewicz, Jędrzej Kocięcki, Mikołaj Olesiński

Politechnika Wrocławska

Czy wyświetlenia FB i IG da się oszacować z lajków?

Czy da się oszacować wyświetlenia filmów i rolek z lajków i komentarzy, gdy platforma ich nie pokazuje?

Problem

TikTok, YouTube, X: wyświetlenia są w eksporcie. Facebook, Instagram: nie widać ich.

Pytanie

Czy model, który nigdy nie widział wyświetleń z FB i IG, oszacuje je z lajków i komentarzy?

Odpowiedź w skrócie

Tak: typowy błąd ok. $\times 2{,}4$ (FB) i $\times 2{,}7$ (IG); wystarcza prosty stosunek wyświetleń do lajków.

Trzy platformy mają wyświetlenia, FB i IG tylko od nas

Platforma	Marki	Posty z wyśw.	Źródło wyśw.	Wyśw./lajk
TikTok	266	2 491	eksport	25
YouTube	273	2 441	eksport	26
X	252	1 803	eksport	22
Facebook	**20**	**402**	**nasz odczyt, filmy**	**35**
Instagram	**11**	**642**	**nasz odczyt, rolki**	**53**

Razem 348 marek, 5 platform. Pogrubione wiersze to cel: odczyt tylko do oceny.

Eksport: 12 500 wzmianek, 2 500 na platformę; Stack Exchange (538 pytań, 48 marek) tylko jako test. Braki w eksporcie: dalej.

Wyświetlenia FB i IG odczytaliśmy sami, razem z reakcjami

Źródło	Co dodaliśmy	Posty
Facebook	wyświetlenia filmów	402
Instagram	wyświetlenia rolek	642
X, YouTube, TikTok	ponowny odczyt wyśw. i reakcji	2 013 / 1 376 / 426
Stack Exchange	pytania z publicznego API	538

Protokół

- wyświetlenia i reakcje FB/IG odczytane razem, w tej samej chwili
- FB/IG tylko do oceny, nigdy w treningu
- X + YT wybrane przed oceną FB/IG

Uwaga: odczyt FB/IG niezweryfikowany niezależnie. Usunięte posty i inne zestawy treningowe: zapas.

W eksporcie Brand24 brakuje najczęściej wyświetleń FB i IG

Puste wartości	TikTok	YouTube	X	Facebook	Instagram
`view_count`	0%	1%	**25%**	**100%**	**100%**
`shares`	0%	**41%**	0%	0%	**100%**
`comments`	0%	9%	**69%**	0%	0%
`author_name`, `author_followers`	0%	0%	0%	**27%**	**92%**
`country`	4%	19%	**81%**	**79%**	**81%**
`sentiment`	11%	11%	9%	**90%**	**90%**
`likes` = 0	4%	**26%**	**70%**	**30%**	**46%**

12 500 wzmianek, 2 500 na platformę, 19 kolumn; pomarańczowe: braki $\geq$ 25%.

Pozostałe kolumny (m.in. `url`, `content`, `likes`, `b24_estimated_reach`) bez braków lub poniżej 25%. `likes` = 0: lajk wpisany jako zero (na X często brak, a nie prawdziwe zero).

Dane z tekstu i z zewnątrz nie poprawiły błędu o więcej niż $\times 1{,}04$

Wyprowadzone z tekstu i metadanych

- typ wzmianki i sentyment z modelu językowego (etykiety AI): zgodność 3 przebiegów κ 0,77–0,79 (typ), 0,71–0,73 (sentyment); brak ludzkiego wzorca
- czy wzmianka jest o marce: 6,7% bez nazwy marki w tekście
- tekst: TF-IDF, osadzenia zdań e5, statystyki tekstu, sentyment VADER
- grafy: podobieństwo tekstów (GraphSAGE), autor–marka–hashtag (metapath2vec)

Próbowaliśmy dociągnąć z zewnątrz

- Wikipedia (zainteresowanie marką), Wikidata (dane o firmie), szum wokół marki w strumieniu, kalendarz, wielkość marki
- ponowne odczyty wyświetleń i reakcji (X, YouTube, TikTok), brakujące lajki YouTube
- konta tych samych autorów na innych platformach: za mało dopasowań (5–17 postów, potrzeba 40)
- TikTok Research API: wymaga wniosku akademickiego, nie użyte

Żadne dodatkowe źródło nie poprawia błędu o więcej niż $\times 1{,}04$.

Mnożnik lajków to punkt odniesienia dla modeli

Mnożnik lajków

wyświetlenia $= k\times$ lajki; jeden parametr, bez modelu. Punkt odniesienia.

TT / YT / X: CatBoost

8 pól (obserwujący, lajki, komentarze, udostępnienia + flagi braków). Górna granica, nie wynik dla FB/IG.

FB / IG: ridge

2 pola: lajki i komentarze, uczone tylko na X + YT. Test: nasz odczyt FB/IG.

Cel: $\log_{10}$(wyświetlenia). Dodatkowy test: Stack Exchange. Bez tekstu, etykiet AI, kraju i czasu (nie poprawiały wyniku).

Typowy błąd $\times 2$ znaczy: oszacowanie w granicach połowy i dwukrotności

Typowy błąd $\times 10^{\mathrm{MAE}}$

MAE = średnia $|\log_{10}(\text{oszacowanie}) - \log_{10}(\text{prawda})|$.

Przykład: $\times 2$, czyli post z 1 000 wyświetleń oszacowany między 500 a 2 000.

Mnożnik lajków k

Wyświetlenia = $k\times$ lajki. k tylko z platform treningowych, nigdy z celu.

Przykład: $k \approx 25$ (X + YT); 40 lajków $\rightarrow$ 1 000 wyświetleń.

W platformie model bije mnożnik, dzięki dodatkowym polom

	CatBoost	Ridge (2 pola)	Mnożnik lajków
TikTok	$\times$**1,87**	$\times$1,99	$\times$2,23
YouTube	$\times$**2,90**	$\times$4,15	$\times$4,06
X	$\times$**3,03**	$\times$3,30	$\times$3,63

Zysk pochodzi z obserwujących, udostępnień i flag braków, nie z typu modelu.

Uwaga

CatBoost to górna granica dla FB/IG: tam tych pól nie ma.

Typowy błąd, walidacja po markach i autorach. Przedziały ufności i udział w granicach $\times$2: zapas.

Poza platformą wystarcza stosunek wyświetleń do lajków

	Ridge X+YT	Mnożnik	W gr. ×2	Przedział
Facebook (20 marek)	×**2,43**	×2,42	53%	×2,08–×2,99
Instagram (11 marek)	×**2,72**	×2,94	40%	×2,48–×3,03

Co się przenosi

Stosunek wyświetleń do lajków z X + YT. Jeden parametr jest prawie tak dobry jak ridge; stała mediana myli się ×9–×20.

Uwaga

Tylko 20 i 11 marek, wynik kruchy; IG: 72% rolek niedoszacowanych.

Przedział: bootstrap po markach. Wiek odczytu i odczyt w podobnym wieku: zapas.

Poza platformą złożone modele i augmentacja nie biją ridge

Metoda (typowy błąd)	Facebook	Instagram
Proste reguły		
mediana z X + YT	×19,87	×8,69
mnożnik lajków	×2,42	×2,94
Modele (trening X + YouTube)		
regresja ridge (nasz)	**×2,43**	**×2,72**
MLP	×2,47	×2,78
CatBoost	×2,61	×2,95
augmentacja (trend, propensity, mixup; CatBoost i MLP)	×2,42–×2,58	×2,75–×2,96
więcej pól: + udostępnienia (FB), + obserwujący (IG)	×2,44–×2,97	×2,66–×4,58
Odniesienie (używa etykiet platformy docelowej)		
ridge uczony na samej platformie (CV po markach)	×2,42	×2,41

Modele: lajki + komentarze, trening tylko X + YT. Z TikTokiem w treningu: FB ×2,49, IG ×2,69. Więcej pól (do 8, braki uzupełnione lub usunięte) przy przenoszeniu między TT/YT/X: TikTok zawsze gorzej, YT i X lepiej o ×1,05–×1,17; brak stałego zysku.

Wybór platform treningowych mało zmienia wynik FB i IG

Trening na	TikTok	YouTube	X	Facebook	Instagram	Stack Exchange
ridge, ta sama platforma	1,99	4,15	3,30	2,42	2,41	1,77
YT	**2,00**	trening	4,64	2,72	2,63	1,87
FB	2,30	4,26	**3,60**	trening	**2,47**	3,32
IG	2,46	4,50	4,06	2,48	trening	2,46
TT	trening	**4,07**	4,15	2,61	2,59	2,41
X	3,38	5,52	trening	3,07	2,74	4,50
X + YT	2,05	trening	trening	**2,43**	2,72	3,14
TT + YT + X	trening	trening	trening	2,49	2,69	3,08
YT + X + FB + IG	2,12	trening	trening	trening	trening	3,25
TT + YT + X + IG	trening	trening	trening	2,46	trening	3,07
TT + YT + X + FB	trening	trening	trening	trening	2,66	3,08
TT + X + FB + IG	trening	4,08	trening	trening	trening	4,24
TT + YT + FB + IG	trening	trening	4,37	trening	trening	2,11

Ridge na 2 polach (lajki, komentarze), walidacja po markach. Typowy błąd (×); szare = trening. Mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65. Stack Exchange nigdy w treningu; każdy zestaw z X daje tam ×3–×5.

Ridge jest lepszy lub równy mnożnikowi lajków; gorszy tylko na X

		typowy błąd		w granicach ×2	
Cel	Trening na	ridge	mnożnik	ridge / mnożnik	Kto lepszy
TikTok	X + YT	×**2,05**	×2,22	57% / 52%	ridge, o 8%
YouTube	TT + X	×4,09	×**4,02**	39% / 38%	remis
X	TT + YT	×4,47	×**3,42**	27% / 37%	mnożnik, o 23%
Facebook	X + YT	×2,43	×2,42	53% / 54%	remis
Instagram	X + YT	×**2,72**	×2,94	40% / 38%	ridge, o 8%
Stack Exchange	X + YT	×**3,14**	×5,33	28% / 7%	ridge, o 41%

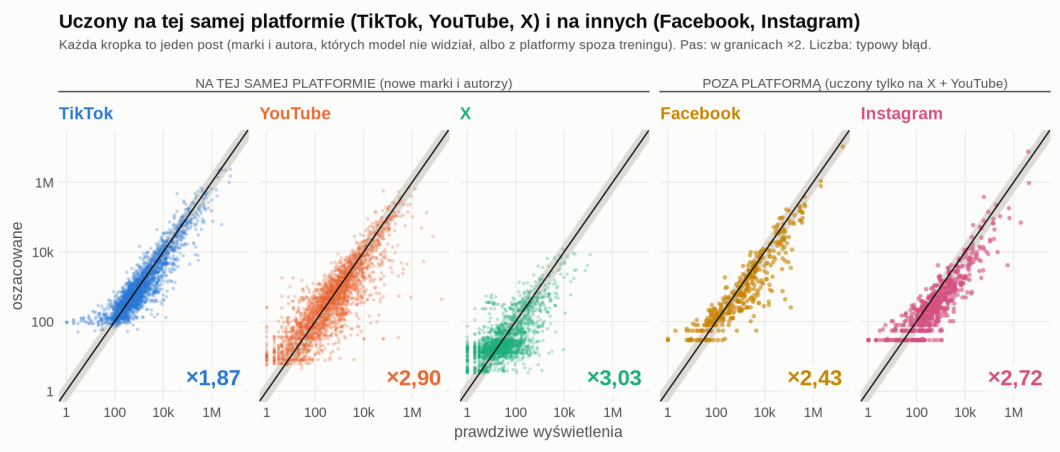
„o 8%" = typowy błąd mniejszy o 8% (np. ×2,22 → ×2,05). Na X 61% postów nie ma liczby komentarzy (wpisujemy 0), a ridge uczony na TT i YT traktuje to jak zero komentarzy; ridge bez komentarzy (lajki + obserwujący) ma tam ×3,82. Na Stack Exchange oba przegrywają ze zwykłą medianą (×2,10); własny ridge SE ×1,77; to pytania i odpowiedzi, nie wideo.

Kiedy który model? Poza platformą wygrywa najprostszy

Sytuacja	Co użyć	Typowy błąd	Dlaczego
Ta sama platforma, mamy wyświetlenia do uczenia (TT, YT, X)	CatBoost na 8 polach	$\times$**1,87** / $\times$**2,90** / $\times$**3,03** (mnożnik $\times$2,23 / $\times$4,06 / $\times$3,63)	korzysta z obserwujących, udostępnień i flag braków
Platforma bez wyświetleń (FB, IG)	ridge na lajkach i komentarzach z X + YT	FB $\times$**2,43**, IG $\times$**2,72**	działa też przy 0 lub ukrytych lajkach (komentarze); na IG lepszy od mnożnika ($\times$2,94)
Prawdziwe wyświetlenia z nowej platformy	ridge uczony na niej	IG $\times$2,40 (z obserwującymi IG $\times$2,23)	obserwujący pomagają tylko w obrębie tej platformy (z X + YT: $\times$4,58)
Pytania i odpowiedzi, nie wideo (Stack Exchange)	nie przenosić	stała mediana $\times$2,10 (ridge $\times$3,14)	stała mediana lepsza od ridge

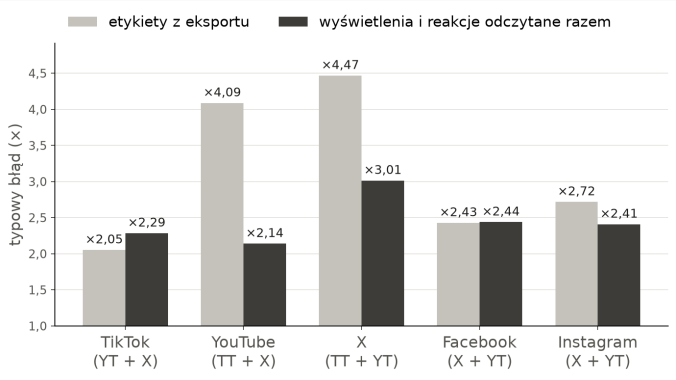
CatBoost przeniesiony z X + YT: FB $\times$2,61, IG $\times$2,95, gorzej niż ridge. CatBoost wygrywa tylko w platformie; poza nią wygrywa najprostszy model.

Oszacowania FB i IG podążają za prawdziwymi wyświetleniami



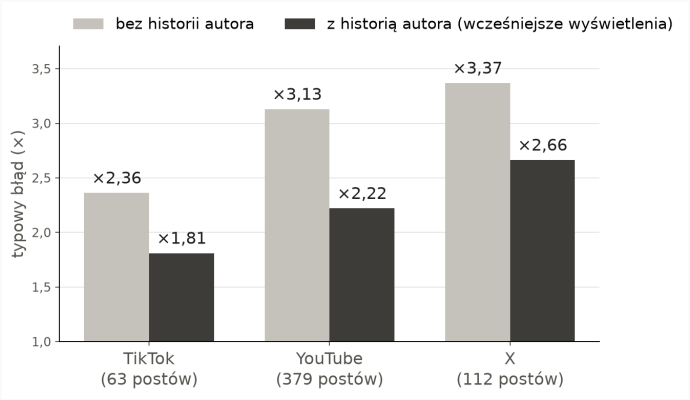
Kropka = post; szary pas = w granicach ×2. IG: 72% rolek niedoszacowanych.

Odczyt reakcji razem z wyświetleniami zmniejsza błąd (poza TikTokiem)



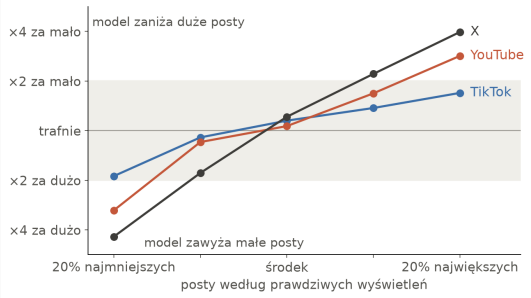
Ten sam model (ridge na lajkach i komentarzach), zmienia się tylko moment odczytu. TikTok: odczytaliśmy tylko 426 postów; na tych samych postach eksport daje $\times 2{,}08$, odczyt $\times 2{,}29$. Eksport TikToka był świeży (wyświetlenia $\times 1{,}09$), YouTube i X przestarzałe ($\times 1{,}35$ i $\times 2$).

Historia autora pomaga tylko tam, gdzie istnieje



Typowy błąd bez i z historią autora (jego wcześniejsze posty), TT, YT, X. Pomaga tylko tam, gdzie historia istnieje (3–16% postów).

Mało reakcji, duży błąd; model ściąga oszacowania do środka



Typowy błąd wg liczby reakcji

	TT	YT	X
0 reakcji	×3,23 3%	×4,59 27%	×3,19 54%
6–100 reak.	×1,75 53%	×2,45 32%	×2,57 9%
wszystkie	×1,87	×2,90	×3,03
bez ≤5 reak.	**×1,81** 83%	**×2,29** 54%	**×2,56** 10%

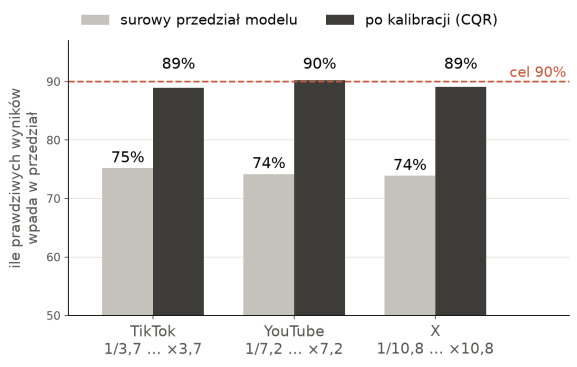
szare: udział postów

Na X 62% ocenianych postów bez lajka. Reakcje = lajki + komentarze + udostępnienia. Mało reakcji = za mało danych.

Walidacja po markach i autorach; kalibracja CQR; brak dryfu w czasie

- **CQR** to korekta dopasowująca szerokość przedziału na danych odłożonych: surowy przedział 90% trafia w 3 z 4 posty, po CQR w 9 z 10 (87–91%)
- **FB:** kalibracja na 25% marek FB, pokrycie 0,917, szerokość 1,83 $\log_{10}$; dla IG nie liczyliśmy
- **Podział:** foldy łączą posty tej samej marki, autora lub tekstu; stała mediana i mnożnik jako odniesienia
- **Czas:** trening na wcześniejszych miesiącach, test 2026-05...08 (MAE TT 0,270, YT 0,450, X 0,473); różnica względem walidacji $-0{,}001$ / $-0{,}011$ / $-0{,}026$: brak dryfu

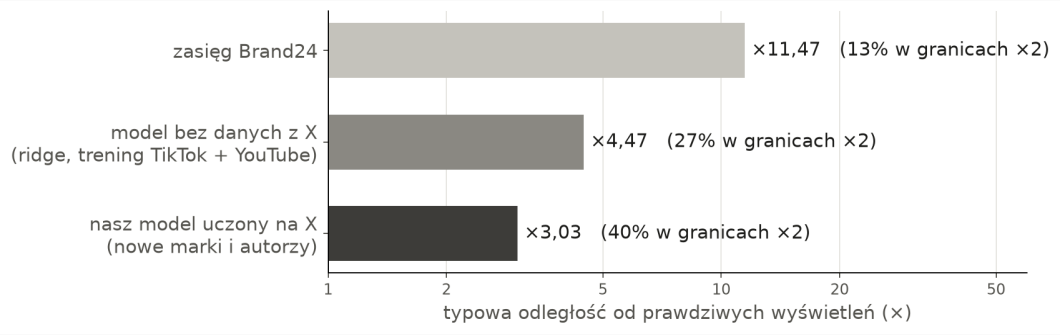
Po kalibracji przedział 90% obejmuje 9 na 10 postów, ale jest szeroki



Wniosek

Na X przedział od 1/11 do ×11 (szacunek 1 000 → ok. 90–11 000); na FB od ok. 1/8 do ×8.

Zasięg Brand24 to nie są wyświetlenia (X)



Te same 1 803 posty z X. Nawet model, który nigdy nie widział X (uczony na TikToku i YouTube), jest bliżej niż zasięg Brand24: $\times 4{,}47$ wobec $\times 11{,}47$.

Wirale i nagłe skoki małych kont widać w samych reakcjach

Wiral = post z top 10% wyświetleń swojej platformy, szukany bez wyświetleń: po lajkach i komentarzach.

	AUC	trafne w top 10%
TikTok	0,98	82%
YouTube	0,88	72%
X	0,86	57%
Facebook	0,94	68%
Instagram	0,98	84%

AUC: 0,5 = losowo, 1 = idealnie; losowo trafiłoby 10%. FB i IG: model z X + YT. Same lajki rankują równie dobrze.

Skok małego konta = post ma $\geq 30\times$ więcej wyświetleń, niż zwykle ma konto tej wielkości. Wykrywamy go z lajków na obserwującego.

	TT	YT	X
AUC	0,98	0,86	0,89
trafne w top 5% wyniku	78%	51%	36%

Przykład z TikToka

23 konta ($\sim$200 obserwujących) miały post $\geq 100\times$ ponad normę: zwykle ok. 600 wyświetleń, tu 185 tys. (9 tys. lajków). 96% w top 5% wyniku.

Norma = typowe wyświetlenia konta tej wielkości, nie jego historia (za mało wcześniejszych postów). **Odstający od modelu:** gdy mamy wyświetlenia (TT, YT, X), wystarczy porównać je z oszacowaniem; na TikToku nadwyżki to częściej promocja (51% wobec 34%), niedobory częściej spam (26% wobec 13%). Bez wyświetleń (FB, IG) nie da się go wskazać, bo oszacowanie pochodzi z reakcji (AUC 0,53–0,65).

Ranking marek w branży: dobry na TikToku i YouTube, na X bez przewagi

Pytanie klienta: która marka z branży miała w tym miesiącu najwięcej wyświetleń?

Jak liczymy. Dla pary branża $\times$ miesiąc sumujemy oszacowane wyświetlenia każdej marki i układamy marki w kolejność; to samo z prawdziwych wyświetleń. Porównujemy obie kolejności.

Miara (Kendall τ). Bierzemy każdą parę marek: czy model postawił ją w tej samej kolejności co prawda? τ = (pary zgodne − niezgodne) / wszystkie pary. 1 = ta sama kolejność, 0 = losowo, -1 = odwrócona.

Przykład obok: 6 marek to 15 par; 13 ustawionych dobrze, 2 źle $\Rightarrow \tau = (13-2)/15 = 0{,}73$. Wybraliśmy grupę o τ najbliższym średniej, nie najlepszą.

TikTok, finanse i ubezpieczenia, maj 2026

Marka	wyświetlenia (tys.)		miejsce	
	prawda	model	prawda	model
Travelers	898	594	1	1
U.S. Bank	59	51	2	3
Wells Fargo	38	152	3	2
Capital One	16	16	4	5
Barclays	13	21	5	4
Guardian Life	5	6	6	6

Cały zbiór, średni τ modelu: **0,73 / 0,70 / 0,60** (TT / YT / X), ok. 86% / 85% / 80% par w dobrej kolejności (grupy: 52 / 51 / 42; marki z $\geq$3 postami, grupy z $\geq$3 markami). Reguła Brand24 na X: τ 0,63, o włos lepiej, ale jej poziom jest $\times$11 za wysoki; na TT i YT jej zasięg to wyświetlenia, więc porównanie nie ma sensu.

Wzmianki spoza marki da się znaleźć, ale z wieloma fałszywymi alarmami

Problem. Brand24 przypisuje post do marki po słowie kluczowym. Czasem post jest o czymś zupełnie innym.

Co robimy. Grupujemy podobne teksty grafem z podziałem Louvain i patrzymy, czy post pasuje do reszty swojej marki. Robimy to bez wyświetleń.

Miara. AUC 0,68 (0,5 = losowo, 1 = idealnie): najpewniejsze flagi są trafne, ale poza nimi jest dużo fałszywych alarmów.

Udało się znaleźć, np.

- **Cricket Wireless:** wszystkie 20 wzmianek jest w jednej grupie z postami o krykiecie (sporcie)
- **AT&T:** wzmianki o stadionie AT&T, a nie o operatorze

Ograniczenia: mało marek i niezweryfikowany odczyt; co dalej

Ograniczenia

- prawda FB/IG = nasz odczyt publicznych stron, niezweryfikowany niezależnie
- usunięte posty (IG 27%, FB 14%), kierunek wpływu nieznany
- wiek odczytu: eksport 23 dni, FB/IG 310–334 dni
- mało marek: FB 20, IG 11
- tylko dostępne filmy i rolki
- etykiety AI bez ludzkiego wzorca (κ 0,71–0,79)
- wynik FB/IG z jednego zestawu treningowego (X + YT)
- na X ridge gorszy od mnożnika; na Stack Exchange przenoszenie zawodzi
- korelacja, nie przyczynowość

Co dalej

- niezależna weryfikacja odczytu FB/IG
- więcej marek na FB i IG
- zwykłe posty FB/IG, nie tylko filmy i rolki
- inne platformy (Reddit, LinkedIn)
- ludzka weryfikacja etykiet AI
- praktyczny przykład sumy marki na FB/IG

Wnioski: FB i IG da się oszacować z lajków

Trzy wnioski

1. Błąd ok. $\times 2{,}4$ (FB), $\times 2{,}7$ (IG); wystarcza stosunek wyświetleń do lajków z X + YT.
2. Zastrzeżenie: 20 i 11 marek, niezweryfikowany odczyt, odczyt po 310–334 dniach; nie uogólniać.
3. W tej samej platformie więcej pól pomaga ($\times 1{,}87$ vs $\times 2{,}23$ na TikToku); na Stack Exchange przenoszenie zawodzi.
4. Wybór modelu zależy od sytuacji (slajd „Kiedy który model?”): CatBoost tylko w platformie, poza nią ridge albo mnożnik.

Rekomendacja

Orientacyjnie: wyświetlenia $\approx 25\times$ lajki; IG zwykle zaniżony. Model z większą liczbą pól dodawaj dopiero przy danych tej samej platformy.

W platformie wszystkie rodziny modeli dają podobny błąd

Typowy błąd	TT	YT	X
Proste odniesienia			
mediana platformy	×4,60	×8,79	×4,65
mnożnik obserwujących	×8,30	×7,16	×7,57
mnożnik lajków	×2,23	×4,06	×3,63
Liniowe i jądrowe			
ridge	×1,89	×3,51	×3,07
kNN	×1,92	×3,04	×3,09
SVR (RBF)	×1,87	×2,90	×3,02
Drzewa decyzyjne			
las losowy	×1,88	×2,90	×2,97
extra trees	×1,88	×2,88	×2,99
gradient boosting	×1,89	×2,84	×2,98
LightGBM	×1,88	×2,86	×2,99
XGBoost	×1,87	×2,82	×2,93
CatBoost (końcowy)	×1,87	×2,83	×2,95

Typowy błąd	TT	YT	X
Sieci neuronowe			
MLP	×1,89	×2,84	×3,00
GraphSAGE	×1,90	×2,93	×2,98
dostrojony transformer	×1,95	×2,84	×3,09
Wstępnie wytrenowane dla tabel			
TabPFN v2	×1,85	×2,77	×2,92
TabICL	×1,87	×2,79	×2,92
Zespoły modeli			
średnia 3 najlepszych rodzin	×1,86	×2,79	×2,94
stos wszystkich rodzin	×1,82	×2,66	×2,76

Walidacja tylko po markach, 8 pól, strojenie zagnieżdżone; liczby nieco niższe niż w wynikach głównych (po markach i autorach). Stos nie jest modelem końcowym: zysk ×1,03–×1,07, kilkanaście modeli, TabPFN ok. 150× wolniejszy.

Protokół i usunięte posty

- Facebook: 402 z 470 postów (68 usuniętych)
- Instagram: 642 z 976 (261 usuniętych, 19 bez licznika, 54 z ukrytymi lajkami)
- FB/IG: wyświetlenia i reakcje odczytane razem; prawda = nasz odczyt publicznych stron, niezweryfikowany niezależnie
- historia autora: tylko wcześniejsze posty tego autora
- X + YT wybrane przed oceną FB/IG jako najbardziej podobne w reakcjach; inne zestawy: FB $\times$2,39–$\times$3,07, IG $\times$2,47–$\times$2,82 (wynik zależy od wyboru umiarkowanie)
- Eksport: 12 500 wzmianek, 2 500 na platformę; autorzy: TT 2 411, YT 2 041, X 1 658, FB 182+ (część bez autora), IG 541
- Stack Exchange: 538 pytań z publicznego API, 48 marek, tylko test na innej platformie

Wyniki w platformie, pełna tabela

	CatBoost (MAE)	W gr. $\times 2$	Ridge (2 pola)	Mnożnik lajków	Stała mediana
TikTok	$\times$**1,87** (0,273)	67%	$\times$1,99	$\times$2,23	$\times$4,60
YouTube	$\times$**2,90** (0,462)	43%	$\times$4,15	$\times$4,06	$\times$8,77
X	$\times$**3,03** (0,482)	40%	$\times$3,30	$\times$3,63	$\times$4,63

W gr. $\times 2$: udział postów oszacowanych w zakresie 2 razy w górę lub w dół od prawdy. Stała mediana: ten sam szacunek dla każdego posta.

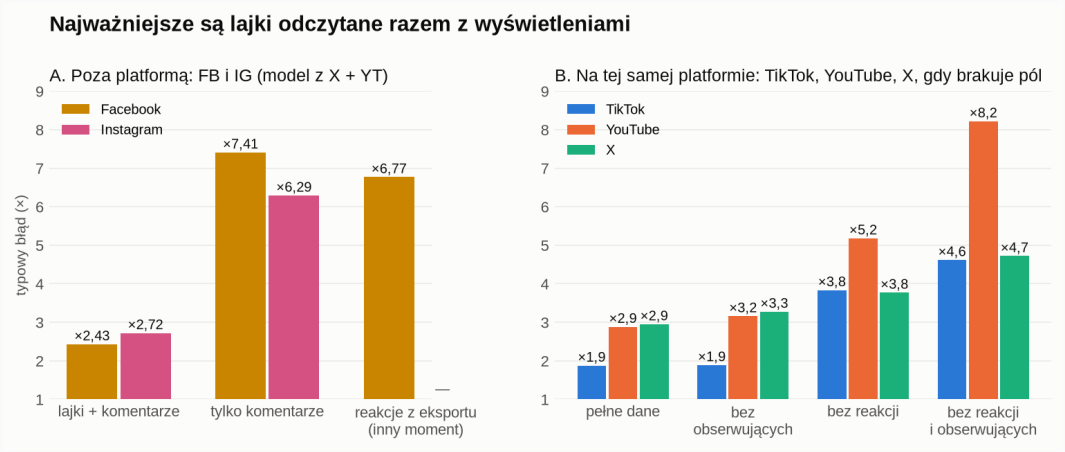
Zysk dodatkowych pól

CatBoost lepszy od mnożnika o 0,075–0,147 MAE; 95% CI różnicy MAE nie zawiera zera. Ridge na samych 2 polach prawie nie pomaga (TT $\times$1,99 vs $\times$2,23, YT $\times$4,15 vs $\times$4,06, X $\times$3,30 vs $\times$3,63): zysk pochodzi z obserwujących, udostępnień i flag braków. CatBoost na 8 polach to górna granica dla FB/IG.

FB i IG, szczegóły i zastrzeżenia

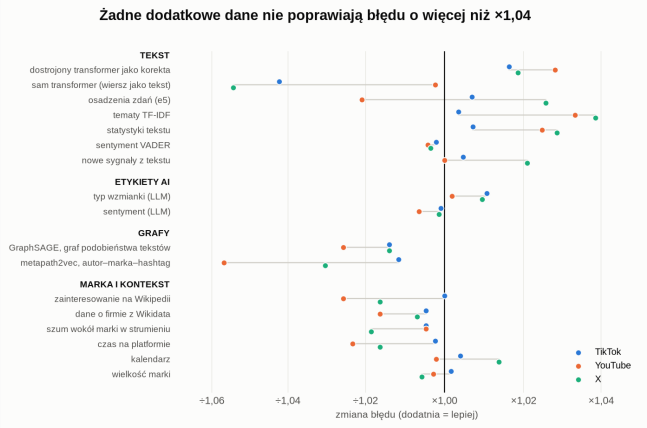
- Ridge FB $\times$2,43 (MAE 0,385), IG $\times$2,72 (MAE 0,435); ridge i k z X + YT, bez FB/IG w treningu; przedział: bootstrap po markach (FB 402 posty, IG 642)
- Mnożnik vs ridge: FB $\times$2,42 vs $\times$2,43; IG $\times$2,94 vs $\times$2,72
- Stała mediana z X + YT: FB $\times$19,87, IG $\times$8,69
- k z X+YT $\approx$ 25 wyśw./lajk, a na FB 35, na IG 53; IG: 72% rolek niedoszacowanych
- Wiek odczytu: 23 vs 310–334 dni. Po odczycie X+YT w wieku bliższym celom (mediana 137 dni): IG $\times$2,41, FB $\times$2,44

Czego model potrzebuje



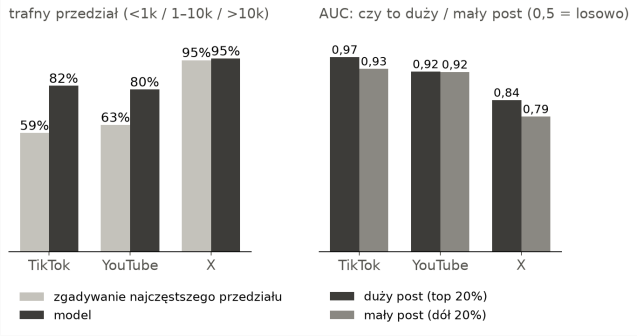
Co widać: typowy błąd (oś pionowa) przy różnych zestawach pól; A: FB i IG (model z X + YT), B: TT, YT, X, gdy brakuje pól. Kluczowe: lajki odczytane w tej samej chwili co wyświetlenia. Same komentarze: $\times 6{,}3$–$\times 7{,}4$.

Dodatkowe dane, ile zmieniły błąd



Co widać: jeden punkt to zmiana błędu po dodaniu źródła (oś pozioma, w prawo = lepiej) dla TT, YT, X; żadne źródło nie daje więcej niż $\times 1{,}04$.

Klasyfikacja działa na TT i YT; na X to zgadywanie

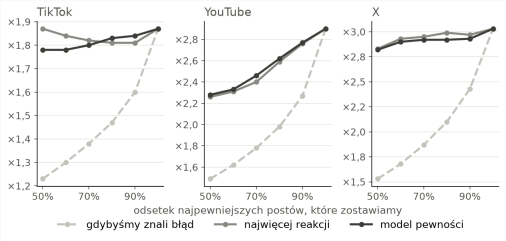


Na X 95% postów ma <1k wyświetleń, więc 95% trafności to zgadywanie najczęstszego przedziału (trafność zrównoważona 43%).

Jak próbowaliśmy poprawić duże i małe posty

- cel „wyświetlenia na lajk” → **prawie bez zmian**
- większa waga skrajnych postów → **bez zmian**
- inne funkcje błędu (RMSE, kwantyl) → duże posty **nadal zaniżone**
- osobny model dla postów bez reakcji → **bez zysku**
- korekta wyniku po fakcie → **bez poprawy**

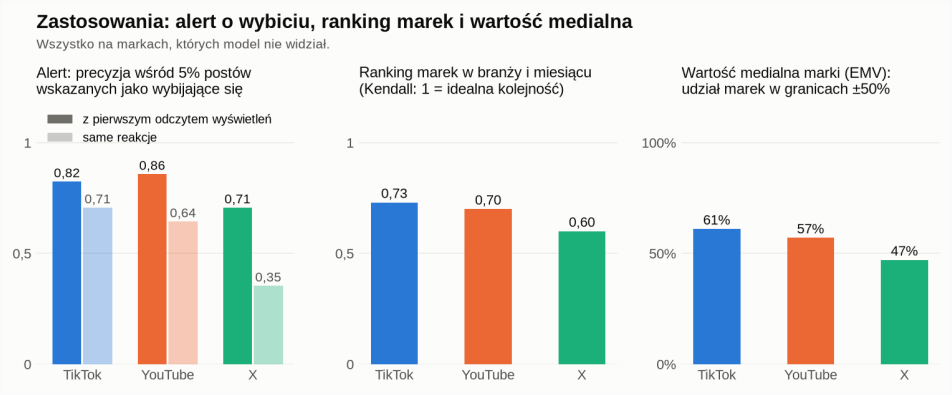
Model pewności prawie nie wie, które posty trafi



- Najpewniejsze 80% postów: błąd $\times$1,83 / $\times$2,62 / $\times$2,92 wobec $\times$1,87 / $\times$2,90 / $\times$3,03 dla wszystkich (TT / YT / X); ze znajomością prawdziwego błędu byłoby $\times$1,47 / $\times$1,98 / $\times$2,10.
- Zysk widać tylko na YouTube, a tam sama liczba reakcji daje to samo (szara linia = ciemna). AUC „błąd $> \times 2$”: 0,54 / 0,62 / 0,53.
- Posty z $\geq$80% pewności to 8% / 2% / 0,4% próby, a trafia w nich tylko 70% / 56% / 63%: pewność jest zawyżona.

Błąd siedzi głównie w poziomie autora, widocznym tylko w jego historii. Walidacja po markach i autorach.

Alert, ranking marek i wartość medialna (TT, YT, X)



Alert: z pierwszego odczytu model wskazuje 5% postów, które trafią do top 5%. **Ranking:** zgodność kolejności marek (Kendall). **Wartość medialna:** marki w ±50% prawdy.

Wzmianki spoza marki: szczegóły i odstające

Cztery sygnały bez wyświetleń: nazwa marki w tekście, embeddingi, graf podobieństwa tekstów z podziałem Louvain i klasyfikator tekstu. Ocena na 300 postach.

Wynik. AUC 0,68 (próg 0,75 nie osiągnięty). W najwyższych 5% wyniku 78% postów faktycznie nie dotyczy marki. Udział wzmianek spoza marki zależy od definicji: od 7% do 64%. Najlepsze ulepszenie (siatka Louvain $\times$ k): AUC 0,73; z cechami tekstu 0,77, ale to 1 z 14 prób, do potwierdzenia. Wzmianki spoza marki nie psują modelu: błąd $\times$2,6 wobec $\times$2,4.

Czy to tłumaczy odstające?

Nie. Wynik flagi dla odstających (górne i dolne 5% reszt, 678 postów) ma AUC **0,47** (0,45–0,50); flaga obejmuje tylko 3% nadwyżek.

Pojedyncze przypadki to jednak pomyłka marki:

- **X, AAA:** wpis o grze, „AAA" to klasa gier. $\times$296 więcej wyświetleń (ok. 1 200) niż oszacowanie (ok. 4).
- **X, Tripadvisor:** ogólne podsumowanie opinii o parku rozrywki; marka to jedna z kilku wymienionych stron. 9 wyświetleń wobec oszacowania ok. 520.