Szacowanie ukrytych wyświetleń postów z reakcji

Przeniesienie modelu między platformami

Zespół projektu AMC

Politechnika Wrocławska

Czy wyświetlenia FB i IG da się oszacować z lajków?

Czy da się oszacować wyświetlenia filmów i rolek z lajków i komentarzy, gdy platforma ich nie pokazuje?

Problem

TikTok, YouTube, X: wyświetlenia są w eksporcie. Facebook, Instagram: nie widać ich.

Pytanie

Czy model, który nigdy nie widział wyświetleń z FB i IG, oszacuje je z lajków i komentarzy?

Odpowiedź w skrócie

Tak: typowy błąd ok. $\times 2{,}4$ (FB) i $\times 2{,}7$ (IG); wystarcza prosty stosunek wyświetleń do lajków.

Trzy platformy mają wyświetlenia, FB i IG tylko od nas

Platforma	Marki	Posty z wyśw.	Źródło wyśw.	Wyśw./lajk
TikTok	266	2 491	eksport	25
YouTube	273	2 441	eksport	26
X	252	1 803	eksport	22
Facebook	**20**	**402**	**nasz odczyt, filmy**	**35**
Instagram	**11**	**642**	**nasz odczyt, rolki**	**53**

Razem 348 marek, 5 platform. Pogrubione wiersze to cel: odczyt tylko do oceny.

Eksport: 12 500 wzmianek, 2 500 na platformę; Stack Exchange (538 pytań, 48 marek) tylko jako test.
Szczegóły: zapas.

Wyświetlenia FB i IG odczytaliśmy sami, razem z reakcjami

Źródło	Co dodaliśmy	Posty
Facebook	wyświetlenia filmów	402
Instagram	wyświetlenia rolek	642
X, YouTube, TikTok	ponowny odczyt wyśw. i reakcji	2 013 / 1 376 / 426
Stack Exchange	pytania z publicznego API	538

Protokół

- wyświetlenia i reakcje FB/IG odczytane razem, w tej samej chwili
- FB/IG tylko do oceny, nigdy w treningu
- X + YT wybrane przed oceną FB/IG

Uwaga: odczyt FB/IG niezweryfikowany niezależnie. Usunięte posty i inne zestawy treningowe: zapas.

Mnożnik lajków to punkt odniesienia dla modeli

Mnożnik lajków

wyświetlenia $= k\times$ lajki; jeden parametr, bez modelu. Punkt odniesienia.

TT / YT / X: CatBoost

8 pól (obserwujący, lajki, komentarze, udostępnienia + flagi braków). Górna granica, nie wynik dla FB/IG.

FB / IG: ridge

2 pola: lajki i komentarze, uczone tylko na X + YT. Test: nasz odczyt FB/IG.

Cel: $\log_{10}$(wyświetlenia). Dodatkowy test: Stack Exchange. Bez tekstu, etykiet AI, kraju i czasu (nie poprawiały wyniku).

Typowy błąd $\times 2$ znaczy: oszacowanie w granicach połowy i dwukrotności

Typowy błąd $\times 10^{\mathrm{MAE}}$

MAE = średnia $|\log_{10}(\text{oszacowanie}) - \log_{10}(\text{prawda})|$.

Przykład: $\times 2$, czyli post z 1 000 wyświetleń oszacowany między 500 a 2 000.

Mnożnik lajków k

Wyświetlenia = $k\times$ lajki. k tylko z platform treningowych, nigdy z celu.

Przykład: $k \approx 25$ (X + YT); 40 lajków $\rightarrow$ 1 000 wyświetleń.

W platformie model bije mnożnik, dzięki dodatkowym polom

	CatBoost	Ridge (2 pola)	Mnożnik lajków
TikTok	$\times$**1,87**	$\times$1,99	$\times$2,23
YouTube	$\times$**2,90**	$\times$4,15	$\times$4,06
X	$\times$**3,03**	$\times$3,30	$\times$3,63

Zysk pochodzi z obserwujących, udostępnień i flag braków, nie z typu modelu.

Uwaga

CatBoost to górna granica dla FB/IG: tam tych pól nie ma.

Typowy błąd, walidacja po markach i autorach. Przedziały ufności, udział w granicach $\times 2$ i stała mediana: zapas.

Poza platformą wystarcza stosunek wyświetleń do lajków

	Ridge X+YT	Mnożnik	W gr. ×2	Przedział
Facebook (20 marek)	×**2,43**	×2,42	53%	×2,08–×2,99
Instagram (11 marek)	×**2,72**	×2,94	40%	×2,48–×3,03

Co się przenosi

Stosunek wyświetleń do lajków z X + YT. Jeden parametr jest prawie tak dobry jak ridge; stała mediana myli się ×9–×20.

Uwaga

Tylko 20 i 11 marek, wynik kruchy; IG: 72% rolek niedoszacowanych.

Przedział: bootstrap po markach. Wiek odczytu i odczyt w podobnym wieku: zapas.

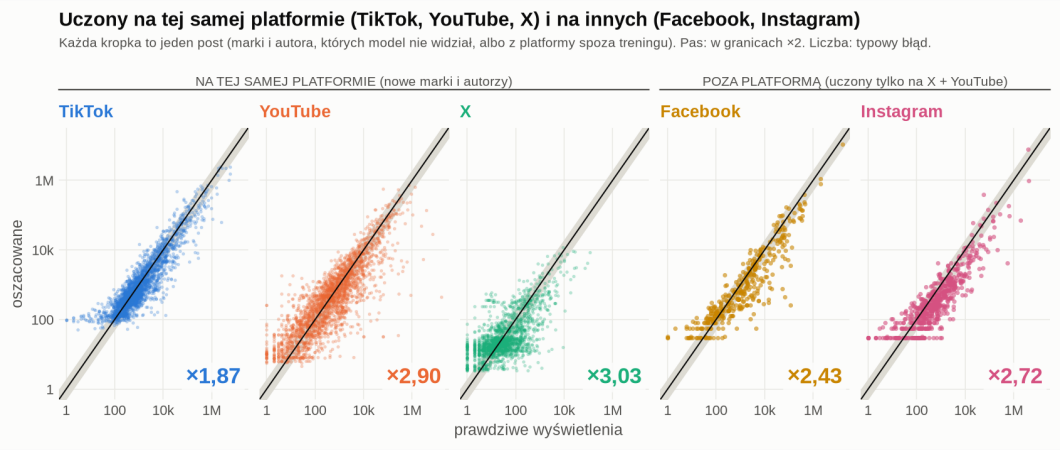
Poza platformą ridge prawie nie bije mnożnika

Cel	Trening na	Ridge	Mnożnik	Wynik
TikTok	X + YT	$\times$**2,05**	$\times$2,22	wygrana
YouTube	TT + X	$\times$4,09	$\times$**4,02**	porażka (nieznacznie)
X	TT + YT	$\times$4,47	$\times$**3,42**	porażka
Facebook	X + YT	$\times$2,43	$\times$2,42	remis
Instagram	X + YT	$\times$**2,72**	$\times$2,94	wygrana
Stack Exchange	X + YT	$\times$**3,14**	$\times$5,33	wygrana (ale mediana $\times$2,10 lepsza)

Ridge względem mnożnika: 3 wygrane, 1 remis, 2 porażki.

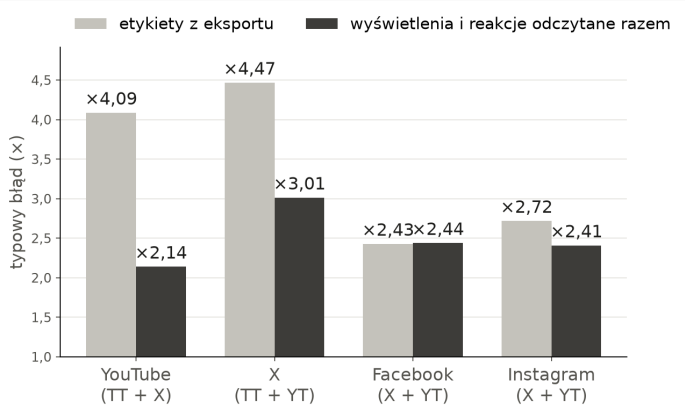
Stack Exchange: przenoszenie zawodzi, stała mediana $\times$2,10 lepsza od ridge $\times$3,14 i mnożnika $\times$5,33.
Przedziały różnic: zapas.

Oszacowania FB i IG podążają za prawdziwymi wyświetleniami



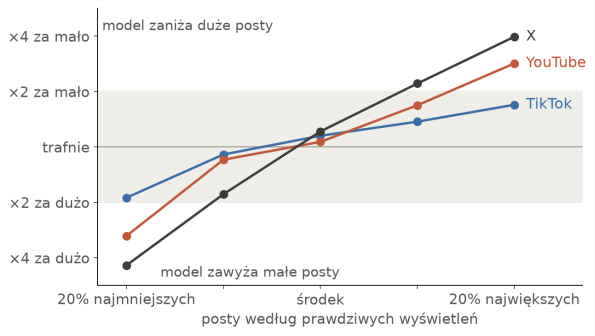
Kropka = post; szary pas = w granicach ×2. IG: 72% rolek niedoszacowanych.

Odczyt reakcji razem z wyświetleniami zmniejsza błąd



Ten sam model (ridge na lajkach i komentarzach), zmienia się tylko moment odczytu. Historia autora pomaga tylko tam, gdzie ją mamy (zapas).

Mało reakcji, duży błąd; model ściąga oszacowania do środka

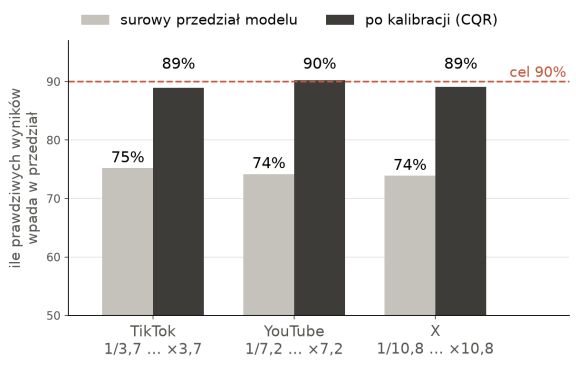


Typowy błąd wg reakcji

	TT	YT	X
0 reakcji	×3,23	×4,59	×3,19
wszystkie	×1,87	×2,90	×3,03
bez $\leq$5 r.	**×1,81**	**×2,29**	**×2,56**

Na X 62% ocenianych postów bez lajka. Reakcje = lajki + komentarze + udostępnienia; pełna tabela: zapas.

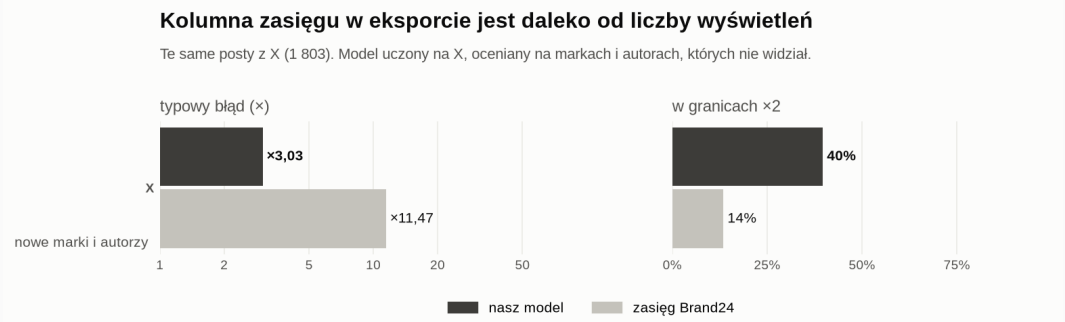
Po kalibracji przedział 90% obejmuje 9 na 10 postów, ale jest szeroki



Wniosek

Na X przedział od 1/11 do ×11 (szacunek 1 000 → ok. 90–11 000); na FB od ok. 1/8 do ×8.

Zasięg Brand24 to nie są wyświetlenia (X)



Odległość od prawdziwych wyświetleń: zasięg Brand24 $\times 11{,}47$, nasze oszacowanie $\times 3{,}03$ (1 803 posty z X).

Ograniczenia: mało marek i niezweryfikowany odczyt

Ograniczenia

- prawda FB/IG = nasz odczyt, niezweryfikowany niezależnie
- usunięte posty (IG 27%, FB 14%)
- wiek odczytu: eksport 23 dni, FB/IG 310–334 dni
- mało marek: FB 20, IG 11

Co dalej

- niezależna weryfikacja odczytu
- więcej marek na FB i IG
- zwykłe posty, nie tylko filmy i rolki

Pozostałe ograniczenia i kierunki (etykiety AI, jeden zestaw treningowy, inne platformy): zapas.

Wnioski: FB i IG da się oszacować z lajków

Trzy wnioski

1. Błąd ok. $\times$2,4 (FB), $\times$2,7 (IG); wystarcza stosunek wyświetleń do lajków z X + YT.
2. Zastrzeżenie: 20 i 11 marek, niezweryfikowany odczyt, odczyt po 310–334 dniach; nie uogólniać.
3. W tej samej platformie więcej pól pomaga ($\times$1,87 vs $\times$2,23 na TikToku); na Stack Exchange przenoszenie zawodzi.

Rekomendacja

Orientacyjnie: wyświetlenia $\approx 25\times$ lajki; IG zwykle zaniżony. Model z większą liczbą pól dodawaj dopiero przy danych tej samej platformy.

Zapas: protokół i usunięte posty

- Facebook: 402 z 470 postów (68 usuniętych)
- Instagram: 642 z 976 (261 usuniętych, 19 bez licznika, 54 z ukrytymi lajkami)
- FB/IG: wyświetlenia i reakcje odczytane razem; prawda = nasz odczyt publicznych stron, niezweryfikowany niezależnie
- historia autora: tylko wcześniejsze posty tego autora
- X + YT wybrane przed oceną FB/IG jako najbardziej podobne w reakcjach; inne zestawy: FB $\times$2,39–$\times$3,07, IG $\times$2,47–$\times$2,82 (wynik zależy od wyboru umiarkowanie)
- Eksport: 12 500 wzmianek, 2 500 na platformę; autorzy: TT 2 411, YT 2 041, X 1 658, FB 182+ (część bez autora), IG 541
- Stack Exchange: 538 pytań z publicznego API, 48 marek, tylko test na innej platformie

Zapas: wyniki w platformie, pełna tabela

	CatBoost (MAE)	W gr. ×2	Ridge (2 pola)	Mnożnik lajków	Stała mediana
TikTok	×**1,87** (0,273)	67%	×1,99	×2,23	×4,60
YouTube	×**2,90** (0,462)	43%	×4,15	×4,06	×8,77
X	×**3,03** (0,482)	40%	×3,30	×3,63	×4,63

W gr. ×2: udział postów oszacowanych w zakresie 2 razy w górę lub w dół od prawdy. Stała mediana: ten sam szacunek dla każdego posta.

Zysk dodatkowych pól

CatBoost lepszy od mnożnika o 0,075–0,147 MAE; 95% CI różnicy MAE nie zawiera zera. Ridge na samych 2 polach prawie nie pomaga (TT ×1,99 vs ×2,23, YT ×4,15 vs ×4,06, X ×3,30 vs ×3,63): zysk pochodzi z obserwujących, udostępnień i flag braków. CatBoost na 8 polach to górna granica dla FB/IG.

Zapas: FB i IG, szczegóły i zastrzeżenia

- Ridge FB $\times$2,43 (MAE 0,385), IG $\times$2,72 (MAE 0,435); ridge i k z X + YT, bez FB/IG w treningu; przedział: bootstrap po markach (FB 402 posty, IG 642)
- Mnożnik vs ridge: FB $\times$2,42 vs $\times$2,43; IG $\times$2,94 vs $\times$2,72
- Stała mediana z X + YT: FB $\times$19,87, IG $\times$8,69
- k z X+YT $\approx$ 25 wyśw./lajk, a na FB 35, na IG 53; IG: 72% rolek niedoszacowanych
- Wiek odczytu: 23 vs 310–334 dni. Po odczycie X+YT w wieku bliższym celom (mediana 137 dni): IG $\times$2,41, FB $\times$2,44

Zapas: różnice ridge i mnożnika z przedziałami ufności

Cel	Trening na	Różnica MAE [95% CI]	Wynik
TikTok	X + YT	−0,034 [−0,038; −0,029]	wygrana
YouTube	TT + X	+0,007 [0,002; 0,011]	porażka (nieznacznie)
X	TT + YT	+0,116 [0,094; 0,137]	porażka
Facebook	X + YT	+0,002 [−0,017; 0,022]	remis
Instagram	X + YT	−0,034 [−0,047; −0,020]	wygrana
Stack Exchange	X + YT	−0,229 [−0,240; −0,207]	wygrana, ale zob. niżej

różnica = ridge − mnożnik; minus = ridge lepszy. Stack Exchange: ridge ×3,14, mnożnik ×5,33.

Praktycznie istotne (>0,05 MAE): tylko Stack Exchange (lepiej niż mnożnik, ale gorzej od mediany ×2,10) i X (gorzej). Własny ridge SE ×1,77, z samego YouTube ×1,87; to pytania i odpowiedzi, nie wideo.

Zapas: błąd wg liczby reakcji

	TT	YT	X
0 reakcji	×3,23 3%	×4,59 27%	×3,19 54%
6–100 reakcji	×1,75 53%	×2,45 32%	×2,57 9%
wszystkie posty	×1,87	×2,90	×3,03
bez postów z ≤5 reak.	**×1,81** 83%	**×2,29** 54%	**×2,56** 10%

szare: udział postów; reakcje = lajki + komentarze + udostępnienia. Mało reakcji = za mało danych: 0 reakcji daje błąd ×3–×4,6.

Zapas: walidacja i kalibracja przedziałów

- **CQR** to korekta dopasowująca szerokość przedziału na danych odłożonych: surowy przedział 90% trafia w 3 z 4 posty, po CQR w 9 z 10 (87–91%)
- **FB:** kalibracja na 25% marek FB, pokrycie 0,917, szerokość 1,83 $\log_{10}$; dla IG nie liczyliśmy
- **Podział:** foldy łączą posty tej samej marki, autora lub tekstu; stała mediana i mnożnik jako odniesienia
- **Czas:** trening na wcześniejszych miesiącach, test 2026-05...08 (MAE TT 0,270, YT 0,450, X 0,473); różnica względem walidacji $-0{,}001$ / $-0{,}011$ / $-0{,}026$: brak dryfu

Zapas: wszystkie ograniczenia i kierunki

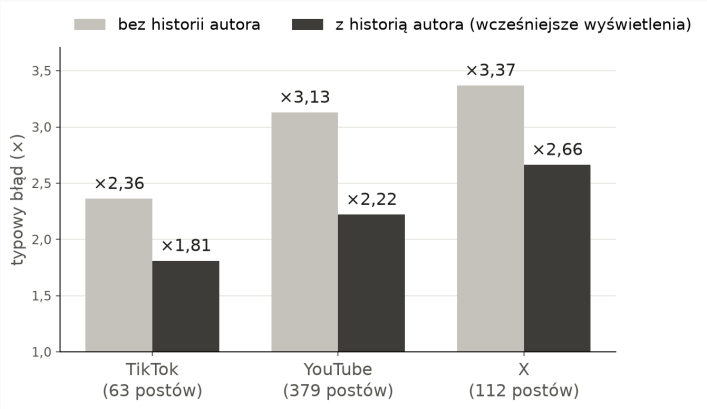
Ograniczenia

- prawda FB/IG = nasz odczyt publicznych stron, niezweryfikowany niezależnie
- usunięte posty (IG 27%, FB 14%), kierunek wpływu nieznany
- wiek odczytu: eksport 23 dni, FB/IG 310–334 dni
- mało marek: FB 20, IG 11
- tylko dostępne filmy i rolki
- etykiety AI bez ludzkiego wzorca (κ 0,71–0,79)
- wynik FB/IG z jednego zestawu treningowego (X + YT)
- na X ridge gorszy od mnożnika; na Stack Exchange przenoszenie zawodzi
- korelacja, nie przyczynowość

Co dalej

- niezależna weryfikacja odczytu FB/IG
- więcej marek na FB i IG
- zwykłe posty FB/IG, nie tylko filmy i rolki
- inne platformy (Reddit, LinkedIn)
- ludzka weryfikacja etykiet AI
- praktyczny przykład sumy marki na FB/IG

Zapas: historia autora



Typowy błąd bez i z historią autora (jego wcześniejsze posty), TT, YT, X. Pomaga tylko tam, gdzie historia istnieje (3–16% postów).

Zapas: braki w eksporcie Brand24

12 500 wzmianek, 2 500 na platformę, 19 kolumn (tabela: 18 poza `platform`). **Puste wartości** w każdej kolumnie, udział na platformie; pomarańczowe: braki $\geq 25\%$. `b24_estimated_reach` to „zasięg" Brand24.

kolumna	TikTok	YouTube	X	Facebook	Instagram
`mention_id`	0%	0%	0%	0%	0%
`url`	0%	0%	0%	0%	0%
`created_at`	0%	0%	0%	0%	0%
`metrics_updated_at`	0%	0%	0%	0%	0%
`brand`	0%	0%	0%	0%	0%
`language`	0%	0%	0%	0%	0%
`country`	4%	19%	**81%**	**79%**	**81%**
`title`	0%	0%	**100%**	0%	0%
`content`	0%	0%	0%	0%	0%
`author_name`	0%	0%	0%	**27%**	**92%**

kolumna	TikTok	YouTube	X	Facebook	Instagram
`author_url`	0%	0%	0%	**27%**	**92%**
`author_followers`	0%	0%	0%	**27%**	**92%**
`view_count`	0%	1%	**25%**	**100%**	**100%**
`likes`	0%	5%	0%	0%	0%
`comments`	0%	9%	**69%**	0%	0%
`shares`	0%	**41%**	0%	0%	**100%**
`sentiment`	11%	11%	9%	**90%**	**90%**
`b24_estimated_reach`	0%	0%	0%	0%	0%
`likes` $= 0$	4%	**26%**	**70%**	**30%**	**46%**

`likes` $= 0$: lajk wpisany jako zero (na X często brak, a nie prawdziwe zero).

Zapas: dane wyprowadzone i próbowane

Wyprowadzone z tekstu i metadanych

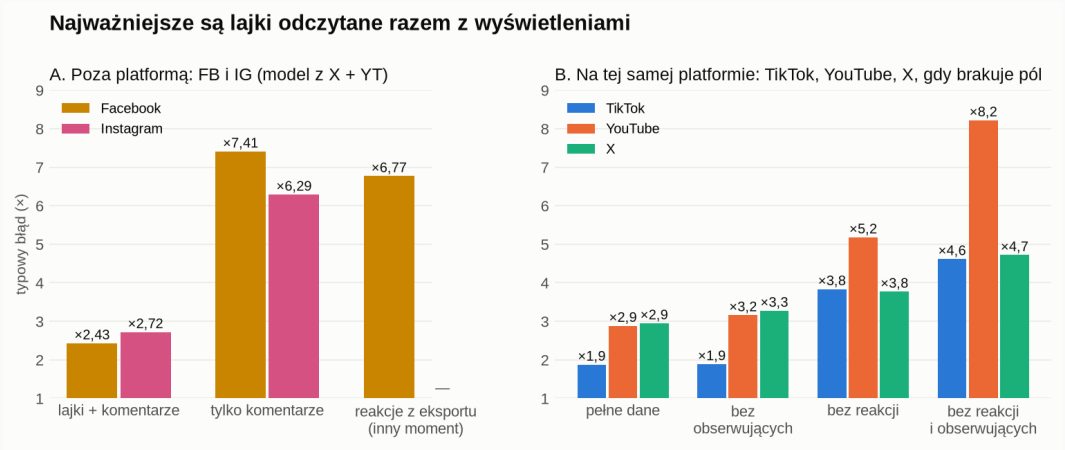
- typ wzmianki i sentyment z modelu językowego (etykiety AI): zgodność 3 przebiegów κ 0,77–0,79 (typ), 0,71–0,73 (sentyment); brak ludzkiego wzorca
- czy wzmianka jest o marce: 6,7% bez nazwy marki w tekście
- tekst: TF-IDF, osadzenia zdań e5, statystyki tekstu, sentyment VADER
- grafy: podobieństwo tekstów (GraphSAGE), autor–marka–hashtag (metapath2vec)

Próbowaliśmy dociągnąć z zewnątrz

- Wikipedia (zainteresowanie marką), Wikidata (dane o firmie), szum wokół marki w strumieniu, kalendarz, wielkość marki
- ponowne odczyty wyświetleń i reakcji (X, YouTube, TikTok), brakujące lajki YouTube
- konta tych samych autorów na innych platformach: za mało dopasowań (5–17 postów, potrzeba 40)
- TikTok Research API: wymaga wniosku akademickiego, nie użyte

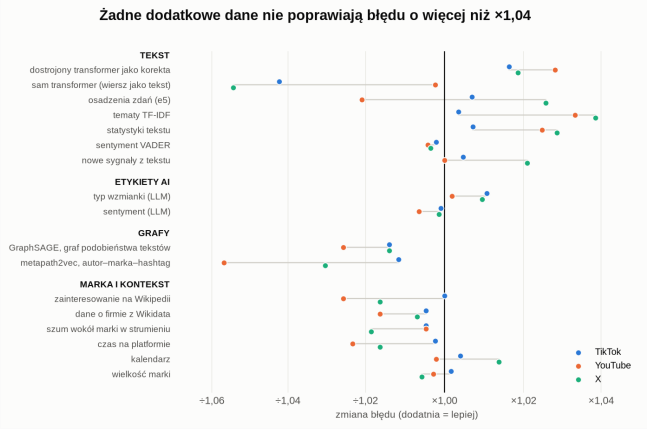
Żadne dodatkowe źródło nie poprawia błędu o więcej niż $\times 1{,}04$.

Zapas: czego model potrzebuje



Co widać: typowy błąd (oś pionowa) przy różnych zestawach pól; A: FB i IG (model z X + YT), B: TT, YT, X, gdy brakuje pól. Kluczowe: lajki odczytane w tej samej chwili co wyświetlenia. Same komentarze: $\times 6{,}3$–$\times 7{,}4$.

Zapas: dodatkowe dane, ile zmieniły błąd



Co widać: jeden punkt to zmiana błędu po dodaniu źródła (oś pozioma, w prawo = lepiej) dla TT, YT, X; żadne źródło nie daje więcej niż $\times 1{,}04$.

Zapas: modele na tej samej platformie (TikTok, YouTube, X)

Model (ta sama platforma, typowy błąd)	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	×4,60	×8,79	×4,65
stały mnożnik obserwujących	×8,30	×7,16	×7,57
stały mnożnik lajków	×2,23	×4,06	×3,63
Modele liniowe i jądrowe			
regresja liniowa (ridge)	×1,89	×3,51	×3,07
k najbliższych sąsiadów (kNN)	×1,92	×3,04	×3,09
SVR z jądrem RBF	×1,87	×2,90	×3,02
Drzewa decyzyjne			
las losowy	×1,88	×2,90	×2,97
extra trees	×1,88	×2,88	×2,99
gradient boosting (scikit-learn)	×1,89	×2,84	×2,98
LightGBM	×1,88	×2,86	×2,99
XGBoost	×1,87	×2,82	×2,93
CatBoost (model końcowy)	×1,87	×2,83	×2,95
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	×1,89	×2,84	×3,00
GraphSAGE (graf podobnych tekstów)	×1,90	×2,93	×2,98
dostrojony transformer	×1,95	×2,84	×3,09
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	×1,85	×2,77	×2,92
TabICL	×1,87	×2,79	×2,92
Zespoły modeli			
średnia 3 najlepszych rodzin	×1,86	×2,79	×2,94
stos wszystkich rodzin	×1,82	×2,66	×2,76

Walidacja tylko po markach, 8 pól, strojenie zagnieżdżone; dlatego liczby nieco niższe niż w wynikach głównych (po markach i autorach). Stos nie jest modelem końcowym: zysk ×1,03–×1,07, kilkanaście modeli, TabPFN ok. 150× wolniejszy.

Zapas: siatka platform treningowych (ridge na 2 polach)

Trening na	TikTok	YouTube	X	Facebook	Instagram	Stack Exchange
ridge, ta sama platforma	1,99	4,15	3,30	2,42	2,41	1,77
YT	**2,00**	trening	4,64	2,72	2,63	1,87
FB	2,30	4,26	**3,60**	trening	**2,47**	3,32
IG	2,46	4,50	4,06	2,48	trening	2,46
TT	trening	**4,07**	4,15	2,61	2,59	2,41
X	3,38	5,52	trening	3,07	2,74	4,50
X + YT	2,05	trening	trening	**2,43**	2,72	3,14
TT + YT + X	trening	trening	trening	2,49	2,69	3,08
YT + X + FB + IG	2,12	trening	trening	trening	trening	3,25
TT + YT + X + IG	trening	trening	trening	2,46	trening	3,07
TT + YT + X + FB	trening	trening	trening	trening	2,66	3,08
TT + X + FB + IG	trening	4,08	trening	trening	trening	4,24
TT + YT + FB + IG	trening	trening	4,37	trening	trening	2,11

Ridge na 2 polach (lajki, komentarze), walidacja po markach (nie po markach i autorach). Typowy błąd (×); szare = trening. Mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65, czyli nie zależy od wyboru X + YT.

Stack Exchange (538 pytań) nigdy nie jest w treningu: najlepszy z samego YouTube ×1,87, własny ridge SE ×1,77; każdy zestaw z X daje ×3–×5.

Zapas: modele poza platformą (Facebook, Instagram)

Metoda (typowy błąd)	Facebook	Instagram
Proste reguły		
mediana z X + YT	×19,87	×8,69
mnożnik lajków	×2,42	×2,94
Modele (trening X + YouTube)		
regresja ridge (nasz)	**×2,43**	**×2,72**
MLP	×2,47	×2,78
CatBoost	×2,61	×2,95
Augmentacja		
CatBoost + trend	×2,54	×2,96
MLP + trend	×2,46	×2,79
CatBoost + propensity	×2,49	×2,89
MLP + propensity	×2,42	×2,75
CatBoost + mixup	×2,58	×2,95
MLP + mixup	×2,46	×2,76
Odniesienie (używa etykiet platformy docelowej)		
ridge uczony na samej platformie (CV po markach)	×2,42	×2,41

Wszystkie modele: 2 pola (lajki, komentarze), trening tylko na X + YouTube, nigdy na FB/IG. Złożone modele i augmentacja nie dają wyraźnej poprawy względem prostej regresji; mnożnik lajków jest na FB prawie tak samo dobry. Ridge uczony na samej platformie ma IG 72% rolek niedoszacowanych; z TikTokiem w treningu (TT + YT + X): FB ×2,49, IG ×2,69; TikTok jako dodatkowy test ×2,05.

Zapas: klasyfikacja i próby naprawy skrajnych postów

Klasyfikacja: <1k / 1–10k / >10k

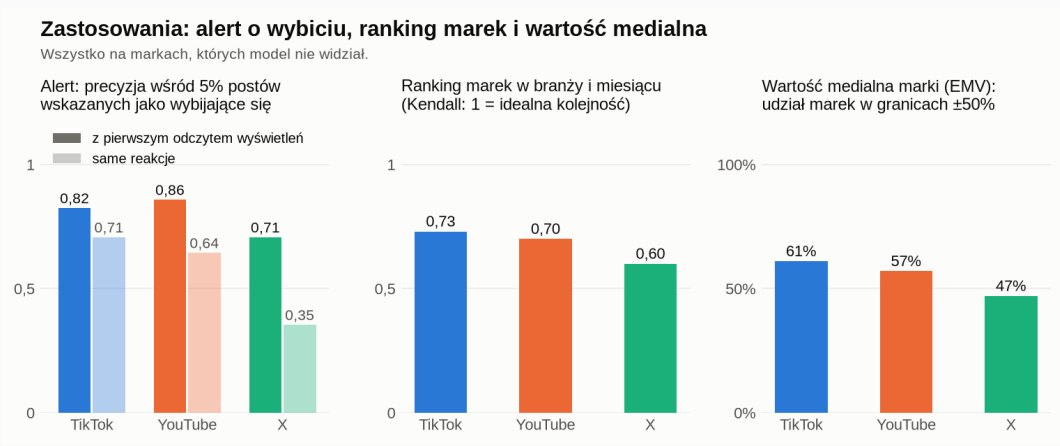
	TT	YT	X
trafny przedział	82%	80%	95%
zgadywanie najczęstszego	59%	63%	95%
trafność zrównoważona	77%	72%	43%
prawdopodobieństwo (AUC; 0,5 = losowo, 1 = idealnie)			
czy to duży post (top 20%)	0,97	0,92	0,84
czy to mały post (dół 20%)	0,93	0,92	0,79

Klasyfikacja działa na TT i YT; na X 95% postów ma <1k, więc 95% to zgadywanie.

Jak próbowaliśmy poprawić duże i małe posty

- **cel „wyświetlenia na lajk”** → prawie bez zmian
- **większa waga skrajnych postów** → bez zmian
- **inne funkcje błędu** (RMSE, kwantyl) → duże posty nadal zaniżone
- **osobny model dla postów bez reakcji** → bez zysku
- **korekta wyniku po fakcie** → bez poprawy

Zapas: trzy zastosowania (TT, YT, X)



Precyzja alertu o wybiciu (5% postów), zgodność rankingu marek (Kendall), udział marek w $\pm 50\%$ wartości medialnej.

Zapas: obserwujący IG i sumy marek

Obserwujący IG

	lajki + koment.	+ obserwujący
ridge na samym IG	$\times$2,40	$\times$2,23
transfer X+YT $\rightarrow$ IG	$\times$2,72	$\times$4,58

Obserwujący pomagają na samym IG, ale psują przenoszenie z X + YT: obserwujący na X/YT oznaczają inny poziom wyświetleń niż na IG.

Sumy marek

Po jednej korekcie błąd sumy marki: $\times$1,7 / $\times$2,0 / $\times$2,1.