Szacowanie ukrytych wyświetleń postów z reakcji

Przeniesienie modelu między platformami

Zespół projektu AMC

Politechnika Wrocławska

Pytanie badawcze

Czy da się oszacować wyświetlenia filmów i rolek w mediach społecznościowych z lajków i komentarzy?

Problem

TikTok, YouTube, X: wyświetlenia są w eksporcie.

Facebook, Instagram: nie widać ich; Brand24 daje tylko „zasięg" z reguły (porównanie na końcu).

Pytanie szczegółowe

Czy model, który nigdy nie widział wyświetleń z FB i IG, oszacuje wyświetlenia filmów FB i rolek IG z lajków i komentarzy?

Dane: 348 marek, 5 platform

Platforma	Skrót	Marki	Autorzy	Źródło wyśw.	Posty z wyśw.	Wyśw./lajk
TikTok	TT	266	2 411	eksport Brand24	2 491	25
YouTube	YT	273	2 041	eksport Brand24	2 441	26
X	X	252	1 658	eksport Brand24	1 803	22
Facebook	FB	20	$\geq$182*	nasz odczyt, filmy	402	35
Instagram	IG	11	541	nasz odczyt, rolki	642	53

Eksport: 12 500 wzmianek, 2 500 na platformę. Do tego Stack Exchange: 538 pytań z publicznego API, 48 marek, tylko test na innej platformie.

FB i IG: wyświetlenia odczytane przez nas, **tylko do oceny**; zwykłe posty nie mają licznika. Pełna tabela braków w eksporcie: zapas.

* co najmniej; część postów bez autora.

Dane dodane przez nas i protokół

Źródło	Co	Ile
Facebook	wyświetlenia filmów	402 z 470 (68 usuniętych)
Instagram	wyświetlenia rolek	642 z 976 (261 usuniętych, 19 bez licznika, 54 z ukrytymi lajkami)
X, YouTube, TikTok	ponowny odczyt wyśw. i reakcji	2 013 / 1 376 / 426 postów
Stack Exchange	pytania z publicznego API	538 pytań, 48 marek

Jak zbieraliśmy i dzieliliśmy dane

- FB/IG: wyświetlenia i reakcje odczytane razem, w tej samej chwili
- historia autora: tylko wcześniejsze posty tego autora
- zestaw X + YT ustalony z góry z podobieństwa reakcji (klasyfikator platformy: AUC 0,65 dla X/YT kontra FB/IG, 0,85 dla TikToka); mediana z 15 zestawów bez celu: FB $\times$2,58, IG $\times$2,65, więc wybór prawie bez znaczenia

Metoda: mnożnik lajków i jego rozszerzenia

Mnożnik lajków (punkt odniesienia)

wyświetlenia $= k\times$ lajki, jeden parametr k, bez modelu.

To główna prosta metoda; pozostałe modele pytają, czy coś do niej dodają.

Ridge: rozszerzenie na 2 pola

Poza platformą (FB, IG): **ridge** na $\log(1 + \text{lajki})$, $\log(1 + \text{komentarze})$, uczony tylko na X + YT.

FB/IG mają tylko lajki i komentarze.

CatBoost: ta sama platforma

TT, YT, X: **CatBoost** na 8 polach (obserwujący, lajki, komentarze, udostępnienia + 4 flagi „pole puste").

Górna granica, nie wynik dla FB/IG.

Dane zewnętrzne: nasz odczyt FB/IG (nigdy w treningu) i Stack Exchange; test na markach i autorach, których model nie widział.

Cel: $\log_{10}$(wyświetlenia). Bez tekstu, etykiet AI, kraju i czasu (nie poprawiały wyniku).

Jak czytać wyniki

Typowy błąd $\times 10^{\mathrm{MAE}}$

MAE = średnia $|\log_{10}(\text{oszacowanie}) - \log_{10}(\text{prawda})|$. Typowy błąd to 10^{MAE} (średnia geometryczna współczynnika błędu).

Przykład: $\times 2$ znaczy, że post z 1 000 wyświetleń jest zwykle oszacowany między 500 a 2 000.

W granicach $\times 2$

Udział postów, dla których oszacowanie jest w zakresie 2 razy w górę lub w dół od prawdy.

Mnożnik lajków

$\log_{10}(\text{wyświetlenia}) = \log_{10}(\max(\text{lajki}, 1)) + k$, czyli wyświetlenia $= k\times$ lajki; post z 0 lajków liczymy jak z 1.

k z X + YT $= 10^{1,393} \approx 25$ wyświetleń na lajk. Przykład: $k = 25$, 40 lajków $\rightarrow$ 1 000 wyświetleń.

Skąd k i stała mediana

Ta sama platforma: k liczymy na foldach treningowych tej platformy. Poza platformą: tylko z platform treningowych, nigdy z celu. Stała mediana: ten sam szacunek dla każdego posta.

Wyniki: ta sama platforma

	CatBoost (MAE)	W gr. $\times 2$	Ridge (2 pola)	Mnożnik lajków	Stała mediana
TikTok	$\times$**1,87** (0,273)	67%	$\times$1,99	$\times$2,23	$\times$4,60
YouTube	$\times$**2,90** (0,462)	43%	$\times$4,15	$\times$4,06	$\times$8,77
X	$\times$**3,03** (0,482)	40%	$\times$3,30	$\times$3,63	$\times$4,63

W platformie model bije mnożnik, ale głównie dzięki dodatkowym polom

CatBoost jest lepszy od mnożnika o 0,075–0,147 MAE; 95% CI różnicy MAE nie zawiera zera. Ridge na samych 2 polach prawie nie pomaga (TT $\times$1,99 vs $\times$2,23, YT $\times$4,15 vs $\times$4,06, X $\times$3,30 vs $\times$3,63): zysk pochodzi z obserwujących, udostępnień i flag braków, nie z typu modelu. CatBoost na 8 polach to górna granica, nie wynik dla FB/IG.

Walidacja po markach i autorach. Stos wszystkich modeli ($\times$1,82 / $\times$2,66 / $\times$2,76) daje tylko $\times$1,03–$\times$1,07 zysku przy kilkunastu modelach: zapas.

Wyniki: poza platformą (Facebook, Instagram)

	Ridge X+YT (MAE)	Przedział	W gr. $\times 2$	Mnożnik
FB (402, 20 marek)	$\times$**2,43** (0,385)	$\times 2{,}08$–$\times 2{,}99$	53%	$\times 2{,}42$
IG (642, 11 marek)	$\times$**2,72** (0,435)	$\times 2{,}48$–$\times 3{,}03$	40%	$\times 2{,}94$

Wkład: mnożnik z X + YT działa na FB i IG (20 i 11 marek, wynik kruchy)

Ridge i k z X + YT, bez FB/IG w treningu; przedział: bootstrap po markach. Jednoparametrowy mnożnik jest prawie tak samo dobry jak ridge (FB $\times 2{,}42$ vs $\times 2{,}43$; IG $\times 2{,}94$ vs $\times 2{,}72$). Podanie wszystkim postom tej samej mediany myli się $\times 9$–$\times 20$ (FB $\times 19{,}87$, IG $\times 8{,}69$).

Uwaga

k z X+YT $\approx$ 25 wyśw./lajk, a na FB 35, na IG 53; IG: 72% rolek niedoszacowanych; wiek odczytu 23 vs 310–334 dni. Po odczycie X+YT w wieku bliższym celom (mediana 137 dni) IG spada z $\times 2{,}72$ do $\times 2{,}41$, a FB zostaje $\times 2{,}44$.

Czy poza platformą potrzebny jest model? Prawie nie

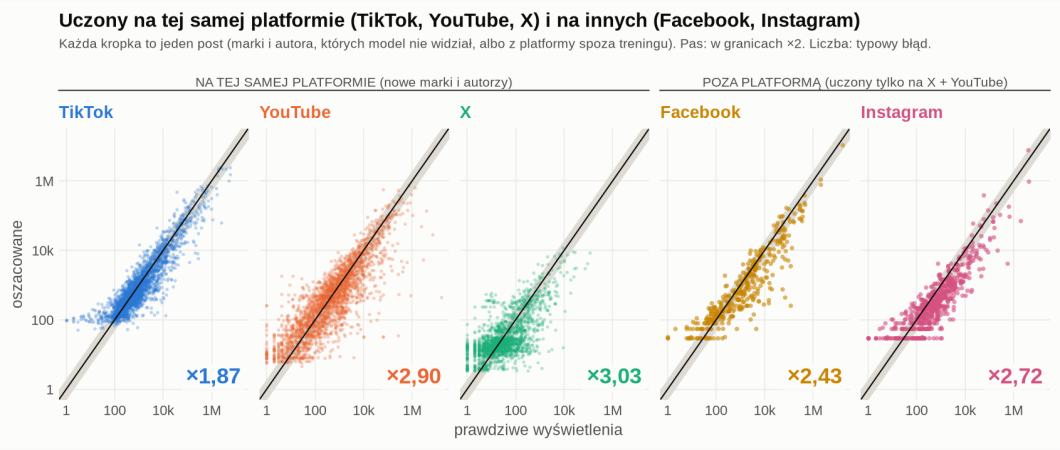
Cel	Trening na	Ridge	Mnożnik	Różnica MAE [95% CI]	Wynik
TikTok	X + YT	**×2,05**	×2,22	−0,034 [−0,038; −0,029]	wygrana
YouTube	TT + X	×4,09	**×4,02**	+0,007 [0,002; 0,011]	porażka (nieznacznie)
X	TT + YT	×4,47	**×3,42**	+0,116 [0,094; 0,137]	porażka
Facebook	X + YT	×2,43	×2,42	+0,002 [−0,017; 0,022]	remis
Instagram	X + YT	**×2,72**	×2,94	−0,034 [−0,047; −0,020]	wygrana
Stack Exchange	X + YT	×3,14	×5,33	−0,229 [−0,240; −0,207]	wygrana, ale zob. niżej

różnica = ridge − mnożnik; minus = ridge lepszy. k z platform treningowych, nigdy z celu. **Ridge względem mnożnika: 3 wygrane (TT, IG, Stack Exchange), 1 remis (FB), 2 porażki (YT nieznacznie, X).**

Stack Exchange: przenoszenie zawodzi

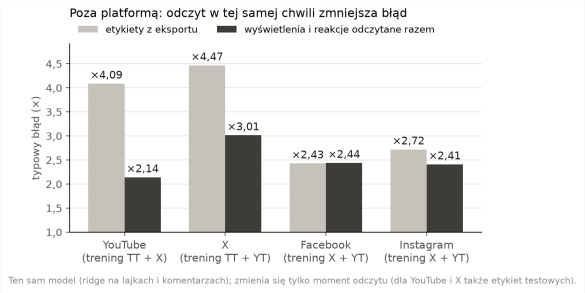
Stała mediana (×2,10) jest lepsza od ridge (×3,14) i mnożnika (×5,33); to pytania i odpowiedzi, nie wideo. Własny ridge SE ×1,77, z samego YouTube ×1,87.

Oszacowane a prawdziwe wyświetlenia



Kropka = post; oś pozioma: prawdziwe, pionowa: oszacowane wyświetlenia (log); szary pas = w granicach $\times 2$.

Od czego zależy błąd: czas i historia autora



Ten sam model (ridge na lajkach i komentarzach); zmienia się tylko moment odczytu (dla YouTube i X także etykiet testowych).

Typowy błąd bez i z odczytem wyświetleń i reakcji w tej samej chwili (ten sam model).

Czas

Trening na wcześniejszych miesiącach, test na miesiącach 2026-05...08; różnica MAE względem walidacji po markach $-0{,}001$ / $-0{,}011$ / $-0{,}026$ (TT/YT/X): brak dryfu. Liczy się odczyt reakcji razem z wyświetleniami.

Autor

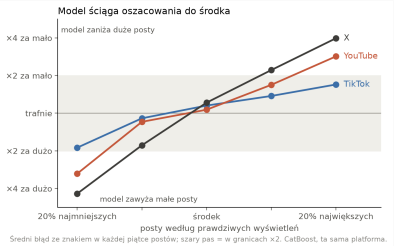
Historia autora pomaga tylko tam, gdzie ją mamy (3–16% postów); dla nowych autorów nie pomoże (wykres: zapas).

Od czego zależy błąd: liczba reakcji i wielkość posta

Typowy błąd (×) wg liczby reakcji (TT, YT, X)

	TT	YT	X
0 reakcji	×3,23 3%	×4,59 27%	×3,19 54%
6–100 reakcji	×1,75 53%	×2,45 32%	×2,57 9%
wszystkie posty	×1,87	×2,90	×3,03
bez postów z ≤5 reak.	**×1,81** 83%	**×2,29** 54%	**×2,56** 10%

szare: udział postów; reakcje = lajki + komentarze + udostępnienia

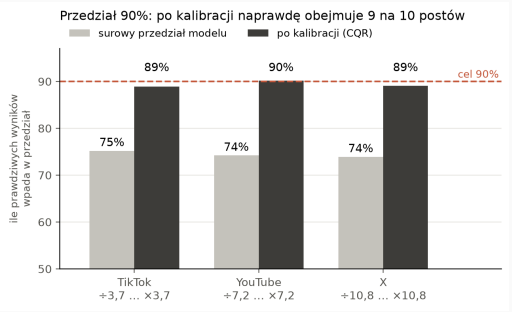


Średni błąd ze znakiem w kwintylach postów (od 20% najmniejszych do 20% największych): model zawyża małe i zaniża duże.

Mało reakcji = za mało danych: 0 reakcji daje błąd ×3–×4,6; na X 62% ocenianych postów bez lajka.

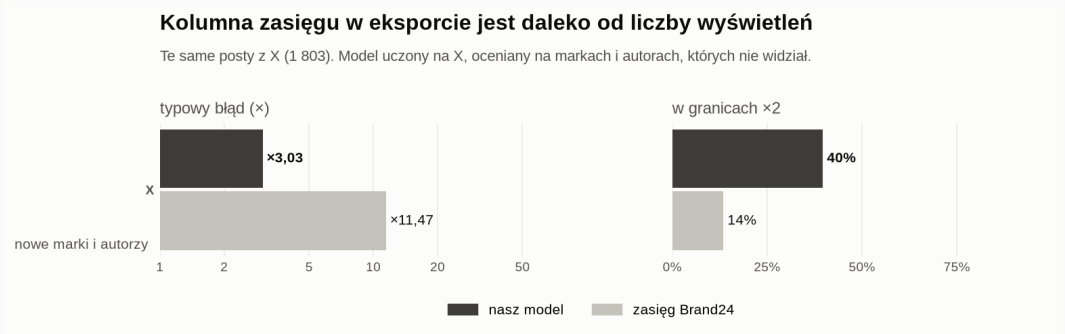
Walidacja i kalibracja: co sprawdziliśmy

- **Podział i odniesienia:** foldy łączą posty tej samej marki, autora lub tekstu; test na nieznanej marce i autorze; zawsze stała mediana i mnożnik lajków; przedziały: bootstrap po markach
- **Spoza treningu i w czasie:** nasze odczyty FB/IG; test w czasie MAE TT 0,270, YT 0,450, X 0,473, blisko walidacji
- **CQR** to konformalna korekta przedziałów na danych odłożonych: surowy przedział 90% trafia w 3 z 4 posty, po CQR w 9 z 10 (87–91%)
- Koszt: na X przedział 90% to od $\div 11$ do $\times 11$; szacunek 1 000 daje przedział ok. 90–11 000, mało użyteczny



Odsetek prawdziwych wyświetleń w przedziale 90%, przed i po kalibracji; pod nazwą szerokość przedziału.

Porównanie z kolumną zasięgu Brand24 (X)



Te same 1 803 posty z X: typowy błąd naszego modelu $\times 3{,}03$ wobec $\times 11{,}47$ dla zasięgu Brand24. Zasięg to inna miara niż wyświetlenia: pokazujemy, jak daleko od nich jest liczba, którą klient dostaje dziś.

Ograniczenia i co dalej

Ograniczenia

- mało marek: FB 20, IG 11, wynik kruchy
- wiek odczytu: eksport 23 dni, nasz odczyt FB/IG 310–334 dni po publikacji
- tylko dostępne filmy i rolki; usunięte posty (IG 27%, FB 14%) mogą przekrzywiać ocenę
- na X ridge gorszy od mnożnika lajków; na Stack Exchange przenoszenie zawodzi
- etykiety AI bez ludzkiego wzorca (zgodność modeli κ 0,71–0,79)
- korelacja, nie przyczynowość

Co dalej

- więcej marek na FB i IG
- zwykłe posty FB/IG, nie tylko filmy i rolki
- inne platformy (Reddit, LinkedIn)
- ludzka weryfikacja etykiet AI
- praktyczny przykład sumy marki na FB/IG

Wnioski

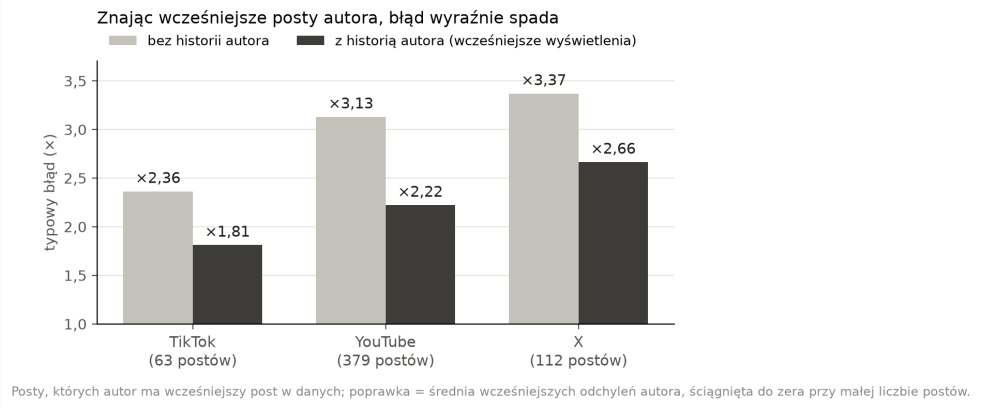
Co z tego wynika

1. FB/IG: wystarcza $k \approx 25$ wyświetleń na lajk z X+YT; ridge dodaje mało (IG $\times$2,94 $\rightarrow$ $\times$2,72, FB bez różnicy).
2. Model z większą liczbą pól ma sens na tej samej platformie ($\times$1,87 vs $\times$2,23 na TikToku), głównie dzięki obserwującym i udostępnieniom.
3. Ridge względem mnożnika: 3 wygrane, 1 remis, 2 porażki; na Stack Exchange (pytania i odpowiedzi) przenoszenie zawodzi.
4. Tylko 20 i 11 marek, odczyt FB/IG po 310–334 dniach (eksport 23): nie uogólniać. Reakcje muszą być odczytane razem z wyświetleniami.

Rekomendacja praktyczna

Dla FB/IG bez własnych wyświetleń: szacuj wyświetlenia $\approx 25\times$ lajki i podawaj typowy błąd $\times$2,4 (FB) / $\times$2,9 (IG); model z większą liczbą pól dodawaj dopiero przy danych tej samej platformy.

Zapas: historia autora



Typowy błąd bez i z historią autora (jego wcześniejsze posty), TT, YT, X. Pomaga tylko tam, gdzie historia istnieje (3–16% postów).

Zapas: braki w eksporcie Brand24

12 500 wzmianek, 2 500 na platformę, 19 kolumn (tabela: 18 poza `platform`). **Puste wartości** w każdej kolumnie, udział na platformie; pomarańczowe: braki $\geq 25\%$. `b24_estimated_reach` to „zasięg" Brand24.

kolumna	TikTok	YouTube	X	Facebook	Instagram
`mention_id`	0%	0%	0%	0%	0%
`url`	0%	0%	0%	0%	0%
`created_at`	0%	0%	0%	0%	0%
`metrics_updated_at`	0%	0%	0%	0%	0%
`brand`	0%	0%	0%	0%	0%
`language`	0%	0%	0%	0%	0%
`country`	4%	19%	**81%**	**79%**	**81%**
`title`	0%	0%	**100%**	0%	0%
`content`	0%	0%	0%	0%	0%
`author_name`	0%	0%	0%	**27%**	**92%**

kolumna	TikTok	YouTube	X	Facebook	Instagram
`author_url`	0%	0%	0%	**27%**	**92%**
`author_followers`	0%	0%	0%	**27%**	**92%**
`view_count`	0%	1%	**25%**	**100%**	**100%**
`likes`	0%	5%	0%	0%	0%
`comments`	0%	9%	**69%**	0%	0%
`shares`	0%	**41%**	0%	0%	**100%**
`sentiment`	11%	11%	9%	**90%**	**90%**
`b24_estimated_reach`	0%	0%	0%	0%	0%
`likes` $= 0$	4%	**26%**	**70%**	**30%**	**46%**

`likes` $= 0$: lajk wpisany jako zero (na X często brak, a nie prawdziwe zero).

Zapas: dane wyprowadzone i próbowane

Wyprowadzone z tekstu i metadanych

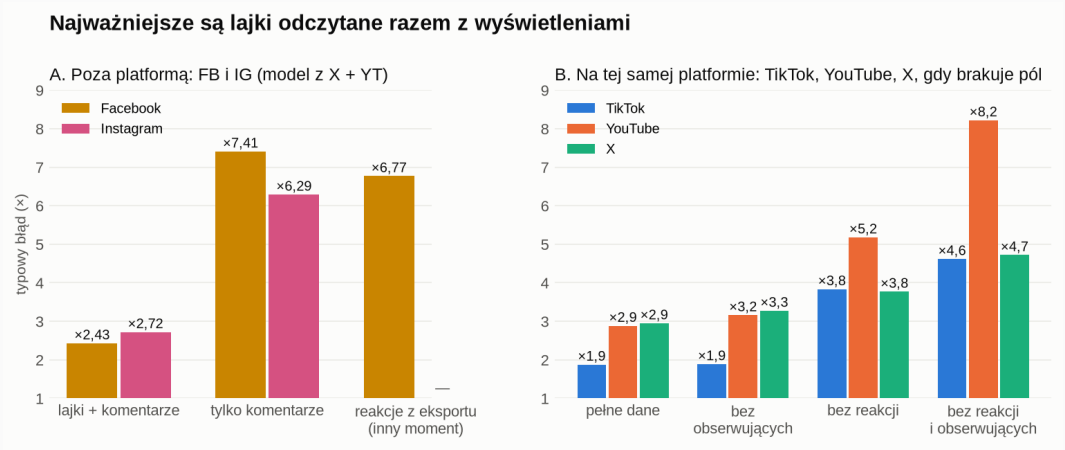
- typ wzmianki i sentyment z modelu językowego (etykiety AI): zgodność 3 przebiegów κ 0,77–0,79 (typ), 0,71–0,73 (sentyment); brak ludzkiego wzorca
- czy wzmianka jest o marce: 6,7% bez nazwy marki w tekście
- tekst: TF-IDF, osadzenia zdań e5, statystyki tekstu, sentyment VADER
- grafy: podobieństwo tekstów (GraphSAGE), autor–marka–hashtag (metapath2vec)

Próbowaliśmy dociągnąć z zewnątrz

- Wikipedia (zainteresowanie marką), Wikidata (dane o firmie), szum wokół marki w strumieniu, kalendarz, wielkość marki
- ponowne odczyty wyświetleń i reakcji (X, YouTube, TikTok), brakujące lajki YouTube
- konta tych samych autorów na innych platformach: za mało dopasowań (5–17 postów, potrzeba 40)
- TikTok Research API: wymaga wniosku akademickiego, nie użyte

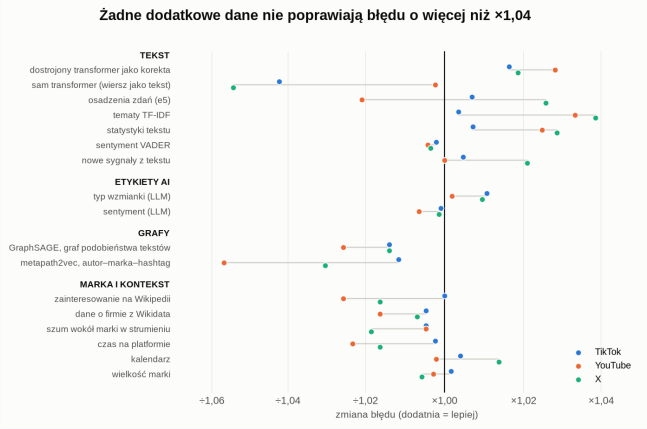
Żadne dodatkowe źródło nie poprawia błędu o więcej niż $\times 1{,}04$.

Zapas: czego model potrzebuje



Co widać: typowy błąd (oś pionowa) przy różnych zestawach pól; A: FB i IG (model z X + YT), B: TT, YT, X, gdy brakuje pól. Kluczowe: lajki odczytane w tej samej chwili co wyświetlenia. Same komentarze: $\times 6{,}3$–$\times 7{,}4$.

Zapas: dodatkowe dane, ile zmieniły błąd



Co widać: jeden punkt to zmiana błędu po dodaniu źródła (oś pozioma, w prawo = lepiej) dla TT, YT, X; żadne źródło nie daje więcej niż $\times 1{,}04$.

Zapas: modele na tej samej platformie (TikTok, YouTube, X)

Model (ta sama platforma, typowy błąd)	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	×4,60	×8,79	×4,65
stały mnożnik obserwujących	×8,30	×7,16	×7,57
stały mnożnik lajków	×2,23	×4,06	×3,63
Modele liniowe i jądrowe			
regresja liniowa (ridge)	×1,89	×3,51	×3,07
k najbliższych sąsiadów (kNN)	×1,92	×3,04	×3,09
SVR z jądrem RBF	×1,87	×2,90	×3,02
Drzewa decyzyjne			
las losowy	×1,88	×2,90	×2,97
extra trees	×1,88	×2,88	×2,99
gradient boosting (scikit-learn)	×1,89	×2,84	×2,98
LightGBM	×1,88	×2,86	×2,99
XGBoost	×1,87	×2,82	×2,93
CatBoost (model końcowy)	×1,87	×2,83	×2,95
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	×1,89	×2,84	×3,00
GraphSAGE (graf podobnych tekstów)	×1,90	×2,93	×2,98
dostrojony transformer	×1,95	×2,84	×3,09
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	×1,85	×2,77	×2,92
TabICL	×1,87	×2,79	×2,92
Zespoły modeli			
średnia 3 najlepszych rodzin	×1,86	×2,79	×2,94
stos wszystkich rodzin	×1,82	×2,66	×2,76

Walidacja tylko po markach, 8 pól, strojenie zagnieżdżone; dlatego liczby nieco niższe niż w wynikach głównych (po markach i autorach). Stos nie jest modelem końcowym: zysk ×1,03–×1,07, kilkanaście modeli, TabPFN ok. 150× wolniejszy.

Zapas: siatka platform treningowych (ridge na 2 polach)

Trening na	TikTok	YouTube	X	Facebook	Instagram	Stack Exchange
ridge, ta sama platforma	1,99	4,15	3,30	2,42	2,41	1,77
YT	**2,00**	trening	4,64	2,72	2,63	1,87
FB	2,30	4,26	**3,60**	trening	**2,47**	3,32
IG	2,46	4,50	4,06	2,48	trening	2,46
TT	trening	**4,07**	4,15	2,61	2,59	2,41
X	3,38	5,52	trening	3,07	2,74	4,50
X + YT	2,05	trening	trening	**2,43**	2,72	3,14
TT + YT + X	trening	trening	trening	2,49	2,69	3,08
YT + X + FB + IG	2,12	trening	trening	trening	trening	3,25
TT + YT + X + IG	trening	trening	trening	2,46	trening	3,07
TT + YT + X + FB	trening	trening	trening	trening	2,66	3,08
TT + X + FB + IG	trening	4,08	trening	trening	trening	4,24
TT + YT + FB + IG	trening	trening	4,37	trening	trening	2,11

Ridge na 2 polach (lajki, komentarze), walidacja po markach (nie po markach i autorach). Typowy błąd (×); szare = trening. Mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65, czyli nie zależy od wyboru X + YT.

Stack Exchange (538 pytań) nigdy nie jest w treningu: najlepszy z samego YouTube ×1,87, własny ridge SE ×1,77; każdy zestaw z X daje ×3–×5.

Zapas: modele poza platformą (Facebook, Instagram)

Metoda (typowy błąd)	Facebook	Instagram
Proste reguły		
mediana z X + YT	×19,87	×8,69
mnożnik lajków	×2,42	×2,94
Modele (trening X + YouTube)		
regresja ridge (nasz)	**×2,43**	**×2,72**
MLP	×2,47	×2,78
CatBoost	×2,61	×2,95
Augmentacja		
CatBoost + trend	×2,54	×2,96
MLP + trend	×2,46	×2,79
CatBoost + propensity	×2,49	×2,89
MLP + propensity	×2,42	×2,75
CatBoost + mixup	×2,58	×2,95
MLP + mixup	×2,46	×2,76
Odniesienie (używa etykiet platformy docelowej)		
ridge uczony na samej platformie (CV po markach)	×2,42	×2,41

Wszystkie modele: 2 pola (lajki, komentarze), trening tylko na X + YouTube, nigdy na FB/IG. Złożone modele i augmentacja nie dają wyraźnej poprawy względem prostej regresji; mnożnik lajków jest na FB prawie tak samo dobry. Ridge uczony na samej platformie ma IG 72% rolek niedoszacowanych; z TikTokiem w treningu (TT + YT + X): FB ×2,49, IG ×2,69; TikTok jako dodatkowy test ×2,05.

Zapas: klasyfikacja i próby naprawy skrajnych postów

Klasyfikacja: <1k / 1–10k / >10k

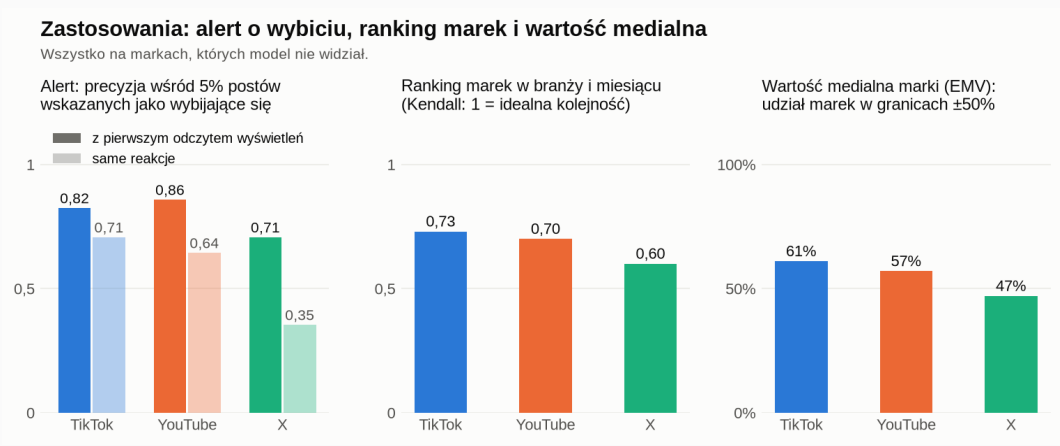
	TT	YT	X
trafny przedział	82%	80%	95%
zgadywanie najczęstszego	59%	63%	95%
trafność zrównoważona	77%	72%	43%
prawdopodobieństwo (AUC; 0,5 = losowo, 1 = idealnie)			
czy to duży post (top 20%)	0,97	0,92	0,84
czy to mały post (dół 20%)	0,93	0,92	0,79

Klasyfikacja działa na TT i YT; na X 95% postów ma <1k, więc 95% to zgadywanie.

Jak próbowaliśmy poprawić duże i małe posty

- **cel „wyświetlenia na lajk”** → prawie bez zmian
- **większa waga skrajnych postów** → bez zmian
- **inne funkcje błędu** (RMSE, kwantyl) → duże posty nadal zaniżone
- **osobny model dla postów bez reakcji** → bez zysku
- **korekta wyniku po fakcie** → bez poprawy

Zapas: trzy zastosowania (TT, YT, X)



Precyzja alertu o wybiciu (5% postów), zgodność rankingu marek (Kendall), udział marek w $\pm 50\%$ wartości medialnej.

Zapas: obserwujący IG i sumy marek

Obserwujący IG

	lajki + koment.	+ obserwujący
ridge na samym IG	$\times$2,40	$\times$2,23
transfer X+YT $\rightarrow$ IG	$\times$2,72	$\times$4,58

Obserwujący pomagają na samym IG, ale psują przenoszenie z X + YT: obserwujący na X/YT oznaczają inny poziom wyświetleń niż na IG.

Sumy marek

Po jednej korekcie błąd sumy marki: $\times$1,7 / $\times$2,0 / $\times$2,1.