Szacowanie ukrytych wyświetleń postów z reakcji

Przeniesienie modelu między platformami

Zespół projektu AMC

Politechnika Wrocławska

Pytanie badawcze

Czy da się oszacować widoczność (wyświetlenia) postów w mediach społecznościowych?

Problem

TikTok, YouTube, X: wyświetlenia są w eksporcie.

Facebook, Instagram: nie widać ich; Brand24 daje tylko „zasięg" z reguły (porównanie na końcu).

Pytanie szczegółowe

Czy model, który nigdy nie widział wyświetleń z FB i IG, oszacuje je z lajków i komentarzy?

Dane: 348 marek, 5 platform

Platforma	Skrót	Marki	Autorzy	Źródło wyśw.	Posty z wyśw.	Mediana wyśw.	Wyśw./lajk
TikTok	TT	266	2 411	eksport Brand24	2 491	729	25
YouTube	YT	273	2 041	eksport Brand24	2 441	433	26
X	X	252	1 658	eksport Brand24	1 803	27	22
Facebook	FB	20	$\geq$182	nasz odczyt, filmy	402	1 413	35
Instagram	IG	11	541	nasz odczyt, rolki	642	504	53

Eksport: 12 500 wzmianek, 2 500 na platformę. Do tego Stack Exchange: 538 pytań z publicznego API, 48 marek, tylko test na innej platformie.

FB i IG: wyświetlenia odczytane przez nas, **tylko do oceny**; zwykłe posty nie mają licznika. IG: właściciel znany dla 627 z 642 rolek. Pełna tabela braków w eksporcie: zapas.

Dane dodane przez nas i protokół

Źródło	Co	Ile	Do czego
Facebook	wyświetlenia filmów	402 z 470 (68 usuniętych)	ocena poza platformą
Instagram	wyświetlenia rolek	642 z 976 (261 usuniętych, 19 bez licznika, 54 z ukrytymi lajkami)	ocena poza platformą
X, YouTube, TikTok	ponowny odczyt wyśw. i reakcji	2 013 / 1 376 / 426 postów	prawdziwe etykiety
Stack Exchange	pytania z publicznego API	538 pytań, 48 marek	test na innej platformie
Instagram	właściciele rolek	627 rolek (541 autorów)	autorzy w walidacji

Jak zbieraliśmy i dzieliliśmy dane

- FB/IG: wyświetlenia i reakcje odczytane razem, w tej samej chwili (nasz ponowny odczyt)
- historia autora: tylko wcześniejsze posty tego autora
- zestaw treningowy X + YT ustalony z góry z podobieństwa reakcji, nie z wyników FB/IG

Eksport Brand24 jest nieaktualny w poziomie, stabilny w rankingu; ponowne odczyty to punkt odniesienia. Dane wyprowadzone i próbowane: zapas.

Metoda

Ta sama platforma

TikTok, YouTube, X

CatBoost na 8 polach:

`log(1+obserwujący)`, `log(1+lajki)`, `log(1+komentarze)`, `log(1+udostępnienia)` + 4 flagi „pole puste” (obserwujący, lajki, komentarze, udostępnienia)

test na markach i autorach, których model nie widział

Poza platformą

Facebook, Instagram

ridge na 2 polach:

`log(1+lajki)`, `log(1+komentarze)` (jedyne, które ma każda platforma)

uczony tylko na X + YouTube

Inne metody (MLP, CatBoost, augmentacje) nie pobiły ridge (zapas)

Dane zewnętrzne

nasz odczyt wyświetleń FB/IG, nigdy w treningu

inna platforma: Stack Exchange

Cel: $\log_{10}$(wyświetlenia). Nie używamy tekstu, etykiet AI, kraju ani czasu (nie poprawiały wyniku).

Jak czytać wyniki

Typowy błąd $\times 10^{\mathbf{MAE}}$

MAE = średnia
$|\log_{10}(\text{oszacowanie}) - \log_{10}(\text{prawda})|$.

Przykład: $\times 2$ znaczy, że post z 1 000 wyświetleń jest zwykle oszacowany gdzieś między 500 a 2 000.

W granicach $\times 2$

Udział postów, dla których oszacowanie jest w zakresie 2 razy w górę lub w dół od prawdy.

Zbiór testowy

Marki i autorzy, których model nie widział w treningu.

Dwa proste odniesienia

stała mediana: ten sam szacunek dla każdego posta;
mnożnik lajków: wyświetlenia = $k\times$ lajki.

Wyniki: ta sama platforma

	CatBoost (MAE)	W granicach $\times 2$	Stała mediana	Mnożnik lajków
TikTok	$\times$**1,87** (0,273)	67%	$\times$4,60	$\times$2,23
YouTube	$\times$**2,90** (0,462)	43%	$\times$8,77	$\times$4,06
X	$\times$**3,03** (0,482)	40%	$\times$4,63	$\times$3,63

Walidacja po markach i autorach, 8 pól. Test na markach i autorach, których model nie widział.

CatBoost lepszy od mnożnika lajków o 0,075–0,147 MAE; przedziały ufności wykluczają zero.

Dlaczego nie stos wszystkich modeli ($\times$1,82 / $\times$2,66 / $\times$2,76)?

Zysk to tylko $\times$1,03–$\times$1,07; trzeba utrzymywać kilkanaście modeli (TabPFN jest ok. 150$\times$ wolniejszy); przedziały i przenoszenie opieramy na jednym modelu. Tabela modeli (walidacja tylko po markach, 8 pól, stąd liczby nieco niższe): zapas.

Wyniki: poza platformą (Facebook, Instagram)

	Ridge X+YT (MAE)	Przedział ufn.	W gr. ×2	Mediana X+YT	Mnożnik lajków
Facebook (402 filmy, 20 marek)	**×2,43** (0,385)	×2,08–×2,99	53%	×19,87	×2,42
Instagram (642 rolki, 11 marek)	**×2,72** (0,435)	×2,48–×3,03	40%	×8,69	×2,94

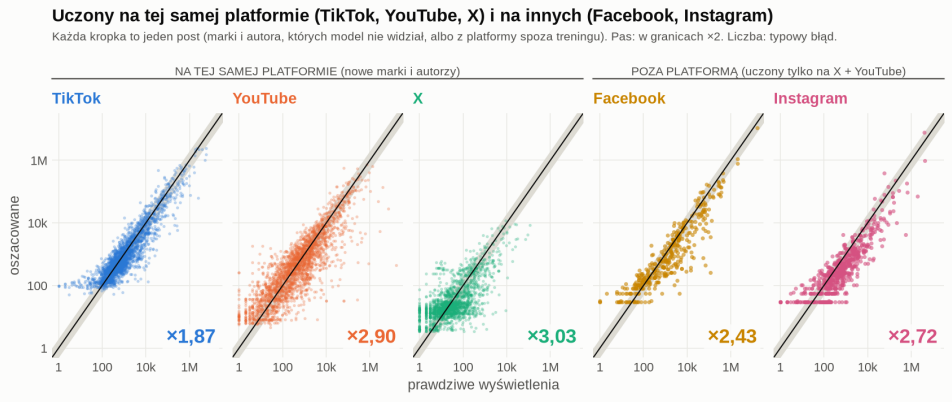
Ridge uczony tylko na X + YouTube, 0 postów z FB/IG w treningu. Przedział: bootstrap po markach (95%), dla typowego błędu. Mało marek, więc wynik kruchy.

Co się przenosi: stosunek wyświetleń do reakcji. Na FB ridge (×2,43) ≈ prosty mnożnik lajków (×2,42), różnica nieistotna. Ridge pomaga na TikToku, IG i Stack Exchange, nie na FB.

Ridge uczony na samej platformie: FB ×2,42, IG ×2,41. IG: 72% rolek niedoszacowanych.

Zestaw X + YT ustaliliśmy z góry z podobieństwa reakcji (IG podobny do X i YT, nie do TT), nie z wyników FB/IG. Z TikTokiem (TT + YT + X): FB ×2,49, IG ×2,69; TikTok zostaje też jako dodatkowy test (×2,05).

Oszacowane a prawdziwe wyświetlenia



Co widać: jedna kropka to jeden post; oś pozioma to prawdziwe wyświetlenia, pionowa oszacowane (skala log); szary pas = w granicach $\times 2$, liczba = typowy błąd.

Czy to więcej niż mnożnik lajków?

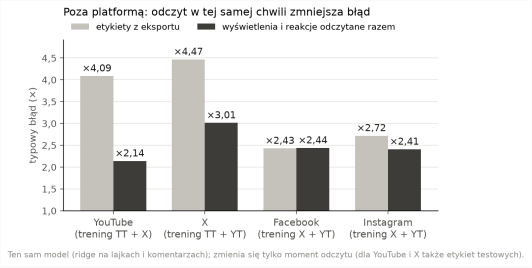
Cel	Trening na	Regresja	Mnożnik lajków	Różnica MAE [95% CI]	Mediana źródła
TikTok	X + YT	**×2,05**	×2,22	−0,034 [−0,038; −0,029]	×11,0
YouTube	TT + X	×4,09	**×4,02**	+0,007 [0,002; 0,011]	×9,0
X	TT + YT	×4,47	**×3,42**	+0,116 [0,094; 0,137]	×21,8
Facebook	X + YT	×2,43	×2,42	+0,002 [−0,017; 0,022]	×19,9
Instagram	X + YT	**×2,72**	×2,94	−0,034 [−0,047; −0,020]	×8,7
Stack Exchange	X + YT	×3,14	×5,33	−0,229 [−0,240; −0,207]	**×2,1**

Ridge na 2 polach (lajki, komentarze), walidacja po markach; trening tylko na platformach z eksportu, nigdy na FB/IG. Różnica MAE: regresja minus mnożnik (ujemna = regresja lepsza).

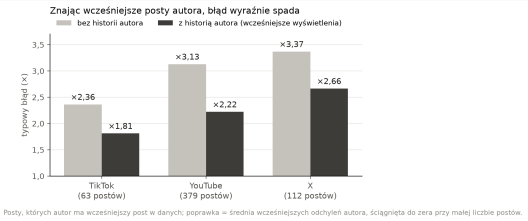
Regresja lepsza na TikToku, IG i Stack Exchange, bez różnicy na FB, gorsza na YouTube (nieznacznie) i X (62% postów bez lajka). Stack Exchange: gorzej niż mediana przy treningu z X; z samego YouTube ×1,87.

Wybór platform treningowych (siatka 5 platform): zapas; mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65, więc nie zależy od wyboru X + YT.

Od czego zależy błąd: czas i historia autora



Co widać: typowy błąd (oś pionowa) bez i z odczytem wyświetleń i reakcji w tej samej chwili; to ten sam model, zmienia się tylko moment odczytu.



Co widać: typowy błąd bez i z historią autora (tylko jego wcześniejsze posty z wyświetleniami), TT, YT, X; w nawiasie liczba postów z historią.

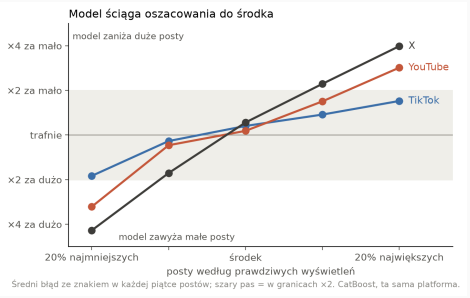
Trening na wcześniejszych miesiącach i test na późniejszych daje ten sam błąd co walidacja po markach: brak dryfu w czasie. Liczy się, by wyświetlenia i reakcje były odczytane razem. Autorzy mają stały poziom wyświetleń, którego nie widać z reakcji; w danych historię ma tylko 3–16% postów.

Od czego zależy błąd: liczba reakcji i wielkość posta

Typowy błąd (×) wg liczby reakcji (TT, YT, X)

	TT	YT	X
0 reakcji	×3,23 3%	×4,59 27%	×3,19 54%
1–5 reakcji	×2,01 13%	×2,91 19%	×2,96 36%
6–100 reakcji	×1,75 53%	×2,45 32%	×2,57 9%
ponad 100 reakcji	×1,92 30%	×2,08 22%	×2,51 1%
wszystkie posty	×1,87	×2,90	×3,03
bez postów z 0 reakcji	×1,84 97%	×2,44 73%	×2,86 46%
bez postów z ≤5 reakcjami	**×1,81** 83%	**×2,29** 54%	**×2,56** 10%

szare: udział postów; reakcje = lajki + komentarze + udostępnienia

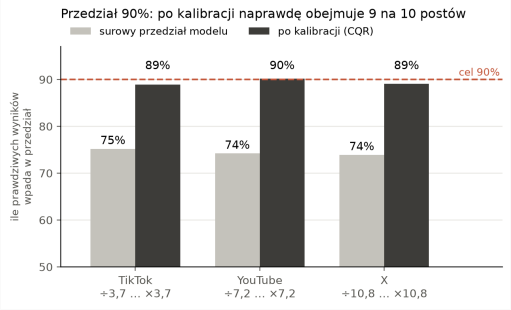


Co widać: średni błąd ze znakiem w piątkach postów (oś pozioma: od 20% najmniejszych do 20% największych); model zawyża małe i zaniża duże.

Mało reakcji = za mało danych: posty z 0 reakcji mają błąd ×3–×4,6; na X 70% postów bez lajka. Bez postów z ≤5 reakcjami błąd spada, ale na X zostaje tylko 10% postów. Próby naprawy skrajności i klasyfikacja: zapas.

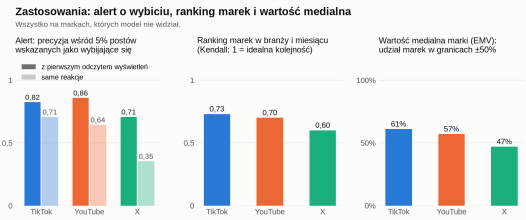
Walidacja i kalibracja: dlaczego ufamy wynikom

- **Podział:** foldy łączą posty tej samej marki, autora lub identycznego tekstu; test na nieznanej marce i autorze
- **Przedziały ufności:** bootstrap po markach; sparowany dla różnic modeli
- **Odniesienia:** zawsze mediana i mnożnik lajków
- **Spoza treningu:** nasze odczyty FB/IG; leave-platform-out: każdą z 5 platform ukrywamy po kolei
- **Test w czasie:** MAE TikTok 0,270, YouTube 0,450, X 0,473, blisko walidacji po markach
- **Kalibracja:** surowy przedział 90% trafia w 3 z 4 posty; po CQR w 9 z 10 (87–91%), kosztem szerokości: na X od $\div 11$ do $\times 11$
- Sumy marek: po jednej korekcie błąd $\times 1{,}7$ / $\times 2{,}0$ / $\times 2{,}1$



Co widać: jaki procent prawdziwych wyświetleń wpada w przedział 90% (oś pionowa), przed i po kalibracji, TT, YT, X; pod nazwą szerokość przedziału.

Zastosowania i porównanie z kolumną zasięgu (X)



Co widać: trzy zastosowania na TT, YT, X: precyzja alertu o wybiciu (5% postów), zgodność rankingu marek (Kendall), udział marek w $\pm 50\%$ wartości medialnej.



Co widać: te same 1 803 posty z X; po lewej typowy błąd (skala log), po prawej udział w granicach $\times 2$. Zasięg to inna miara niż wyświetlenia: pokazujemy, jak daleko od nich jest liczba, którą klient dostaje dziś.

Co dalej: czego nie zrobiliśmy

Dane

- więcej marek na FB i IG (teraz 20 i 11)
- usunięte posty (IG 27%, FB 14%) mogą przekrzywiać ocenę
- zwykłe posty FB/IG, nie tylko filmy i rolki
- inne platformy (Reddit, LinkedIn)

Etykiety i zastosowanie

- ludzka weryfikacja etykiet AI: zgodność modeli κ 0,71–0,79, brak ludzkiego wzorca
- praktyczny przykład sumy marki na FB/IG

Nowy wynik: obserwujący IG

	lajki + koment.	+ obserwujący
ridge na samym IG	$\times$2,40	$\times$2,23
transfer X+YT $\rightarrow$ IG	$\times$2,72	$\times$4,58

Obserwujący pomagają na samym IG, ale psują przenoszenie z X + YT.

Ograniczenia i wnioski

Ograniczenia

- mało marek: FB 20, IG 11, wynik kruchy
- wiek odczytu: eksport 23 dni, nasz odczyt FB/IG 310–334 dni
- tylko dostępne filmy i rolki
- X: regresja gorsza od stałego mnożnika lajków
- korelacja, nie przyczynowość

Wnioski

1. Ridge na lajkach i komentarzach, uczony tylko na X i YouTube, szacuje FB z błędem $\times 2{,}43$, IG $\times 2{,}72$; mediana myli się $\times 9$–$\times 20$
2. Przenosi się stosunek wyświetleń do reakcji; prosty mnożnik lajków jest na FB prawie tak samo dobry ($\times 2{,}42$); ridge pomaga na TikToku, IG i Stack Exchange
3. Reakcje muszą być odczytane razem z wyświetleniami
4. Stack Exchange: gorzej niż mediana przy treningu z X; z samego YouTube $\times 1{,}87$

Zapas: braki w eksporcie Brand24

12 500 wzmianek, 2 500 na platformę, 19 kolumn (tabela: 18 poza `platform`). **Puste wartości** w każdej kolumnie, udział na platformie; pomarańczowe: braki $\geq 25\%$. `b24_estimated_reach` to „zasięg" Brand24.

kolumna	TikTok	YouTube	X	Facebook	Instagram
`mention_id`	0%	0%	0%	0%	0%
`url`	0%	0%	0%	0%	0%
`created_at`	0%	0%	0%	0%	0%
`metrics_updated_at`	0%	0%	0%	0%	0%
`brand`	0%	0%	0%	0%	0%
`language`	0%	0%	0%	0%	0%
`country`	4%	19%	**81%**	**79%**	**81%**
`title`	0%	0%	**100%**	0%	0%
`content`	0%	0%	0%	0%	0%
`author_name`	0%	0%	0%	**27%**	**92%**

kolumna	TikTok	YouTube	X	Facebook	Instagram
`author_url`	0%	0%	0%	**27%**	**92%**
`author_followers`	0%	0%	0%	**27%**	**92%**
`view_count`	0%	1%	**25%**	**100%**	**100%**
`likes`	0%	5%	0%	0%	0%
`comments`	0%	9%	**69%**	0%	0%
`shares`	0%	**41%**	0%	0%	**100%**
`sentiment`	11%	11%	9%	**90%**	**90%**
`b24_estimated_reach`	0%	0%	0%	0%	0%
`likes` $= 0$	4%	**26%**	**70%**	**30%**	**46%**

`likes` $= 0$: lajk wpisany jako zero (na X często brak, a nie prawdziwe zero).

Zapas: dane wyprowadzone i próbowane

Wyprowadzone z tekstu i metadanych

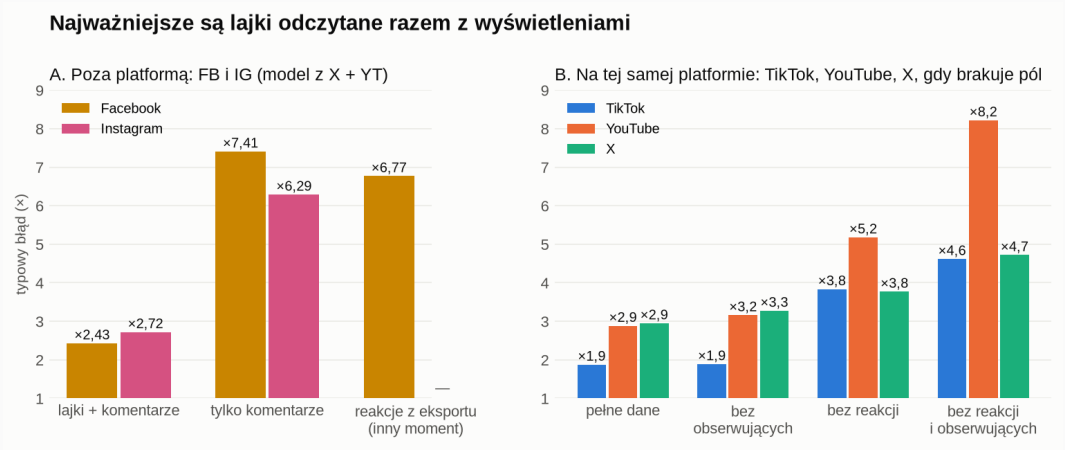
- typ wzmianki i sentyment z modelu językowego (etykiety AI): zgodność 3 przebiegów κ 0,77–0,79 (typ), 0,71–0,73 (sentyment); brak ludzkiego wzorca
- czy wzmianka jest o marce: 6,7% bez nazwy marki w tekście
- tekst: TF-IDF, osadzenia zdań e5, statystyki tekstu, sentyment VADER
- grafy: podobieństwo tekstów (GraphSAGE), autor–marka–hashtag (metapath2vec)

Próbowaliśmy dociągnąć z zewnątrz

- Wikipedia (zainteresowanie marką), Wikidata (dane o firmie), szum wokół marki w strumieniu, kalendarz, wielkość marki
- ponowne odczyty wyświetleń i reakcji (X, YouTube, TikTok), brakujące lajki YouTube
- konta tych samych autorów na innych platformach: za mało dopasowań (5–17 postów, potrzeba 40)
- TikTok Research API: wymaga wniosku akademickiego, nie użyte

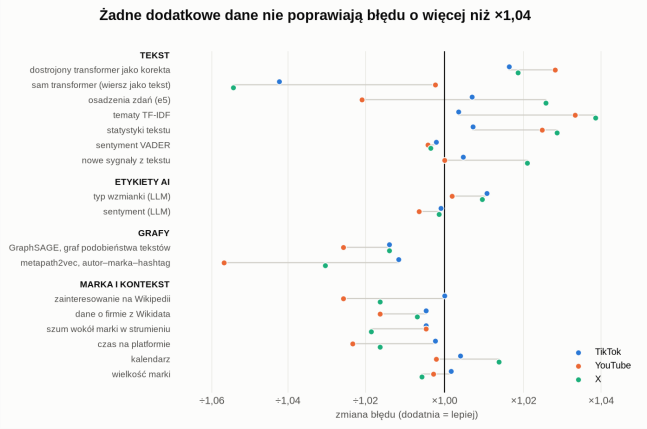
Żadne dodatkowe źródło nie poprawia błędu o więcej niż $\times 1{,}04$.

Zapas: czego model potrzebuje



Co widać: typowy błąd (oś pionowa) przy różnych zestawach pól; A: FB i IG (model z X + YT), B: TT, YT, X, gdy brakuje pól. Kluczowe: lajki odczytane w tej samej chwili co wyświetlenia. Same komentarze: $\times 6{,}3$–$\times 7{,}4$.

Zapas: dodatkowe dane, ile zmieniły błąd



Co widać: jeden punkt to zmiana błędu po dodaniu źródła (oś pozioma, w prawo = lepiej) dla TT, YT, X; żadne źródło nie daje więcej niż $\times 1{,}04$.

Zapas: modele na tej samej platformie (TikTok, YouTube, X)

Model (ta sama platforma, typowy błąd)	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	×4,60	×8,79	×4,65
stały mnożnik obserwujących	×8,30	×7,16	×7,57
stały mnożnik lajków	×2,23	×4,06	×3,63
Modele liniowe i jądrowe			
regresja liniowa (ridge)	×1,89	×3,51	×3,07
k najbliższych sąsiadów (kNN)	×1,92	×3,04	×3,09
SVR z jądrem RBF	×1,87	×2,90	×3,02
Drzewa decyzyjne			
las losowy	×1,88	×2,90	×2,97
extra trees	×1,88	×2,88	×2,99
gradient boosting (scikit-learn)	×1,89	×2,84	×2,98
LightGBM	×1,88	×2,86	×2,99
XGBoost	×1,87	×2,82	×2,93
CatBoost (model końcowy)	×1,87	×2,83	×2,95
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	×1,89	×2,84	×3,00
GraphSAGE (graf podobnych tekstów)	×1,90	×2,93	×2,98
dostrojony transformer	×1,95	×2,84	×3,09
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	×1,85	×2,77	×2,92
TabICL	×1,87	×2,79	×2,92
Zespoły modeli			
średnia 3 najlepszych rodzin	×1,86	×2,79	×2,94
stos wszystkich rodzin	×1,82	×2,66	×2,76

Walidacja tylko po markach, 8 pól, strojenie zagnieżdżone; dlatego liczby nieco niższe niż w wynikach głównych (po markach i autorach). Stos nie jest modelem końcowym: zysk ×1,03–×1,07, kilkanaście modeli, TabPFN ok. 150× wolniejszy.

Zapas: siatka platform treningowych (ridge na 2 polach)

Trening na	TikTok	YouTube	X	Facebook	Instagram	Stack Exchange
ridge, ta sama platforma	1,99	4,15	3,30	2,42	2,41	1,77
YT	**2,00**	trening	4,64	2,72	2,63	1,87
FB	2,30	4,26	**3,60**	trening	**2,47**	3,32
IG	2,46	4,50	4,06	2,48	trening	2,46
TT	trening	**4,07**	4,15	2,61	2,59	2,41
X	3,38	5,52	trening	3,07	2,74	4,50
X + YT	2,05	trening	trening	**2,43**	2,72	3,14
TT + YT + X	trening	trening	trening	2,49	2,69	3,08
YT + X + FB + IG	2,12	trening	trening	trening	trening	3,25
TT + YT + X + IG	trening	trening	trening	2,46	trening	3,07
TT + YT + X + FB	trening	trening	trening	trening	2,66	3,08
TT + X + FB + IG	trening	4,08	trening	trening	trening	4,24
TT + YT + FB + IG	trening	trening	4,37	trening	trening	2,11

Ridge na 2 polach (lajki, komentarze), walidacja po markach (nie po markach i autorach). Typowy błąd (×); szare = trening. Mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65, czyli nie zależy od wyboru X + YT.

Stack Exchange (538 pytań) nigdy nie jest w treningu: najlepszy z samego YouTube ×1,87, własny ridge SE ×1,77; każdy zestaw z X daje ×3–×5.

Zapas: modele poza platformą (Facebook, Instagram)

Metoda (typowy błąd)	Facebook	Instagram
Proste reguły		
mediana z X + YT	×19,87	×8,69
mnożnik lajków	×2,42	×2,94
Modele (trening X + YouTube)		
regresja ridge (nasz)	**×2,43**	**×2,72**
MLP	×2,47	×2,78
CatBoost	×2,61	×2,95
Augmentacja		
CatBoost + trend	×2,54	×2,96
MLP + trend	×2,46	×2,79
CatBoost + propensity	×2,49	×2,89
MLP + propensity	×2,42	×2,75
CatBoost + mixup	×2,58	×2,95
MLP + mixup	×2,46	×2,76
Odniesienie (używa etykiet platformy docelowej)		
ridge uczony na samej platformie (CV po markach)	×2,42	×2,41

Wszystkie modele: 2 pola (lajki, komentarze), trening tylko na X + YouTube, nigdy na FB/IG. Złożone modele i augmentacja nie dają wyraźnej poprawy względem prostej regresji; mnożnik lajków jest na FB prawie tak samo dobry.

Zapas: klasyfikacja i próby naprawy skrajnych postów

Klasyfikacja: <1k / 1–10k / >10k

	TT	YT	X
trafny przedział	82%	80%	95%
zgadywanie najczęstszego	59%	63%	95%
trafność zrównoważona	77%	72%	43%
prawdopodobieństwo (AUC; 0,5 = losowo, 1 = idealnie)			
czy to duży post (top 20%)	0,97	0,92	0,84
czy to mały post (dół 20%)	0,93	0,92	0,79

Klasyfikacja działa na TT i YT; na X 95% postów ma <1k, więc 95% to zgadywanie.

Jak próbowaliśmy poprawić duże i małe posty

- **cel „wyświetlenia na lajk”** → prawie bez zmian
- **większa waga skrajnych postów** → bez zmian
- **inne funkcje błędu** (RMSE, kwantyl) → duże posty nadal zaniżone
- **osobny model dla postów bez reakcji** → bez zysku
- **korekta wyniku po fakcie** → bez poprawy