Szacowanie ukrytych wyświetleń postów z reakcji

Przeniesienie modelu między platformami

Zespół projektu AMC

Politechnika Wrocławska

Pytanie badawcze

Czy da się oszacować widoczność (wyświetlenia) postów w mediach społecznościowych?

Problem

TikTok, YouTube, X: wyświetlenia są w eksporcie.

Facebook, Instagram: nie widać ich; Brand24 daje tylko „zasięg" z reguły.

Pytanie szczegółowe

Czy model, który nigdy nie widział wyświetleń z FB i IG, oszacuje je z lajków i komentarzy?

Eksport Brand24: co jest w danych i czego brakuje

12 500 wzmianek, 2 500 na platformę, 19 kolumn (tabela: 18 poza `platform`). **Puste wartości** w każdej kolumnie, udział na platformie; pomarańczowe: braki $\geq 25\%$. `b24_estimated_reach` to „zasięg" Brand24.

kolumna	TikTok	YouTube	X	Facebook	Instagram
`mention_id`	0%	0%	0%	0%	0%
`url`	0%	0%	0%	0%	0%
`created_at`	0%	0%	0%	0%	0%
`metrics_updated_at`	0%	0%	0%	0%	0%
`brand`	0%	0%	0%	0%	0%
`language`	0%	0%	0%	0%	0%
`country`	4%	19%	**81%**	**79%**	**81%**
`title`	0%	0%	**100%**	0%	0%
`content`	0%	0%	0%	0%	0%
`author_name`	0%	0%	0%	**27%**	**92%**

kolumna	TikTok	YouTube	X	Facebook	Instagram
`author_url`	0%	0%	0%	**27%**	**92%**
`author_followers`	0%	0%	0%	**27%**	**92%**
`view_count`	0%	1%	**25%**	**100%**	**100%**
`likes`	0%	5%	0%	0%	0%
`comments`	0%	9%	**69%**	0%	0%
`shares`	0%	**41%**	0%	0%	**100%**
`sentiment`	11%	11%	9%	**90%**	**90%**
`b24_estimated_reach`	0%	0%	0%	0%	0%
`likes` $= 0$	4%	**26%**	**70%**	**30%**	**46%**

`likes` $= 0$: lajk wpisany jako zero (na X często brak, a nie prawdziwe zero).

Dane: 348 marek, 5 platform

Platforma	Marki	Autorzy	Źródło wyśw.	Posty z wyśw.	Mediana	Wyśw./lajk
TikTok	266	2 411	eksport	2 491	729	25
YouTube	273	2 041	eksport	2 441	433	26
X	252	1 658	eksport	1 803	27	22
Facebook	20	$\geq$182	nasz odczyt, filmy	402	1 413	35
Instagram	11	541	nasz odczyt, rolki	642	504	53

FB i IG: wyświetlenia odczytane przez nas, **tylko do oceny**; zwykłe posty nie mają licznika. IG: właściciel znany dla 627 z 642 rolek.

Jakie dane dodaliśmy sami: pozyskane

Źródło	Co	Ile	Do czego
Facebook	wyświetlenia filmów	402 z 470 (68 usuniętych)	ocena poza platformą
Instagram	wyświetlenia rolek	642 z 976 (261 usuniętych, 19 bez licznika, 54 z ukrytymi lajkami)	ocena poza platformą
X	ponowny odczyt wyśw. i reakcji	2 013 postów	prawdziwe etykiety
YouTube	ponowny odczyt wyśw. i reakcji	1 376 postów	prawdziwe etykiety
TikTok	ponowny odczyt wyśw. i reakcji	426 postów	prawdziwe etykiety
Stack Exchange	pytania z publicznego API, 48 marek	538 pytań	test na innej platformie
Instagram	właściciele rolek	627 rolek (541 autorów)	autorzy w walidacji

Eksport Brand24 jest nieaktualny w poziomie, stabilny w rankingu; ponowne odczyty to punkt odniesienia.

Jakie dane dodaliśmy sami: wyprowadzone i próbowane

Wyprowadzone z tekstu i metadanych

- typ wzmianki i sentyment z modelu językowego (etykiety AI): zgodność 3 przebiegów κ 0,77–0,79 (typ), 0,71–0,73 (sentyment); brak ludzkiego wzorca
- czy wzmianka jest o marce: 6,7% bez nazwy marki w tekście
- tekst: TF-IDF, osadzenia zdań e5, statystyki tekstu, sentyment VADER
- grafy: podobieństwo tekstów (GraphSAGE), autor–marka–hashtag (metapath2vec)

Próbowaliśmy dociągnąć z zewnątrz

- Wikipedia (zainteresowanie marką), Wikidata (dane o firmie), szum wokół marki w strumieniu, kalendarz, wielkość marki
- ponowne odczyty wyświetleń i reakcji (X, YouTube, TikTok), brakujące lajki YouTube
- konta tych samych autorów na innych platformach: za mało dopasowań (5–17 postów, potrzeba 40)
- TikTok Research API: wymaga wniosku akademickiego, nie użyte

Żadne dodatkowe źródło nie poprawia błędu o więcej niż $\times 1{,}04$.

Metoda

Ta sama platforma

TikTok, YouTube, X

CatBoost na 8 polach:

`log(1+obserwujący)`, `log(1+lajki)`, `log(1+komentarze)`, `log(1+udostępnienia)` + 4 flagi „pole puste”

test na markach i autorach, których model nie widział

Poza platformą

Facebook, Instagram

ridge na 2 polach:

`log(1+lajki)`, `log(1+komentarze)` (jedyne, które ma każda platforma)

uczony tylko na X + YouTube

Dane zewnętrzne

nasz odczyt wyświetleń FB/IG, nigdy w treningu

inna platforma: Stack Exchange

Cel: $\log_{10}$(wyświetlenia). Nie używamy tekstu, etykiet AI, kraju ani czasu (nie poprawiały wyniku).
Błąd: typowy błąd 10^{MAE} (MAE na $\log_{10}$ wyświetleń); $\times 2$ = oszacowanie zwykle 2 razy za duże albo za małe

Wyniki: ta sama platforma

	CatBoost (MAE)	W granicach ×2	Stała mediana	Mnożnik lajków	Zasięg Brand24
TikTok	×**1,87** (0,273)	67%	×4,60	×2,23	= wyświetlenia
YouTube	×**2,90** (0,462)	43%	×8,77	×4,06	= wyświetlenia
X	×**3,03** (0,482)	40%	×4,63	×3,63	×11,47

Test na markach i autorach, których model nie widział.

CatBoost lepszy od mnożnika lajków o 0,075–0,147 MAE; przedziały ufności wykluczają zero.

Zasięg Brand24: kolumna zasięgu z eksportu porównana z prawdziwymi wyświetleniami na tych samych postach.

Wyniki: poza platformą

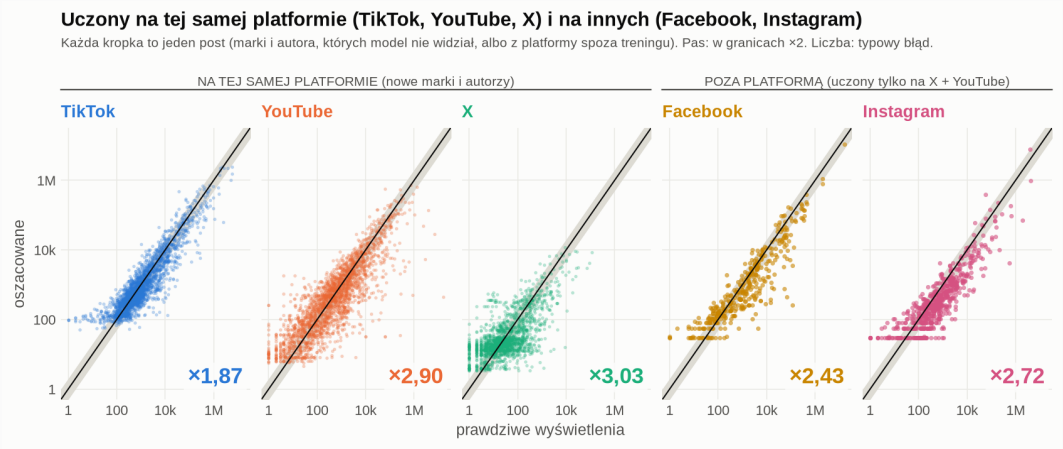
	Ridge X+YT (MAE)	W granicach ×2	Mediana X+YT	Ridge na celu	Zasięg Brand24
Facebook	×**2,43** (0,385)	53%	×19,87	×2,42	×13,14
Instagram	×**2,72** (0,435)	40%	×8,69	×2,41	×26,44

Model uczony tylko na X + YouTube, 0 postów z FB/IG w treningu.
FB: tyle samo co ridge uczony na samym FB. IG: nieco gorzej; 72% rolek niedoszacowanych.
Zasięg Brand24: kolumna zasięgu z eksportu porównana
z prawdziwymi wyświetleniami na tych samych postach.

Zestaw X + YouTube ustaliliśmy z góry: reakcje na IG są podobne do X i YouTube,
a nie do TikToka. Z TikTokiem (TT + YT + X): FB ×2,49, IG ×2,69, czyli prawie bez zmian;

TikTok zostaje też jako dodatkowy test (×2,05).

Oszacowane a prawdziwe wyświetlenia



Czy to więcej niż mnożnik lajków?

Cel	Źródło	Regresja	Mnożnik lajków	Różnica MAE [95% CI]	Mediana źródła
TikTok	X + YT	**×2,05**	×2,22	−0,034 [−0,038; −0,029]	×11,0
YouTube	TT + X	×4,09	**×4,02**	+0,007 [0,002; 0,011]	×9,0
X	TT + YT	×4,47	**×3,42**	+0,116 [0,094; 0,137]	×21,8
Facebook	X + YT	×2,43	×2,42	+0,002 [−0,017; 0,022]	×19,9
Instagram	X + YT	**×2,72**	×2,94	−0,034 [−0,047; −0,020]	×8,7
Stack Exchange	X + YT	×3,14	×5,33	−0,229 [−0,240; −0,207]	**×2,1**

Trening tylko na platformach z eksportu (TT, YT, X), nigdy na FB/IG. Regresja lepsza na 3 celach, bez różnicy na FB, gorsza na YouTube (nieznacznie) i X (62% postów bez lajka).

Czy wynik zależy od wyboru platform treningowych?

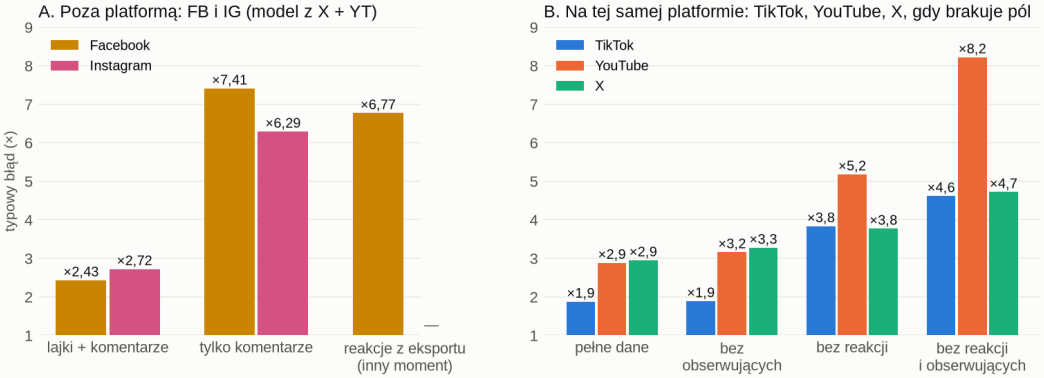
Trening na	TikTok	YouTube	X	Facebook	Instagram
ridge, ta sama platforma	1,99	4,15	3,30	2,42	2,41
YT	**2,00**	trening	4,64	2,72	2,63
FB	2,30	4,26	**3,60**	trening	**2,47**
IG	2,46	4,50	4,06	2,48	trening
TT	trening	**4,07**	4,15	2,61	2,59
X	3,38	5,52	trening	3,07	2,74
X + YT	2,05	trening	trening	**2,43**	2,72
TT + YT + X	trening	trening	trening	2,49	2,69
YT + X + FB + IG	2,12	trening	trening	trening	trening
TT + YT + X + IG	trening	trening	trening	2,46	trening
TT + YT + X + FB	trening	trening	trening	trening	2,66
TT + X + FB + IG	trening	4,08	trening	trening	trening
TT + YT + FB + IG	trening	trening	4,37	trening	trening

Typowy błąd (×); szare = trening. Mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65, czyli nie zależy od wyboru X + YT.

Stack Exchange (538 pytań, 48 marek): ridge z X + YT ×3,14, mnożnik lajków ×5,33, mediana SE ×1,96; przenosi się kolejność (Spearman 0,57), nie poziom.

Czego model potrzebuje

Najważniejsze są lajki odczytane razem z wyświetleniami



Kluczowe: lajki odczytane w tej samej chwili co wyświetlenia. Same komentarze: $\times 6{,}3$–$\times 7{,}4$.

Co testowaliśmy: ta sama platforma

Model (ta sama platforma, typowy błąd)	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	×4,60	×8,79	×4,65
stały mnożnik obserwujących	×8,30	×7,16	×7,57
stały mnożnik lajków	×2,23	×4,06	×3,63
Modele liniowe i jądrowe			
regresja liniowa (ridge)	×1,89	×3,51	×3,07
k najbliższych sąsiadów (kNN)	×1,92	×3,04	×3,09
SVR z jądrem RBF	×1,87	×2,90	×3,02
Drzewa decyzyjne			
las losowy	×1,88	×2,90	×2,97
extra trees	×1,88	×2,88	×2,99
gradient boosting (scikit-learn)	×1,89	×2,84	×2,98
LightGBM	×1,88	×2,86	×2,99
XGBoost	×1,87	×2,82	×2,93
CatBoost (model końcowy)	×1,87	×2,83	×2,95
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	×1,89	×2,84	×3,00
GraphSAGE (graf podobnych tekstów)	×1,90	×2,93	×2,98
dostrojony transformer	×1,95	×2,84	×3,09
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	×1,85	×2,77	×2,92
TabICL	×1,87	×2,79	×2,92
Zespoły modeli			
średnia 3 najlepszych rodzin	×1,86	×2,79	×2,94
stos wszystkich rodzin	×1,82	×2,66	×2,76

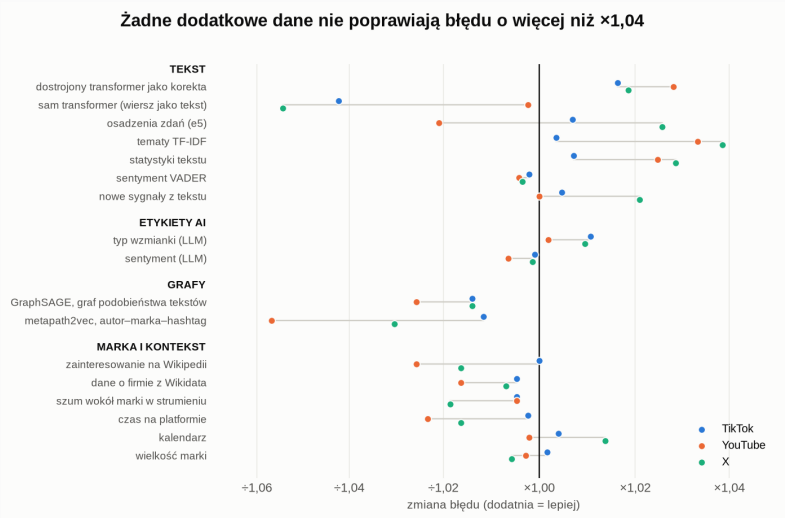
Ponad 20 dodatkowych źródeł (tekst, etykiety AI, grafy, Wikipedia) poprawia błąd najwyżej ×1,04.

Co testowaliśmy: poza platformą (FB, IG)

Metoda (typowy błąd)	Facebook	Instagram
Proste reguły		
mediana z X + YT	×19,87	×8,69
mnożnik lajków	×2,42	×2,94
Modele (trening X + YouTube)		
regresja ridge (nasz)	**×2,43**	**×2,72**
MLP	×2,47	×2,78
CatBoost	×2,61	×2,95
Augmentacja		
CatBoost + trend	×2,54	×2,96
MLP + trend	×2,46	×2,79
CatBoost + propensity	×2,49	×2,89
MLP + propensity	×2,42	×2,75
CatBoost + mixup	×2,58	×2,95
MLP + mixup	×2,46	×2,76
Odniesienie (używa etykiet platformy docelowej)		
ridge uczony na samej platformie (CV po markach)	×2,42	×2,41

Trening tylko na eksporcie X + YouTube, nigdy na FB/IG. Złożone modele i augmentacja nie dają wyraźnej poprawy względem prostej regresji na 2 polach (lajki, komentarze).

Dodatkowe dane: ile zmieniły błąd



Walidacja: dlaczego ufamy wynikom

Podział danych

Foldy łączą posty tej samej marki, tego samego autora lub identycznego tekstu: każdy test na nieznanej marce i autorze.

Przedziały ufności

Bootstrap po markach; sparowany bootstrap dla różnic między modelami.

Zawsze proste odniesienia

Mediana i stały mnożnik lajków.

Dane spoza treningu

Nasze odczyty FB/IG, nigdy nieużyte w uczeniu. Leave-platform-out: każdą z 5 platform ukrywamy po kolei.

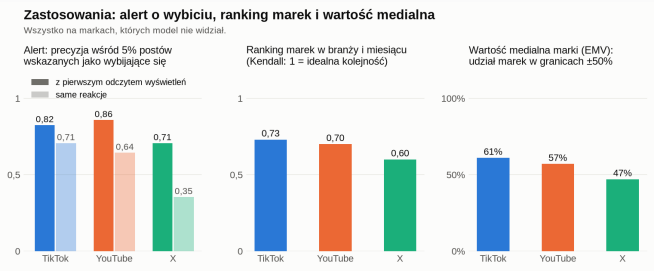
Test w czasie

Trening na wcześniejszych miesiącach, test na późniejszym: MAE TikTok 0,270, YouTube 0,450, X 0,473, blisko walidacji po markach.

Kalibracja

Przedział 90% obejmuje 87–91% postów na tej samej platformie.

Zastosowania i porównanie z kolumną zasięgu (X)





Zasięg to inna miara niż wyświetlenia: pokazujemy, jak daleko od wyświetleń jest liczba, którą klient dostaje dziś.

Ograniczenia i wnioski

Ograniczenia

- mało marek: FB 20, IG 11
- wiek odczytu: eksport 23 dni, nasz odczyt FB/IG 310–334 dni
- tylko dostępne filmy i rolki
- X: regresja gorsza od stałego mnożnika lajków
- korelacja, nie przyczynowość

Wnioski

1. Tak: ridge na lajkach i komentarzach, uczony tylko na X i YouTube, szacuje FB z błędem $\times 2{,}43$, IG $\times 2{,}72$; mediana myli się $\times 9$–$\times 20$
2. Przenosi się stosunek wyświetleń do lajków; reakcje muszą być odczytane razem z wyświetleniami
3. Nie wszędzie: X gorszy od mnożnika, Stack Exchange tylko kolejność