Szacowanie ukrytych wyświetleń postów z reakcji

Przeniesienie modelu między platformami

Zespół projektu AMC

Politechnika Wrocławska

Pytanie badawcze

Czy da się oszacować wyświetlenia filmów i rolek w mediach społecznościowych z lajków i komentarzy?

Problem

TikTok, YouTube, X: wyświetlenia są w eksporcie.

Facebook, Instagram: nie widać ich; Brand24 daje tylko „zasięg" (porównanie na końcu).

Pytanie szczegółowe

Czy model, który nigdy nie widział wyświetleń z FB i IG, oszacuje wyświetlenia filmów FB i rolek IG z lajków i komentarzy?

Odpowiedź w skrócie

Tak, z błędem ok. $\times 2{,}4$ (FB) i $\times 2{,}7$ (IG); wystarcza prosty stosunek wyświetleń do lajków z innych platform.

Dane: 348 marek, 5 platform

Platforma	Skrót	Marki	Autorzy	Źródło wyśw.	Posty z wyśw.	Wyśw./lajk
TikTok	TT	266	2 411	eksport Brand24	2 491	25
YouTube	YT	273	2 041	eksport Brand24	2 441	26
X	X	252	1 658	eksport Brand24	1 803	22
Facebook	**FB**	**20**	**182+ (część bez autora)**	**nasz odczyt, filmy**	**402**	**35**
Instagram	**IG**	**11**	**541**	**nasz odczyt, rolki**	**642**	**53**

Eksport: 12 500 wzmianek, 2 500 na platformę. Do tego Stack Exchange: 538 pytań z publicznego API, 48 marek, tylko test na innej platformie.

Wiersze FB i IG (pogrubione) to cel: wyświetlenia odczytane przez nas, **tylko do oceny**; zwykłe posty nie mają licznika. Pełna tabela braków w eksporcie: zapas.

Dane dodane przez nas i protokół

Źródło	Co	Ile
Facebook	wyświetlenia filmów	402 z 470 (68 usuniętych)
Instagram	wyświetlenia rolek	642 z 976 (261 usuniętych, 19 bez licznika, 54 z ukrytymi lajkami)
X, YouTube, TikTok	ponowny odczyt wyśw. i reakcji	2 013 / 1 376 / 426 postów
Stack Exchange	pytania z publicznego API	538 pytań, 48 marek

Jak zbieraliśmy i dzieliliśmy dane

- FB/IG: wyświetlenia i reakcje odczytane razem, w tej samej chwili; prawda FB/IG = nasz odczyt publicznych stron, niezweryfikowany niezależnie
- historia autora: tylko wcześniejsze posty tego autora
- X + YT wybrane przed oceną FB/IG jako najbardziej podobne w reakcjach; inne zestawy: FB $\times$2,39–$\times$3,07, IG $\times$2,47–$\times$2,82 — wynik zależy od wyboru umiarkowanie

Trzy metody

Mnożnik lajków

wyświetlenia $= k\times$ lajki, jeden parametr k, bez modelu.

Prosty punkt odniesienia; pozostałe modele pytają, czy coś do niego dodają.

TT / YT / X: CatBoost

8 pól: 4 liczby (obserwujący, lajki, komentarze, udostępnienia) + 4 flagi, czy pole puste.

Test: nieznane marki i autorzy tej samej platformy. Górna granica, nie wynik dla FB/IG.

FB / IG: mnożnik i ridge

Mnożnik lajków i **ridge** na 2 polach ($\log(1+\text{lajki})$, $\log(1+\text{komentarze})$), uczone tylko na X + YT.

Test: nasz odczyt FB/IG, nigdy w treningu.

Dodatkowy test: Stack Exchange. Cel: $\log_{10}$(wyświetlenia). Bez tekstu, etykiet AI, kraju i czasu (nie poprawiały wyniku).

Jak czytać wyniki

Typowy błąd $\times 10^{\mathrm{MAE}}$

MAE = średnia $|\log_{10}(\text{oszacowanie}) - \log_{10}(\text{prawda})|$; typowy błąd to 10^{MAE}.

Przykład: $\times 2$ znaczy, że post z 1 000 wyświetleń jest zwykle oszacowany między 500 a 2 000.

Mnożnik lajków k

Wyświetlenia = $k\times$ lajki (post z 0 lajków liczymy jak z 1). k liczymy tylko z platform treningowych, nigdy z celu.

Przykład: $k = 10^{1,393} \approx 25$ (X + YT); 40 lajków $\rightarrow$ 1 000 wyświetleń.

Wyniki: ta sama platforma

	CatBoost (MAE)	W gr. ×2	Ridge (2 pola)	Mnożnik lajków	Stała mediana
TikTok	×**1,87** (0,273)	67%	×1,99	×2,23	×4,60
YouTube	×**2,90** (0,462)	43%	×4,15	×4,06	×8,77
X	×**3,03** (0,482)	40%	×3,30	×3,63	×4,63

W gr. ×2: udział postów oszacowanych w zakresie 2 razy w górę lub w dół od prawdy. Stała mediana: ten sam szacunek dla każdego posta.

W platformie model bije mnożnik, ale głównie dzięki dodatkowym polom

CatBoost jest lepszy od mnożnika o 0,075–0,147 MAE; 95% CI różnicy MAE nie zawiera zera. Ridge na samych 2 polach prawie nie pomaga (TT ×1,99 vs ×2,23, YT ×4,15 vs ×4,06, X ×3,30 vs ×3,63): zysk pochodzi z obserwujących, udostępnień i flag braków, nie z typu modelu. CatBoost na 8 polach to górna granica dla FB/IG — tam tych pól nie ma.

Walidacja po markach i autorach.

Wyniki: poza platformą (Facebook, Instagram)

	Ridge X+YT (MAE)	Przedział	W gr. ×2	Mnożnik
FB (402, 20 marek)	×**2,43** (0,385)	×2,08–×2,99	53%	×2,42
IG (642, 11 marek)	×**2,72** (0,435)	×2,48–×3,03	40%	×2,94

Co się przenosi: stosunek wyświetleń do lajków z X + YT i zmierzony błąd (20 i 11 marek, wynik kruchy)

Ridge i k z X + YT, bez FB/IG w treningu; przedział: bootstrap po markach. Jednoparametrowy mnożnik jest prawie tak samo dobry jak ridge (FB ×2,42 vs ×2,43; IG ×2,94 vs ×2,72). Podanie wszystkim postom tej samej mediany myli się ×9–×20 (FB ×19,87, IG ×8,69).

Uwaga

k z X+YT $\approx$ 25 wyśw./lajk, a na FB 35, na IG 53; IG: 72% rolek niedoszacowanych; wiek odczytu 23 vs 310–334 dni. Po odczycie X+YT w wieku bliższym celom (mediana 137 dni): IG ×2,41, FB ×2,44.

Czy poza platformą potrzebny jest model? Prawie nie

Cel	Trening na	Ridge	Mnożnik	Różnica MAE [95% CI]	Wynik
TikTok	X + YT	**×2,05**	×2,22	−0,034 [−0,038; −0,029]	wygrana
YouTube	TT + X	×4,09	**×4,02**	+0,007 [0,002; 0,011]	porażka (nieznacznie)
X	TT + YT	×4,47	**×3,42**	+0,116 [0,094; 0,137]	porażka
Facebook	X + YT	×2,43	×2,42	+0,002 [−0,017; 0,022]	remis
Instagram	X + YT	**×2,72**	×2,94	−0,034 [−0,047; −0,020]	wygrana
Stack Exchange	X + YT	×3,14	×5,33	−0,229 [−0,240; −0,207]	wygrana, ale zob. niżej

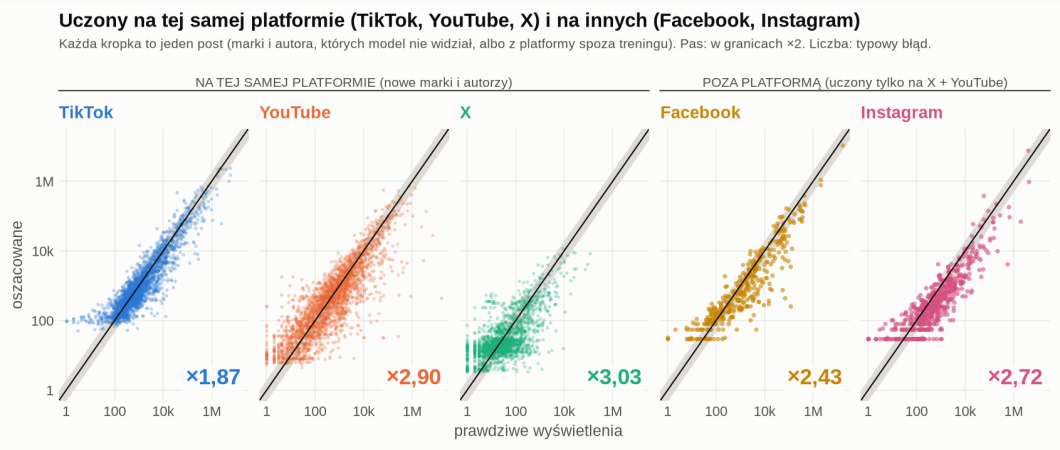
różnica = ridge − mnożnik; minus = ridge lepszy. *k* z platform treningowych, nigdy z celu.

Ridge względem mnożnika: 3 wygrane, 1 remis (FB), 2 porażki; praktycznie istotne (>0,05 MAE): tylko Stack Exchange (lepiej niż mnożnik, ale gorzej od mediany) i X (gorzej).

Stack Exchange: przenoszenie zawodzi

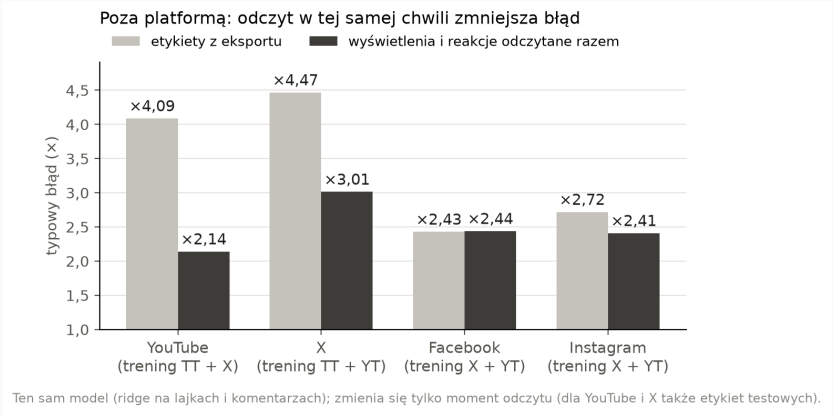
Stała mediana (×2,10) jest lepsza od ridge (×3,14) i mnożnika (×5,33); to pytania i odpowiedzi, nie wideo. Własny ridge SE ×1,77, z samego YouTube ×1,87.

Oszacowane a prawdziwe wyświetlenia



Kropka = post; szary pas = w granicach ×2. IG: 72% rolek niedoszacowanych.

Od czego zależy błąd: odczyt reakcji razem z wyświetleniami



Ten sam model (ridge na lajkach i komentarzach); zmienia się tylko moment odczytu (dla YouTube i X także etykiet testowych).

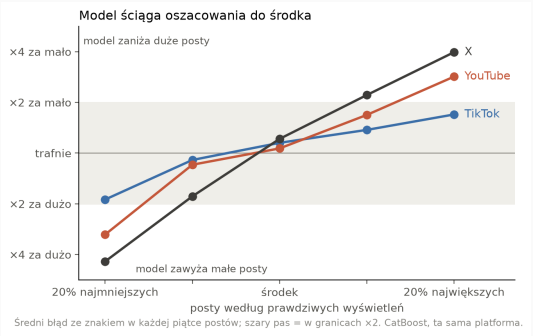
Typowy błąd bez i z odczytem wyświetleń i reakcji w tej samej chwili (ten sam model). Historia autora pomaga tylko tam, gdzie ją mamy (3–16% postów); dla nowych autorów nie pomoże (zapas).

Od czego zależy błąd: liczba reakcji i wielkość posta

Typowy błąd (×) wg liczby reakcji (TT, YT, X)

	TT	YT	X
0 reakcji	×3,23 3%	×4,59 27%	×3,19 54%
6–100 reakcji	×1,75 53%	×2,45 32%	×2,57 9%
wszystkie posty	×1,87	×2,90	×3,03
bez postów z ≤5 reak.	**×1,81** 83%	**×2,29** 54%	**×2,56** 10%

szare: udział postów; reakcje = lajki + komentarze + udostępnienia



Błąd ze znakiem w kwintylach wielkości posta: model zawyża małe i zaniża duże.

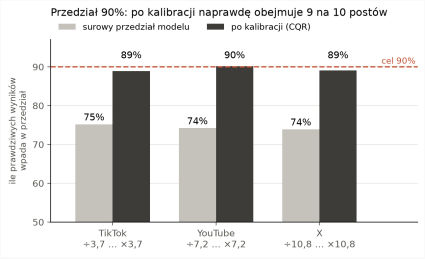
Mało reakcji = za mało danych: 0 reakcji daje błąd ×3–×4,6; na X 62% ocenianych postów bez lajka.

Walidacja i kalibracja przedziałów

Wniosek

Po kalibracji przedział 90% naprawdę obejmuje 9 na 10 postów, ale jest szeroki: na X od 1/11 do $\times 11$ (szacunek 1 000 $\rightarrow$ ok. 90–11 000); na FB od ok. 1/8 do $\times 8$; dla IG nie liczyliśmy.

- **CQR** to korekta, która dopasowuje szerokość przedziału na danych odłożonych: surowy przedział 90% trafia w 3 z 4 posty, po CQR w 9 z 10 (87–91%)
- **FB:** kalibracja na 25% marek FB, pokrycie 0,917, szerokość 1,83 $\log_{10}$
- **Podział:** foldy łączą posty tej samej marki, autora lub tekstu; stała mediana i mnożnik jako odniesienia
- **Czas:** trening na wcześniejszych miesiącach, test 2026-05...08 (MAE TT 0,270, YT 0,450, X 0,473); różnica względem walidacji $-0{,}001$ / $-0{,}011$ / $-0{,}026$: brak dryfu



Odsetek prawdziwych wyświetleń w przedziale 90%, przed i po kalibracji; pod nazwą szerokość przedziału.

Kolumna zasięgu Brand24 to nie są wyświetlenia (X)



Zasięg Brand24 to inna miara niż wyświetlenia. Pokazujemy, jak daleko od prawdziwych wyświetleń jest ta liczba ($\times 11{,}47$) i nasze oszacowanie ($\times 3{,}03$), na tych samych 1 803 postach z X.

Ograniczenia i co dalej

Ograniczenia: dane

- prawda FB/IG = nasz odczyt publicznych stron, niezweryfikowany niezależnie
- usunięte posty (IG 27%, FB 14%), kierunek wpływu nieznany
- wiek odczytu: eksport 23 dni, FB/IG 310–334 dni po publikacji
- mało marek: FB 20, IG 11
- tylko dostępne filmy i rolki
- etykiety AI bez ludzkiego wzorca (κ 0,71–0,79)

Ograniczenia: metoda

- wynik FB/IG z jednego zestawu treningowego (X + YT)
- na X ridge gorszy od mnożnika; na Stack Exchange przenoszenie zawodzi
- korelacja, nie przyczynowość

Co dalej

- niezależna weryfikacja odczytu FB/IG
- więcej marek na FB i IG
- zwykłe posty FB/IG, nie tylko filmy i rolki
- inne platformy (Reddit, LinkedIn)
- ludzka weryfikacja etykiet AI
- praktyczny przykład sumy marki na FB/IG

Wnioski

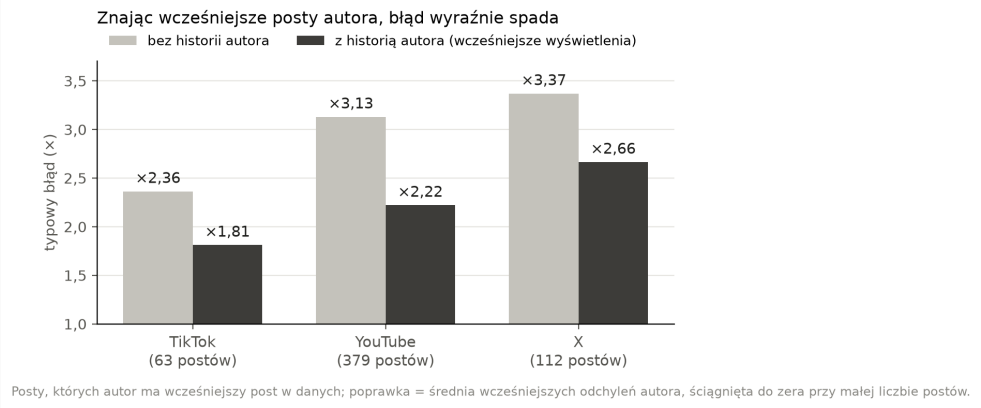
Co z tego wynika

1. Tak, wyświetlenia FB/IG da się oszacować z lajków i komentarzy: błąd ok. $\times 2{,}4$ (FB), $\times 2{,}7$ (IG); wystarcza stosunek wyświetleń do lajków z X + YT, ridge dodaje mało.
2. Zastrzeżenie: 20 i 11 marek, nasz niezweryfikowany odczyt, usunięte posty, odczyt po 310–334 dniach (eksport 23); nie uogólniać. Reakcje muszą być odczytane razem z wyświetleniami.
3. Na tej samej platformie model z większą liczbą pól ma sens ($\times 1{,}87$ vs $\times 2{,}23$ na TikToku), głównie dzięki obserwującym i udostępnieniom; na Stack Exchange przenoszenie zawodzi.

Rekomendacja praktyczna

Orientacyjnie: wyświetlenia $\approx 25\times$ lajki (reguła dolnej granicy); zmierzone na postach ok. rocznych; IG zwykle zaniżony (72% rolek); przy danych odczytanych w podobnym wieku: IG $\times 2{,}41$, FB $\times 2{,}44$. Model z większą liczbą pól dodawaj dopiero przy danych tej samej platformy.

Zapas: historia autora



Typowy błąd bez i z historią autora (jego wcześniejsze posty), TT, YT, X. Pomaga tylko tam, gdzie historia istnieje (3–16% postów).

Zapas: braki w eksporcie Brand24

12 500 wzmianek, 2 500 na platformę, 19 kolumn (tabela: 18 poza `platform`). **Puste wartości** w każdej kolumnie, udział na platformie; pomarańczowe: braki $\geq 25\%$. `b24_estimated_reach` to „zasięg" Brand24.

kolumna	TikTok	YouTube	X	Facebook	Instagram
`mention_id`	0%	0%	0%	0%	0%
`url`	0%	0%	0%	0%	0%
`created_at`	0%	0%	0%	0%	0%
`metrics_updated_at`	0%	0%	0%	0%	0%
`brand`	0%	0%	0%	0%	0%
`language`	0%	0%	0%	0%	0%
`country`	4%	19%	**81%**	**79%**	**81%**
`title`	0%	0%	**100%**	0%	0%
`content`	0%	0%	0%	0%	0%
`author_name`	0%	0%	0%	**27%**	**92%**

kolumna	TikTok	YouTube	X	Facebook	Instagram
`author_url`	0%	0%	0%	**27%**	**92%**
`author_followers`	0%	0%	0%	**27%**	**92%**
`view_count`	0%	1%	**25%**	**100%**	**100%**
`likes`	0%	5%	0%	0%	0%
`comments`	0%	9%	**69%**	0%	0%
`shares`	0%	**41%**	0%	0%	**100%**
`sentiment`	11%	11%	9%	**90%**	**90%**
`b24_estimated_reach`	0%	0%	0%	0%	0%
`likes` $= 0$	4%	**26%**	**70%**	**30%**	**46%**

`likes` $= 0$: lajk wpisany jako zero (na X często brak, a nie prawdziwe zero).

Zapas: dane wyprowadzone i próbowane

Wyprowadzone z tekstu i metadanych

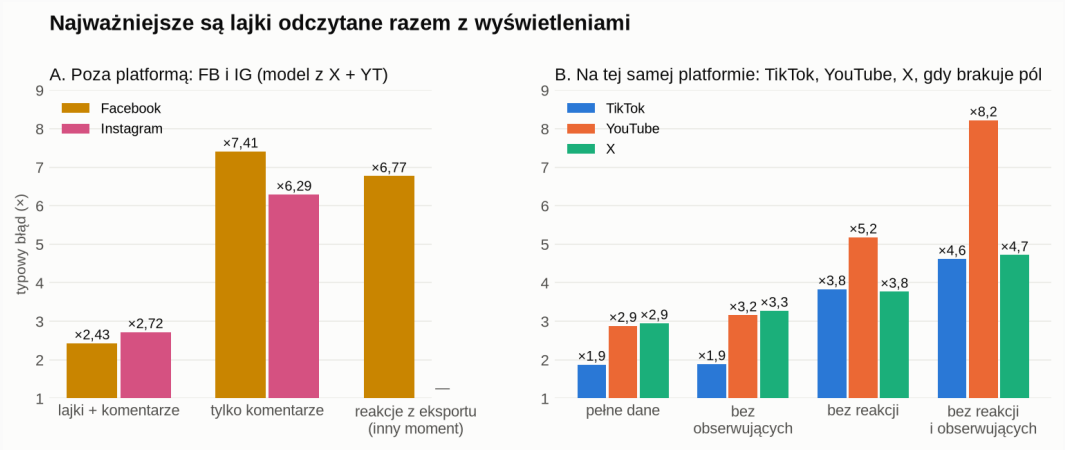
- typ wzmianki i sentyment z modelu językowego (etykiety AI): zgodność 3 przebiegów κ 0,77–0,79 (typ), 0,71–0,73 (sentyment); brak ludzkiego wzorca
- czy wzmianka jest o marce: 6,7% bez nazwy marki w tekście
- tekst: TF-IDF, osadzenia zdań e5, statystyki tekstu, sentyment VADER
- grafy: podobieństwo tekstów (GraphSAGE), autor–marka–hashtag (metapath2vec)

Próbowaliśmy dociągnąć z zewnątrz

- Wikipedia (zainteresowanie marką), Wikidata (dane o firmie), szum wokół marki w strumieniu, kalendarz, wielkość marki
- ponowne odczyty wyświetleń i reakcji (X, YouTube, TikTok), brakujące lajki YouTube
- konta tych samych autorów na innych platformach: za mało dopasowań (5–17 postów, potrzeba 40)
- TikTok Research API: wymaga wniosku akademickiego, nie użyte

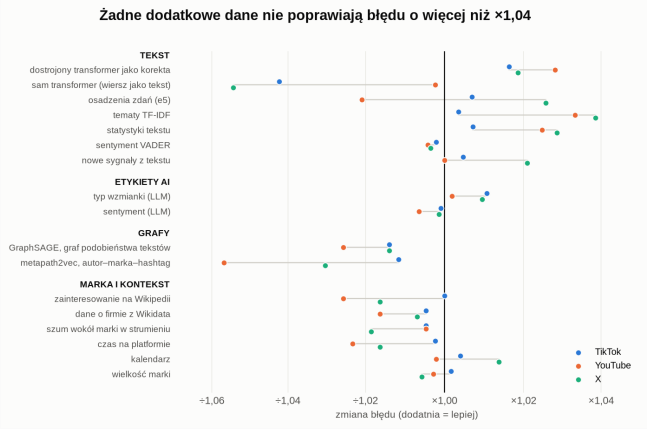
Żadne dodatkowe źródło nie poprawia błędu o więcej niż $\times 1{,}04$.

Zapas: czego model potrzebuje



Co widać: typowy błąd (oś pionowa) przy różnych zestawach pól; A: FB i IG (model z X + YT), B: TT, YT, X, gdy brakuje pól. Kluczowe: lajki odczytane w tej samej chwili co wyświetlenia. Same komentarze: $\times 6{,}3$–$\times 7{,}4$.

Zapas: dodatkowe dane, ile zmieniły błąd



Co widać: jeden punkt to zmiana błędu po dodaniu źródła (oś pozioma, w prawo = lepiej) dla TT, YT, X; żadne źródło nie daje więcej niż $\times 1{,}04$.

Zapas: modele na tej samej platformie (TikTok, YouTube, X)

Model (ta sama platforma, typowy błąd)	TikTok	YouTube	X
Proste odniesienia			
mediana wyświetleń platformy	×4,60	×8,79	×4,65
stały mnożnik obserwujących	×8,30	×7,16	×7,57
stały mnożnik lajków	×2,23	×4,06	×3,63
Modele liniowe i jądrowe			
regresja liniowa (ridge)	×1,89	×3,51	×3,07
k najbliższych sąsiadów (kNN)	×1,92	×3,04	×3,09
SVR z jądrem RBF	×1,87	×2,90	×3,02
Drzewa decyzyjne			
las losowy	×1,88	×2,90	×2,97
extra trees	×1,88	×2,88	×2,99
gradient boosting (scikit-learn)	×1,89	×2,84	×2,98
LightGBM	×1,88	×2,86	×2,99
XGBoost	×1,87	×2,82	×2,93
CatBoost (model końcowy)	×1,87	×2,83	×2,95
Sieci neuronowe			
perceptron wielowarstwowy (MLP)	×1,89	×2,84	×3,00
GraphSAGE (graf podobnych tekstów)	×1,90	×2,93	×2,98
dostrojony transformer	×1,95	×2,84	×3,09
Modele wstępnie wytrenowane dla tabel			
TabPFN v2	×1,85	×2,77	×2,92
TabICL	×1,87	×2,79	×2,92
Zespoły modeli			
średnia 3 najlepszych rodzin	×1,86	×2,79	×2,94
stos wszystkich rodzin	×1,82	×2,66	×2,76

Walidacja tylko po markach, 8 pól, strojenie zagnieżdżone; dlatego liczby nieco niższe niż w wynikach głównych (po markach i autorach). Stos nie jest modelem końcowym: zysk ×1,03–×1,07, kilkanaście modeli, TabPFN ok. 150× wolniejszy.

Zapas: siatka platform treningowych (ridge na 2 polach)

Trening na	TikTok	YouTube	X	Facebook	Instagram	Stack Exchange
ridge, ta sama platforma	1,99	4,15	3,30	2,42	2,41	1,77
YT	**2,00**	trening	4,64	2,72	2,63	1,87
FB	2,30	4,26	**3,60**	trening	**2,47**	3,32
IG	2,46	4,50	4,06	2,48	trening	2,46
TT	trening	**4,07**	4,15	2,61	2,59	2,41
X	3,38	5,52	trening	3,07	2,74	4,50
X + YT	2,05	trening	trening	**2,43**	2,72	3,14
TT + YT + X	trening	trening	trening	2,49	2,69	3,08
YT + X + FB + IG	2,12	trening	trening	trening	trening	3,25
TT + YT + X + IG	trening	trening	trening	2,46	trening	3,07
TT + YT + X + FB	trening	trening	trening	trening	2,66	3,08
TT + X + FB + IG	trening	4,08	trening	trening	trening	4,24
TT + YT + FB + IG	trening	trening	4,37	trening	trening	2,11

Ridge na 2 polach (lajki, komentarze), walidacja po markach (nie po markach i autorach). Typowy błąd (×); szare = trening. Mediana po 15 zestawach bez celu: FB ×2,58, IG ×2,65, czyli nie zależy od wyboru X + YT.

Stack Exchange (538 pytań) nigdy nie jest w treningu: najlepszy z samego YouTube ×1,87, własny ridge SE ×1,77; każdy zestaw z X daje ×3–×5.

Zapas: modele poza platformą (Facebook, Instagram)

Metoda (typowy błąd)	Facebook	Instagram
Proste reguły		
mediana z X + YT	×19,87	×8,69
mnożnik lajków	×2,42	×2,94
Modele (trening X + YouTube)		
regresja ridge (nasz)	**×2,43**	**×2,72**
MLP	×2,47	×2,78
CatBoost	×2,61	×2,95
Augmentacja		
CatBoost + trend	×2,54	×2,96
MLP + trend	×2,46	×2,79
CatBoost + propensity	×2,49	×2,89
MLP + propensity	×2,42	×2,75
CatBoost + mixup	×2,58	×2,95
MLP + mixup	×2,46	×2,76
Odniesienie (używa etykiet platformy docelowej)		
ridge uczony na samej platformie (CV po markach)	×2,42	×2,41

Wszystkie modele: 2 pola (lajki, komentarze), trening tylko na X + YouTube, nigdy na FB/IG. Złożone modele i augmentacja nie dają wyraźnej poprawy względem prostej regresji; mnożnik lajków jest na FB prawie tak samo dobry. Ridge uczony na samej platformie ma IG 72% rolek niedoszacowanych; z TikTokiem w treningu (TT + YT + X): FB ×2,49, IG ×2,69; TikTok jako dodatkowy test ×2,05.

Zapas: klasyfikacja i próby naprawy skrajnych postów

Klasyfikacja: <1k / 1–10k / >10k

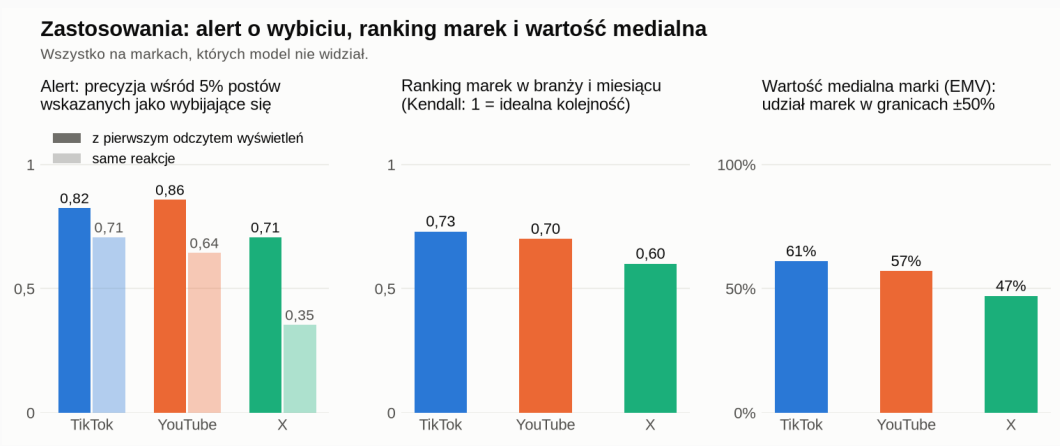
	TT	YT	X
trafny przedział	82%	80%	95%
zgadywanie najczęstszego	59%	63%	95%
trafność zrównoważona	77%	72%	43%
prawdopodobieństwo (AUC; 0,5 = losowo, 1 = idealnie)			
czy to duży post (top 20%)	0,97	0,92	0,84
czy to mały post (dół 20%)	0,93	0,92	0,79

Klasyfikacja działa na TT i YT; na X 95% postów ma <1k, więc 95% to zgadywanie.

Jak próbowaliśmy poprawić duże i małe posty

- **cel „wyświetlenia na lajk”** → prawie bez zmian
- **większa waga skrajnych postów** → bez zmian
- **inne funkcje błędu** (RMSE, kwantyl) → duże posty nadal zaniżone
- **osobny model dla postów bez reakcji** → bez zysku
- **korekta wyniku po fakcie** → bez poprawy

Zapas: trzy zastosowania (TT, YT, X)



Precyzja alertu o wybiciu (5% postów), zgodność rankingu marek (Kendall), udział marek w $\pm 50\%$ wartości medialnej.

Zapas: obserwujący IG i sumy marek

Obserwujący IG

	lajki + koment.	+ obserwujący
ridge na samym IG	$\times$2,40	$\times$2,23
transfer X+YT $\rightarrow$ IG	$\times$2,72	$\times$4,58

Obserwujący pomagają na samym IG, ale psują przenoszenie z X + YT: obserwujący na X/YT oznaczają inny poziom wyświetleń niż na IG.

Sumy marek

Po jednej korekcie błąd sumy marki: $\times$1,7 / $\times$2,0 / $\times$2,1.