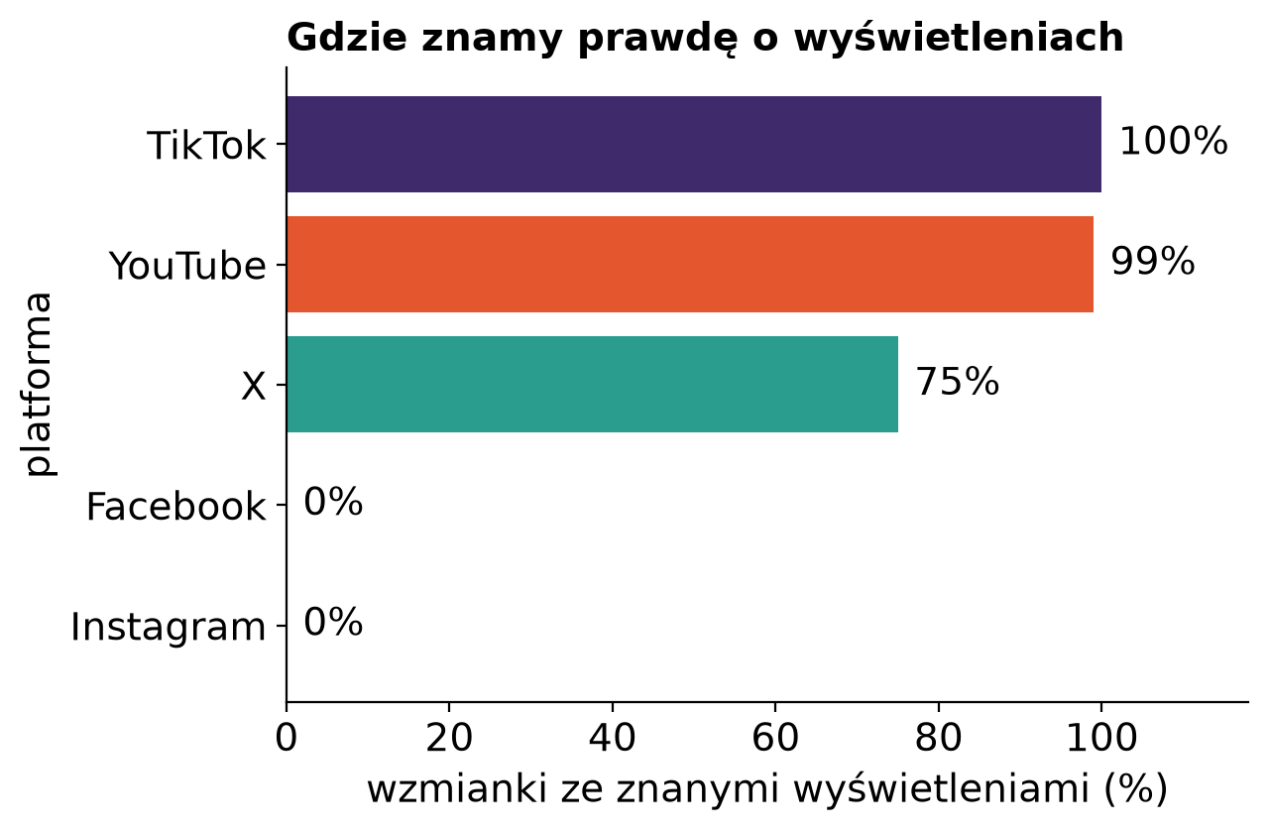
1 · DANE I PUNKT ODNIESIENIA

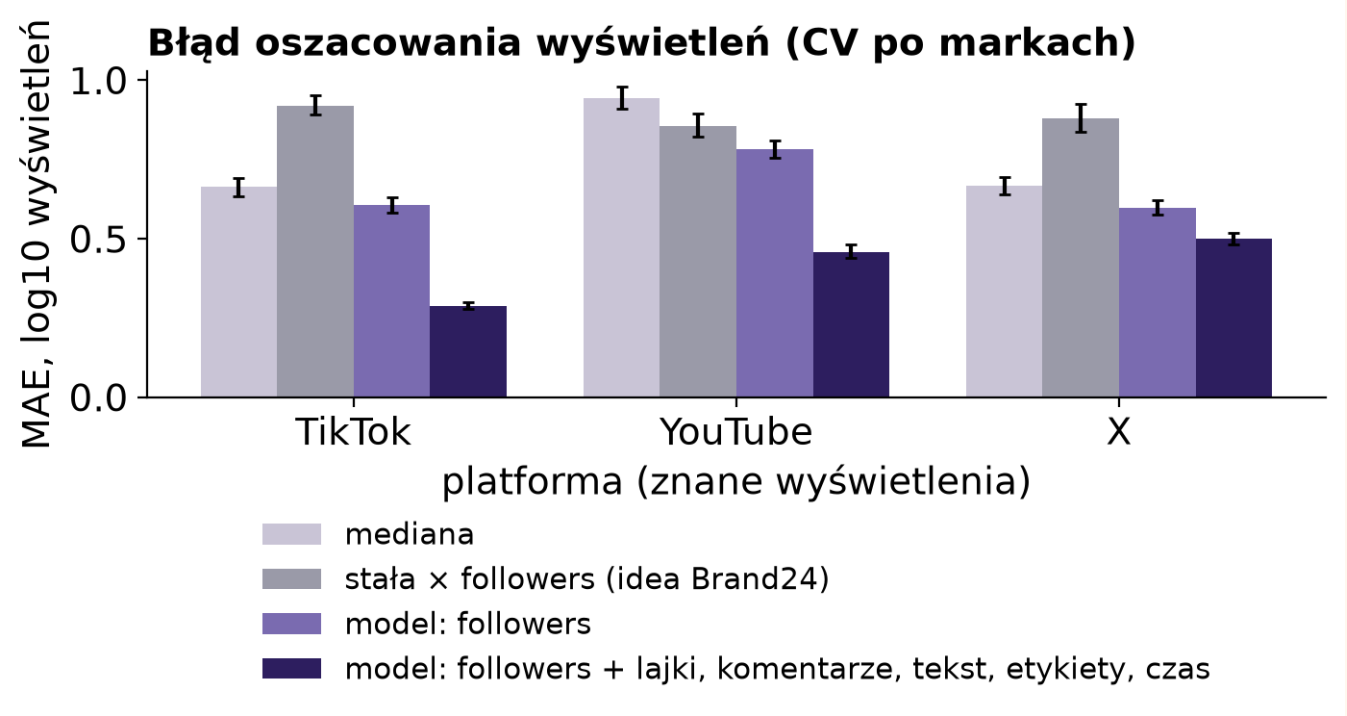
Wyświetlenia znamy tylko na trzech z pięciu platform, a reguła Brand24 na X myli się około 12 razy



- **TikTok i YouTube:** zasięg Brand24 to dokładnie liczba wyświetleń, więc to nasza prawda.
- **X:** wyświetlenia są dla 75% postów, a zasięg Brand24 to osobne oszacowanie z błędem średnio 1,08 w log10.
- **Facebook i Instagram:** brak wyświetleń, więc nie da się sprawdzić żadnego oszacowania wprost.

12 500 wzmianek, po 2 500 z każdej platformy. Próba nie jest równomierna w czasie (ok. 85% z kwietnia–sierpnia 2026).

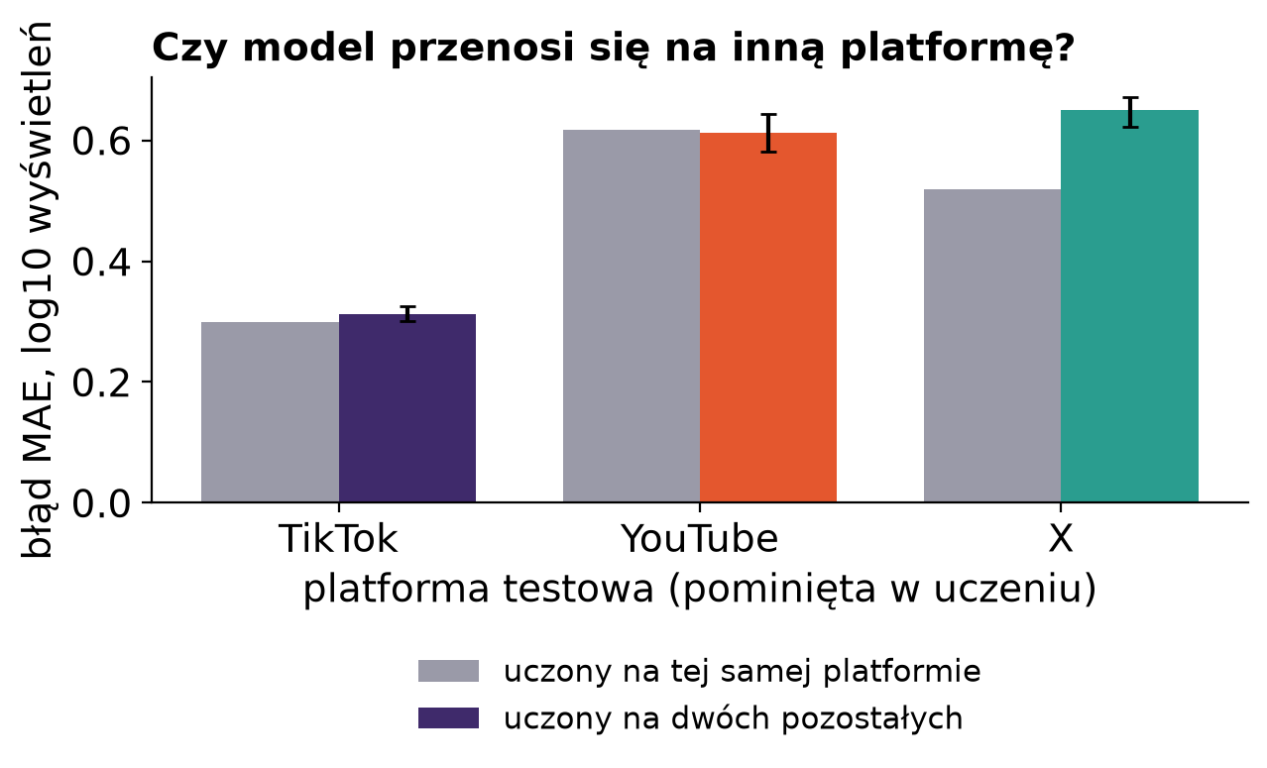
Wyświetlenia wyjaśniają głównie lajki i komentarze, a nie followersi, tekst czy typ wzmianki



- **Engagement:** dodanie lajków, komentarzy i udostępnień obniża błąd z 0,61 do 0,29 na TikToku i z 0,78 do 0,46 na YouTube.
- **Stała × followers:** najgorszy model, gorszy niż zgadywanie mediany na TikToku i X.
- **Tekst, nasze etykiety, czas:** nie poprawiają wyniku w granicach szumu.

MAE na log10: 0,3 oznacza typowy błąd około dwukrotny. Walidacja: 5 grup marek, słupki = 95% przedział (bootstrap po markach). Zależność, nie przyczyna.

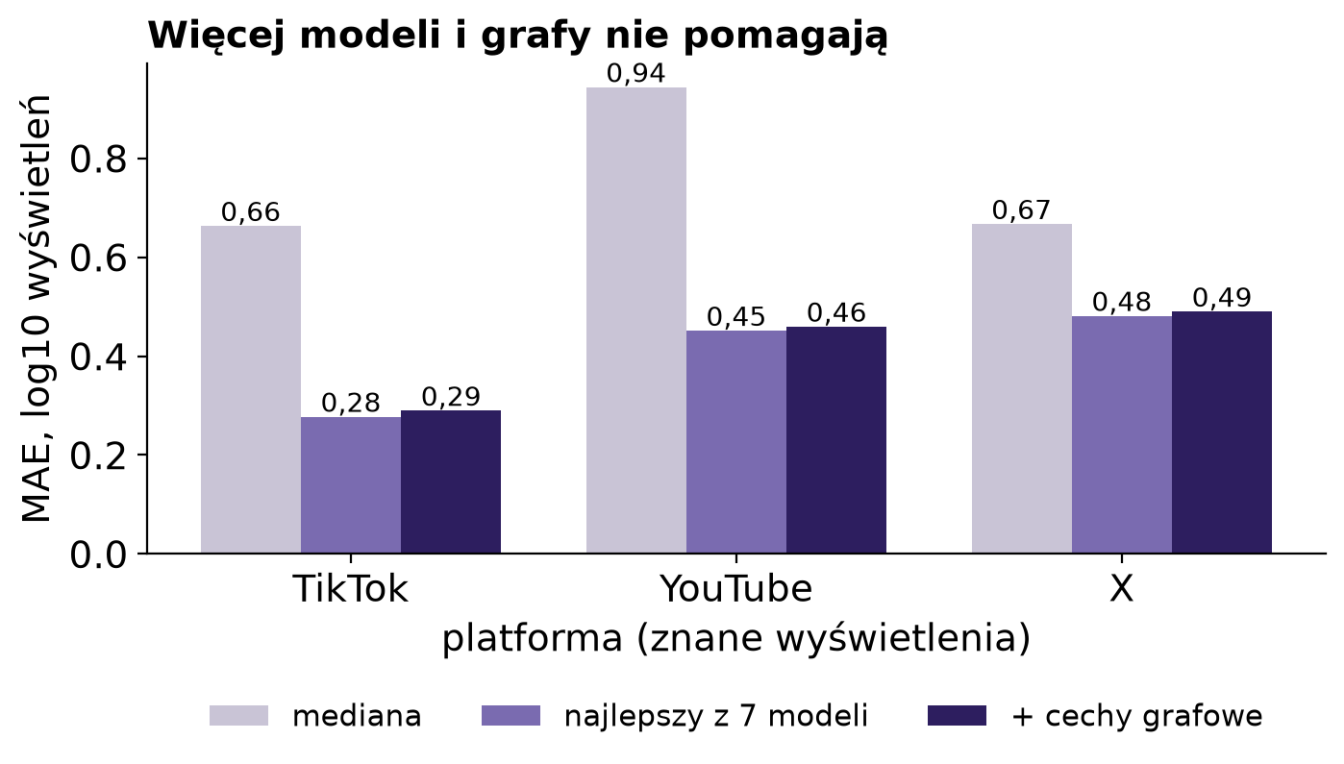
Na Facebooku i Instagramie da się tylko oszacować wyświetlenia, z niepewnością rzędu ×14 w każdą stronę



- **Przenosi się dobrze:** na TikToku i YouTube błąd po uczeniu na innych platformach to 0,31 i 0,61, jak przy uczeniu na własnej.
- **Facebook:** Brand24 podaje ok. 21 razy więcej niż wynika z engagementu, ale prawdy brak.
- **Uwaga:** przedziały z innych platform pokrywają tylko 82% przypadków przy celu 90%, więc są zbyt optymistyczne.

Etykiety (typ, sentyment) tworzy instrument AI: kappa 0,77–0,79 i 0,71–0,73 między trzema modelami. To spójność, nie trafność.

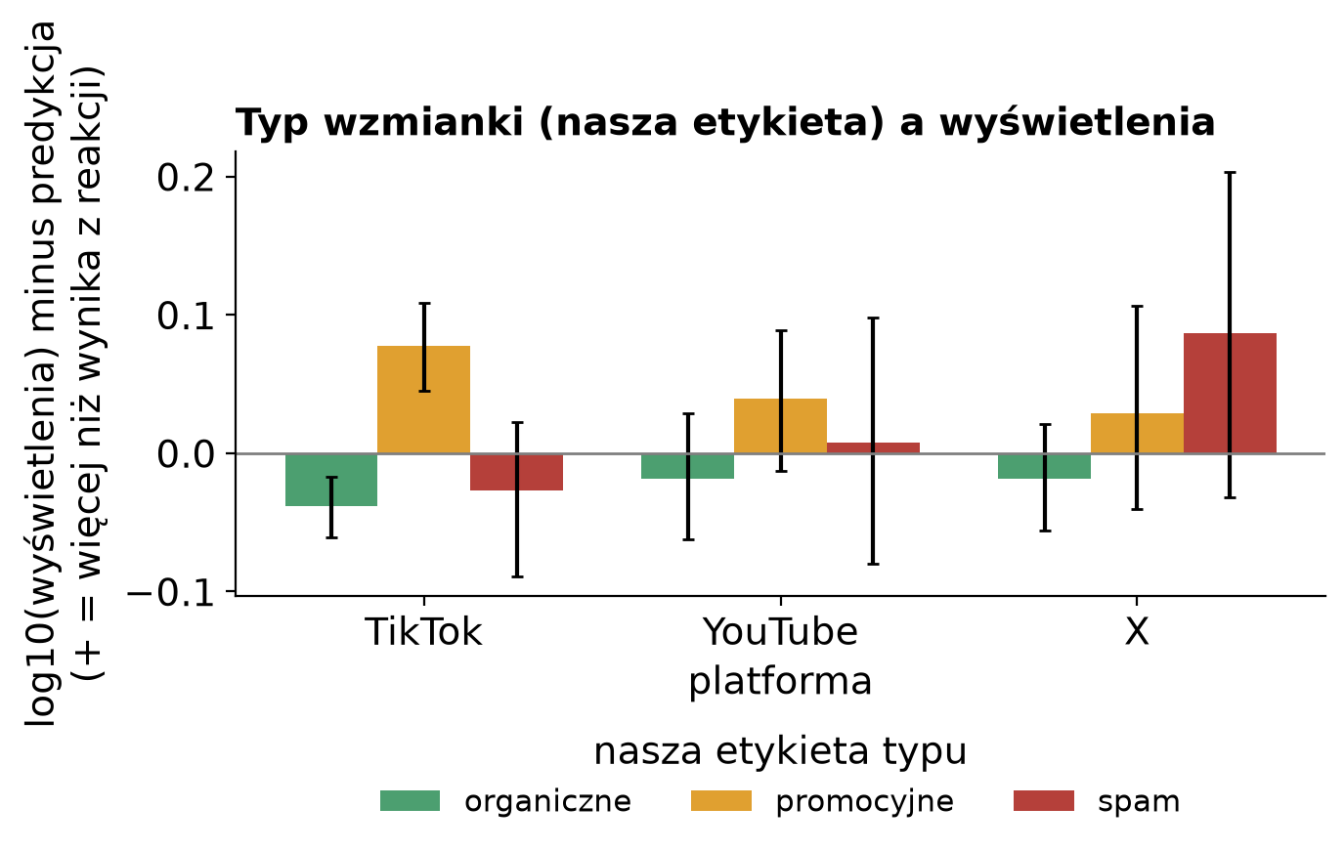
Sześć rodzin modeli, grafy autorów i tekstów oraz podział na grupy nie pobiły samych lajków i komentarzy



- **Modele:** ridge, kNN, lasy losowe, boosting i blend mieszczą się w swoich przedziałach (TikTok 0,28, YouTube 0,45, X 0,48).
- **Grafy:** średnia autora, sąsiedzi z grafu podobieństwa tekstu i wygładzanie po sąsiadach dają co najwyżej 0,009 na YouTube, w granicach błędu.
- **Gdzie błąd jest największy:** posty z najmniejszą liczbą reakcji (YouTube 0,72 wobec 0,30 w górnym kwartylu) i spam na X (0,56 wobec 0,47).

Ta sama walidacja co wcześniej (5 grup marek, MAE na log10). Cechy zależne od wyświetleń liczone tylko z części treningowej. Osobny model na przedział followersów wypadł gorzej niż jeden wspólny.

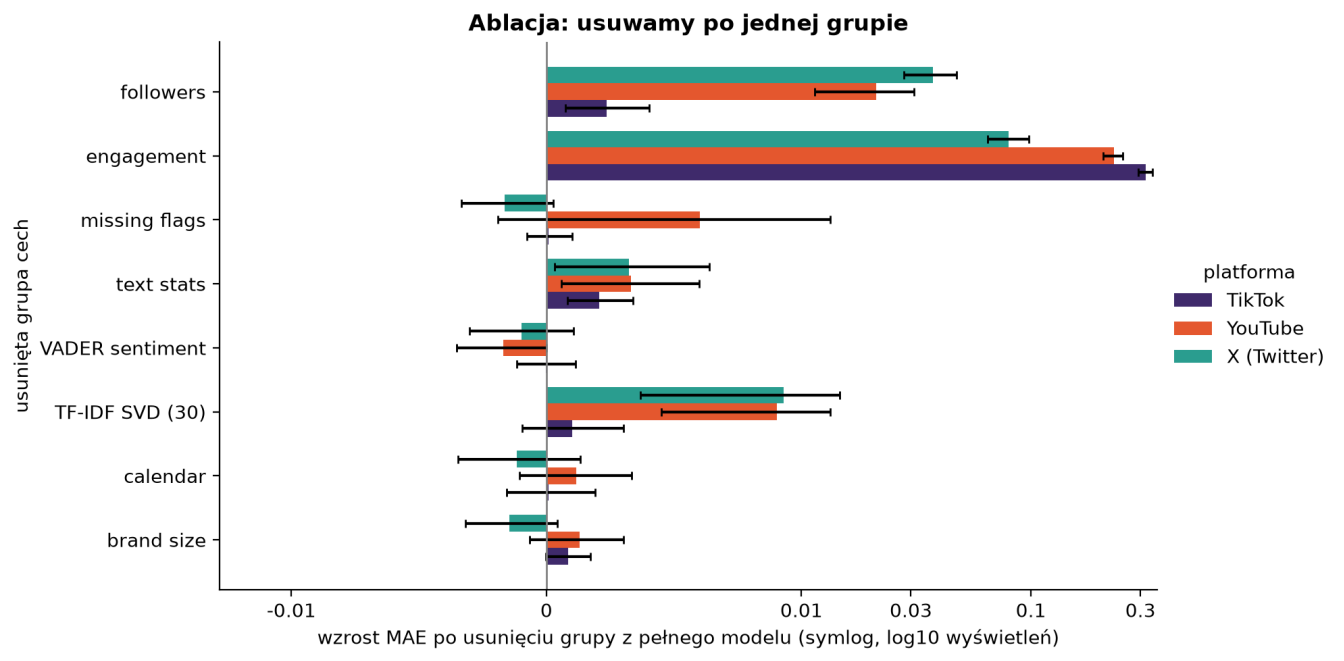
Nasze etykiety AI niemal nie zmieniają wyświetleń przy tych samych reakcjach: promocyjne na TikToku mają o około 20% więcej



- **Co mierzymy:** różnicę między faktycznymi wyświetleniami a tym, co przewidują lajki i komentarze, osobno dla organicznych, promocyjnych i spamu.
- **TikTok:** promocyjne +0,08 log10 (około +20%), przedział ufności nad zerem; reszta w granicach błędu.
- **Wniosek:** etykiety typu nie poprawiają oszacowania wyświetleń; przy tych samych reakcjach spam i reklama nie wyróżniają się wyraźnie od zwykłych postów.

Etykiety tworzą trzy modele Haiku, a 4 668 niezgodnych wzmianek rozstrzyga Sonnet. Zgodność trzech modeli 79%, kappa typu 0,77–0,79. To zgodność maszyn, nie sprawdzenie względem ludzkiego wzorca.

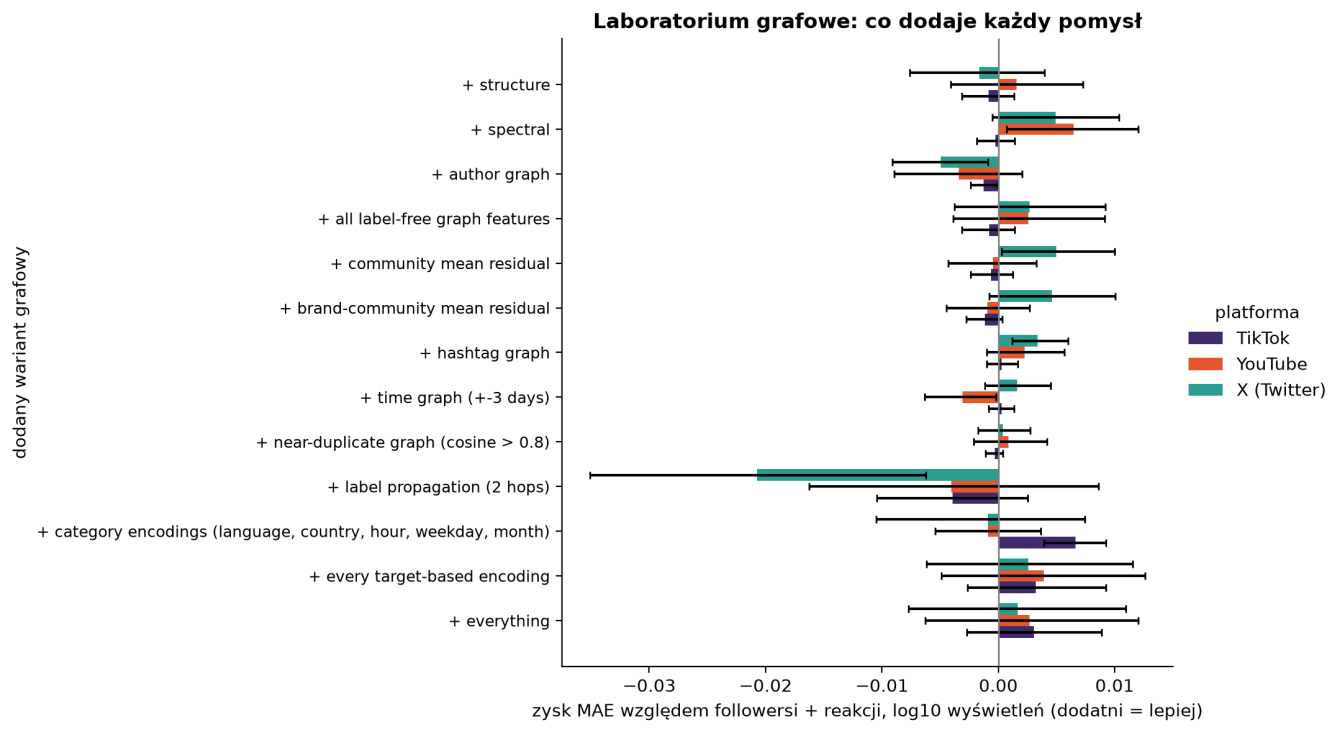
Tekst daje drobny, ale realny zysk na YouTube i X; reakcje są niezbędne, a followersi i graf marek pomagają tylko miejscami



- **Tekst (statystyki i tematy TF-IDF):** poprawia błąd o 0,014 na YouTube i 0,016 na X; na TikToku nic. Zysk jest mały, ale przedział ufności nie obejmuje zera.
- **Ablacja:** po usunięciu reakcji błąd rośnie o 0,32 (TikTok) i 0,23 (YouTube). Sentyment VADER, kalendarz i wielkość marki nic nie wnoszą.
- **Odwrotnie:** lajki, komentarze i udostępnienia da się przewidzieć (R^2 0,76 lajki na TikToku), a followersów prawie nie (R^2 0,22). Graf marek poprawia tylko X o 0,011.

Słupki = wzrost błędu po usunięciu grupy z pełnego modelu (oś symlog), 95% przedział z bootstrapu po markach. Reakcje wyjaśniają większość, reszta to poprawki rzędu 0,01.

Dziesięć pomysłów grafowych i kodowań cech nie poprawia oszacowania wyświetleń, a propagacja etykiet je pogarsza

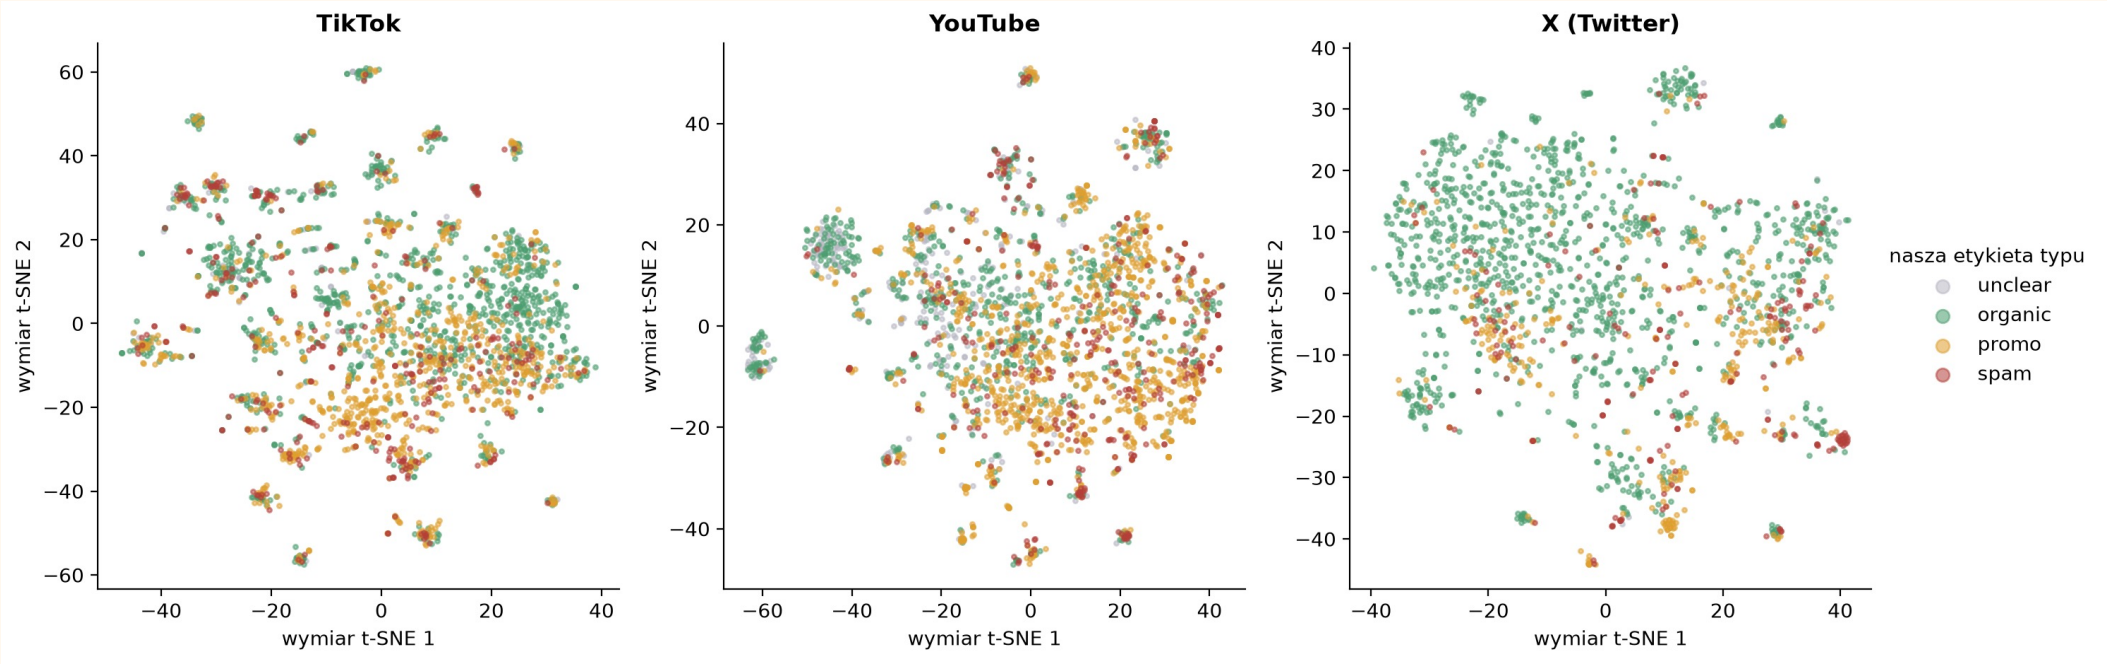


- **Co sprawdziliśmy:** społeczności (Louvain), PageRank, embedding spektralny, graf autor–marka, hashtagi, czas, near-duplikaty i kodowania kategorii.
- **Wynik:** największe zyski to ok. 0,007 (kodowania kategorii, TikTok) i 0,006 (spektralny, YouTube), czyli w praktyce zero.
- **Propagacja etykiet:** pogarsza wynik na wszystkich platformach (X -0,021), bo na treningu widzi własne wyniki odbite przez pętle grafu.

Zysk sparowany względem followersi + reakcji, CV po markach, 95% bootstrap. Cechy zależne od wyświetleń liczone tylko z części treningowej.

8 · CO GRAF POKAZUJE O WZMIANKACH

Graf nie poprawia oszacowania, ale pokazuje kampanie copy-paste: promocje i spam tworzą ciasne skupiska prawie identycznych postów



Kopie:

od 6% do 14% wzmianek ma niemal identyczną kopię; spamu jest wśród nich 38% vs 9% na X.

Wyświetlenia kopii:

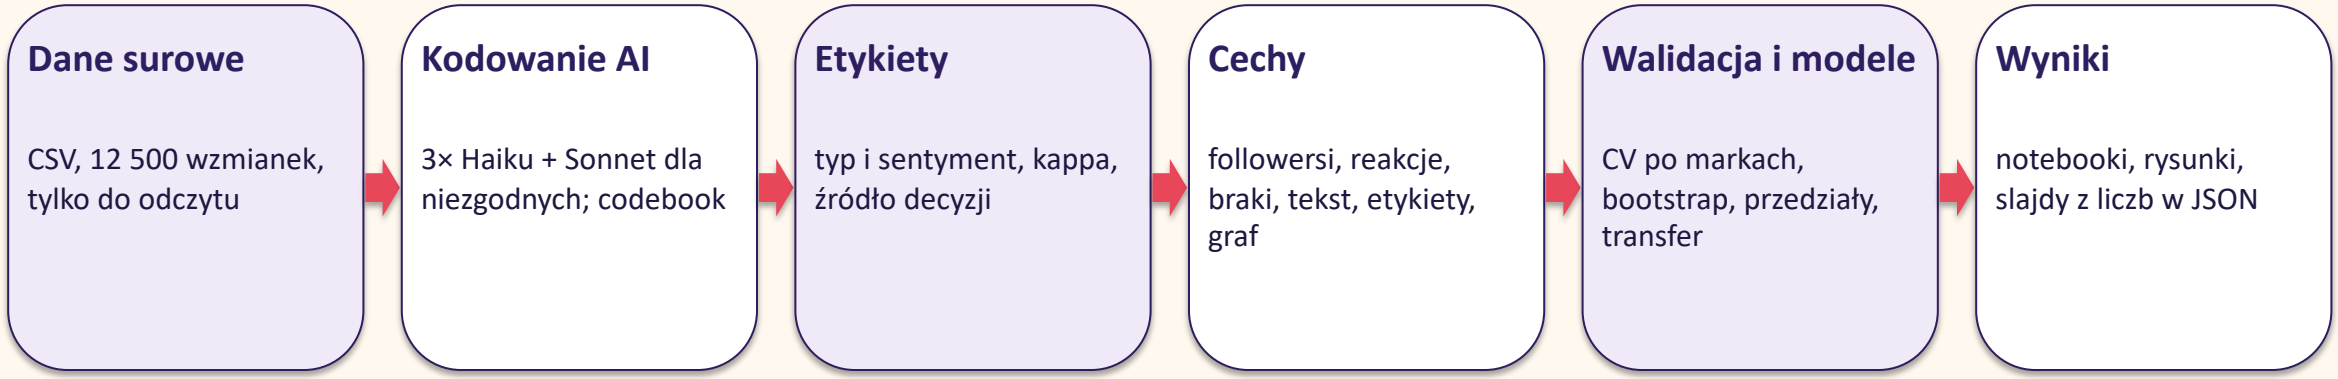
pary kopii mają skorelowane wyświetlenia (0,66–0,82) wobec ok. 0 dla losowych par.

Etykiety i typ:

krawędzie łączą ten sam typ częściej niż z przypadku (65% vs 52% na X), ale głos sąsiadów nie poprawia przewidywania typu (F1 0,63 z samego tekstu).

Mapa t-SNE z 30 tematów TF-IDF, kolor = nasza etykieta typu. Duplikaty: cosinus > 0,8. Społeczności to głównie branże (auta, banki, fast food, linie lotnicze).

Od surowego CSV do wyniku: każdy krok to skrypt lub notebook, a AI koduje wzmianki i pomaga w kodzie, ale nie pisze tekstu pracy



- **Gdzie używamy AI:** kodowanie wzmianek (instrument), pomoc przy kodzie i notebookach, sprawdzanie błędów.
- **Czego AI nie robi:** nie pisze tekstu preprintu ani plakatu, nie rusza surowych danych.
- **Kontrola:** log każdej sesji w repozytorium, małe commity, stałe ziarna, kod od surowych danych do rysunku.
- **Granica:** etykiety AI nie były oceniane względem punktowanego ludzkiego wzorca; to nasze główne ograniczenie.